Extended abstract — Preparação da Dissertação (PREPD), Mestrado em Engenharia Informática, ISEP

Título provisório

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Respostas limitadas ao conteúdo validado de cada pergunta

Francisco Reis (1201373)
Orientador: Nuno Silva Supervisor na empresa: Bruno Guimarães (Adhara)
novembro de 2026

1 Introdução e Enquadramento do Problema

Os bancos de perguntas de escolha múltipla são um recurso habitual na preparação para exames na área da saúde. O Adhara QBank é a plataforma da Adhara, uma empresa portuguesa de educação médica, para este fim. Existe em várias línguas e terá algumas centenas de utilizadores, que resolvem exames em três modos: Teste, Estudo e Simulado. A equipa científica da Adhara valida a informação de cada pergunta: vinheta clínica, opções, resposta correta, explicação, dicas, catalogação e informação complementar. Cada versão linguística tem o seu próprio conteúdo validado.

Durante o estudo, o utilizador pode ter dúvidas que a explicação no ecrã não resolve, por exemplo porque é que uma opção está errada. A plataforma não lhe permite esclarecê-las no momento, embora a base de dados guarde mais informação sobre cada pergunta do que a que aparece no ecrã. A literatura propõe assistentes baseados em modelos de linguagem de grande dimensão (LLM) como apoio ao estudo em educação médica (Abd-alrazaq et al., 2023). Num ensaio controlado com estudantes de medicina, um destes assistentes trouxe benefícios para a aprendizagem (Gan et al., 2024). Um assistente genérico traz, porém, dois riscos. Pode gerar respostas plausíveis mas incorretas (Hu et al., 2025), que contradizem o conteúdo validado. Pode também ser manipulado através do *prompt* (Emekci & Budakoglu, 2025), o que num exame compromete a integridade da avaliação.

Delimitação. O trabalho não constrói um tutor médico geral nem um sistema de resposta a qualquer pergunta clínica. O assistente responde apenas a dúvidas sobre a pergunta em curso. O contexto é o registo validado dessa pergunta, lido pelo seu identificador, sem pesquisa num corpus nem conhecimento externo.

Problema. O problema é conceber um assistente conversacional baseado em LLM que responda apenas com a informação que a base de dados guarda para cada pergunta. O assistente deve manter-se fiel a esse contexto, recusar questões fora do âmbito e respeitar as regras de cada modo, como não revelar a resposta correta antes do tempo. Deve fazê-lo em todas as línguas do QBank e conciliar a qualidade da resposta com a segurança, o custo e a latência de uma conversa.

Partes interessadas. Os utilizadores do QBank (estudantes de medicina, médicos e enfermeiros) precisam de respostas corretas e rápidas. Na Adhara, a gestão define o custo e a integração na plataforma, e a equipa científica responde pelo conteúdo e pela validação das respostas. O ISEP acompanha o trabalho através do orientador.

2 Perguntas de Investigação e Objetivos

Questões de investigação.

RQ1 Como utilizam os sistemas conversacionais baseados em LLM um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais reportam essas abordagens?

RQ2 Como avaliam estes sistemas a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

A revisão sistemática responde às duas questões. As respostas orientam o desenho do assistente (O3 e O4) e a sua avaliação (O5).

Objetivos. Cada objetivo tem uma evidência verificável:

O1. Sistematizar a literatura sobre assistentes com respostas limitadas a um contexto. *Evidência:* revisão com protocolo, diagrama PRISMA e síntese por RQ.

O2. Levantar com a Adhara os requisitos, as regras por modo e os campos que formam o contexto. *Evidência:* requisitos e *backlog* revistos pela Adhara.

O3. Implementar e integrar o assistente no fluxo de resolução de perguntas do QBank. *Evidência:* versão integrada e demonstrada em perguntas reais.

O4. Aplicar as regras de cada modo e a recusa fora do âmbito, sem depender só das instruções ao modelo. *Evidência:* testes de âmbito e adversariais aprovados.

O5. Avaliar a correção, a fidelidade, a recusa, o comportamento em várias línguas, a latência, o custo e a utilidade percebida. *Evidência:* resultados da avaliação face aos critérios de sucesso definidos nos requisitos.

Contributos. Uma revisão sistemática sobre assistentes com contexto definido em educação e saúde; um assistente integrado no QBank que usa apenas o conteúdo validado da pergunta e respeita as regras de cada modo; uma forma de entregar ao modelo o contexto fechado de cada pergunta e de recusar o que não tem suporte nele; e um protocolo de avaliação que mede em conjunto a correção, a fidelidade e a recusa, em várias línguas, com a latência e o custo. Para a Adhara, o benefício é um apoio ao estudo que não contradiz o seu conteúdo.

3 Estado da Arte

Fundamentos. Os assistentes como o ChatGPT assentam em LLM pré-treinados da série GPT, baseados na arquitetura *Transformer*. A partir de certa dimensão, estes modelos executam tarefas descritas no *prompt*, com ou sem exemplos, sem alterar os seus parâmetros (aprendizagem em contexto). São depois alinhados com as preferências humanas, o que lhes permite seguir instruções (Wu et al., 2023). É esta capacidade que permite definir um assistente através de instruções e do contexto enviado, mas as instruções orientam o modelo sem garantir que são cumpridas. Em medicina, os LLM são avaliados sobretudo com perguntas de escolha múltipla de exames, como as do MedQA. Estes *benchmarks* têm limitações conhecidas (Hu et al., 2025) e medem a escolha da resposta correta, e não a explicação fiel de uma resposta já validada, que é o que o QBank precisa.

Processo de pesquisa. O autor conduziu uma revisão sistemática da literatura segundo Kitchenham e Charters (2007) e relatou-a segundo o PRISMA 2020 (Page et al., 2021). A revisão responde à RQ1 e à RQ2. Pesquisou o IEEE Xplore, a ACM Digital Library e o Scopus, no título, resumo e palavras-chave, para 2021 a 2026. Quatro expressões combinam as palavras-chave *large language model*/*LLM* com quatro grupos de termos:

- *grounding*, *context injection*, *retrieval-augmented generation* (RQ1);
- *faithfulness*, *factuality*, *correctness*, *evaluation* (RQ2);
- *prompt injection*, *jailbreak*, *guardrails* (RQ1);
- *out-of-scope*, *abstention* (RQ2).

As expressões da RQ1 e a da fidelidade incluem também *chatbot* ou *conversational system*. Os critérios de inclusão exigem um estudo primário sobre um sistema conversacional baseado em LLM, em educação ou saúde, com respostas dependentes de um contexto definido e avaliadas. Exigem

ainda proximidade ao caso: contexto fechado, avaliação da fidelidade ou da recusa, controlo do âmbito ou várias línguas. A avaliação da qualidade pontuou cada estudo de 0 a 5 e excluiu os estudos abaixo de 3,5. Dos 1547 registos, 1417 eram únicos. A triagem por título e resumo deixou 48 estudos para leitura integral, e a revisão inclui 38.

Principais abordagens. A Tabela 1 compara as duas formas de fornecer o contexto ao modelo e as duas formas de controlar o âmbito.

Tabela 1: Abordagens encontradas na revisão e implicações para o QBank.

Abordagem	**Evidência**	**Implicação para o QBank**
Recuperação (RAG): pesquisa por semelhança num corpus	26 dos 38 estudos. No MedQA, três variantes ficaram abaixo do modelo sem contexto (Xie et al., 2026). No PubMedQA, oito documentos recuperados deram 17,6% de exatidão, contra 27,0% sem contexto (Rahat et al., 2026).	O erro nasce da seleção do contexto, que o QBank não precisa de fazer.
Contexto fechado, fornecido diretamente	Poucos estudos. O AskNow usa a transcrição da aula, com correção de 4,53 a 4,88 em 5 (Liu et al., 2026). Com o identificador do curso, a recuperação do documento certo passou de 0,006 para 1,00 de precisão (Wei et al., 2026).	O identificador da pergunta é sempre conhecido; a seleção do contexto é exata.
Instruções no *prompt*	Cumprimento das políticas do docente em 30% dos casos (Rayhan et al., 2026).	Não chegam para as regras por modo.
Controlo fora do modelo	Controlo de acesso ao conteúdo: 90% (Rayhan et al., 2026). Modelos de guarda: 207 ms com 42,6% de falsos positivos, ou 10,6 s com 16,3% (Walczak & Sawicki, 2026).	Os controlos têm um custo em latência que limita os filtros possíveis.

Debate sobre o contexto. O RAG (Hu et al., 2025) domina a literatura, e os estudos que comparam o mesmo modelo com e sem contexto relatam ganhos. Um grupo de estudos de resposta a perguntas médicas mostra, porém, que o contexto não é neutro. Contexto recuperado com ruído pode ser pior do que nenhum (Rahat et al., 2026; Xie et al., 2026). Em todos estes estudos, o erro nasce da seleção do contexto. Os sistemas com contexto fechado, como o AskNow, ilustram a alternativa, mas são poucos (Liu et al., 2026). O caso mais próximo do QBank explica soluções de exames de engenharia com o par pergunta–solução como contexto. Atingiu 0,94 de fidelidade, mas demorou 9,35 s por explicação (Khan et al., 2025).

Debate sobre o âmbito e a avaliação. Os estudos divergem sobre onde aplicar as regras. As instruções ao modelo são baratas mas frágeis; os controlos fora do modelo cumprem mais as regras, mas acrescentam latência ou bloqueiam pedidos legítimos (Rayhan et al., 2026; Walczak & Sawicki, 2026). A avaliação é heterogénea: exatidão em *benchmarks*, métricas automáticas de fidelidade calculadas por outro LLM, especialistas e utilizadores. Poucos estudos combinam estes métodos. A recusa aparece em 16% dos estudos, e os estudos multilingues medem o desempenho por língua, não a consistência com o mesmo conteúdo validado. A latência e o custo são referidos em 16% e 11% dos estudos, embora cada etapa de controlo acrescente tempo: um segundo modelo de filtragem acrescentou 1,2 s e 1,8 vezes o custo (Emekci & Budakoglu, 2025).

Lacuna. Nenhum dos 38 estudos descreve um assistente de estudo que responda apenas com o contexto fechado e validado de cada pergunta de um banco de perguntas. Nenhum aplica regras por modo de exame nem avalia, em várias línguas, a correção, a fidelidade e a recusa em conjunto. Poucos relacionam a latência e o custo com as escolhas de arquitetura. Os sistemas mais próximos partilham uma ou duas destas características. Este trabalho trata esta lacuna: as respostas às duas RQ orientam o desenho do assistente (O3 e O4) e o seu protocolo de avaliação (O5).

4 Metodologia Proposta

O trabalho segue a metodologia Design Science Research (DSR), nas seis atividades de Peffers et al. (2007): identificar o problema, definir os objetivos, desenhar e desenvolver, demonstrar, avaliar e comunicar. A DSR adequa-se porque a pergunta principal pede um artefacto e a sua avaliação. O desenvolvimento decorre em incrementos curtos, planeados a partir de um *backlog* priorizado, e cada incremento é demonstrado.

Materiais e técnicas. O contexto vem da base de dados do QBank, com os campos de cada pergunta escolhidos no levantamento de requisitos. O assistente usa um LLM, através de uma API ou executado localmente; o desenho compara as duas opções.

Avaliação. A avaliação verifica o objetivo O5 com três instrumentos:

1. testes técnicos com perguntas reais do QBank em várias línguas, cada uma com dúvidas respondíveis, dúvidas fora do âmbito e tentativas de manipulação; medem a correção, a fidelidade, a taxa de recusa, a latência e o custo por pedido;
2. avaliação da correção e da fidelidade por especialistas da área da saúde numa amostra das respostas; um LLM juiz serve apenas de apoio, validado numa subamostra;
3. questionário de utilidade e usabilidade a utilizadores do QBank.

Viabilidade. O contexto é conhecido à partida, pelo que o sistema dispensa a infraestrutura de recuperação. A latência e o custo são medidos desde o primeiro incremento. O acesso aos dados do QBank e a disponibilidade de especialistas para a avaliação ficam por confirmar com a Adhara, no início da dissertação.

5 Plano de Trabalho

Até ao documento final de PREPD (novembro de 2026 a janeiro de 2027). Esta fase estuda o caso e prepara o trabalho, sem desenvolvimento:

- concluir a revisão sistemática: avaliação da qualidade, extração e síntese;
- estudar o caso do QBank e as alternativas técnicas identificadas na revisão;
- definir a metodologia e os instrumentos de avaliação;
- escrever o documento final e preparar a apresentação.

Até à dissertação (DIMEI) (fevereiro a julho de 2027). O trabalho segue as atividades da DSR em cinco fases: requisitos com a Adhara, desenho da solução, desenvolvimento iterativo, avaliação e escrita da dissertação. Os principais entregáveis são os requisitos, a arquitetura, o assistente integrado no QBank, os resultados da avaliação e a dissertação. A Figura 1 mostra as fases e três marcos: M1 documento de PREPD, M2 protótipo funcional e M3 dissertação submetida.

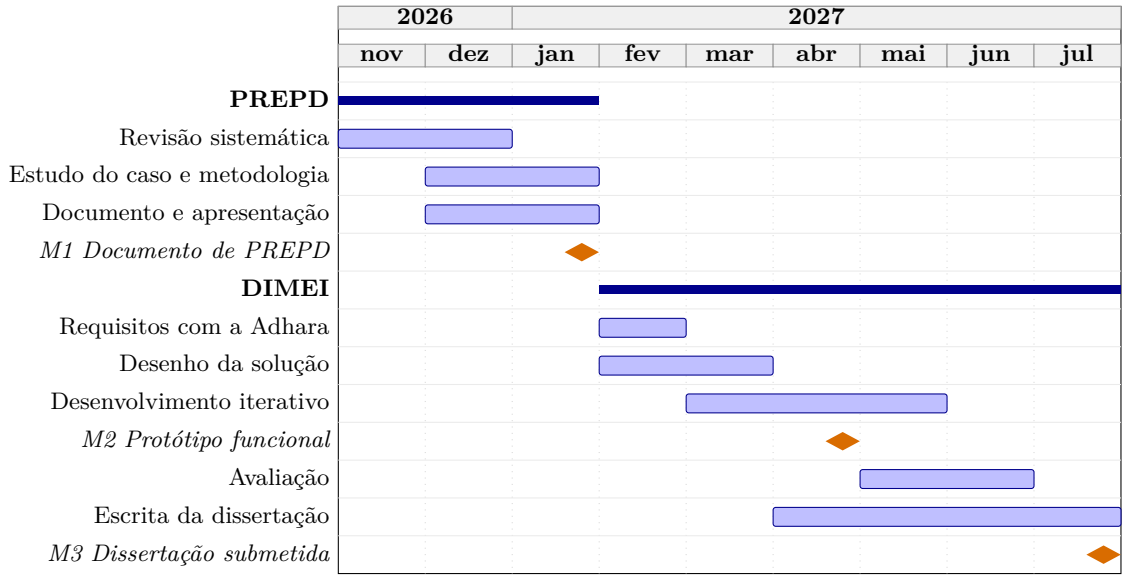


Figura 1: Plano de trabalho preliminar, com as fases e os marcos (M).

O plano é preliminar. O levantamento de requisitos com a Adhara pode alterar o âmbito e a duração das fases seguintes. Os riscos com nível mais alto são respostas infiéis ao conteúdo validado, o custo do modelo, o tempo de resposta e a revelação da resposta por manipulação do *prompt*. São mitigados pelo contexto fechado, pelas regras aplicadas fora do modelo, pela medição do custo e da latência desde o primeiro incremento e por testes adversariais. Os riscos são revistos no fim de cada iteração.

6 Considerações Éticas e Profissionais

Código seguido. O trabalho segue o Código Europeu de Conduta para a Integridade da Investigação (ALLEA, 2023), assente na fiabilidade, honestidade, respeito e responsabilização. Aplica-o de forma concreta. Não fabrica, não falsifica nem omite resultados, e reporta também os negativos. Todas as referências foram lidas e verificadas na fonte. As decisões da revisão e os *scripts* estão guardados para que possa ser repetida. O conjunto de teste e os critérios de sucesso são fixados antes de se conhecerem os resultados, que são reportados por língua.

Dados, pessoas e impactos. O projeto envolve cinco situações com riscos:

- *Informação confidencial e trabalho numa empresa.* O conteúdo do QBank pertence à Adhara e o trabalho usa-o apenas neste projeto. A propriedade do código e o que pode ser publicado são acordados por escrito com a Adhara. Desenvolver e avaliar um produto da empresa onde o trabalho decorre é um potencial conflito de interesses, mitigado por um protocolo de avaliação definido à partida, com especialistas e utilizadores.
- *API externa.* Se o assistente usar um modelo de terceiros, o sistema envia apenas a mensagem, o histórico da conversa e os dados da pergunta, sem dados que identifiquem o utilizador. O envio exige a autorização da Adhara, e a escolha do fornecedor considera a retenção dos pedidos, a não utilização para treino e a localização do processamento.
- *Dados pessoais.* O registo estatístico das dúvidas terá finalidade e prazo de conservação definidos. Como dados pseudonimizados continuam a ser dados pessoais, ou o registo é anónimo, ou segue o RGPD (Parlamento Europeu e Conselho da União Europeia, 2016).
- *Participação humana.* O questionário pede consentimento informado, recolhe apenas o necessário e guarda as respostas de forma anónima. A necessidade de parecer de uma comissão de ética será confirmada com o orientador antes da recolha.

- *Impacto nos utilizadores.* Uma resposta errada pode induzir erros de aprendizagem. O contexto fechado, a recusa, os testes adversariais e a avaliação por especialistas reduzem este risco. O assistente informa o utilizador de que interage com um sistema de inteligência artificial, como exige o Regulamento da IA da UE (Parlamento Europeu e Conselho da União Europeia, 2024).

Competências profissionais e uso de IA. O autor assegura a engenharia de software e a integração com a formação do mestrado e com o acompanhamento do orientador. Adquire as competências sobre LLM e a sua avaliação através da revisão sistemática e do protótipo. O autor não tem formação médica, pelo que a validação clínica das respostas cabe a especialistas da área da saúde. O autor usou ferramentas de IA generativa nos *scripts* da revisão, na proposta de decisões de triagem, na extração de dados e no apoio à escrita. Verificou cada decisão e cada valor na fonte original e é o único responsável pelo conteúdo. O conteúdo do QBank e o código da Adhara não são enviados a ferramentas de IA externas sem a autorização da Adhara.

Referências Bibliográficas

Abd-alrazaq, A., AlSaad, R., Alhuwail, D., et al. (2023). Large Language Models in Medical Education: Opportunities, Challenges, and Future Directions. *JMIR Medical Education*, *9*, e48291. https://doi.org/10.2196/48291

ALLEA. (2023). *The European Code of Conduct for Research Integrity – Revised Edition 2023*. https://doi.org/10.26356/ECOC

Emekci, H., & Budakoglu, G. (2025). Securing With Dual-LLM Architecture: ChatTEDU an Open Access Chatbot's Defense. *IEEE Access*. https://doi.org/10.1109/ACCESS.2025.3623268

Gan, W., Ouyang, J., Li, H., et al. (2024). Integrating ChatGPT in Orthopedic Education for Medical Undergraduates: Randomized Controlled Trial. *Journal of Medical Internet Research*, *26*, e57037. https://doi.org/10.2196/57037

Hu, Z., Peng, Z., Bi, Z., Shen, Q., Liu, Z., Lou, J., et al. (2025). Advancing Healthcare with Large Language Models: Techniques and Application. *IEEE/CAA Journal of Automatica Sinica*, *12*(12), 2371–2398. https://doi.org/10.1109/JAS.2025.125540

Khan, U. A., Khan, F., Khan, E., Hasnain, M. A., & Moinuddin, A. A. (2025). Towards Efficient Educational Chatbots: Benchmarking RAG Frameworks. *2025 International Conference on Emerging Technologies in Computing and Communication (ETCC)*. https://doi.org/10.1109/ETCC65847.2025.11108323

Kitchenham, B., & Charters, S. (2007). *Guidelines for Performing Systematic Literature Reviews in Software Engineering* (rel. téc. N.º EBSE-2007-01). Keele University e Durham University.

Liu, Z., Wang, Y., Ho, H.-R., Wu, Y., Zhao, Y., & Mutlu, B. (2026). AskNow: An LLM-powered Interactive System for Real-Time Question Answering in Large-Scale Classrooms. *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. https://doi.org/10.1145/3772318.3790328

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., et al. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, *372*, n71. https://doi.org/10.1136/bmj.n71

Parlamento Europeu e Conselho da União Europeia. (2016). Regulamento (UE) 2016/679 relativo à proteção das pessoas singulares no que diz respeito ao tratamento de dados pessoais (Regulamento Geral sobre a Proteção de Dados). https://eur-lex.europa.eu/eli/reg/2016/679/oj

Parlamento Europeu e Conselho da União Europeia. (2024). Regulamento (UE) 2024/1689 que cria regras harmonizadas em matéria de inteligência artificial (Regulamento da Inteligência Artificial). https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*, *24*(3), 45–77. https://doi.org/10.2753/MIS0742-1222240302

Rahat, M. T. I., Safowan, R., Abir, M., & Rahman, R. M. (2026). Noise, Distraction, and Mitigation: An Analysis of RAG Failure Modes in Medical Question Answering. *2026 International Conference on Artificial Intelligence in Information and Communication (ICAIIC)*. https://doi.org/10.1109/ICAIIC68212.2026.11454362

Rayhan, M. H., Edwards, G. R., Pandey, A., Seth, V., Salvi, N., Glaser, N., Chrysochoou, M., & Calyam, P. (2026). SAGE: Student-Focused Adaptive Guidance Engine for Intelligent Tutoring with Regulated Learning. *2026 IEEE International Conference on Human-Machine Systems (ICHMS)*. https://doi.org/10.1109/ICHMS69701.2026.11602253

Walczak, J., & Sawicki, B. (2026). Comparative Evaluation of Llama Guard 3 and GPT OSS Safeguard as LLM Guardrails for a University Administrative Chatbot. *2026 Progress in Applied Electrical Engineering (PAEE)*. https://doi.org/10.1109/PAEE71887.2026.11660667

Wei, H., Chai, Y., You, S., Jia, Y., Lu, W., & Sok, M. (2026). Cloud-Edge Retrieval-Augmented Agent Tutor for Trustworthy Personalized Learning in Resource-Constrained Higher Education. *2026 5th International Conference on Artificial Intelligence, Internet of Things and Cloud Computing Technology (AIoTC)*. https://doi.org/10.1109/AIoTC71250.2026.11689071

Wu, T., He, S., Liu, J., Sun, S., Liu, K., Han, Q.-L., et al. (2023). A Brief Overview of ChatGPT: The History, Status Quo and Potential Future Development. *IEEE/CAA Journal of Automatica Sinica*, *10*(5), 1122–1136. https://doi.org/10.1109/JAS.2023.123618

Xie, W., Fang, Y., Zheng, X., Liu, D., & Li, Z. (2026). When Retrieval Hurts: A Critical Analysis of RAG in Medical Question Answering. *Proceedings of the 2025 3rd International Conference on Artificial Intelligence, Systems and Network Security*. https://doi.org/10.1145/3797161.3797211