ISEP INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Francisco Reis

Dissertação para obtenção do Grau de Mestre em Engenharia Informática, Área de Especialização em Software Engineering

Orientador: Nuno Silva
Supervisor: Bruno Guimarães

Porto, 2 de novembro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 2 de novembro de 2026

Resumo

O Adhara QBank é uma plataforma de estudo na área da saúde, onde estudantes e profissionais resolvem exames compostos por perguntas de escolha múltipla nos modos Teste, Estudo e Simulado. Cada pergunta inclui informação validada pela equipa científica, como a vinheta clínica, as opções de resposta, a resposta correta, a explicação, dicas e informação complementar. Como a explicação apresentada durante o exame pode não esclarecer todas as dúvidas, esta dissertação, desenvolvida em colaboração com a Adhara, concebe, implementa e avalia um assistente conversacional multilingue integrado no QBank. O assistente responde a questões sobre a pergunta em curso recorrendo exclusivamente à informação associada a essa pergunta, respeitando as restrições de cada modo e recusando questões fora do contexto disponível.

A avaliação considera a correção e fidelidade das respostas à informação da pergunta, a capacidade de recusa, o desempenho, o custo e a utilidade e usabilidade percebidas pelos utilizadores. A abordagem segue a metodologia *Design Science Research*.

Palavras-chave: Modelos de Linguagem, Banco de Perguntas, Educação Médica, Geração Fundamentada em Contexto, Assistente Conversacional, Engenharia de Prompts

Abstract

Adhara QBank is a health-sciences study platform where students and healthcare professionals take exams composed of multiple-choice questions in Test, Study and Mock Exam modes. Each question includes information validated by the scientific team, such as a clinical vignette, answer options, the correct answer, an explanation, hints and supplementary information. Since the explanation shown during an exam may not resolve every doubt, this dissertation, developed in collaboration with Adhara, designs, implements and evaluates a multilingual conversational assistant integrated into QBank. The assistant answers questions about the current item using only the information associated with that question, respects the restrictions of each mode and refuses questions outside the available context.

The evaluation considers the correctness and faithfulness of answers to the question's information, refusal capability, performance, cost, and users' perceived usefulness and usability. The work follows the Design Science Research methodology.

Agradecimentos

Conteúdo

Lista de Figuras **xiii**

Lista de Tabelas **xv**

Lista de Acrónimos **xvii**

1 Introdução **1**
1.1 Contexto e Motivação . . . 1
1.2 A Organização e o Adhara QBank . . . 1
1.3 Definição do Problema . . . 2
1.4 Objetivos . . . 3
1.5 Questões de Investigação . . . 4
1.6 Abordagem Metodológica . . . 4
1.7 Gestão de Riscos . . . 5
1.8 Contribuições Esperadas . . . 5
1.9 Considerações Éticas e Profissionais . . . 6
1.10 Estrutura do Documento . . . 7

2 Estado da Arte **9**
2.1 Fundamentos Teóricos . . . 9
2.1.1 Aprendizagem com Perguntas e *Feedback* . . . 9
2.1.2 Assistentes Conversacionais . . . 10
2.1.3 Modelos de Linguagem de Grande Dimensão . . . 10
2.1.4 Formas de Fornecer Contexto ao Modelo . . . 10
2.1.5 Alucinação, Fidelidade e Recusa . . . 11
2.1.6 Controlo do Âmbito e Segurança . . . 11
2.1.7 Avaliação de Respostas . . . 12
2.2 Protocolo da Revisão . . . 12
2.2.1 Questões da Revisão . . . 12
2.2.2 Fontes e Estratégia de Pesquisa . . . 13
2.2.3 Critérios de Inclusão e Exclusão . . . 14
2.2.4 Seleção dos Estudos . . . 14
2.2.5 Avaliação da Qualidade e Extração de Dados . . . 15
2.3 Resultados da Pesquisa e da Seleção . . . 16
2.4 Síntese Crítica . . . 17
2.4.1 Como o Contexto Chega ao Modelo (RQ1) . . . 18
2.4.2 Controlo do Âmbito e Segurança (RQ1) . . . 19
2.4.3 Compromissos Operacionais (RQ1) . . . 19
2.4.4 Avaliação da Correção, da Fidelidade e do Âmbito (RQ2) . . . 20
2.4.5 Limitações Recorrentes . . . 21
2.5 Lacuna de Investigação . . . 21

2.6 Ameaças à Validade 22
2.7 Conclusões do Capítulo 22

3 Desenho da Solução **23**
3.1 Requisitos 23
3.1.1 Requisitos Funcionais 23
3.1.2 Requisitos Não Funcionais 23
3.2 Contexto de Cada Pergunta 24
3.3 Arquitetura 24
3.4 Estratégias de *Prompting* e Restrições 24
3.5 Verificações Fora do Modelo 24
3.6 Escolha do Modelo 25

Bibliografia **27**

Apêndice A Estudos Prioritários da Revisão **35**

Lista de Figuras

2.1 Duas formas de fornecer contexto ao modelo: (a) recuperação a partir de um corpus; (b) leitura direta dos dados da pergunta em curso, a abordagem do QBank. 11
2.2 Diagrama PRISMA da seleção dos estudos 16

3.1 Arquitetura do assistente 24

Lista de Tabelas

1.1 Dimensionamento do Adhara QBank e restrições preliminares indicadas pela Adhara. 2
1.2 Riscos do projeto, classificação e medidas de mitigação. 5

2.1 Critérios *Population, Intervention, Comparison, Outcomes, Context* (PICOC) da revisão e onde são aplicados. 13
2.2 Expressões de pesquisa e questões a que respondem. 14
2.3 Critérios de inclusão e exclusão. 14
2.4 Campos de extração de dados. 15
2.5 Registo da pesquisa (2 de novembro de 2026; título, resumo e palavras-chave; 2021–2026). 16
2.6 Indicadores descritivos dos 211 estudos incluídos (a partir de títulos e resumos). 17
2.7 Da evidência à oportunidade de investigação. 21

A.1 Classificação dos estudos prioritários. 35

Lista de Acrónimos

API	*Application Programming Interface*.
DSR	*Design Science Research*.
IA	Inteligência Artificial.
ICL	*In-Context Learning*.
LLM	*Large Language Model*.
MCQ	*Multiple-Choice Question*.
PICOC	*Population, Intervention, Comparison, Outcomes, Context*.
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*.
QA	*Question Answering*.
RAG	*Retrieval-Augmented Generation*.
RAGAS	*Retrieval Augmented Generation Assessment*.
RGPD	Regulamento Geral sobre a Proteção de Dados.
RQ	*Research Question*.
SUS	*System Usability Scale*.

Capítulo 1

Introdução

Este capítulo apresenta o contexto e a motivação do trabalho, a organização onde é desenvolvido, o problema abordado, os objetivos e as questões de investigação, a abordagem metodológica, a gestão de riscos, as contribuições esperadas, as considerações éticas e profissionais e a organização do documento.

1.1 Contexto e Motivação

Os bancos de perguntas de escolha múltipla (*Multiple-Choice Question*s (MCQs)) são um recurso habitual na preparação para exames na área da saúde. O Adhara QBank é uma plataforma de estudo da Adhara com cerca de 50 mil perguntas de escolha múltipla em seis línguas, usada por estudantes de medicina, médicos e enfermeiros (Secção 1.2).

Durante o estudo, o utilizador pode ficar com dúvidas que a explicação estática da pergunta não resolve, por exemplo, porque é que uma determinada opção está errada ou como se relaciona um achado da vinheta com a resposta correta. Atualmente, a plataforma não oferece forma de esclarecer essas dúvidas no momento, embora a base de dados contenha mais informação sobre a pergunta do que aquela que é apresentada no ecrã.

Os assistentes conversacionais baseados em *Large Language Model*s (LLMs) têm sido propostos como apoio ao estudo em educação e em educação médica (Abd-alrazaq et al. 2023; Kasneci et al. 2023), com benefícios reportados, por exemplo, num ensaio controlado com estudantes de medicina (Gan et al. 2024). Em contexto médico, porém, recorrer a um assistente genérico é arriscado: os LLMs podem gerar respostas plausíveis mas incorretas ou infiéis ao contexto que lhes é fornecido (Huang et al. 2025), e essas respostas podem não coincidir com o conteúdo validado pela equipa científica. Fundamentar a resposta em informação fornecida ao modelo, por exemplo através de *Retrieval-Augmented Generation* (RAG) (Lewis et al. 2020), pode reduzir este risco (Jang et al. 2025), mas não o elimina (Huang et al. 2025). Além disso, as instruções que limitam o assistente podem ser contornadas por manipulação do *prompt* (Geng et al. 2026; Greshake et al. 2023), o que, num exame, pode comprometer a integridade da avaliação. A literatura aponta ainda a necessidade de orientações para a utilização de Inteligência Artificial (IA) em educação médica (Gordon et al. 2024).

1.2 A Organização e o Adhara QBank

O trabalho é desenvolvido em colaboração com a Adhara (Adhara, Unipessoal, Lda.), uma empresa portuguesa especializada em educação médica digital e em formação pós-graduada

para profissionais de saúde. O Adhara QBank é a sua plataforma de preparação para exames com perguntas de escolha múltipla. Existe em português europeu, português do Brasil, inglês, espanhol, francês e italiano e reúne cerca de 50 mil perguntas no conjunto das línguas. A Adhara tem cerca de 3100 utilizadores, dos quais se espera que 10 a 20% adiram ao QBank.

O utilizador resolve exames de 40 perguntas em três modos: Teste, Estudo e Simulado. Cada pergunta tem informação validada pela equipa científica da Adhara: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação, catalogação e informação complementar. Cada versão linguística do QBank tem o seu próprio conteúdo validado.

No levantamento inicial com a Adhara foram identificados os dados de dimensionamento e as restrições preliminares resumidos na Tabela 1.1. Estas restrições orientam as decisões de desenho do Capítulo 3 e serão consolidadas durante o levantamento de requisitos.

Tabela 1.1: Dimensionamento do Adhara QBank e restrições preliminares indicadas pela Adhara.

Aspeto	**Valor ou estado**
Línguas	Português europeu, português do Brasil, inglês, espanhol, francês e italiano
Perguntas	Cerca de 50 mil, no conjunto das línguas
Utilizadores da Adhara	Cerca de 3100
Adesão esperada ao QBank	10 a 20% dos utilizadores da Adhara, ou seja, 310 a 620
Utilização do assistente	Desconhecida à partida; será medida através das estatísticas de utilização
Tempo de resposta aceitável	2 a 3 segundos
Orçamento para o LLM	Cerca de 100 € por mês
Envio do conteúdo das perguntas para uma *Application Programming Interface* (API) externa	Aceitável para a Adhara
Crescimento da base de dados (cache e registos)	A verificar; hipótese de exportação e limpeza semanal
Validação das respostas	A definir; hipótese de extrair os pares pergunta–resposta do assistente para validação pela equipa da Adhara ou por um agente de IA
Prioridade entre qualidade, custo e privacidade	Por definir
Disponibilidade exigida (*SLA*)	Por definir

1.3 Definição do Problema

Durante a resolução de uma pergunta no Adhara QBank, o utilizador pode precisar de esclarecer aspetos que não são cobertos pela explicação apresentada no ecrã. A base de dados contém informação adicional associada à pergunta, mas não existe uma forma integrada de a consultar através de perguntas em linguagem natural. Recorrer a fontes externas ou a assistentes genéricos pode produzir respostas que não correspondem ao conteúdo validado do item ou que introduzem informação alheia ao contexto.

O problema abordado nesta dissertação é, assim, conceber um assistente conversacional baseado em LLM que responda apenas com a informação já guardada na base de dados

para cada pergunta (vinheta, opções, catalogação, resposta correta, explicação, dicas e informação complementar), sem recorrer a conhecimento externo, e que se mantenha fiel a esse contexto. O assistente não deve responder a questões fora do âmbito da pergunta nem comprometer a integridade da avaliação.

O problema tem as seguintes características:

- **Âmbito por modo.** O QBank tem três modos, mas o assistente só está disponível nos modos Teste e Estudo; não aparece no modo Simulado. Em cada modo, a resposta tem de respeitar as regras do modo e o estado de revelação da resposta correta.
- **Multilinguismo.** O QBank existe em várias línguas e o assistente tem de responder na língua do QBank em que o utilizador está a estudar, com base no conteúdo validado nessa língua.
- **Contexto fechado por item.** O contexto relevante é conhecido à partida (os dados da pergunta em curso) e é fornecido diretamente ao modelo, sem uma etapa de pesquisa num corpus de documentos.
- **Restrições a harmonizar.** As capacidades conversacionais genéricas do modelo têm de ser harmonizadas com restrições de fidelidade ao contexto, qualidade da resposta, segurança, custo, latência e integração na arquitetura do QBank. As restrições preliminares estão na Tabela 1.1 e serão consolidadas com a Adhara. Com 310 a 620 utilizadores esperados no QBank, uma utilização do assistente ainda desconhecida, um tempo de resposta de 2 a 3 segundos e um orçamento de cerca de 100 € por mês, o custo e a latência de cada pedido ao modelo são restrições de desenho e não apenas métricas de avaliação.
- **Várias partes interessadas.** Utilizadores (estudantes, médicos e enfermeiros) e Adhara, incluindo a equipa científica responsável pelo conteúdo.
- **Consequências.** Uma resposta fora do conteúdo validado pode induzir erros de aprendizagem e afetar a credibilidade da plataforma, a privacidade dos utilizadores e os custos de operação (Abd-alrazaq et al. 2023; Huang et al. 2025).

1.4 Objetivos

O objetivo geral é conceber, implementar e avaliar um assistente conversacional integrado no Adhara QBank que esclareça dúvidas sobre cada pergunta de escolha múltipla, usando exclusivamente a informação da base de dados dessa pergunta.

Para o atingir, definem-se os seguintes objetivos específicos:

1. sistematizar o conhecimento existente sobre assistentes conversacionais baseados em LLMs com respostas limitadas a um contexto definido, e sobre a forma como essas respostas são avaliadas (Capítulo 2);
2. levantar, com a Adhara, os requisitos do assistente, incluindo as regras por modo e as restrições de fidelidade, segurança, custo e latência;
3. identificar os campos da base de dados relevantes para responder a dúvidas sobre cada pergunta e definir como são fornecidos ao modelo;
4. conceber e implementar mecanismos para limitar as respostas ao contexto da pergunta, responder na língua do QBank e recusar questões sem suporte nesse contexto;

5. integrar o assistente no fluxo de resolução de perguntas do QBank, nos modos Teste e Estudo;
6. avaliar a correção e a fidelidade das respostas, a capacidade de recusa, o comportamento em várias línguas, a latência e o custo, e a utilidade e usabilidade percebidas pelos utilizadores.

1.5 Questões de Investigação

O trabalho é orientado por duas questões de investigação (*Research Question*s (RQs)), respondidas através da revisão da literatura do Capítulo 2 e usadas para orientar o desenho e a avaliação do assistente:

RQ1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

A RQ1 abrange o mecanismo pelo qual o contexto chega ao modelo, os mecanismos de controlo do âmbito e de segurança e os compromissos de fiabilidade, latência, custo e integração. A RQ2 abrange os métodos, as métricas e os resultados da avaliação das respostas.

1.6 Abordagem Metodológica

O trabalho segue a metodologia *Design Science Research* (DSR), na qual o conhecimento é produzido através da conceção e avaliação de um artefacto que resolve um problema relevante (Hevner et al. 2004). São seguidas as seis atividades propostas por Peffers et al. (2007):

1. **Identificação do problema e motivação**: caracterização do problema com a Adhara (Secções 1.1 e 1.3).
2. **Definição dos objetivos da solução**: objetivos e critérios de sucesso (Secção 1.4), informados pela revisão da literatura (Capítulo 2).
3. **Desenho e desenvolvimento**: requisitos, arquitetura do assistente e integração no QBank (Capítulo 3), desenvolvidos de forma iterativa a partir de um *backlog* priorizado.
4. **Demonstração**: utilização do assistente em perguntas reais do QBank, nos modos Teste e Estudo.
5. **Avaliação**: avaliação técnica com perguntas respondíveis e não respondíveis a partir dos dados de cada item, em várias línguas, analisando correção, fidelidade, recusa, latência e custo; avaliação da correção por especialistas da Adhara; e avaliação da utilidade e usabilidade junto de utilizadores, através de questionário.
6. **Comunicação**: esta dissertação.

O estado da arte é construído através de uma revisão sistemática da literatura, conduzida segundo as orientações de Kitchenham e Charters (2007) e relatada segundo o *Preferred*

Reporting Items for Systematic Reviews and Meta-Analyses (PRISMA) 2020 (Page et al. 2021). O protocolo, a pesquisa, a seleção e a síntese estão descritos no Capítulo 2.

1.7 Gestão de Riscos

Os riscos do projeto foram identificados no início do trabalho e classificados quanto à probabilidade (P) e ao impacto (I), numa escala de 1 (muito baixo) a 5 (muito alto). O nível de cada risco é o produto $P \times I$: baixo até 5, médio de 6 a 11 e alto a partir de 12. A Tabela 1.2 apresenta os riscos e as respetivas medidas de mitigação. Os riscos são revistos no fim de cada iteração do desenvolvimento.

Tabela 1.2: Riscos do projeto, classificação e medidas de mitigação.

Id	Risco	P	I	P×I	Mitigação
R1	Respostas incorretas ou infiéis ao conteúdo validado da pergunta	3	5	15	Contexto fechado por pergunta; instruções de recusa; avaliação da fidelidade com perguntas de teste e por especialistas da Adhara
R2	Custo da API acima de 100 € por mês, sendo a utilização do assistente desconhecida à partida	3	4	12	Estimativa de custo por pedido; contexto compacto; cache de respostas; limites de utilização; monitorização do consumo
R3	Tempo de resposta acima de 2 a 3 segundos	3	4	12	Resposta em *streaming*; contexto compacto; cache; medição da latência desde o início do desenvolvimento
R4	Revelação da resposta correta ou desvio do âmbito por manipulação do *prompt*	3	4	12	Regras de cada modo aplicadas fora do modelo (por exemplo, não enviar dados ainda não revelados); testes adversariais
R5	Qualidade desigual entre as seis línguas	3	3	9	Conjunto de teste em todas as línguas; uso do conteúdo validado da língua do QBank
R6	Pouca disponibilidade dos especialistas da Adhara para a avaliação	3	3	9	Planear a avaliação cedo; usar uma amostra; LLM juiz como apoio, validado numa subamostra
R7	Alteração de preço, de modelo ou indisponibilidade do fornecedor da API	2	4	8	Camada de abstração do fornecedor; alternativa identificada; registo da versão do modelo usada
R8	Atraso no cronograma	3	3	9	*Backlog* priorizado; versão mínima funcional primeiro; acompanhamento com o orientador
R9	Crescimento da base de dados com a cache e os registos	2	2	4	Política de retenção; exportação e limpeza periódica

1.8 Contribuições Esperadas

Como resultados, este trabalho pretende contribuir com:

- uma revisão sistemática sobre assistentes conversacionais baseados em LLMs com respostas limitadas a um contexto definido, em educação e saúde, com uma síntese dos mecanismos de contextualização, de controlo de âmbito e de avaliação (Capítulo 2);
- um assistente conversacional integrado no fluxo de resolução de perguntas do Adhara QBank, que responde na língua do QBank, usando apenas a informação validada da pergunta em curso, e que respeita as regras de cada modo;
- uma abordagem para fornecer ao modelo o contexto fechado de cada pergunta e para recusar questões sem suporte nesse contexto;

- um protocolo e um conjunto de testes para avaliar a correção, a fidelidade ao contexto, a capacidade de recusa, o comportamento multilingue, a latência e o custo do assistente.

1.9 Considerações Éticas e Profissionais

Esta dissertação segue o *Software Engineering Code of Ethics and Professional Practice*, elaborado pela ACM e pela IEEE Computer Society (ACM/IEEE-CS Joint Task Force on Software Engineering Ethics and Professional Practices 1999), considerando os seus princípios relativos ao interesse público, à qualidade do produto, à integridade do julgamento profissional e à responsabilidade dos engenheiros de software. No desenvolvimento do assistente, estes princípios são aplicados através da limitação das respostas ao contexto autorizado, da avaliação da sua correção e fidelidade e da documentação das limitações conhecidas do sistema.

O trabalho observa também o Código Europeu de Conduta para a Integridade da Investigação (ALLEA 2023) e o Código de Ética e de Conduta do P.PORTO (Politécnico do Porto 2020), nomeadamente no que respeita à integridade científica, à referenciação das fontes e à proteção da confidencialidade. O conteúdo do QBank é propriedade da Adhara e é usado apenas no âmbito deste trabalho. Caso sejam recolhidos ou tratados dados pessoais durante a avaliação com utilizadores, o plano de recolha, utilização, conservação e eliminação desses dados será definido de acordo com o Regulamento Geral sobre a Proteção de Dados (RGPD) (Parlamento Europeu e Conselho da União Europeia 2016) e com as orientações do ISEP. Sendo um sistema de IA usado em contexto educativo, são também consideradas as obrigações de transparência do Regulamento da Inteligência Artificial da União Europeia (Parlamento Europeu e Conselho da União Europeia 2024), nomeadamente informar o utilizador de que está a interagir com um sistema de IA.

Utilização de um modelo através de uma API externa. A infraestrutura disponível não permite executar o modelo de linguagem localmente, pelo que o assistente usará um LLM acedido através de uma API externa paga. Isto implica que o pedido do utilizador e o contexto da pergunta são enviados a um serviço de terceiros. Para limitar os riscos:

- são enviados apenas os dados necessários para responder: a mensagem do utilizador, o histórico da conversa sobre a pergunta e os dados dessa pergunta; não são enviados dados identificativos do utilizador;
- o fornecedor será escolhido tendo em conta as suas condições de tratamento de dados, nomeadamente a retenção dos pedidos, a não utilização para treino e a localização do processamento, e a relação com o fornecedor será enquadrada no RGPD (Parlamento Europeu e Conselho da União Europeia 2016);
- a Adhara, enquanto detentora do conteúdo do QBank, considerou aceitável o envio dos dados das perguntas para o fornecedor; as condições serão formalizadas na escolha do fornecedor.

Registo das perguntas para fins estatísticos. As perguntas feitas ao assistente poderão ser registadas e agrupadas por tema, para fins estatísticos e de melhoria do conteúdo. Este registo terá uma finalidade definida, será feito sem associar as perguntas à identidade do utilizador, terá um prazo de conservação definido e será comunicado ao utilizador.

A utilização de ferramentas de IA neste trabalho é declarada de forma transparente:

- **Funcionalidade do protótipo**: o assistente usa um LLM, acedido por API, para gerar as respostas.
- **Revisão da literatura**: foi usado um assistente de IA para apoiar a escrita dos *scripts* de recolha, deduplicação e triagem, e para propor decisões de triagem por título e resumo. Todas as decisões ficaram registadas com o respetivo motivo e foram verificadas pelo autor (Secção 2.2.4). As referências foram verificadas nas fontes originais.
- **Desenvolvimento de software**: assistentes de IA podem ser usados para apoiar a escrita, revisão e depuração de código.
- **Revisão do documento**: ferramentas de IA podem ser usadas para revisão linguística, sem substituir o julgamento do autor sobre o conteúdo.

1.10 Estrutura do Documento

Para além deste capítulo, o documento está organizado da seguinte forma. O Capítulo 2 apresenta o estado da arte: os fundamentos teóricos e uma revisão sistemática da literatura, com o protocolo, os resultados da pesquisa e da seleção, a síntese crítica dos estudos e a lacuna de investigação. O Capítulo 3 descreve o desenho da solução: requisitos e arquitetura do assistente e a sua integração no QBank. Os capítulos seguintes apresentam a implementação, a avaliação e os resultados, e as conclusões e o trabalho futuro.

Capítulo 2

Estado da Arte

Este capítulo apresenta o estado da arte sobre assistentes conversacionais baseados em LLMs cujas respostas são limitadas a um contexto definido pela aplicação, com foco em educação e saúde. Começa por apresentar os fundamentos teóricos (Secção 2.1). Descreve depois o protocolo da revisão sistemática (Secção 2.2) e os resultados da pesquisa e da seleção (Secção 2.3). Segue-se a síntese crítica dos estudos, organizada pelas questões de investigação (Secção 2.4), a lacuna de investigação que dela resulta (Secção 2.5), as ameaças à validade (Secção 2.6) e as conclusões do capítulo (Secção 2.7).

2.1 Fundamentos Teóricos

Esta secção apresenta os fundamentos em que o trabalho assenta: o papel das perguntas de escolha múltipla e do *feedback* na aprendizagem, os assistentes conversacionais, o funcionamento e as limitações dos LLMs, as formas de lhes fornecer contexto, o controlo do âmbito e a avaliação das respostas. A literatura recente sobre sistemas concretos é analisada a partir da Secção 2.2, através da revisão sistemática.

2.1.1 Aprendizagem com Perguntas e Feedback

Responder a perguntas não serve apenas para avaliar: o esforço de recordar a informação melhora a retenção a longo prazo mais do que voltar a estudá-la, um fenómeno conhecido como efeito de teste (Roediger e Karpicke 2006). Este efeito foi também observado em educação médica, onde os testes frequentes são propostos como estratégia de aprendizagem e não só de avaliação (Larsen et al. 2008). Os bancos de perguntas como o QBank apoiam-se neste princípio.

O efeito da prática depende do *feedback* que se segue à resposta. Hattie e Timperley (2007) definem o *feedback* como a informação que ajuda o estudante a reduzir a distância entre o desempenho atual e o desejado, respondendo a três perguntas: para onde vou, como estou a ir e qual o passo seguinte. Shute (2008) conclui que o *feedback* elaborado, que explica porque é que uma resposta está certa ou errada, tende a ser mais eficaz do que a simples indicação de certo ou errado, e que deve ser específico e ajustado ao estudante. A explicação de cada pergunta do QBank é um *feedback* elaborado, mas é igual para todos os utilizadores e não responde à dúvida concreta de cada um.

Um assistente conversacional permite aproximar esse *feedback* de uma tutoria individual, na qual o estudante pergunta o que não percebeu. A tutoria individual é há muito associada a ganhos de aprendizagem elevados face ao ensino em grupo (Bloom 1984), e esta é uma

das motivações para o uso de LLMs em educação (Kasneci et al. 2023). O mesmo enquadramento justifica as regras por modo: no modo Teste, um assistente que revele a resposta antes de o estudante responder anula o esforço de recordar, de que depende o efeito de teste.

2.1.2 Assistentes Conversacionais

Os assistentes conversacionais evoluíram de sistemas baseados em regras e padrões, como a ELIZA (Weizenbaum 1966), para sistemas que selecionam respostas de uma base de conhecimento e, mais recentemente, para sistemas generativos baseados em LLMs (Adamopoulou e Moussiades 2020). Podem ser classificados, entre outros critérios, pelo domínio (aberto ou fechado), pelo objetivo (informativo, orientado a tarefas ou de conversa livre) e pelo método de produção da resposta (regras, recuperação ou geração) (Adamopoulou e Moussiades 2020). Nesta classificação, o assistente do QBank é de domínio fechado, informativo e generativo. A sua particularidade é que o domínio não é o da plataforma em geral mas o da pergunta em curso: o contexto muda a cada item.

2.1.3 Modelos de Linguagem de Grande Dimensão

Os LLMs atuais baseiam-se na arquitetura *Transformer*, em que mecanismos de atenção relacionam cada elemento do texto com os restantes (Vaswani et al. 2017). São treinados em grandes corpora para prever o elemento seguinte do texto e, a partir de certa escala, conseguem executar tarefas descritas no *prompt*, com ou sem exemplos, sem alterar os seus parâmetros: a aprendizagem em contexto (*In-Context Learning* (ICL)) (Brown et al. 2020). O ajuste por instruções com *feedback* humano torna os modelos mais capazes de seguir instruções e de produzir respostas úteis (Ouyang et al. 2022). É esta capacidade que permite definir o comportamento de um assistente através de instruções de sistema, mas as instruções orientam o modelo sem garantir que são cumpridas.

O texto é processado em *tokens*, unidades que correspondem aproximadamente a partes de palavras. Cada modelo aceita um número máximo de *tokens* por pedido (a janela de contexto). Nas APIs comerciais, o custo é calculado pelo número de *tokens* de entrada e de saída, e o tempo de resposta cresce com o comprimento da resposta, que é gerada *token* a *token*. A quantidade de dados da pergunta incluída no *prompt* afeta, assim, diretamente o custo e a latência. Além disso, ter a informação no contexto não garante que é usada: Liu et al. (2024a) mostram que o desempenho é melhor quando a informação relevante está no início ou no fim do contexto e piora quando está no meio, o que é relevante para a forma como os campos da pergunta são organizados no *prompt*.

O desempenho dos LLMs varia também com a língua. Numa avaliação de modelos generativos em dezenas de línguas, Ahuja et al. (2023) observaram melhores resultados em inglês e nas línguas com mais recursos do que nas línguas com menos recursos. As seis línguas do QBank são de recursos elevados, mas a diferença entre línguas, incluindo entre as variantes europeia e brasileira do português, tem de ser verificada na avaliação.

2.1.4 Formas de Fornecer Contexto ao Modelo

Na geração aumentada por recuperação (RAG), o sistema pesquisa num corpus os excertos mais relevantes para a pergunta do utilizador e inclui-os no *prompt* antes da geração (Lewis et al. 2020). Em alternativa, quando o contexto relevante é conhecido à partida, pode

ser incluído diretamente no *prompt*, sem pesquisa. Esta forma de condicionar o modelo pelo contexto do *prompt*, sem alterar os seus parâmetros, enquadra-se na aprendizagem em contexto (ICL). No QBank, o contexto é o registo da pergunta em curso, identificado pelo seu ID, pelo que não existe uma etapa de recuperação. Ambas as abordagens dependem de o modelo usar o contexto fornecido e não o seu conhecimento interno. A Figura 2.1 compara as duas: a diferença está no passo destacado, em que a pesquisa por semelhança, sujeita a erros de recuperação, é substituída pela leitura direta do registo do item. Uma terceira alternativa, o ajuste fino (*fine-tuning*), altera os parâmetros do modelo com dados do domínio. Não é adequada ao caso, porque o conhecimento teria de ser atualizado sempre que o conteúdo muda e não garante que a resposta se limita a um item.

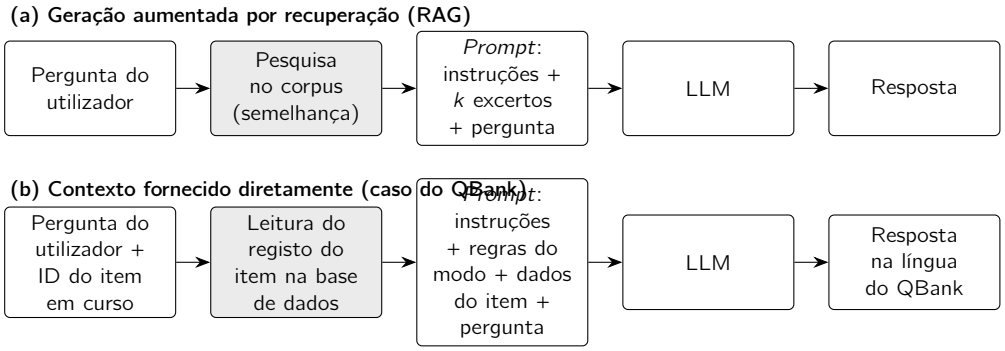


Figura 2.1: Duas formas de fornecer contexto ao modelo: (a) recuperação a partir de um corpus; (b) leitura direta dos dados da pergunta em curso, a abordagem do QBank.

2.1.5 Alucinação, Fidelidade e Recusa

Um LLM gera texto plausível a partir do conhecimento adquirido no treino e do texto que recebe no *prompt*. Designa-se por alucinação a geração de conteúdo incorreto ou não suportado. Huang et al. (2025) distinguem a alucinação de factualidade (conteúdo que contradiz factos do mundo) da alucinação de fidelidade (conteúdo que se afasta do contexto ou das instruções fornecidas). No caso do QBank, a propriedade mais relevante é a fidelidade: o assistente deve responder com base nos dados validados da pergunta, mesmo que o modelo tenha conhecimento próprio diferente.

Uma forma de reduzir respostas sem suporte é o modelo abster-se quando o contexto não contém a informação necessária. Kadavath et al. (2022) mostram que os modelos conseguem, em parte, estimar se sabem a resposta, mas essa estimativa não é perfeita. Num assistente de contexto fechado, a recusa não pode depender só desta capacidade: tem de ser pedida explicitamente nas instruções e avaliada com perguntas cuja resposta não está no contexto.

2.1.6 Controlo do Âmbito e Segurança

Um assistente de âmbito restrito deve recusar pedidos fora desse âmbito (abstenção ou recusa). As instruções que definem esse âmbito podem ser contornadas por injeção de instruções (*prompt injection*), quer diretamente pelo utilizador quer através de conteúdo externo incluído no *prompt* (Geng et al. 2026; Greshake et al. 2023). Os mecanismos de defesa incluem filtros de entrada e de saída, modelos classificadores dedicados (*guardrails*) e arquiteturas com mais do que um modelo.

Perez e Ribeiro (2022) distinguem dois objetivos destes ataques: desviar o modelo da tarefa definida (*goal hijacking*) e levá-lo a revelar as suas instruções ou o contexto (*prompt leaking*). A *OWASP Top 10 for LLM Applications* coloca a injeção de instruções em primeiro lugar entre os riscos de aplicações com LLMs e inclui a fuga das instruções de sistema (OWASP Foundation 2024). No QBank, uma fuga com consequências seria revelar a resposta correta no modo Teste. Daqui resulta um princípio de desenho: a informação que não pode ser revelada não deve estar no *prompt*, porque nenhuma instrução garante que o modelo não a revela.

2.1.7 Avaliação de Respostas

A avaliação de sistemas de resposta com contexto combina métricas de referência (exatidão, F1, semelhança semântica), métricas específicas de fidelidade ao contexto, como as do *Retrieval Augmented Generation Assessment* (RAGAS) (Es et al. 2024), avaliação por um LLM juiz (*LLM-as-a-judge*) (Zheng et al. 2023), avaliação por especialistas e estudos com utilizadores.

Estas abordagens têm custos e limitações diferentes. As métricas de referência exigem respostas de referência e penalizam formulações corretas mas diferentes. As métricas de fidelidade, como a do RAGAS, decompõem a resposta em afirmações e verificam se cada uma é suportada pelo contexto, sem precisar de uma resposta de referência (Es et al. 2024). Um LLM juiz permite avaliar muitas respostas a baixo custo, mas tem enviesamentos conhecidos, como a preferência pela posição ou por respostas mais longas (Zheng et al. 2023), pelo que deve ser validado com avaliação humana numa amostra. A avaliação por especialistas é a referência para a correção em contexto médico, mas é cara. A utilidade percebida e a usabilidade avaliam-se junto dos utilizadores, por exemplo com a escala *System Usability Scale* (SUS) (Brooke 1996).

2.2 Protocolo da Revisão

A revisão segue as orientações de Kitchenham e Charters (2007) para revisões sistemáticas em engenharia de software e é relatada segundo o PRISMA 2020 (Page et al. 2021). O protocolo definiu, antes da pesquisa final, as questões, as fontes, as expressões de pesquisa, os critérios de seleção e os campos de extração. As alterações feitas depois da pesquisa piloto estão justificadas na Secção 2.2.2.

2.2.1 Questões da Revisão

A revisão responde às duas questões de investigação definidas no Capítulo 1:

RQ1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

Cada questão é coberta por duas expressões de pesquisa (Tabela 2.2): a RQ1 pela Q1 (contexto) e pela Q3 (segurança do âmbito); a RQ2 pela Q2 (fidelidade e correção) e pela Q4 (recusa fora do âmbito).

O âmbito das questões foi estruturado com os critérios *Population, Intervention, Comparison, Outcomes, Context* (PICOC) (População, Intervenção, Comparação, Resultados e Contexto) recomendados por Kitchenham e Charters (2007). A Tabela 2.1 mostra cada critério e onde é aplicado: a população, a intervenção e os resultados dão origem aos blocos das expressões de pesquisa; o contexto é aplicado nos critérios de seleção, para não excluir na pesquisa estudos que não mencionam o domínio no título ou no resumo.

Tabela 2.1: Critérios PICOC da revisão e onde são aplicados.

Critério	**Definição**	**Aplicação**
População	Sistemas conversacionais e de resposta a perguntas baseados em LLMs	Blocos LLM e *chatbot*/*Question Answering* (QA) (Q1–Q4)
Intervenção	Limitação das respostas a um contexto definido pela aplicação (RAG, contexto no *prompt*, *grounding*) e controlo do âmbito (*guardrails*, recusa)	Bloco de contexto (Q1), segurança (Q3) e recusa (Q4)
Comparação	Entre formas de fornecer o contexto e com o modelo sem contexto, quando reportada	Extração (não restringe a pesquisa)
Resultados	Correção factual, fidelidade ao contexto, adesão ao âmbito e recusa, robustez a manipulação; latência e custo	Bloco de avaliação (Q2, Q4); critério I4; extração
Contexto	Educação e saúde; estudos primários publicados entre 2021 e 2026	Filtro de anos; critérios I1–I3

2.2.2 Fontes e Estratégia de Pesquisa

Fontes. Foram usadas três fontes: IEEE Xplore e ACM Digital Library, que cobrem a literatura de engenharia informática, sistemas e IA, e Scopus, uma base multidisciplinar que cobre também revistas de educação e saúde. As fontes foram escolhidas antes da pesquisa final.

Pesquisa piloto. Antes de fixar as expressões, foi feita uma pesquisa piloto nas três fontes, limitada aos primeiros 30 títulos de cada pesquisa. O piloto levou a três decisões: (i) estreitar as expressões a sistemas conversacionais e de resposta a perguntas, porque as versões gerais devolviam sobretudo geração de código, *hardware* de inferência e recomendação; (ii) retirar latência e custo dos blocos de pesquisa e tratá-los como campos de extração, pelo mesmo motivo; (iii) separar a segurança do âmbito (Q3) e a recusa fora do âmbito (Q4) em expressões próprias.

Expressões de pesquisa. Cada expressão combina blocos de conceitos: os sinónimos de um bloco são ligados por `OR` e os blocos por `AND`. Nenhuma expressão excede oito conectores booleanos. A Tabela 2.2 apresenta as quatro expressões.

Campos pesquisados. Em todas as fontes, as expressões foram aplicadas ao título, ao resumo e às palavras-chave, com o filtro de anos 2021–2026. No Scopus foi usado o campo `TITLE-ABS-KEY(...)`. No IEEE Xplore e na ACM Digital Library, que não têm um campo equivalente, cada termo foi expandido para os três campos (por exemplo, no IEEE Xplore, `("Document Title":LLM OR "Abstract":LLM OR "Author Keywords":LLM)`), mantendo a lógica booleana. A versão exata executada em cada fonte está guardada no registo da pesquisa.

Tabela 2.2: Expressões de pesquisa e questões a que respondem.

Id	RQ	Expressão
Q1	RQ1	`("large language model"OR LLM) AND (grounding OR "context injection"OR "prompt context"OR "retrieval-augmented generation") AND (chatbot OR "conversational system"OR "question answering")`
Q2	RQ2	`("large language model"OR LLM) AND (faithfulness OR factuality OR correctness) AND (chatbot OR "conversational system") AND (evaluation OR benchmark)`
Q3	RQ1	`("large language model"OR LLM) AND ("prompt injection"OR "prompt leakage"OR jailbreak OR guardrails) AND (chatbot OR "conversational system")`
Q4	RQ2	`("large language model"OR LLM) AND ("out-of-scope"OR abstention) AND (evaluation OR benchmark)`

Tabela 2.3: Critérios de inclusão e exclusão.

	Inclusão		Exclusão
I1	Publicado entre 27-10-2021 e 27-10-2026	E1	Duplicado
I2	Em inglês ou português	E2	Sem resumo, editorial, opinião, tutorial, descrição de *workshop* ou sem informação metodológica suficiente
I3	Estudo primário sobre sistema conversacional ou de resposta a perguntas baseado em LLM, aplicado a educação ou saúde, cujas respostas dependem de um contexto definido (RAG, contexto no *prompt* ou base de conhecimento)	E3	Não usa LLM; não é sistema conversacional ou de QA; fora de educação e saúde; método genérico sem aplicação; ou sem contexto definido
I4	Descreve a avaliação das respostas ou dos mecanismos de controlo (correção, fidelidade, recusa ou segurança)	E4	Revisão ou *survey* (excluída da síntese; pode apoiar o enquadramento)

Execução e registo. As pesquisas foram executadas a 2 de novembro de 2026. Foram exportados todos os resultados de cada pesquisa, com resumo, em RIS (IEEE Xplore e Scopus) ou BibTeX (ACM Digital Library). Para cada par fonte–pesquisa foram registados a expressão executada, a data, os filtros, o total indicado pela fonte e o número de registos exportados (Tabela 2.5).

2.2.3 Critérios de Inclusão e Exclusão

A Tabela 2.3 apresenta os critérios de seleção. O critério I3 delimita o foco da revisão a educação e saúde, que são os domínios do QBank, e exige que a resposta dependa de um contexto definido. Não exige recuperação de informação: um estudo em que o contexto é fornecido diretamente ao modelo cumpre-o, tal como um estudo com RAG. Excecionalmente, foram incluídos três estudos de outros domínios que avaliam diretamente o efeito do contexto incluído no *prompt*, por ser essa a técnica do caso de estudo.

2.2.4 Seleção dos Estudos

A seleção seguiu quatro passos, todos registados em ficheiros e reprodutíveis através de *scripts*:

Tabela 2.4: Campos de extração de dados.

#	Campo	Descrição	Questão
1	Referência	Autores, ano, fonte e tipo de publicação	—
2	Domínio e utilizadores	Educação ou saúde; estudantes, doentes, profissionais	RQ1
3	Origem do contexto	RAG, grafo de conhecimento, contexto no *prompt*, base de dados ou outro	RQ1
4	Controlo da resposta	Instruções, filtros, citações, verificação, recusa, *guardrails*	RQ1, RQ2
5	Modelo e componentes	Modelo de linguagem, *fine-tuning*, execução local ou na nuvem	RQ1
6	Avaliação	Método (métricas, LLM juiz, especialistas, utilizadores), dados e dimensão da amostra	RQ2
7	Resultados	Correção, fidelidade, recusa e segurança	RQ2
8	Compromissos e limitações	Latência, custo, integração, privacidade e limitações reportadas	RQ1

1. **Deduplicação.** Os registos das três fontes foram juntos e os duplicados removidos, primeiro pelo DOI normalizado e depois pelo título normalizado. Cada registo guarda a fonte e a pesquisa de onde veio.
2. **Triagem por regras (fase A).** Foram aplicadas regras explícitas sobre o título e o resumo, que implementam os critérios E2, E3 e E4 e o foco do I3 e do I4: registo sem resumo ou que não é artigo; revisão ou *survey*; ausência de termos de LLM; ausência de termos de sistema conversacional ou QA; ausência de termos de educação ou saúde; e ausência de termos de avaliação das respostas. As regras e os termos usados estão no *script* de triagem.
3. **Triagem por leitura (fase B).** Os registos que passaram a fase A foram lidos (título e resumo) e classificados como incluídos ou excluídos, com um critério e um motivo por registo. Esta triagem foi feita com apoio de um assistente de IA, que propôs as decisões e os motivos; as decisões foram verificadas pelo autor (Secção 1.9).
4. **Priorização.** Dentro dos incluídos, foram marcados como prioritários os estudos que cumprem pelo menos uma das seguintes condições, escolhidas pela proximidade ao caso de estudo: (a) contexto fechado e próximo do QBank (perguntas de exame ou de escolha múltipla, materiais de um curso ou um documento específico); (b) avaliação explícita da correção, da fidelidade ou da recusa; (c) mecanismo de controlo do âmbito ou de segurança; (d) suporte a várias línguas.

2.2.5 Avaliação da Qualidade e Extração de Dados

Na leitura do texto integral, cada estudo será avaliado com cinco critérios de qualidade, cada um classificado como *sim* (1), *parcial* (0,5) ou *não* (0): (QA1) o objetivo está claro; (QA2) o sistema, o modelo e a origem do contexto estão descritos; (QA3) os dados, as perguntas ou os cenários de avaliação estão descritos; (QA4) o método de avaliação é adequado às conclusões; (QA5) as limitações e ameaças à validade são discutidas. A pontuação não exclui estudos: serve para ponderar a evidência na síntese.

Os campos de extração estão na Tabela 2.4. Nesta fase, a extração foi feita a partir dos resumos; os campos serão confirmados e completados com o texto integral.

Tabela 2.5: Registo da pesquisa (2 de novembro de 2026; título, resumo e palavras-chave; 2021–2026).

Fonte	**Q1**	**Q2**	**Q3**	**Q4**	**Exportados**
IEEE Xplore	756 (753)	24	38	29	844
ACM Digital Library	358	24	16	25 (26)	424
Scopus	102	131	14	32	279
Total					**1547**

Total indicado pela fonte; entre parênteses, o número exportado quando é diferente.

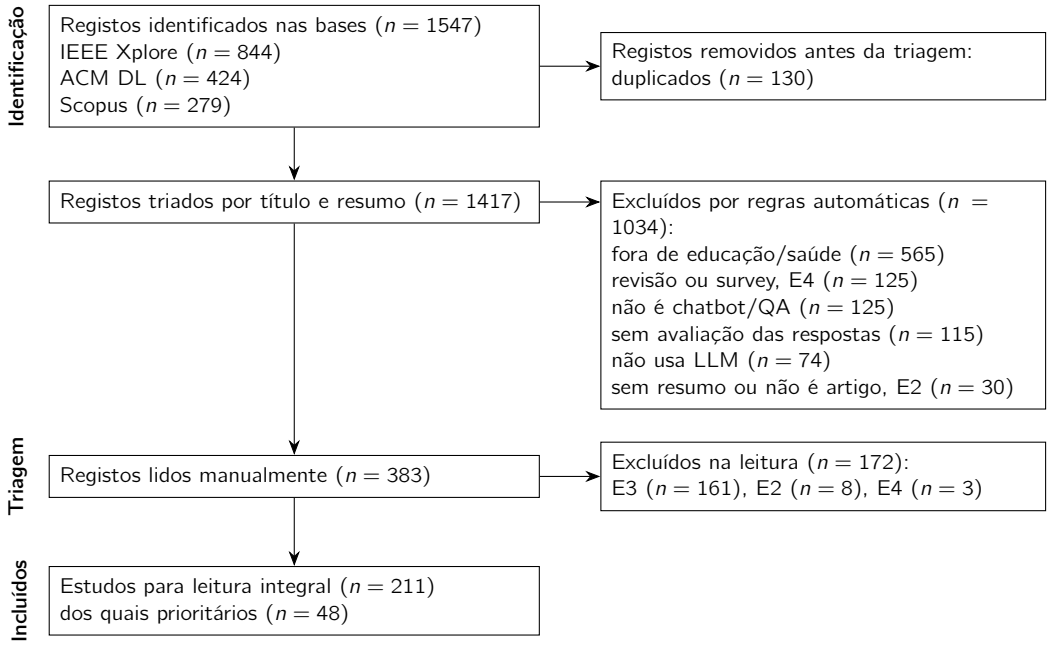


Figura 2.2: Diagrama PRISMA 2020 da seleção dos estudos. A avaliação do texto integral ainda está por fazer.

2.3 Resultados da Pesquisa e da Seleção

A Tabela 2.5 apresenta o registo da pesquisa. Foram exportados 1547 registos: 844 do IEEE Xplore, 424 da ACM Digital Library e 279 do Scopus. No IEEE Xplore, 3 dos 756 resultados da Q1 não puderam ser exportados pela própria plataforma; na ACM Digital Library, a exportação da Q4 devolveu 26 registos para um total indicado de 25. A Q1 concentra a maior parte dos resultados, por cobrir a literatura de RAG aplicada a qualquer domínio.

O fluxo de seleção está na Figura 2.2. Foram removidos 130 duplicados (126 entre pesquisas da mesma fonte e 4 entre fontes), ficando 1417 registos únicos. As regras da fase A excluíram 1034 registos, sobretudo por estarem fora de educação e saúde (565), por serem revisões (125), por não serem sistemas conversacionais ou de QA (125) ou por não descreverem a avaliação das respostas (115). Na fase B foram lidos 383 registos, dos quais 172 foram excluídos (161 por E3, 8 por E2 e 3 por E4), principalmente por serem métodos de RAG genéricos ou por pertencerem a outros domínios. Foram incluídos 211 estudos para leitura integral, dos quais 48 foram marcados como prioritários.

Tabela 2.6: Indicadores descritivos dos 211 estudos incluídos (a partir de títulos e resumos).

Aspeto referido no título ou resumo	**N.º**	**%**
Origem do contexto (RQ1)		
RAG	170	81
Grafo de conhecimento ou ontologia	32	15
Fine-tuning	35	17
Contexto no *prompt*, ICL ou engenharia de *prompts*	22	10
Controlo do âmbito e aspetos operacionais (RQ1)		
Citações ou rastreabilidade das fontes	21	10
Segurança (injeção, *jailbreak*, *guardrails*)	16	8
Recusa, abstenção ou perguntas fora do âmbito	7	3
Várias línguas ou língua diferente do inglês	27	13
Latência ou tempo de resposta	23	11
Custo	15	7
Avaliação (RQ2)		
Exatidão (*accuracy*)	109	52
Métricas automáticas (fidelidade, RAGAS, ROUGE, BLEU, F1 e semelhantes)	51	24
Benchmark de escolha múltipla ou de exame	36	17
Especialistas, clínicos ou docentes (como avaliadores ou utilizadores)	45	21
Estudo com utilizadores, questionário ou entrevistas	22	10
LLM como juiz	5	2

Dos 211 estudos incluídos, 198 vieram da Q1, 11 da Q2, 12 da Q3 e 4 da Q4 (um estudo pode vir de mais do que uma pesquisa). Por fonte, 153 vieram do IEEE Xplore, 57 da ACM Digital Library e apenas 1 do Scopus, cujos resultados incluíram muitos registos fora do âmbito, como números completos de revistas e livros de resumos. A literatura é muito recente: 101 estudos são de 2026, 79 de 2025 e 31 de 2024. Por tema, 64 estudos tratam assistentes de saúde para doentes ou profissionais, 54 assistentes de apoio à aprendizagem, 51 QA médico avaliado em *benchmarks*, 27 assistentes institucionais de universidades, 8 segurança e *guardrails*, 4 controlo do âmbito e recusa, e 3 o efeito do contexto incluído no *prompt*.

A Tabela 2.6 resume indicadores descritivos dos 211 estudos, obtidos por pesquisa de termos nos títulos e resumos. São indicadores de frequência e não de eficácia, e tendem a subestimar o que os textos integrais descrevem, porque nem todos os resumos referem todos os aspetos do estudo. A classificação dos 48 estudos prioritários está no Apêndice A.

2.4 Síntese Crítica

Esta síntese é preliminar: baseia-se nos títulos e resumos dos estudos incluídos, com destaque para os 48 prioritários, e será revista após a leitura dos textos integrais. Os estudos são agrupados por mecanismo e por tipo de avaliação, e não resumidos um a um. A frequência de uma técnica descreve a sua utilização, mas não prova que seja a mais eficaz.

2.4.1 Como o Contexto Chega ao Modelo (RQ1)

Predomínio do RAG. A forma dominante de limitar as respostas a um contexto é o RAG, referido em 81% dos estudos incluídos. Em educação, o contexto é tipicamente o material de um curso: manuais, diapositivos, enunciados e registos das aulas (Barzanji et al. 2026; Feng et al. 2024; Han e Emara 2026; Sayeed et al. 2026; Seshadri et al. 2026; Yan e Shi 2026). Em saúde, são diretrizes clínicas, literatura médica ou bases de perguntas e respostas (Azam et al. 2024; Christiawan et al. 2025; Nurfadhilah et al. 2025; Raputri et al. 2025). Vários estudos acrescentam grafos de conhecimento ou ontologias, quer para estruturar o que é recuperado (Zhang e Shafiq 2025), quer para validar a resposta depois de gerada (Zhao et al. 2025).

O contexto ajuda, mas também pode prejudicar. Os estudos que comparam o mesmo modelo com e sem contexto relatam, em geral, melhorias da correção e da fidelidade (Azam et al. 2024; Nurfadhilah et al. 2025; Raputri et al. 2025). Contudo, um grupo de estudos de QA médico mostra que a recuperação pode piorar os resultados. Xie et al. (2026) observaram que três variantes de RAG ficaram abaixo do modelo sem contexto no MedQA-USMLE: a recuperação corrigiu 5–6% das perguntas mas induziu em erro 6–7%, e a confiança do recuperador não previa quando o contexto ajudava. Rahat et al. (2026) registaram uma queda da exatidão de 68,8% para 17,6% no PubMedQA quando o modelo recebia documentos recuperados; nos casos analisados, os documentos desviavam o modelo (41,8%) ou contradiziam o seu conhecimento (37,6%), e uma alteração do *prompt* recuperou parte da perda. Liu et al. (2026a) concluíram que a qualidade da base de conhecimento pesa mais do que a quantidade. Na mesma linha, os estudos que incluem conhecimento de grafos diretamente no *prompt* mostram que contexto pouco relevante pode baixar o desempenho abaixo do modelo sem contexto (Ghanbari e Dividino 2025a,b).

Contexto fechado e fornecido diretamente. São poucos os estudos em que o contexto é fixo e conhecido à partida, como no QBank. Os mais próximos fundamentam as respostas na aula em curso (Liu et al. 2026b) ou numa apresentação gravada (Xu et al. 2026), ou respondem a perguntas sobre um único relatório radiológico (Hamidi e Roberts 2026). No estudo de Xu et al. (2026), o assistente fundamentado nos materiais da apresentação melhorou a experiência de aprendizagem, enquanto um assistente genérico não superou o vídeo sem assistente, o que sugere que o valor está no contexto e não apenas na presença de um assistente. Zheng et al. (2026) compararam *fine-tuning*, RAG e contexto no *prompt* num serviço de apoio técnico, e a combinação de contexto no *prompt* com RAG obteve a maior correção. Não foi identificado, ao nível dos resumos, nenhum estudo em que o contexto seja o registo completo de uma pergunta de escolha múltipla validada (vinheta, opções, explicação e informação complementar) usado para esclarecer dúvidas do estudante.

Perguntas de escolha múltipla e de exame. Os estudos com perguntas de exame tratam, sobretudo, a escolha da resposta correta em *benchmarks* como o MedQA e o MedMCQA (Liu et al. 2026a; Xie et al. 2026; Zhang e Shafiq 2025), e não a explicação de uma pergunta cuja resposta já é conhecida. A exceção mais próxima é o assistente de Khan et al. (2025), que explica as soluções de perguntas de um exame de acesso à pós-graduação em engenharia e foi avaliado em fidelidade, relevância, latência e por avaliação humana.

2.4.2 Controlo do Âmbito e Segurança (RQ1)

Instruções no prompt não chegam. O resultado mais relevante para o QBank é o de Rayhan et al. (2026): num tutor de programação, os tutores baseados apenas em instruções no *prompt* tiveram uma utilidade semelhante à do sistema proposto (42% e 44%), mas cumpriram as políticas do docente em apenas 30% dos casos, contra 90% com um controlo de acesso explícito ao conteúdo. Da mesma forma, o CS50.ai usa *guardrails* pedagógicos para que o assistente apoie o estudante sem lhe dar diretamente as soluções (Liu et al. 2024b), e o CourseAssist classifica a intenção do estudante para garantir respostas pedagogicamente adequadas (Feng et al. 2024). Estes mecanismos correspondem às regras por modo do QBank, por exemplo não revelar a resposta correta antes do tempo no modo Teste.

Recusa fora do âmbito. Poucos estudos avaliam a recusa (3% dos incluídos). As abordagens encontradas são: modelos de *guardrail* com uma categoria de restrição de tema (Walczak e Sawicki 2026); *fine-tuning* com exemplos de recusa, num assistente multilingue para estudantes (Abrar et al. 2025); e monitorização dos estados internos do modelo para detetar respostas fora do domínio (Li et al. 2026). Walczak e Sawicki (2026) relatam um compromisso claro: o modelo com maior sensibilidade gera muitos falsos positivos, e o mais preciso é demasiado lento para uso síncrono. Notam ainda que as classificações dos especialistas e a perceção dos utilizadores divergem.

Defesas contra injeção de instruções. A defesa mais avaliada em contexto real é a arquitetura com dois modelos, em que um primeiro LLM filtra os pedidos e só os pedidos aprovados chegam ao modelo que responde. O ChatTEDU bloqueou as 180 tentativas de ataque identificadas em 4501 interações reais, com 0,28% de falsos positivos e 18% de latência adicional; 15% dos ataques eram multilingues (Emekci e Budakoglu 2025). O SecureContext EDU usa a mesma ideia com um classificador de ameaças (Kavitha et al. 2026). Outros estudos treinam classificadores dedicados (Mathew et al. 2026; Tien e Huong 2024) ou usam bibliotecas de *guardrails* (Shah et al. 2026). No QBank, o contexto vem da base de dados validada e não de documentos externos, o que reduz o risco de injeção indireta (Greshake et al. 2023), mas não o de injeção direta pelo utilizador.

2.4.3 Compromissos Operacionais (RQ1)

Apenas 11% dos estudos referem a latência e 7% o custo. Quando são reportados, os compromissos são relevantes: o assistente com um LLM juiz de Bellard et al. (2025) demorou em média 15,7 s por pergunta, a um custo de cerca de 0,003 USD; a camada de segurança do ChatTEDU acrescentou 18% de latência (Emekci e Budakoglu 2025); e o RAG baseado em grafos exigiu 10 a 20 vezes mais recursos do que o RAG vetorial, para ganhos apenas em certos tipos de pergunta (Jain et al. 2025). Vários estudos privilegiam modelos executados localmente, por razões de privacidade e custo (Nurfadhilah et al. 2025; Ruga et al. 2025; Trang et al. 2025). Raramente, porém, se relaciona a escolha do mecanismo de contexto com o seu impacto na latência e no custo.

Várias línguas. 13% dos estudos tratam línguas diferentes do inglês ou várias línguas. As abordagens incluem: um RAG trilingue com *embeddings* multilingues (Sbai et al. 2025); traduzir os documentos e as perguntas para inglês e a resposta de volta (Ruga et al. 2025); e usar modelos adaptados à língua local, que obtiveram maior fidelidade (cerca de 0,95)

do que um modelo geral (Nurfadhilah et al. 2025). Estes estudos avaliam, em geral, o desempenho por língua, mas raramente a fidelidade ao mesmo conteúdo validado em várias línguas ou a recusa em várias línguas, que é o que o QBank exige.

2.4.4 Avaliação da Correção, da Fidelidade e do Âmbito (RQ2)

Métricas heterogéneas. A métrica mais referida é a exatidão (52%), sobretudo em *benchmarks* de escolha múltipla. A fidelidade ao contexto é medida, em 24% dos estudos, com métricas automáticas do tipo RAGAS (Es et al. 2024): por exemplo, 0,875 de fidelidade num assistente de saúde mental (Christiawan et al. 2025) e cerca de 0,95 num assistente de educação de doentes (Nurfadhilah et al. 2025). Estas métricas dependem, por sua vez, de um LLM avaliador, pelo que herdam as suas limitações (Zheng et al. 2023). Como as métricas, os dados e os modelos diferem entre estudos, os valores não são diretamente comparáveis.

LLM como juiz, especialistas e utilizadores. Buti e Mohamed (2026) avaliaram um assistente de aconselhamento académico com um LLM juiz num *benchmark* de 55 perguntas revistas por especialistas, e encontraram poucas alucinações (3 em 53), concluindo que o contexto recuperado restringe o modelo sem eliminar o risco de invenção. Liao et al. (2026) combinaram um LLM juiz com auditoria por estudantes de medicina, e Oh et al. (2026) propuseram uma avaliação automática de agentes clínicos em diálogo multi-turno, validada por especialistas. Em educação, os docentes avaliam a correção das respostas (Liu et al. 2026b; Miroyan et al. 2025), e os estudos com utilizadores medem a utilidade percebida e a usabilidade (Barzanji et al. 2026; Han e Emara 2026; Seshadri et al. 2026; Xu et al. 2026). Poucos estudos combinam as três formas de avaliação.

Fidelidade ao contexto versus conhecimento do modelo. Um aspeto pouco avaliado, mas central para o QBank, é se o modelo segue o contexto quando este contradiz o seu conhecimento. Jain et al. (2025) fizeram-no com manuais alterados de propósito para contradizer o conhecimento do modelo, e verificaram diferenças entre abordagens de RAG. As taxonomias de erros de Hamidi e Roberts (2026) e Rahat et al. (2026), que separam alucinação, abstenção indevida e desvio provocado pelo contexto, são uma alternativa mais informativa do que uma única métrica agregada.

Avaliação da recusa. A recusa é avaliada em poucos estudos e de formas diferentes: precisão da recusa (Abrar et al. 2025), taxa de abstenção (Ishadya et al. 2026), falsos positivos e falsos negativos de abstenção (Hamidi e Roberts 2026), cumprimento das políticas do docente (Rayhan et al. 2026) e taxa de rejeição fora do domínio (Li et al. 2026). Ishadya et al. (2026) mostram que menos abstenção e mais respostas suportadas podem coexistir, o que indica que a recusa deve ser avaliada em conjunto com a correção.

Dimensão das avaliações. Muitas avaliações usam conjuntos pequenos: 14 perguntas (Sayeed et al. 2026), 25 pares sintéticos (Bellard et al. 2025), 50 pares (Feng et al. 2024) ou 55 perguntas (Buti e Mohamed 2026). As avaliações em uso real, com centenas ou milhares de utilizadores, medem sobretudo a utilidade percebida e não a fidelidade de cada resposta (Emekci e Budakoglu 2025; Seshadri et al. 2026).

2.4.5 Limitações Recorrentes

Os estudos analisados partilham as seguintes limitações:

- avaliações em conjuntos pequenos, frequentemente sintéticos, e sem validação externa;
- fidelidade medida por LLMs avaliadores, sem verificação humana sistemática;
- recusa e perguntas fora do âmbito raramente avaliadas, e avaliadas separadamente da correção;
- avaliação multilingue centrada no desempenho por língua e não na consistência com o mesmo conteúdo validado;
- latência e custo raramente reportados e não relacionados com as escolhas de arquitetura;
- poucos estudos com contexto fechado e fornecido diretamente, apesar de a evidência mostrar que a recuperação introduz erros próprios.

2.5 Lacuna de Investigação

A Tabela 2.7 apresenta a cadeia que liga a evidência à oportunidade de investigação.

Tabela 2.7: Da evidência à oportunidade de investigação.

Evidência	**Limitação**	**Lacuna**	**Oportunidade**
O RAG domina (81%); a recuperação pode introduzir contexto que desvia ou contradiz o modelo.	Poucos estudos usam contexto fechado, validado e fornecido diretamente, como o de uma pergunta de exame.	Pouca evidência sobre a fidelidade de assistentes que respondem apenas com o contexto validado de cada item.	Assistente que usa só os dados da pergunta em curso, avaliado em fidelidade e correção.
Instruções no *prompt* não garantem o cumprimento das políticas (30% contra 90%).	A recusa é avaliada em 3% dos estudos, com métricas diferentes.	Pouca evidência sobre recusa e regras por modo em assistentes de estudo para exames.	Mecanismos de recusa e regras por modo (Teste e Estudo) avaliados com perguntas fora do âmbito.
Estudos multilingues avaliam o desempenho por língua.	Consistência com o mesmo conteúdo validado em várias línguas raramente avaliada.	Pouca evidência sobre fidelidade e recusa em várias línguas em simultâneo.	Avaliação da fidelidade e da recusa nas línguas do QBank.
Avaliações pequenas, com LLM juiz ou só com utilizadores.	Poucos estudos combinam métricas, especialistas e utilizadores.	Falta de protocolos de avaliação completos.	Protocolo que combina testes técnicos, especialistas da Adhara e utilizadores.

Em síntese, a literatura mostra como fundamentar as respostas de um assistente num contexto, sobretudo através de RAG, e como medir a sua fidelidade. Contudo, no corpus analisado não foi encontrado um assistente de estudo que responda apenas com o contexto fechado e validado de cada pergunta de um banco de perguntas, que respeite regras por modo de exame e que seja avaliado, em várias línguas, quanto à correção, à fidelidade e à recusa em simultâneo. Esta lacuna é preliminar e será confirmada após a leitura dos textos integrais. É a esta oportunidade que o presente trabalho procura responder.

2.6 Ameaças à Validade

- **Fontes e campos.** A pesquisa limitou-se a três fontes, ao inglês e ao português e ao título, resumo e palavras-chave. Na IEEE Xplore e na ACM Digital Library, a restrição a estes campos foi feita expandindo cada termo, o que pode não ser exatamente equivalente ao `TITLE-ABS-KEY`. No Scopus, a pesquisa devolveu registos que não são artigos, o que sugere uma restrição de campos menos estrita.
- **Triagem por regras.** A fase A excluiu registos por ausência de termos no título e no resumo. Estudos relevantes que não usem esses termos podem ter sido excluídos (falsos negativos). As regras estão documentadas e podem ser repetidas.
- **Revisor único e apoio de IA.** A triagem foi feita por um único revisor, com apoio de um assistente de IA. Para mitigar o enviesamento, cada decisão tem um critério e um motivo registados e foi verificada pelo autor.
- **Síntese a partir de resumos.** A síntese e os indicadores da Tabela 2.6 baseiam-se nos resumos e serão revistos com o texto integral e com a avaliação da qualidade.
- **Janela temporal.** O filtro das interfaces é anual (2021–2026); o cumprimento exato das datas de 27-10-2021 a 27-10-2026 será confirmado na leitura integral.
- **Evolução rápida.** A literatura sobre LLMs evolui depressa: quase metade dos estudos incluídos é de 2026.

2.7 Conclusões do Capítulo

A revisão identificou 1547 registos em três fontes e incluiu 211 estudos para leitura integral, dos quais 48 são prioritários. Quanto à RQ1, a forma dominante de limitar as respostas é o RAG, mas a evidência mostra que a recuperação também introduz erros, e que as instruções no *prompt*, sozinhas, não garantem o cumprimento do âmbito; os mecanismos mais robustos combinam controlo explícito do conteúdo, filtros dedicados e recusa. Os compromissos de latência e custo são pouco reportados. Quanto à RQ2, a avaliação é heterogénea: exatidão em *benchmarks*, métricas automáticas de fidelidade dependentes de LLMs avaliadores, avaliação por especialistas e estudos com utilizadores, raramente combinados, e com pouca avaliação da recusa e do comportamento em várias línguas.

Para o assistente do QBank, estas conclusões traduzem-se em decisões de desenho e de avaliação: fornecer ao modelo apenas o contexto validado da pergunta em curso; não depender apenas de instruções no *prompt* para o âmbito e para as regras por modo; tratar a segurança contra injeção direta; e avaliar a correção, a fidelidade e a recusa em conjunto, nas várias línguas do QBank, combinando testes técnicos, especialistas da Adhara e utilizadores. O Capítulo 3 parte destas conclusões para o desenho da solução.

Capítulo 3

Desenho da Solução

3.1 Requisitos

Os requisitos resultam do levantamento feito com a Adhara.

3.1.1 Requisitos Funcionais

- **RF1.** O assistente responde a dúvidas sobre a pergunta em causa (enunciado, opções, explicações, dicas e informação-chave).
- **RF2.** O assistente usa exclusivamente a informação guardada na base de dados para essa pergunta, sem acesso à Internet nem a conhecimento externo.
- **RF3.** Se a informação necessária não estiver no contexto, o assistente di-lo claramente.
- **RF4.** Perguntas fora do âmbito da pergunta são recusadas com uma frase fixa.
- **RF5.** O assistente está disponível nos modos Teste e Estudo e não no modo Simulado.
- **RF6.** Quando a resposta correta não foi revelada ao aluno, o assistente não a revela.
- **RF7.** O assistente deve responder a perguntas escritas em várias línguas.

3.1.2 Requisitos Não Funcionais

- **RNF1. Latência:** tempo de resposta aceitável entre 2 e 3 segundos.
- **RNF2. Custo:** custo mensal de modelos limitado a um orçamento definido com a Adhara.
- **RNF3. Escalabilidade:** 10 a 20% dos utilizadores em simultâneo (cerca de 250 a 500 em 2500 utilizadores).
- **RNF4. Privacidade:** o envio dos dados das perguntas para uma API externa foi indicado como aceitável pela Adhara; o tratamento de dados dos utilizadores deve cumprir o RGPD.
- **RNF5. Validação:** respostas do assistente validadas pela equipa científica antes de serem consideradas fiáveis (processo a definir).

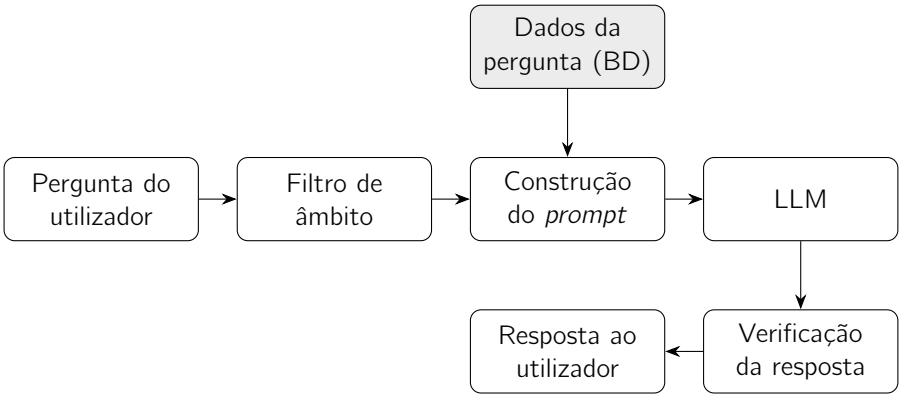


Figura 3.1: Arquitetura proposta do assistente conversacional.

3.2 Contexto de Cada Pergunta

Cada pergunta do QBank está guardada com campos estruturados: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação (geral e de cada opção), catalogação e informação complementar. Para cada pedido, o contexto fornecido ao LLM é construído a partir destes campos, em função do modo do QBank e de a resposta já ter sido revelada ou não.

3.3 Arquitetura

A Figura 3.1 apresenta a arquitetura proposta. Antes de chegar ao LLM, a pergunta do utilizador passa por um filtro de âmbito; depois da geração, a resposta é verificada antes de ser mostrada.

3.4 Estratégias de Prompting e Restrições

O *prompt* do assistente define o seu papel, as regras de contexto, de âmbito, de segurança e de estilo, e o formato de saída. As regras principais são:

- usar apenas a informação do contexto e dizer quando esta não existe;
- recusar assuntos fora da pergunta com uma frase fixa;
- ignorar instruções do utilizador que tentem alterar as regras ou revelar o *prompt*;
- não escrever as letras das opções, referindo-se às opções pelo seu texto, porque a ordem das opções muda entre sessões.

3.5 Verificações Fora do Modelo

Como as restrições só no *prompt* podem não ser cumpridas por todos os modelos, a arquitetura inclui verificações determinísticas:

- **antes do modelo:** filtro de âmbito para recusar perguntas claramente fora do tema;
- **depois do modelo:** deteção de fuga de instruções, de letras de opções e de valores que não existem no contexto.

3.6 Escolha do Modelo

A escolha entre um modelo executado localmente e um serviço externo depende da latência, do custo, da privacidade e da qualidade (fidelidade e cumprimento das regras). Os modelos são comparados no Capítulo **??**.

Bibliografia

Abd-alrazaq, Alaa, Rawan AlSaad, Dari Alhuwail et al. (2023). «Large Language Models in Medical Education: Opportunities, Challenges, and Future Directions». Em: *JMIR Medical Education* 9, e48291. doi: 10.2196/48291.

Abrar, M. et al. (2025). «Domain-Specific Fine-Tuning of LLMs for Multilingual Student Advisory in Higher Education». Em: *2025 2nd International Conference on Advanced Computing and Emerging Technologies (ACET)*. Estudo R0809 da revisão. doi: 10.1109/ACET67282.2025.11430234.

ACM/IEEE-CS Joint Task Force on Software Engineering Ethics and Professional Practices (1999). *Software Engineering Code of Ethics and Professional Practice (Version 5.2)*. url: https://www.acm.org/code-of-ethics/software-engineering-code.

Adamopoulou, Eleni e Lefteris Moussiades (2020). «Chatbots: History, Technology, and Applications». Em: *Machine Learning with Applications* 2, p. 100006. doi: 10.1016/j.mlwa.2020.100006.

Ahuja, Kabir et al. (2023). «MEGA: Multilingual Evaluation of Generative AI». Em: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 4232–4267. doi: 10.18653/v1/2023.emnlp-main.258.

ALLEA (2023). *The European Code of Conduct for Research Integrity – Revised Edition 2023*. Berlin: ALLEA – All European Academies. doi: 10.26356/ECOC.

Azam, A., Z. Naz e M. U. G. Khan (2024). «CancerBot: A Retrieval-Augmented Generation based Cancer Chatbot Using Large Language Models». Em: *2024 18th International Conference on Open Source Systems and Technologies (ICOSST)*. Estudo R0162 da revisão. doi: 10.1109/ICOSST64562.2024.10871155.

Barzanji, Chrakhan et al. (2026). «ST-Buddy: Designing and Evaluating a Course-Grounded LLM Chatbot for Academic and Administrative Support». Em: *Proceedings of the Extended Abstracts of the 2026 CHI Conference on Human Factors in Computing Systems*. Estudo R1019 da revisão. doi: 10.1145/3772363.3798558.

Bellard, B. et al. (2025). «Development and Evaluation of an Agentic RAG with Embedded LLM-as-a Judge for Heart Failure Management: A Pilot Study». Em: *2025 IEEE International Conference on Big Data (BigData)*. Estudo R0561 da revisão. doi: 10.1109/BigData66926.2025.11402164.

BENGMAH, A. et al. (2025). «AI-Driven Diabetes Management: A Retrieval-Augmented Conversational Approach*». Em: *2025 12th International Conference on Wireless Networks and Mobile Communications (WINCOM)*. Estudo R0514 da revisão. doi: 10.1109/WINCOM65874.2025.11313355.

Bloom, Benjamin S. (1984). «The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring». Em: *Educational Researcher* 13.6, pp. 4–16. doi: 10.3102/0013189X013006004.

Brooke, John (1996). «SUS: A "Quick and Dirty" Usability Scale». Em: *Usability Evaluation in Industry*. Ed. por Patrick W. Jordan et al. London: Taylor & Francis, pp. 189–194.

Brown, Tom B. et al. (2020). «Language Models are Few-Shot Learners». Em: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, pp. 1877–1901.

Bui, Tuan et al. (2025). «Formal Reasoning for Intelligent QA Systems: A Case Study in the Educational Domain». Em: *Proceedings of the 2nd ACM Workshop in AI-Powered Question & Answering Systems*. Estudo R1110 da revisão. doi: 10.1145/3746274.3760392.

Buti, Ronit e Abdallah Mohamed (2026). «Evaluating RAG-Based Course Advising Chatbots Using LLM-as-a-Judge Methodology». Em: *Proceedings of the 28th Western Canadian Conference on Computing Education*. Estudo R1022 da revisão. doi: 10.1145/3828792.3828802.

Christiawan, J. et al. (2025). «Sanity-LLM: Enhancing Mental Health Chatbots with Retrieval-Augmented Generation (RAG)». Em: *2025 International Conference on Informatics, Multimedia, Cyber and Information System (ICIMCIS)*. Estudo R0071 da revisão. doi: 10.1109/ICIMCIS68501.2025.11327020.

Elnozahy, W. A., G. A. El Khayat e E. I. Aboulsafa (2026). «A Governed Closed-Domain Question Answering System for Decision Assistance in Education». Em: *2026 IEEE International Conference on Smart Sustainable Systems for Computer and Engineering Applications (3SCEA)*. Estudo R0446 da revisão. doi: 10.1109/3SCEA68071.2026.11603208.

Emekci, H. e G. Budakoglu (2025). «Securing With Dual-LLM Architecture: ChatTEDU an Open Access Chatbot's Defense». Em: *IEEE Access*. Estudo R0765 da revisão. doi: 10.1109/ACCESS.2025.3623268.

Es, Shahul et al. (2024). «RAGAS: Automated Evaluation of Retrieval Augmented Generation». Em: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pp. 150–158. doi: 10.18653/v1/2024.eacl-demo.16.

Feng, Ty, Sa Liu e Dipak Ghosal (2024). «CourseAssist: Pedagogically Appropriate AI Tutor for Computer Science Education». Em: *Proceedings of the 2024 on ACM Virtual Global Computing Education Conference V. 2*. Estudo R1060 da revisão. doi: 10.1145/3649409.3691094.

Fu, R. et al. (2024). «Chatbots on a Mid-Scale Knowledge Base: Using an R2 University as an Example». Em: *2024 5th International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE)*. Estudo R0753 da revisão. doi: 10.1109/ICBAIE63306.2024.11116920.

Gan, Wenyi, Jianfeng Ouyang, Hua Li et al. (2024). «Integrating ChatGPT in Orthopedic Education for Medical Undergraduates: Randomized Controlled Trial». Em: *Journal of Medical Internet Research* 26, e57037. doi: 10.2196/57037.

Geng, T. et al. (2026). «Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies». Em: *Computers, Materials & Continua* 87.1. url: https://www.techscience.com/cmc/v87n1/66084.

Ghanbari, M. e R. Dividino (2025a). «Evaluating Knowledge Graph-Enhanced Context for Multiple-Choice Question Answering». Em: *2025 IEEE International Conference on Knowledge Graph (ICKG)*. Estudo R0559 da revisão. doi: 10.1109/ICKG66886.2025.00020.

– (2025b). «Quantifying Informativeness in Knowledge Graph-Augmented In-Context Learning for Multiple Choice Query Answering». Em: *2025 IEEE International Conference on Knowledge Graph (ICKG)*. Estudo R0619 da revisão. doi: 10.1109/ICKG66886.2025.00021.

Gordon, Morris, Michelle Daniel, Aderonke Ajiboye et al. (2024). «A scoping review of artificial intelligence in medical education: BEME Guide No. 84». Em: *Medical Teacher* 46.4, pp. 446–470. doi: 10.1080/0142159X.2024.2314198.

Greshake, Kai et al. (2023). «Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection». Em: *Proceedings of the*

16th ACM Workshop on Artificial Intelligence and Security (AISec '23), pp. 79–90. doi: 10.1145/3605764.3623985.

Hamidi, A. e K. Roberts (2026). «Large Language Models for Radiology QA: Benchmarking and Error Taxonomy on RadQA». Em: *2026 IEEE 14th International Conference on Healthcare Informatics (ICHI)*. Estudo R0794 da revisão. doi: 10.1109/ICHI69079.2026.00034.

Han, Yuanrong e Salma Emara (2026). «Textbook-Embedded Virtual Teaching Assistant That Answers CS1 Questions With Verifiable Citations». Em: *Proceedings of the 2026 IEEE/ACM 48th International Conference on Software Engineering*. Estudo R0965 da revisão.

Hattie, John e Helen Timperley (2007). «The Power of Feedback». Em: *Review of Educational Research* 77.1, pp. 81–112. doi: 10.3102/003465430298487.

Hevner, Alan R. et al. (2004). «Design Science in Information Systems Research». Em: *MIS Quarterly* 28.1, pp. 75–105.

Huang, Lei et al. (2025). «A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions». Em: *ACM Transactions on Information Systems* 43.2. doi: 10.1145/3703155.

Ishadya, A. P. D., A. Withanaarachchi e S. Jayalal (2026). «Mitigating Bias and Hallucinations in LLMs Through Prompt Engineering and Knowledge-Grounded Approaches in Healthcare Domain». Em: *2026 6th International Conference on Advanced Research in Computing (ICARC)*. Estudo R0558 da revisão. doi: 10.1109/ICARC68737.2026.11453821.

Jain, A., L. Cui e S. Chen (2025). «Aligning LLMs for the Classroom with Knowledge-Based Retrieval: A Comparative RAG Study». Em: *2025 IEEE International Conference on Teaching, Assessment, and Learning for Engineering (TALE)*. Estudo R0616 da revisão. doi: 10.1109/TALE66047.2025.11346682.

Jang, D. et al. (2025). «MedTutor: A Retrieval-Augmented LLM System for Case-Based Medical Education». Em: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 319–353. url: https://aclanthology.org/2025.emnlp-demos.24/.

Kadavath, Saurav et al. (2022). *Language Models (Mostly) Know What They Know*. arXiv: 2207.05221.

Kasneci, Enkelejda, Kathrin Sessler, Stefan Küchemann et al. (2023). «ChatGPT for good? On opportunities and challenges of large language models for education». Em: *Learning and Individual Differences* 103, p. 102274. doi: 10.1016/j.lindif.2023.102274.

Kavitha, G., H. A. M e P. R (2026). «SecureContext EDU: An Open Source University Assistant using Dual - LLM Architecture». Em: *2026 4th International Conference on Sustainable Computing and Smart Systems (ICSCSS)*. Estudo R0237 da revisão. doi: 10.1109/ICSCSS69635.2026.11645927.

Khan, U. A. et al. (2025). «Towards Efficient Educational Chatbots: Benchmarking RAG Frameworks». Em: *2025 International Conference on Emerging Technologies in Computing and Communication (ETCC)*. Estudo R0452 da revisão. doi: 10.1109/ETCC65847.2025.11108323.

Kitchenham, Barbara e Stuart Charters (2007). *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. Rel. téc. EBSE-2007-01. Keele University e Durham University.

Larsen, Douglas P., Andrew C. Butler e Henry L. Roediger (2008). «Test-Enhanced Learning in Medical Education». Em: *Medical Education* 42.10, pp. 959–966. doi: 10.1111/j.1365-2923.2008.03124.x.

Lewis, Patrick et al. (2020). «Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks». Em: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, pp. 9459–9474.

Li, Boquan et al. (2026). «Be Responsible in Your Answers! Monitoring Out-of-Domain Behaviors in Domain-Specific LLMs». Em: *Proceedings of the ACM Web Conference 2026*. Estudo R1183 da revisão. doi: 10.1145/3774904.3792621.

Liao, Yiming et al. (2026). «Med-HEAL: Analyzing and Mitigating Hallucinations in Medical LLMs with Hallucination-Aware In-Context Learning». Em: *Proceedings of the 17th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*. Estudo R1120 da revisão.

Liu, Nelson F. et al. (2024a). «Lost in the Middle: How Language Models Use Long Contexts». Em: *Transactions of the Association for Computational Linguistics* 12, pp. 157–173. doi: 10.1162/tacl_a_00638.

Liu, Rongxin et al. (2024b). «Teaching CS50 with AI: Leveraging Generative Artificial Intelligence in Computer Science Education». Em: *Proceedings of the 55th ACM Technical Symposium on Computer Science Education V. 2*. Estudo R1187 da revisão. doi: 10.1145/3626253.3635427.

Liu, T., M. Zhu e S. P. Zhai (2026a). «Quality Outweighs Quantity: Advancing Medical Question Answering with RAG-MCP Muti-Agent LLM Framework and Curated Knowledge Databases». Em: *2026 IEEE 16th Annual Computing and Communication Workshop and Conference (CCWC)*. Estudo R0301 da revisão. doi: 10.1109/CCWC67433.2026.11393764.

Liu, Ziqi et al. (2026b). «AskNow: An LLM-powered Interactive System for Real-Time Question Answering in Large-Scale Classrooms». Em: *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Estudo R0934 da revisão. doi: 10.1145/3772318.3790328.

Mathew, A. K., D. Rajeev e A. Ravi (2026). «Privacy-Preserving Federated Transformer Framework for Detecting Adversarial Prompts in Healthcare Chatbots». Em: *2026 International Conference on Innovations in Computational Intelligence (ICICI)*. Estudo R0771 da revisão. doi: 10.1109/ICICI68867.2026.11564888.

Miroyan, Mihran et al. (2025). «Analyzing Pedagogical Quality and Efficiency of LLM Responses with TA Feedback to Live Student Questions». Em: *Proceedings of the 56th ACM Technical Symposium on Computer Science Education V. 1*. Estudo R0991 da revisão. doi: 10.1145/3641554.3701965.

Nurfadhilah, E., A. Santosa e P. K. Putra (2025). «Retrieval-Augmented Large Language Models for a Chronic Kidney Disease Patient Education Chatbot». Em: *2025 International Conference on Computer, Control, Informatics and its Applications (IC3INA)*. Estudo R0157 da revisão. doi: 10.1109/IC3INA68387.2025.11325127.

Oh, G., S. Park e B. -H. Kim (2026). «AutoMedic: An Automated Evaluation Framework for Clinical Conversational Agents with Medical Dataset Grounding». Em: *IEEE Journal of Biomedical and Health Informatics*. Estudo R0686 da revisão. doi: 10.1109/JBHI.2026.3703097.

Ouyang, Long et al. (2022). «Training Language Models to Follow Instructions with Human Feedback». Em: *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, pp. 27730–27744.

OWASP Foundation (2024). *OWASP Top 10 for LLM Applications 2025*. url: https://genai.owasp.org/llm-top-10/.

Page, Matthew J. et al. (2021). «The PRISMA 2020 statement: an updated guideline for reporting systematic reviews». Em: *BMJ* 372, n71. doi: 10.1136/bmj.n71.

Parlamento Europeu e Conselho da União Europeia (2016). *Regulamento (UE) 2016/679 relativo à proteção das pessoas singulares no que diz respeito ao tratamento de dados pessoais (Regulamento Geral sobre a Proteção de Dados)*. url: https://eur-lex.europa.eu/eli/reg/2016/679/oj.

– (2024). *Regulamento (UE) 2024/1689 que cria regras harmonizadas em matéria de inteligência artificial (Regulamento da Inteligência Artificial)*. url: https://eur-lex.europa.eu/eli/reg/2024/1689/oj.

Peffers, Ken et al. (2007). «A Design Science Research Methodology for Information Systems Research». Em: *Journal of Management Information Systems* 24.3, pp. 45–77. doi: 10.2753/MIS0742-1222240302.

Perez, Fábio e Ian Ribeiro (2022). *Ignore Previous Prompt: Attack Techniques for Language Models*. NeurIPS ML Safety Workshop. arXiv: 2211.09527.

Politécnico do Porto (2020). *Código de Ética e de Conduta do Politécnico do Porto*. url: https://www.ipp.pt.

Rahat, M. T. I. et al. (2026). «Noise, Distraction, and Mitigation: An Analysis of RAG Failure Modes in Medical Question Answering». Em: *2026 International Conference on Artificial Intelligence in Information and Communication (ICAIIC)*. Estudo R0414 da revisão. doi: 10.1109/ICAIIC68212.2026.11454362.

Raputri, E. et al. (2025). «Retrieval-Augmented LLMs with Indonesian Clinical Trials Guidelines: A Comparative Study». Em: *2025 8th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*. Estudo R0281 da revisão. doi: 10.1109/ISRITI68345.2025.11393253.

Rayhan, M. H. et al. (2026). «SAGE: Student-Focused Adaptive Guidance Engine for Intelligent Tutoring with Regulated Learning». Em: *2026 IEEE International Conference on Human-Machine Systems (ICHMS)*. Estudo R0807 da revisão. doi: 10.1109/ICHMS69701.2026.11602253.

Roediger, Henry L. e Jeffrey D. Karpicke (2006). «Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention». Em: *Psychological Science* 17.3, pp. 249–255. doi: 10.1111/j.1467-9280.2006.01693.x.

Ruga, T. et al. (2025). «A Conversational Agent for Rare Eye Disease Knowledge Support in Local Italian Healthcare Contexts: The ELENA Framework». Em: *2025 IEEE International Conference on Big Data (BigData)*. Estudo R0555 da revisão. doi: 10.1109/BigData66926.2025.11402191.

Sayeed, M. S. et al. (2026). «ATU-Tutor: A RAG-Based Socratic Tutoring System with Agentic AI Adaptive Assessment». Em: *2026 IEEE World AI IoT Congress (AIIoT)*. Estudo R0469 da revisão. doi: 10.1109/AIIoT68874.2026.11569566.

Sbai, A., I. Guessous e E. H. Nfaoui (2025). «Advanced Trilingual RAG Framework: Progressive Architectures for Robust Educational Question Answering». Em: *2025 4th International Conference on Embedded Systems and Artificial Intelligence (ESAI)*. Estudo R0165 da revisão. doi: 10.1109/ESAI67033.2025.11438335.

Seshadri, Vaibhav et al. (2026). «Alan: A Classroom Deployment of An Educational Chatbot That Cites Resources». Em: *Proceedings of the 57th ACM Technical Symposium on Computer Science Education V.2*. Estudo R1001 da revisão. doi: 10.1145/3770761.3777344.

Shah, A. et al. (2026). «Enhancing medical data processing with RAG-augmented fine-tuned LLMs and guardrails». Em: *International Conference on Advancing Technology in Engineering and Science (ICATES 2025)*. Estudo R0709 da revisão. doi: 10.1049/icp.2025.4700.

Shute, Valerie J. (2008). «Focus on Formative Feedback». Em: *Review of Educational Research* 78.1, pp. 153–189. doi: 10.3102/0034654307313795.

Tawfik, M. K. et al. (2025). «Mufakkir: RAG-Based Arabic Educational Chatbot for University Students». Em: *2025 Twelfth International Conference on Intelligent Computing and Information Systems (ICICIS)*. Estudo R0443 da revisão. doi: 10.1109/ICICIS66182.2025.11313212.

Tien, L. A. e P. Van Huong (2024). «Optimizing Transformer Models for Prompt Jailbreak Attack Detection in AI Assistant Systems». Em: *2024 1st International Conference On Cryptography And Information Security (VCRIS)*. Estudo R0763 da revisão. doi: 10.1109/VCRIS63677.2024.10813380.

Trang, T. N. A. et al. (2025). «A Customized AI Chatbot for Educational Environments: Integrating Retrieval-Augmented Generation with Curriculum-Aligned Responses». Em: *2025 RIVF International Conference on Computing and Communication Technologies (RIVF)*. Estudo R0113 da revisão. doi: 10.1109/RIVF68649.2025.11365126.

Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008.

Walczak, J. e B. Sawicki (2026). «Comparative Evaluation of Llama Guard 3 and GPT OSS Safeguard as LLM Guardrails for a University Administrative Chatbot». Em: *2026 Progress in Applied Electrical Engineering (PAEE)*. Estudo R0762 da revisão. doi: 10.1109/PAEE71887.2026.11660667.

Wei, H. et al. (2026). «Cloud-Edge Retrieval-Augmented Agent Tutor for Trustworthy Personalized Learning in Resource-Constrained Higher Education». Em: *2026 5th International Conference on Artificial Intelligence, Internet of Things and Cloud Computing Technology (AIoTC)*. Estudo R0437 da revisão. doi: 10.1109/AIoTC71250.2026.11689071.

Weizenbaum, Joseph (1966). «ELIZA – A Computer Program for the Study of Natural Language Communication between Man and Machine». Em: *Communications of the ACM* 9.1, pp. 36–45. doi: 10.1145/365153.365168.

Xie, Weidong et al. (2026). «When Retrieval Hurts: A Critical Analysis of RAG in Medical Question Answering». Em: *Proceedings of the 2025 3rd International Conference on Artificial Intelligence, Systems and Network Security*. Estudo R0878 da revisão. doi: 10.1145/3797161.3797211.

Xu, Haiyang et al. (2026). «EchoMind: Augmenting Recorded Presentations with Context-Grounded Conversational Agents and Collective Viewer Signals». Em: *Proceedings of the 14th Nordic Conference on Human-Computer Interaction*. Estudo R1056 da revisão.

Yan, Jiameng e Jingzhuo Shi (2026). «Question-Answering Agent Based on Prompt Engineering and RAG». Em: *Proceedings of the 2026 International Conference on Artificial Intelligence, Digital Media and Education*. Estudo R0859 da revisão. doi: 10.1145/3839592.3839607.

Zhang, H. e M. O. Shafiq (2025). «MediTriR: A Triple-Driven Approach to Retrieval-Augmented Generation for Medical Question Answering Tasks». Em: *2025 19th International Conference on Semantic Computing (ICSC)*. Estudo R0042 da revisão. doi: 10.1109/ICSC64641.2025.00032.

Zhao, Chengshuai et al. (2025). «CyberBOT: Ontology-Grounded Retrieval Augmented Generation for Reliable Cybersecurity Education». Em: *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. Estudo R0826 da revisão. doi: 10.1145/3746252.3761478.

Zheng, Lianmin et al. (2023). «Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena». Em: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*.

Zheng, Mingkai et al. (2026). «A Comparative Study on LLM-enabled HPC User Support». Em: *Proceedings of the Practice and Experience in Advanced Research Computing 2026: Resilient Roots + Empowered Communities*. Estudo R0995 da revisão.

Apêndice A

Estudos Prioritários da Revisão

Este apêndice classifica os 48 estudos prioritários da revisão sistemática (Capítulo 2). A classificação foi feita a partir dos títulos e resumos e será confirmada na leitura do texto integral. A coluna Q indica a pesquisa de onde o estudo veio.

Tabela A.1: Classificação dos estudos prioritários.

Estudo	Q	Domínio	Contexto e controlo	Avaliação
Zhang e Shafiq (2025)	Q1	QA médico (MCQ)	RAG com triplos de grafo	Exatidão em MedMCQA e Medical QA
Christiawan et al. (2025)	Q1,Q2	Saúde mental	RAG híbrido com reordenação	RAGAS: fidelidade 0,875
Trang et al. (2025)	Q1	Educação escolar	RAG e regras sobre planos de aula	Descrição do sistema; execução local
Nurfadhilah et al. (2025)	Q1,Q2	Educação de doentes	RAG; LLM adaptado à língua	700 respostas; fidelidade e correção (LLM avaliador)
Azam et al. (2024)	Q1,Q2	Oncologia	RAG sobre literatura	Fidelidade e relevância vs. LLM base
Sbai et al. (2025)	Q1	Educação (trilingue)	RAG com embeddings multilingues	Correção e fidelidade por língua
Kavitha et al. (2026)	Q1,Q3	Universidade	Dois LLM: filtro e RAG controlado	Deteção de ameaças (90%)
Raputri et al. (2025)	Q1,Q2	Diagnóstico clínico	RAG sobre diretrizes locais	Comparação com e sem RAG; médico
Liu et al. (2026a)	Q1	QA médico (MCQ)	RAG multiagente; base curada	Exatidão em MedMCQA e MedQA
Rahat et al. (2026)	Q1	QA médico	RAG sobre PubMed	Exatidão; análise de 165 erros
Wei et al. (2026)	Q1	Ensino superior	RAG local com verificação de políticas	Dados públicos; auditoria de casos
Tawfik et al. (2025)	Q1	Ensino superior (árabe)	RAG híbrido	Exatidão e semelhança da resposta
Elnozahy et al. (2026)	Q1	Ensino superior	QA de domínio fechado com encaminhamento	Proposta de arquitetura
Khan et al. (2025)	Q1,Q2	Exame de acesso (GATE)	RAG sobre soluções de exame	Fidelidade, relevância, latência; avaliação humana
Sayeed et al. (2026)	Q1	Ensino superior	RAG sobre manuais abertos	14 perguntas; LLM e heurísticas
BENGMAH et al. (2025)	Q1	Diabetes	Prompt vs. fine-tuning vs. RAG	Comparação das três abordagens
Ruga et al. (2025)	Q1	Oftalmologia (italiano)	RAG com tradução	Viabilidade técnica
Ishadya et al. (2026)	Q1,Q4	Saúde	Prompting estruturado + RAG/MCP	Exatidão, abstenção, evidência; especialistas
Ghanbari e Dividino (2025a)	Q1	Transferível (MCQ)	Grafo de conhecimento no prompt	Exatidão vs. sem contexto
Bellard et al. (2025)	Q1	Insuficiência cardíaca	RAG com LLM juiz	25 pares; latência e custo
Jain et al. (2025)	Q1	Sala de aula	RAG vetorial vs. grafo	3176 perguntas; manuais alterados

Estudo	Q	Domínio	Contexto e controlo	Avaliação
Ghanbari e Dividino (2025b)	Q1	Transferível (MCQ)	Subgrafos no prompt	Efeito da relevância do contexto
Oh et al. (2026)	Q1	Clínica	Pacientes virtuais de datasets	Métrica CARE; validação por especialistas
Shah et al. (2026)	Q1,Q3	Saúde	RAG, fine-tuning e guardrails	BLEU, ROUGE-L, BERTScore
Zhao et al. (2025)	Q1	Cibersegurança (curso)	RAG validado por ontologia	Implementado num curso
Yan e Shi (2026)	Q1	Eletrónica (curso)	RAG e engenharia de prompts	Exatidão e estabilidade
Xie et al. (2026)	Q1	QA médico (MCQ)	Três variantes de RAG	Exatidão no MedQA; efeito do RAG
Liu et al. (2026b)	Q1	Sala de aula	Contexto da aula em curso	117 estudantes; docentes avaliam correção
Han e Emara (2026)	Q1	Programação (CS1)	RAG sobre o manual, com citações	Citações corretas; inquérito
Miroyan et al. (2025)	Q1	Programação	RAG (GPT-4)	Avaliação e edição por TAs
Zheng et al. (2026)	Q1	Transferível (apoio técnico)	Fine-tuning vs. RAG vs. ICL	Correção; humanos e LLM juiz
Seshadri et al. (2026)	Q1	Programação	RAG sobre materiais, com citações	250 estudantes; inquérito
Barzanji et al. (2026)	Q1	Engenharia de software	Materiais do curso	32 estudantes; SUS 77,8
Buti e Mohamed (2026)	Q1,Q2	Aconselhamento académico	RAG	55 perguntas; LLM juiz
Xu et al. (2026)	Q1	Vídeo-aulas	Materiais da apresentação	Estudo com 75 participantes
Feng et al. (2024)	Q1	Programação	RAG, intenção e decomposição	50 pares vs. GPT-4; entrevistas
Bui et al. (2025)	Q1	Procedimentos académicos	LLM com verificação formal	Benchmark EduMC-QA
Liao et al. (2026)	Q1	Clínica (EHR)	Autocrítica e ICL com exemplos	LLM juiz e estudantes de medicina
Fu et al. (2024)	Q2	Universidade	Base de conhecimento web	Correção e completude; alucinações
Walczak e Sawicki (2026)	Q3	Universidade	Guardrails com restrição de tema	Precisão, recall, latência
Tien e Huong (2024)	Q3	Universidade	Classificador de jailbreak	Exatidão da deteção
Emekci e Budakoglu (2025)	Q3	Universidade	Dois LLM: filtro e geração	4501 interações reais; 0,28% falsos positivos
Mathew et al. (2026)	Q3	Saúde	Deteção federada de injeção	Exatidão e F1
Li et al. (2026)	Q3	Vários domínios	Monitorização de estados internos	Taxa de rejeição fora do domínio
Liu et al. (2024b)	Q3	Programação (CS50)	Guardrails pedagógicos	Demonstração; experiência de uso
Hamidi e Roberts (2026)	Q4	Radiologia	QA sobre um relatório	EM, F1; taxonomia com abstenção
Rayhan et al. (2026)	Q4	Programação	Controlo de acesso por grafo	Políticas: 90% vs. 30% (prompt)
Abrar et al. (2025)	Q4	Universidade (multilingue)	Fine-tuning com exemplos de recusa	Precisão da recusa 0,86