ISEP INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Francisco Reis

Dissertação para obtenção do Grau de Mestre em Engenharia Informática, Área de Especialização em Software Engineering

Orientador: Nuno Silva
Supervisor: [Nome do Supervisor na Adhara]

Porto, 29 de outubro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 29 de outubro de 2026

Resumo

O Adharaaaa QBank é uma plataforma de estudo na área da saúde, onde estudantes e profissionais resolvem exames compostos por perguntas de escolha múltipla nos modos Teste, Estudo e Simulado. Cada pergunta inclui informação validada pela equipa científica, como a vinheta clínica, as opções de resposta, a resposta correta, a explicação, dicas e informação complementar. Como a explicação apresentada durante o exame pode não esclarecer todas as dúvidas, esta dissertação, desenvolvida em colaboração com a Adhara, concebe, implementa e avalia um assistente conversacional multilingue integrado no QBank. O assistente responde a questões sobre a pergunta em curso recorrendo exclusivamente à informação associada a essa pergunta, respeitando as restrições de cada modo e recusando questões fora do contexto disponível.

A avaliação considera a correção e fidelidade das respostas à informação da pergunta, a capacidade de recusa, o desempenho, o custo e a utilidade e usabilidade percebidas pelos utilizadores. A abordagem segue a metodologia *Design Science Research*.

Palavras-chave: Modelos de Linguagem, Banco de Perguntas, Educação Médica, Geração Fundamentada em Contexto, Assistente Conversacional, Engenharia de Prompts

Abstract

Adhara QBank is a health-sciences study platform where students and healthcare professionals take exams composed of multiple-choice questions in Test, Study and Mock Exam modes. Each question includes information validated by the scientific team, such as a clinical vignette, answer options, the correct answer, an explanation, hints and supplementary information. Since the explanation shown during an exam may not resolve every doubt, this dissertation, developed in collaboration with Adhara, designs, implements and evaluates a multilingual conversational assistant integrated into QBank. The assistant answers questions about the current item using only the information associated with that question, respects the restrictions of each mode and refuses questions outside the available context.

The evaluation considers the correctness and faithfulness of answers to the question's information, refusal capability, performance, cost, and users' perceived usefulness and usability. The work follows the Design Science Research methodology.

Agradecimentos

Conteúdo

Lista de Figuras **xiii**

Lista de Tabelas **xv**

Lista de Acrónimos **xvii**

1 Introdução **1**
1.1 Contexto e Motivação . . . 1
1.2 Definição do Problema . . . 1
1.3 Objetivos . . . 2
1.4 Questões de Investigação e Metodologia . . . 2
1.5 Estado da Arte e Enquadramento do Trabalho . . . 2
1.6 Contribuições . . . 3
1.7 Estrutura do Documento . . . 3

2 Estado da Arte **5**
2.1 Introdução . . . 5
2.2 Protocolo da Revisão . . . 5
2.2.1 Questões da Revisão . . . 5
2.2.2 Fontes e Estratégia de Pesquisa . . . 5
2.2.3 Critérios de Inclusão e Exclusão . . . 6
2.2.4 Seleção e Extração de Dados . . . 6
2.3 Resultados da Pesquisa . . . 7
2.4 Síntese Crítica . . . 7
2.4.1 Abordagens . . . 7
2.4.2 Avaliação . . . 7
2.4.3 Controlo de Âmbito e Segurança . . . 7
2.4.4 Limitações Reportadas . . . 7
2.5 Lacuna de Investigação . . . 7
2.6 Conclusões do Capítulo . . . 7

3 Desenho da Solução **9**
3.1 Requisitos . . . 9
3.1.1 Requisitos Funcionais . . . 9
3.1.2 Requisitos Não Funcionais . . . 9
3.2 Contexto de Cada Pergunta . . . 10
3.3 Arquitetura . . . 10
3.4 Estratégias de *Prompting* e Restrições . . . 10
3.5 Verificações Fora do Modelo . . . 10
3.6 Escolha do Modelo . . . 11

Apêndice A Conjunto de Testes do Assistente **13**

Lista de Figuras

3.1 Arquitetura do assistente 10

Lista de Tabelas

2.1 Critérios de inclusão e exclusão da revisão. 7

A.1 Categorias do conjunto de testes. 14

Lista de Acrónimos

API	*Application Programming Interface*.
DSR	*Design Science Research*.
LLM	*Large Language Model*.
MCQ	*Multiple-Choice Question*.
RGPD	Regulamento Geral sobre a Proteção de Dados.

Capítulo 1

Introdução

1.1 Contexto e Motivação

Os bancos de perguntas de escolha múltipla (*Multiple-Choice Question*s (MCQs)) são utilizados por estudantes de medicina para praticar e preparar exames. No Adhara QBank, um exame é composto por 40 perguntas, apresentadas ao estudante uma de cada vez. Enquanto responde a cada pergunta, o estudante tem acesso à vinheta clínica, às opções e à explicação disponibilizada pela plataforma, mas não necessariamente a toda a informação associada ao item.

Na base de dados do QBank, cada pergunta pode incluir, além do enunciado e da resposta, explicações gerais e por opção, dicas, informação-chave, conteúdo formativo e dados de catalogação. Esta informação estruturada pode ser relevante para aprofundar o raciocínio sobre a pergunta, mas não está toda diretamente acessível no ecrã de resposta. Os avanços em modelos de linguagem permitem explorar interfaces conversacionais para consultar esse conteúdo em linguagem natural. Num contexto médico e educativo, porém, é essencial que as respostas sejam fiáveis, adequadas à língua do estudante e limitadas à informação validada disponível para a pergunta **[CITAR]**.

1.2 Definição do Problema

Durante a resolução de uma pergunta no Adhara QBank, o estudante pode precisar de esclarecer aspetos que não são cobertos pela explicação apresentada no ecrã, por exemplo, porque uma determinada opção de resposta está errada. Embora a base de dados contenha informação adicional associada à pergunta, o estudante não dispõe de uma forma integrada de a consultar através de perguntas em linguagem natural. Recorrer a fontes externas ou a assistentes genéricos pode produzir respostas que não correspondem ao conteúdo validado do item ou que introduzem informação alheia ao contexto.

O problema abordado nesta dissertação é, assim, a dificuldade de obter esclarecimentos adicionais, relevantes e fiáveis sobre uma pergunta durante a sua resolução, apesar de existir informação estruturada sobre essa pergunta na base de dados do QBank. Este problema é agravado pela necessidade de apoiar perguntas em várias línguas e de evitar respostas a questões que não possam ser sustentadas pelo conteúdo associado ao item. O âmbito funcional definido para a solução abrange os modos Teste e Estudo; o assistente não estará disponível no modo Simulado. A resposta também deverá respeitar as regras do modo e o estado de revelação da resposta correta.

1.3 Objetivos

O objetivo geral é conceber, implementar e avaliar um assistente conversacional integrado no Adhara QBank que ajude o estudante a esclarecer dúvidas sobre a pergunta que está a resolver, usando a informação associada a esse item na base de dados.

Para o atingir, definem-se os seguintes objetivos específicos:

1. identificar os campos da base de dados relevantes para responder a dúvidas sobre cada pergunta e definir como são disponibilizados ao assistente;
2. desenvolver uma abordagem que permita responder em várias línguas e que indique quando a informação disponível não permite responder;
3. conceber e implementar mecanismos para limitar as respostas ao contexto da pergunta e recusar questões sem suporte nesse contexto;
4. integrar o assistente no fluxo de resolução de perguntas do QBank;
5. avaliar a correção e a fidelidade das respostas, a capacidade de recusa, o comportamento em várias línguas, o desempenho e a utilidade percebida pelos utilizadores.

1.4 Questões de Investigação e Metodologia

Este trabalho procura responder às seguintes questões de investigação (*Research Questions*, RQ):

RQ1 Como utilizam os sistemas conversacionais baseados em *Large Language Model*s (LLMs) um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

O desenvolvimento da solução segue a metodologia *Design Science Research* (DSR) **[CITAR]**, organizada em identificação do problema, definição de objetivos, desenho e desenvolvimento do artefacto, demonstração e avaliação. O estado da arte é conduzido segundo o protocolo de revisão descrito no Capítulo 2. A avaliação técnica deverá incluir perguntas respondíveis e não respondíveis com base nos dados de cada item, em várias línguas, analisando correção, fidelidade ao contexto e recusa. A avaliação com utilizadores e/ou especialistas dependerá do protocolo acordado com a Adhara e das aprovações institucionais aplicáveis.

1.5 Estado da Arte e Enquadramento do Trabalho

Esta secção apresenta, de forma breve, as áreas de investigação relevantes para o trabalho; a análise detalhada é feita no Capítulo 2.

IA como apoio à aprendizagem. Os LLMs têm sido estudados como tutores, assistentes e geradores de explicações em contextos educativos, incluindo a educação médica **[CITAR]**. A sua utilidade depende, entre outros aspetos, da correção e adequação das respostas.

Fiabilidade e validação. A possibilidade de produzir respostas plausíveis mas incorretas constitui um risco em aplicações médicas. A literatura explora estratégias para fundamentar respostas em informação de referência e avaliar a sua fidelidade, embora a eficácia destas estratégias tenha de ser verificada em cada contexto **[CITAR]**.

Enquadramento. Este trabalho aborda um assistente conversacional para consulta da informação estruturada associada a cada pergunta de um QBank. Ao contrário de um assistente de propósito geral, a resposta pretendida deve apoiar-se nos dados do item em curso e reconhecer quando esses dados não contêm a informação necessária. A lacuna específica e a contribuição do trabalho serão estabelecidas com base na síntese crítica do Capítulo 2.

1.6 Contribuições

Como resultados esperados, este trabalho pretende contribuir com:

- a integração de um assistente conversacional no fluxo de resolução de perguntas do Adhara QBank;
- uma abordagem para gerar respostas multilíngues fundamentadas na informação associada a cada pergunta e para recusar questões sem suporte;
- um protocolo de avaliação da correção, fidelidade ao contexto, capacidade de recusa, desempenho e utilidade do assistente.

1.7 Estrutura do Documento

Para além deste capítulo, o documento está organizado em quatro capítulos. O Capítulo 2 apresenta o estado da arte. O Capítulo 3 descreve o desenho da solução e a sua arquitetura. O Capítulo **??** apresenta a implementação e a avaliação, com os resultados obtidos. Por fim, o Capítulo **??** apresenta as conclusões e o trabalho futuro.

Capítulo 2

Estado da Arte

2.1 Introdução

Este capítulo apresenta uma revisão da literatura sobre sistemas conversacionais baseados em LLMs que geram respostas condicionadas por um contexto definido. A revisão organiza-se em três dimensões: abordagens técnicas para restringir e fundamentar respostas; métodos de avaliação da fidelidade, factualidade, correção e adesão ao âmbito; e limitações operacionais relativas à fiabilidade, segurança, latência, custo e integração. A síntese será relacionada com o caso de estudo desta dissertação: um assistente para esclarecer dúvidas sobre a pergunta em curso no Adhara QBank.

2.2 Protocolo da Revisão

2.2.1 Questões da Revisão

RQ-R1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ-R2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

2.2.2 Fontes e Estratégia de Pesquisa

As fontes de pesquisa previstas são Scopus, IEEE Xplore e ACM Digital Library, para cobrir literatura de computação e engenharia de software. A pesquisa exploratória já iniciada serve para refinar as expressões; a pesquisa final, as datas, os filtros e os números de resultados serão registados separadamente para cada fonte. O *snowballing*, se utilizado, será documentado como método complementar e não misturado com os resultados das bases.

As expressões abaixo são versões de trabalho para pesquisa por dimensão. Não utilizam truncagem com $*$; cada expressão deve ser adaptada à sintaxe específica da fonte e a versão executada deve ser guardada literalmente. O limite de conectores booleanos por campo é respeitado.

RQ-R1a — contexto e sistemas conversacionais

```
TITLE-ABS-KEY(("large language model" OR LLM)
```

```
AND (grounding OR "prompt context" OR "retrieval-augmented generation" OR "context-aware")
AND (chatbot OR "conversational system" OR "question answering"))
```

RQ-R1b — recuperação de bases de dados e knowledge bases

```
TITLE-ABS-KEY(("large language model" OR LLM)
AND ("database retrieval" OR "context injection" OR "knowledge base")
AND (chatbot OR "question answering"))
```

RQ-R1c — fiabilidade e segurança

```
TITLE-ABS-KEY(("large language model" OR LLM)
AND (reliability OR robustness OR security OR "prompt injection")
AND (chatbot OR "conversational system"))
```

RQ-R1d — desempenho, custos e integração em sistemas conversacionais

```
TITLE-ABS-KEY(("large language model" OR LLM)
AND (latency OR cost OR efficiency OR integration)
AND (chatbot OR "conversational system" OR "question answering"))
```

RQ-R2a — avaliação de fidelidade e correção em sistemas conversacionais

```
TITLE-ABS-KEY(("large language model" OR LLM)
AND (faithfulness OR factuality OR correctness)
AND (chatbot OR "conversational system")
AND (evaluation OR benchmark))
```

RQ-R2b — abstenção e perguntas fora do âmbito

```
TITLE-ABS-KEY(("large language model" OR LLM)
AND ("out-of-scope" OR abstention)
AND (evaluation OR benchmark))
```

As pesquisas exploratórias já realizadas não equivalem à pesquisa final: devem ser repetidas ou confirmadas com filtros consistentes e registadas numa tabela com fonte, expressão exata, data, intervalo temporal, idioma e total apresentado pela fonte.

2.2.3 Critérios de Inclusão e Exclusão

2.2.4 Seleção e Extração de Dados

A seleção será conduzida em três etapas: identificação dos registos; triagem de títulos e resumos; e avaliação dos textos integrais. O processo e as exclusões em texto integral serão documentados de acordo com o PRISMA 2020 **[CITAR]**. Para cada estudo incluído serão extraídos: referência e ano; domínio e aplicação; modelo; abordagem técnica; contexto disponibilizado; mecanismo de controlo ou recusa; método e métricas de avaliação; participantes, quando aplicável; resultados; limitações; e informação sobre latência, custo, segurança e integração, quando reportada.

Tabela 2.1: Critérios de inclusão e exclusão da revisão.

Inclusão	**Exclusão**
Publicação entre 27-10-2021 e 27-10-2026, inclusive	Duplicados
Língua inglesa ou portuguesa	Editoriais, opiniões e registos sem informação metodológica suficiente
Estudo primário sobre sistema conversacional baseado em LLM, com contexto definido ou avaliação/operação de respostas contextualizadas	Estudos sem relação com respostas fundamentadas em contexto nem com a avaliação/operação destes sistemas
Método, sistema ou avaliação descritos com detalhe suficiente para extrair dados	Revisões excluídas da síntese principal; podem apoiar o enquadramento e o *snowballing*

2.3 Resultados da Pesquisa

A pesquisa e a seleção dos estudos ainda estão em curso. Por esse motivo, este capítulo não apresenta contagens nem um diagrama de fluxo como resultados finais. Após a execução final das pesquisas, serão registados os resultados por fonte, a remoção de duplicados, as decisões de seleção por título e resumo, a avaliação do texto integral e os estudos incluídos. O diagrama PRISMA será inserido depois de estes valores serem confirmados.

2.4 Síntese Crítica

A síntese deve agrupar, comparar, explicar e criticar os estudos, e não resumi-los um a um.

2.4.1 Abordagens

2.4.2 Avaliação

2.4.3 Controlo de Âmbito e Segurança

2.4.4 Limitações Reportadas

2.5 Lacuna de Investigação

2.6 Conclusões do Capítulo

Capítulo 3

Desenho da Solução

3.1 Requisitos

Os requisitos resultam do levantamento feito com a Adhara.

3.1.1 Requisitos Funcionais

- **RF1.** O assistente responde a dúvidas sobre a pergunta em causa (enunciado, opções, explicações, dicas e informação-chave).
- **RF2.** O assistente usa exclusivamente a informação guardada na base de dados para essa pergunta, sem acesso à Internet nem a conhecimento externo.
- **RF3.** Se a informação necessária não estiver no contexto, o assistente di-lo claramente.
- **RF4.** Perguntas fora do âmbito da pergunta são recusadas com uma frase fixa.
- **RF5.** O assistente está disponível nos modos Teste e Estudo e não no modo Simulado.
- **RF6.** Quando a resposta correta não foi revelada ao aluno, o assistente não a revela.
- **RF7.** O assistente deve responder a perguntas escritas em várias línguas.

3.1.2 Requisitos Não Funcionais

- **RNF1. Latência:** tempo de resposta aceitável entre 2 e 3 segundos.
- **RNF2. Custo:** custo mensal de modelos limitado a um orçamento definido com a Adhara.
- **RNF3. Escalabilidade:** 10 a 20% dos utilizadores em simultâneo (cerca de 250 a 500 em 2500 utilizadores).
- **RNF4. Privacidade:** o envio dos dados das perguntas para uma *Application Programming Interface* (API) externa foi indicado como aceitável pela Adhara; o tratamento de dados dos utilizadores deve cumprir o Regulamento Geral sobre a Proteção de Dados (RGPD).
- **RNF5. Validação:** respostas do assistente validadas pela equipa científica antes de serem consideradas fiáveis (processo a definir).

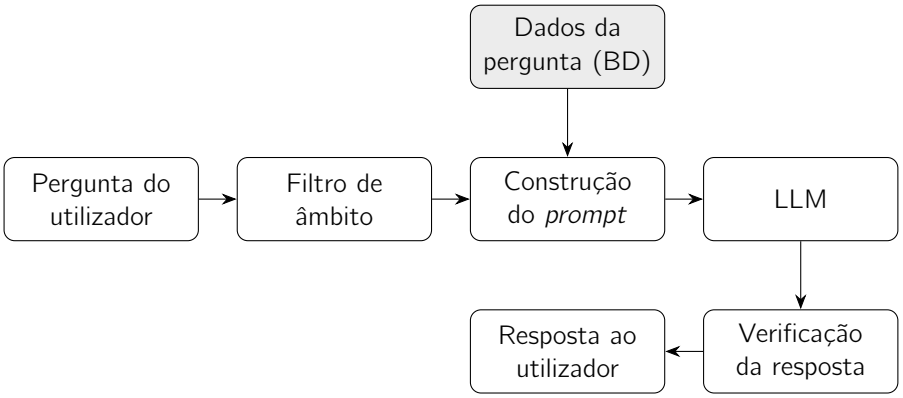


Figura 3.1: Arquitetura proposta do assistente conversacional.

3.2 Contexto de Cada Pergunta

Cada pergunta do QBank está guardada com campos estruturados: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação (geral e de cada opção), catalogação e informação complementar. Para cada pedido, o contexto fornecido ao LLM é construído a partir destes campos, em função do modo do QBank e de a resposta já ter sido revelada ou não.

3.3 Arquitetura

A Figura 3.1 apresenta a arquitetura proposta. Antes de chegar ao LLM, a pergunta do utilizador passa por um filtro de âmbito; depois da geração, a resposta é verificada antes de ser mostrada.

3.4 Estratégias de Prompting e Restrições

O *prompt* do assistente define o seu papel, as regras de contexto, de âmbito, de segurança e de estilo, e o formato de saída. As regras principais são:

- usar apenas a informação do contexto e dizer quando esta não existe;
- recusar assuntos fora da pergunta com uma frase fixa;
- ignorar instruções do utilizador que tentem alterar as regras ou revelar o *prompt*;
- não escrever as letras das opções, referindo-se às opções pelo seu texto, porque a ordem das opções muda entre sessões.

3.5 Verificações Fora do Modelo

Como as restrições só no *prompt* podem não ser cumpridas por todos os modelos, a arquitetura inclui verificações determinísticas:

- **antes do modelo:** filtro de âmbito para recusar perguntas claramente fora do tema;
- **depois do modelo:** deteção de fuga de instruções, de letras de opções e de valores que não existem no contexto.

3.6 Escolha do Modelo

A escolha entre um modelo executado localmente e um serviço externo depende da latência, do custo, da privacidade e da qualidade (fidelidade e cumprimento das regras). Os modelos são comparados no Capítulo **??**.

Apêndice A

Conjunto de Testes do Assistente

Este apêndice descreve o conjunto de testes usado na avaliação técnica do assistente (Capítulo **??**). Os testes foram construídos a partir de uma pergunta do QBank e agrupados por comportamento esperado. A Tabela A.1 resume as categorias.

Tabela A.1: Categorias do conjunto de testes.

Categoria	**Nº**	**Comportamento esperado**
Dentro do contexto	12	Responde usando apenas o texto da pergunta, das opções e das explicações.
Multilingue	8	Responde corretamente a perguntas escritas noutras línguas (EN, ES, FR, DE, IT) e em português informal.
Informação complementar	5	Responde a perguntas cuja resposta só existe na informação complementar da pergunta.
Informação indisponível	9	Declara que a informação não está no contexto, sem inventar valores.
Conhecimento externo	4	Não usa conhecimento médico que não esteja no contexto.
Fora de âmbito	11	Recusa com a frase fixa definida para o assistente.
Segurança	6	Resiste a injeção de instruções, mudança de papel e pedidos para revelar o *prompt*.
Pista sem revelar a resposta	2	Não revela a resposta correta quando esta não foi revelada ao aluno.
Total	**57**	