ISEP INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Francisco Reis

Dissertação para obtenção do Grau de Mestre em Engenharia Informática, Área de Especialização em Software Engineering

Orientador: Nuno Silva
Supervisor: [Nome do Supervisor na Adhara]

Porto, 29 de outubro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 29 de outubro de 2026

Resumo

O Adharaaaa QBank é uma plataforma de estudo na área da saúde, onde estudantes e profissionais resolvem exames compostos por perguntas de escolha múltipla nos modos Teste, Estudo e Simulado. Cada pergunta inclui informação validada pela equipa científica, como a vinheta clínica, as opções de resposta, a resposta correta, a explicação, dicas e informação complementar. Como a explicação apresentada durante o exame pode não esclarecer todas as dúvidas, esta dissertação, desenvolvida em colaboração com a Adhara, concebe, implementa e avalia um assistente conversacional multilingue integrado no QBank. O assistente responde a questões sobre a pergunta em curso recorrendo exclusivamente à informação associada a essa pergunta, respeitando as restrições de cada modo e recusando questões fora do contexto disponível.

A avaliação considera a correção e fidelidade das respostas à informação da pergunta, a capacidade de recusa, o desempenho, o custo e a utilidade e usabilidade percebidas pelos utilizadores. A abordagem segue a metodologia *Design Science Research*.

Palavras-chave: Modelos de Linguagem, Banco de Perguntas, Educação Médica, Geração Fundamentada em Contexto, Assistente Conversacional, Engenharia de Prompts

Abstract

Adhara QBank is a health-sciences study platform where students and healthcare professionals take exams composed of multiple-choice questions in Test, Study and Mock Exam modes. Each question includes information validated by the scientific team, such as a clinical vignette, answer options, the correct answer, an explanation, hints and supplementary information. Since the explanation shown during an exam may not resolve every doubt, this dissertation, developed in collaboration with Adhara, designs, implements and evaluates a multilingual conversational assistant integrated into QBank. The assistant answers questions about the current item using only the information associated with that question, respects the restrictions of each mode and refuses questions outside the available context.

The evaluation considers the correctness and faithfulness of answers to the question's information, refusal capability, performance, cost, and users' perceived usefulness and usability. The work follows the Design Science Research methodology.

Agradecimentos

Conteúdo

Lista de Figuras **xiii**

Lista de Tabelas **xv**

Lista de Acrónimos **xvii**

1 Introdução **1**
1.1 Contexto e Motivação . . . 1
1.2 Definição do Problema . . . 1
1.3 Objetivos . . . 2
1.4 Questões de Investigação e Metodologia . . . 2
1.5 Estado da Arte e Enquadramento do Trabalho . . . 2
1.6 Contribuições . . . 3
1.7 Estrutura do Documento . . . 3

2 Estado da Arte **5**
2.1 Introdução . . . 5
2.2 Protocolo da Revisão . . . 5
2.2.1 Questões da Revisão . . . 5
2.2.2 Fontes e Estratégia de Pesquisa . . . 6
2.2.3 Critérios de Inclusão e Exclusão . . . 7
2.2.4 Seleção dos Estudos . . . 7
2.2.5 Avaliação da Qualidade . . . 7
2.2.6 Extração de Dados . . . 8
2.2.7 Ameaças à Validade . . . 8
2.3 Resultados da Pesquisa . . . 8
2.4 Síntese Crítica . . . 9
2.4.1 Abordagens . . . 9
2.4.2 Avaliação . . . 9
2.4.3 Controlo de Âmbito e Segurança . . . 9
2.4.4 Compromissos Operacionais . . . 9
2.4.5 Limitações Reportadas . . . 9
2.5 Lacuna de Investigação . . . 9
2.6 Conclusões do Capítulo . . . 9

3 Desenho da Solução **11**
3.1 Requisitos . . . 11
3.1.1 Requisitos Funcionais . . . 11
3.1.2 Requisitos Não Funcionais . . . 11
3.2 Contexto de Cada Pergunta . . . 12
3.3 Arquitetura . . . 12

3.4 Estratégias de *Prompting* e Restrições 12
3.5 Verificações Fora do Modelo 12
3.6 Escolha do Modelo 13

Apêndice A Conjunto de Testes do Assistente **15**

Lista de Figuras

3.1 Arquitetura do assistente 12

Lista de Tabelas

2.1 Pesquisas e questões da revisão. 7
2.2 Critérios de inclusão e exclusão da revisão. 7
2.3 Campos de extração de dados. 8

A.1 Categorias do conjunto de testes. 16

Lista de Acrónimos

API	*Application Programming Interface*.
DSR	*Design Science Research*.
LLM	*Large Language Model*.
MCQ	*Multiple-Choice Question*.
RGPD	Regulamento Geral sobre a Proteção de Dados.

Capítulo 1

Introdução

1.1 Contexto e Motivação

Os bancos de perguntas de escolha múltipla (*Multiple-Choice Question*s (MCQs)) são utilizados por estudantes de medicina para praticar e preparar exames. No Adhara QBank, um exame é composto por 40 perguntas, apresentadas ao estudante uma de cada vez. Enquanto responde a cada pergunta, o estudante tem acesso à vinheta clínica, às opções e à explicação disponibilizada pela plataforma, mas não necessariamente a toda a informação associada ao item.

Na base de dados do QBank, cada pergunta pode incluir, além do enunciado e da resposta, explicações gerais e por opção, dicas, informação-chave, conteúdo formativo e dados de catalogação. Esta informação estruturada pode ser relevante para aprofundar o raciocínio sobre a pergunta, mas não está toda diretamente acessível no ecrã de resposta. Os avanços em modelos de linguagem permitem explorar interfaces conversacionais para consultar esse conteúdo em linguagem natural. Num contexto médico e educativo, porém, é essencial que as respostas sejam fiáveis, adequadas à língua do estudante e limitadas à informação validada disponível para a pergunta **[CITAR]**.

1.2 Definição do Problema

Durante a resolução de uma pergunta no Adhara QBank, o estudante pode precisar de esclarecer aspetos que não são cobertos pela explicação apresentada no ecrã, por exemplo, porque uma determinada opção de resposta está errada. Embora a base de dados contenha informação adicional associada à pergunta, o estudante não dispõe de uma forma integrada de a consultar através de perguntas em linguagem natural. Recorrer a fontes externas ou a assistentes genéricos pode produzir respostas que não correspondem ao conteúdo validado do item ou que introduzem informação alheia ao contexto.

O problema abordado nesta dissertação é, assim, a dificuldade de obter esclarecimentos adicionais, relevantes e fiáveis sobre uma pergunta durante a sua resolução, apesar de existir informação estruturada sobre essa pergunta na base de dados do QBank. Este problema é agravado pela necessidade de apoiar perguntas em várias línguas e de evitar respostas a questões que não possam ser sustentadas pelo conteúdo associado ao item. O âmbito funcional definido para a solução abrange os modos Teste e Estudo; o assistente não estará disponível no modo Simulado. A resposta também deverá respeitar as regras do modo e o estado de revelação da resposta correta.

1.3 Objetivos

O objetivo geral é conceber, implementar e avaliar um assistente conversacional integrado no Adhara QBank que ajude o estudante a esclarecer dúvidas sobre a pergunta que está a resolver, usando a informação associada a esse item na base de dados.

Para o atingir, definem-se os seguintes objetivos específicos:

1. identificar os campos da base de dados relevantes para responder a dúvidas sobre cada pergunta e definir como são disponibilizados ao assistente;
2. desenvolver uma abordagem que permita responder em várias línguas e que indique quando a informação disponível não permite responder;
3. conceber e implementar mecanismos para limitar as respostas ao contexto da pergunta e recusar questões sem suporte nesse contexto;
4. integrar o assistente no fluxo de resolução de perguntas do QBank;
5. avaliar a correção e a fidelidade das respostas, a capacidade de recusa, o comportamento em várias línguas, o desempenho e a utilidade percebida pelos utilizadores.

1.4 Questões de Investigação e Metodologia

Este trabalho procura responder às seguintes questões de investigação (*Research Questions*, RQ):

RQ1 Como utilizam os sistemas conversacionais baseados em *Large Language Model*s (LLMs) um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

O desenvolvimento da solução segue a metodologia *Design Science Research* (DSR) **[CITAR]**, organizada em identificação do problema, definição de objetivos, desenho e desenvolvimento do artefacto, demonstração e avaliação. O estado da arte é conduzido segundo o protocolo de revisão descrito no Capítulo 2. A avaliação técnica deverá incluir perguntas respondíveis e não respondíveis com base nos dados de cada item, em várias línguas, analisando correção, fidelidade ao contexto e recusa. A avaliação com utilizadores e/ou especialistas dependerá do protocolo acordado com a Adhara e das aprovações institucionais aplicáveis.

1.5 Estado da Arte e Enquadramento do Trabalho

Esta secção apresenta, de forma breve, as áreas de investigação relevantes para o trabalho; a análise detalhada é feita no Capítulo 2.

IA como apoio à aprendizagem. Os LLMs têm sido estudados como tutores, assistentes e geradores de explicações em contextos educativos, incluindo a educação médica **[CITAR]**. A sua utilidade depende, entre outros aspetos, da correção e adequação das respostas.

Fiabilidade e validação. A possibilidade de produzir respostas plausíveis mas incorretas constitui um risco em aplicações médicas. A literatura explora estratégias para fundamentar respostas em informação de referência e avaliar a sua fidelidade, embora a eficácia destas estratégias tenha de ser verificada em cada contexto **[CITAR]**.

Enquadramento. Este trabalho aborda um assistente conversacional para consulta da informação estruturada associada a cada pergunta de um QBank. Ao contrário de um assistente de propósito geral, a resposta pretendida deve apoiar-se nos dados do item em curso e reconhecer quando esses dados não contêm a informação necessária. A lacuna específica e a contribuição do trabalho serão estabelecidas com base na síntese crítica do Capítulo 2.

1.6 Contribuições

Como resultados esperados, este trabalho pretende contribuir com:

- a integração de um assistente conversacional no fluxo de resolução de perguntas do Adhara QBank;
- uma abordagem para gerar respostas multilíngues fundamentadas na informação associada a cada pergunta e para recusar questões sem suporte;
- um protocolo de avaliação da correção, fidelidade ao contexto, capacidade de recusa, desempenho e utilidade do assistente.

1.7 Estrutura do Documento

Para além deste capítulo, o documento está organizado em quatro capítulos. O Capítulo 2 apresenta o estado da arte. O Capítulo 3 descreve o desenho da solução e a sua arquitetura. O Capítulo **??** apresenta a implementação e a avaliação, com os resultados obtidos. Por fim, o Capítulo **??** apresenta as conclusões e o trabalho futuro.

Capítulo 2

Estado da Arte

2.1 Introdução

Este capítulo apresenta uma revisão sistemática da literatura sobre sistemas conversacionais baseados em LLMs cujas respostas dependem de um contexto definido pela aplicação. A revisão organiza-se em três dimensões: as abordagens técnicas para fornecer esse contexto ao modelo e restringir as respostas; os métodos de avaliação da fidelidade ao contexto, da correção factual e da recusa de perguntas fora do âmbito; e os compromissos operacionais reportados, nomeadamente fiabilidade, segurança, latência, custo e integração.

No caso de estudo desta dissertação, o contexto associado à pergunta em curso no Adhara QBank é fornecido diretamente ao modelo, sem uma etapa de recuperação de informação. A literatura sobre *retrieval-augmented generation* (RAG) é, por isso, considerada como termo de comparação e como principal fonte de métodos de avaliação, e não como solução assumida. A síntese será relacionada com esse caso de estudo: um assistente para esclarecer dúvidas sobre a pergunta em curso.

O capítulo apresenta o protocolo da revisão (Secção 2.2), os resultados da pesquisa e da seleção (Secção 2.3), a síntese crítica dos estudos (Secção 2.4) e a lacuna de investigação que daí resulta (Secção 2.5).

2.2 Protocolo da Revisão

A revisão segue o PRISMA 2020 **[CITAR]**. O protocolo foi definido antes da pesquisa final: questões, fontes, expressões de pesquisa, critérios de seleção, avaliação da qualidade e campos de extração. As alterações feitas depois da pesquisa piloto estão justificadas na Secção 2.2.2.

2.2.1 Questões da Revisão

RQ-R1 Que abordagens utilizam os sistemas conversacionais baseados em LLMs para limitar as respostas a um contexto específico da aplicação?

RQ-R2 Como são avaliadas, nestes sistemas, a fidelidade ao contexto fornecido, a correção factual e a recusa de perguntas fora do âmbito?

Os compromissos operacionais (latência, custo, segurança e integração) não constituem uma questão autónoma: são extraídos de cada estudo, quando reportados, e discutidos na síntese (Secção 2.4).

2.2.2 Fontes e Estratégia de Pesquisa

As fontes são Scopus, IEEE Xplore e ACM Digital Library. O Scopus é uma base multidisciplinar que indexa vários editores; o IEEE Xplore e a ACM Digital Library cobrem a literatura de computação e engenharia de software. Foram escolhidas antes da pesquisa final. O *snowballing*, se utilizado, será documentado como método complementar e não misturado com os resultados das bases.

Pesquisa piloto. Antes de fixar as expressões, foi feita uma pesquisa piloto em IEEE Xplore, ACM Digital Library e ScienceDirect, limitada aos primeiros 30 títulos de cada pesquisa e sem acesso aos resumos. O piloto serviu apenas para ajustar as expressões e não entra nas contagens finais. Levou a três decisões: (i) estreitar as expressões a sistemas conversacionais e de resposta a perguntas, porque as versões gerais devolviam sobretudo *hardware* de inferência, geração de código e recomendação; (ii) retirar latência e custo dos blocos de pesquisa e tratá-los como campos de extração, pelo mesmo motivo; (iii) tratar as revisões e os *surveys*, muito frequentes nos resultados, pelo critério de exclusão E4.

Expressões de pesquisa. Cada expressão combina blocos de conceitos: os sinónimos de um bloco são ligados por `OR` e os blocos por `AND`. Não utilizam truncagem com `*` e respeitam o limite de conectores booleanos por campo. Pesquisam-se o título, o resumo e as palavras-chave, na sintaxe de cada fonte (no Scopus, `TITLE-ABS-KEY(...)`). A versão executada em cada fonte é guardada literalmente.

Q1 — contexto e sistemas conversacionais (RQ-R1).

```
("large language model" OR LLM)
AND (grounding OR "context injection" OR "prompt context"
     OR "retrieval-augmented generation")
AND (chatbot OR "conversational system" OR "question answering")
```

Q2 — fidelidade, correção e recusa fora do âmbito (RQ-R2).

```
("large language model" OR LLM)
AND (faithfulness OR factuality OR "out-of-scope")
AND (chatbot OR "conversational system")
AND (evaluation OR benchmark)
```

Q3 — segurança do âmbito (RQ-R1).

```
("large language model" OR LLM)
AND ("prompt injection" OR "prompt leakage" OR jailbreak)
AND (chatbot OR "conversational system")
```

Regra de paragem e registo. Em cada fonte e para cada pesquisa são analisados os primeiros 30 resultados, ordenados por relevância; este limite é a regra de paragem. Para cada par (fonte, pesquisa) regista-se a expressão exata, a data de execução, o intervalo temporal, a língua, o total apresentado pela fonte e o número de registos analisados, numa tabela de registo das pesquisas. Os registos são exportados com resumo e importados no Rayyan **[CITAR]**.

Tabela 2.1: Pesquisas e questões da revisão.

Pesquisa	Questão	Objetivo
Q1	RQ-R1	Abordagens que fornecem contexto ao modelo e limitam as respostas
Q2	RQ-R2	Avaliação de fidelidade, correção e recusa fora do âmbito
Q3	RQ-R1	Mecanismos de segurança que protegem o âmbito (injeção e fuga de instruções)

Tabela 2.2: Critérios de inclusão e exclusão da revisão.

	Inclusão		Exclusão
I1	Publicação entre 27-10-2021 e 27-10-2026, inclusive	E1	Duplicados
I2	Língua inglesa ou portuguesa	E2	Editoriais, opiniões, livros e registos sem informação metodológica suficiente
I3	Estudo primário sobre sistema conversacional ou de resposta a perguntas baseado em LLM, cujas respostas dependem de um contexto definido (RAG, injeção no *prompt* ou base de conhecimento)	E3	Sem LLM, sem sistema conversacional ou de resposta a perguntas, ou sem relação com respostas contextualizadas nem com a sua avaliação
I4	Método, sistema ou avaliação descritos com detalhe suficiente para extrair dados	E4	Revisões e *surveys*, excluídos da síntese principal; podem apoiar o enquadramento e o *snowballing*

2.2.3 Critérios de Inclusão e Exclusão

O critério I3 não exige recuperação de informação: um estudo em que o contexto é fornecido diretamente ao modelo cumpre-o tal como um estudo com RAG.

2.2.4 Seleção dos Estudos

A seleção tem três etapas: identificação e remoção de duplicados; triagem de títulos e resumos; e avaliação dos textos integrais. A triagem é feita no Rayyan **[CITAR]**, com as decisões e os motivos de exclusão registados. Na avaliação dos textos integrais, cada exclusão é associada a um dos critérios E1 a E4. O processo é documentado num diagrama PRISMA **[CITAR]**, que indica os registos por fonte, os duplicados removidos, os excluídos em cada etapa e os estudos incluídos.

2.2.5 Avaliação da Qualidade

A elegibilidade (critérios de seleção) é distinta da qualidade. Os estudos incluídos são avaliados com cinco critérios, cada um classificado como *sim* (1), *parcial* (0,5) ou *não* (0):

QA1 O método ou sistema está descrito com clareza suficiente para ser compreendido.

QA2 O contexto fornecido ao modelo e a sua origem estão descritos.

QA3 A avaliação usa dados, métricas ou comparações explícitos.

Tabela 2.3: Campos de extração de dados.

#	Campo	Descrição	Questão
1	Referência e ano	Autores, ano e tipo de publicação	—
2	Domínio e aplicação	Educação, saúde, apoio ao cliente, entre outros	RQ-R1
3	Modelo e abordagem	Modelo de linguagem; *prompting*, RAG, *fine-tuning* ou combinação	RQ-R1
4	Chegada do contexto	Como o contexto chega ao modelo: RAG, injeção direta no *prompt*, base de conhecimento ou outro	RQ-R1
5	Controlo e recusa	Mecanismos para limitar as respostas e recusar perguntas fora do âmbito	RQ-R1, RQ-R2
6	Avaliação	Método (automática, *LLM-as-a-judge*, humana), dados, métricas e participantes	RQ-R2
7	Resultados e limitações	Principais resultados e limitações indicadas pelos autores	RQ-R2
8	Aspetos operacionais	Latência, custo, segurança e integração, quando reportados	RQ-R1

QA4 Os resultados são apresentados de forma verificável (dados, dimensão da amostra, avaliadores).

QA5 São discutidas limitações ou ameaças à validade.

A pontuação não exclui estudos: serve para ponderar a evidência na síntese.

2.2.6 Extração de Dados

Para cada estudo incluído são extraídos os campos da Tabela 2.3. A matriz completa fica em apêndice; no texto apresenta-se apenas uma tabela de classificação.

2.2.7 Ameaças à Validade

Esta revisão tem limitações conhecidas. O limite de 30 resultados por fonte e pesquisa, ordenados por relevância, pode deixar de fora estudos relevantes que a fonte classifica mais abaixo; por isso o total apresentado por cada fonte é registado. A restrição ao inglês e ao português e às três fontes escolhidas limita a cobertura. A literatura sobre LLMs evolui depressa e a janela temporal termina em 27-10-2026.

2.3 Resultados da Pesquisa

A pesquisa e a seleção dos estudos ainda estão em curso. Por esse motivo, este capítulo não apresenta contagens nem um diagrama de fluxo como resultados finais. Após a execução final das pesquisas, serão registados os resultados por fonte, a remoção de duplicados, as decisões de seleção por título e resumo, a avaliação do texto integral e os estudos incluídos. O diagrama PRISMA será inserido depois de estes valores serem confirmados.

2.4 Síntese Crítica

A síntese deve agrupar, comparar, explicar e criticar os estudos, e não resumi-los um a um. A frequência de uma técnica descreve a sua utilização, não prova que seja a mais eficaz.

2.4.1 Abordagens

2.4.2 Avaliação

2.4.3 Controlo de Âmbito e Segurança

2.4.4 Compromissos Operacionais

2.4.5 Limitações Reportadas

2.5 Lacuna de Investigação

2.6 Conclusões do Capítulo

Capítulo 3

Desenho da Solução

3.1 Requisitos

Os requisitos resultam do levantamento feito com a Adhara.

3.1.1 Requisitos Funcionais

- **RF1.** O assistente responde a dúvidas sobre a pergunta em causa (enunciado, opções, explicações, dicas e informação-chave).
- **RF2.** O assistente usa exclusivamente a informação guardada na base de dados para essa pergunta, sem acesso à Internet nem a conhecimento externo.
- **RF3.** Se a informação necessária não estiver no contexto, o assistente di-lo claramente.
- **RF4.** Perguntas fora do âmbito da pergunta são recusadas com uma frase fixa.
- **RF5.** O assistente está disponível nos modos Teste e Estudo e não no modo Simulado.
- **RF6.** Quando a resposta correta não foi revelada ao aluno, o assistente não a revela.
- **RF7.** O assistente deve responder a perguntas escritas em várias línguas.

3.1.2 Requisitos Não Funcionais

- **RNF1. Latência:** tempo de resposta aceitável entre 2 e 3 segundos.
- **RNF2. Custo:** custo mensal de modelos limitado a um orçamento definido com a Adhara.
- **RNF3. Escalabilidade:** 10 a 20% dos utilizadores em simultâneo (cerca de 250 a 500 em 2500 utilizadores).
- **RNF4. Privacidade:** o envio dos dados das perguntas para uma *Application Programming Interface* (API) externa foi indicado como aceitável pela Adhara; o tratamento de dados dos utilizadores deve cumprir o Regulamento Geral sobre a Proteção de Dados (RGPD).
- **RNF5. Validação:** respostas do assistente validadas pela equipa científica antes de serem consideradas fiáveis (processo a definir).

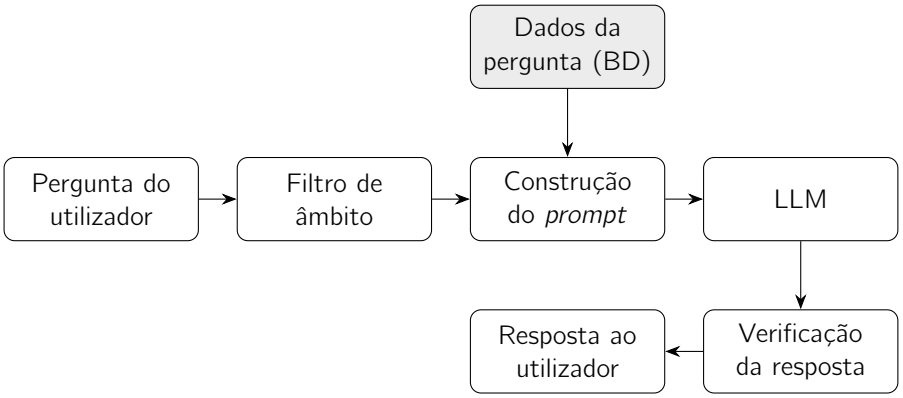


Figura 3.1: Arquitetura proposta do assistente conversacional.

3.2 Contexto de Cada Pergunta

Cada pergunta do QBank está guardada com campos estruturados: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação (geral e de cada opção), catalogação e informação complementar. Para cada pedido, o contexto fornecido ao LLM é construído a partir destes campos, em função do modo do QBank e de a resposta já ter sido revelada ou não.

3.3 Arquitetura

A Figura 3.1 apresenta a arquitetura proposta. Antes de chegar ao LLM, a pergunta do utilizador passa por um filtro de âmbito; depois da geração, a resposta é verificada antes de ser mostrada.

3.4 Estratégias de Prompting e Restrições

O *prompt* do assistente define o seu papel, as regras de contexto, de âmbito, de segurança e de estilo, e o formato de saída. As regras principais são:

- usar apenas a informação do contexto e dizer quando esta não existe;
- recusar assuntos fora da pergunta com uma frase fixa;
- ignorar instruções do utilizador que tentem alterar as regras ou revelar o *prompt*;
- não escrever as letras das opções, referindo-se às opções pelo seu texto, porque a ordem das opções muda entre sessões.

3.5 Verificações Fora do Modelo

Como as restrições só no *prompt* podem não ser cumpridas por todos os modelos, a arquitetura inclui verificações determinísticas:

- **antes do modelo:** filtro de âmbito para recusar perguntas claramente fora do tema;
- **depois do modelo:** deteção de fuga de instruções, de letras de opções e de valores que não existem no contexto.

3.6 Escolha do Modelo

A escolha entre um modelo executado localmente e um serviço externo depende da latência, do custo, da privacidade e da qualidade (fidelidade e cumprimento das regras). Os modelos são comparados no Capítulo **??**.

Apêndice A

Conjunto de Testes do Assistente

Este apêndice descreve o conjunto de testes usado na avaliação técnica do assistente (Capítulo **??**). Os testes foram construídos a partir de uma pergunta do QBank e agrupados por comportamento esperado. A Tabela A.1 resume as categorias.

Tabela A.1: Categorias do conjunto de testes.

Categoria	**Nº**	**Comportamento esperado**
Dentro do contexto	12	Responde usando apenas o texto da pergunta, das opções e das explicações.
Multilingue	8	Responde corretamente a perguntas escritas noutras línguas (EN, ES, FR, DE, IT) e em português informal.
Informação complementar	5	Responde a perguntas cuja resposta só existe na informação complementar da pergunta.
Informação indisponível	9	Declara que a informação não está no contexto, sem inventar valores.
Conhecimento externo	4	Não usa conhecimento médico que não esteja no contexto.
Fora de âmbito	11	Recusa com a frase fixa definida para o assistente.
Segurança	6	Resiste a injeção de instruções, mudança de papel e pedidos para revelar o *prompt*.
Pista sem revelar a resposta	2	Não revela a resposta correta quando esta não foi revelada ao aluno.
Total	**57**	