ISEP INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Francisco Reis

Dissertação para obtenção do Grau de Mestre em Engenharia Informática, Área de Especialização em Software Engineering

Orientador: Nuno Silva
Supervisor: Bruno Guimarães

Porto, 3 de novembro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 3 de novembro de 2026

Resumo

O Adhara QBank é uma plataforma de estudo na área da saúde, onde estudantes e profissionais resolvem exames compostos por perguntas de escolha múltipla nos modos Teste, Estudo e Simulado. Cada pergunta inclui informação validada pela equipa científica, como a vinheta clínica, as opções de resposta, a resposta correta, a explicação, dicas e informação complementar. Como a explicação apresentada durante o exame pode não esclarecer todas as dúvidas, esta dissertação, desenvolvida em colaboração com a Adhara, concebe, implementa e avalia um assistente conversacional multilingue integrado no QBank. O assistente responde a questões sobre a pergunta em curso recorrendo exclusivamente à informação associada a essa pergunta, respeitando as restrições de cada modo e recusando questões fora do contexto disponível.

A avaliação considera a correção e fidelidade das respostas à informação da pergunta, a capacidade de recusa, o desempenho, o custo e a utilidade e usabilidade percebidas pelos utilizadores. A abordagem segue a metodologia *Design Science Research*.

Palavras-chave: Modelos de Linguagem, Banco de Perguntas, Educação Médica, Geração Fundamentada em Contexto, Assistente Conversacional, Engenharia de Prompts

Abstract

Adhara QBank is a health-sciences study platform where students and healthcare professionals take exams composed of multiple-choice questions in Test, Study and Mock Exam modes. Each question includes information validated by the scientific team, such as a clinical vignette, answer options, the correct answer, an explanation, hints and supplementary information. Since the explanation shown during an exam may not resolve every doubt, this dissertation, developed in collaboration with Adhara, designs, implements and evaluates a multilingual conversational assistant integrated into QBank. The assistant answers questions about the current item using only the information associated with that question, respects the restrictions of each mode and refuses questions outside the available context.

The evaluation considers the correctness and faithfulness of answers to the question's information, refusal capability, performance, cost, and users' perceived usefulness and usability. The work follows the Design Science Research methodology.

Agradecimentos

Conteúdo

Lista de Figuras **xiii**

Lista de Tabelas **xv**

Lista de Acrónimos **xvii**

1 Introdução **1**
1.1 Contexto e Motivação . . . 1
1.2 A Organização e o Adhara QBank . . . 1
1.3 Definição do Problema . . . 2
1.4 Objetivos . . . 3
1.5 Questões de Investigação . . . 4
1.6 Abordagem Metodológica . . . 4
1.7 Gestão de Riscos . . . 5
1.8 Contribuições Esperadas . . . 5
1.9 Considerações Éticas e Profissionais . . . 6
1.10 Estrutura do Documento . . . 7

2 Estado da Arte **9**
2.1 Fundamentos Teóricos . . . 9
2.1.1 Aprendizagem com Perguntas e *Feedback* . . . 9
2.1.2 Assistentes Conversacionais . . . 10
2.1.3 Modelos de Linguagem de Grande Dimensão . . . 10
2.1.4 Formas de Fornecer Contexto ao Modelo . . . 10
2.1.5 Alucinação, Fidelidade e Recusa . . . 11
2.1.6 Controlo do Âmbito e Segurança . . . 11
2.1.7 Avaliação de Respostas . . . 12
2.2 Método da Revisão Sistemática . . . 12
2.2.1 Questões, Fontes e Expressões de Pesquisa . . . 12
2.2.2 Critérios e Seleção . . . 13
2.2.3 Resultados da Seleção . . . 14
2.3 Arquiteturas de Contextualização (RQ1) . . . 15
2.3.1 O *Pipeline* de Recuperação e as suas Variantes . . . 16
2.3.2 Conhecimento Estruturado: Grafos e Ontologias . . . 16
2.3.3 Orquestração: Agentes, Encaminhamento e Verificação . . . 17
2.3.4 Engenharia de *Prompts* . . . 18
2.3.5 Ajuste Fino como Alternativa ou Complemento . . . 18
2.3.6 Quando o Contexto Prejudica . . . 18
2.3.7 Contexto Fechado e Perguntas de Exame . . . 19
2.4 Mecanismos de Controlo do Âmbito e de Segurança (RQ1) . . . 20
2.5 Línguas, Latência e Custo (RQ1) . . . 22

2.6 Avaliação da Correção, da Fidelidade e do Âmbito (RQ2) 23
2.7 Sistemas Mais Próximos do Caso de Estudo 25
2.7.1 Limitações Recorrentes 25
2.8 Lacuna de Investigação 25
2.9 Ameaças à Validade 27
2.10 Conclusões do Capítulo 27

3 Desenho da Solução **29**
3.1 Requisitos 29
3.1.1 Requisitos Funcionais 29
3.1.2 Requisitos Não Funcionais 29
3.2 Contexto de Cada Pergunta 30
3.3 Arquitetura 30
3.4 Estratégias de *Prompting* e Restrições 30
3.5 Verificações Fora do Modelo 30
3.6 Escolha do Modelo 31

Bibliografia **33**

Apêndice A Protocolo e Registo da Revisão Sistemática **41**
A.1 Estruturação das Questões 41
A.2 Fontes e Pesquisa 41
A.3 Seleção dos Estudos 42
A.4 Avaliação da Qualidade e Extração de Dados 43

Apêndice B Estudos Prioritários da Revisão **45**

Lista de Figuras

2.1 Duas formas de fornecer contexto ao modelo: (a) recuperação a partir de um corpus; (b) leitura direta dos dados da pergunta em curso, a abordagem do QBank. 11
2.2 Diagrama PRISMA da seleção dos estudos 14

3.1 Arquitetura do assistente 30

Lista de Tabelas

1.1 Dimensionamento do Adhara QBank e restrições preliminares indicadas pela Adhara. 2
1.2 Riscos do projeto, classificação e medidas de mitigação. 5

2.1 Expressões de pesquisa e questões a que respondem. 13
2.2 Critérios de inclusão e exclusão. 13
2.3 Indicadores descritivos dos 211 estudos incluídos (a partir de títulos e resumos). 15
2.4 Mecanismos de controlo do âmbito e de segurança encontrados na revisão. 21
2.5 Métricas de avaliação encontradas na revisão, por dimensão. 23
2.6 Sistemas mais próximos do caso de estudo, comparados com o assistente do QBank. 26
2.7 Da evidência à oportunidade de investigação. 26

A.1 Critérios *Population, Intervention, Comparison, Outcomes, Context* (PICOC) da revisão e onde são aplicados. 41
A.2 Registo da pesquisa (2 de novembro de 2026; título, resumo e palavras-chave; 2021–2026). 42
A.3 Campos de extração de dados. 43

B.1 Classificação dos estudos prioritários. 45

Lista de Acrónimos

API	*Application Programming Interface*.
DSR	*Design Science Research*.
IA	Inteligência Artificial.
ICL	*In-Context Learning*.
LLM	*Large Language Model*.
MCQ	*Multiple-Choice Question*.
PICOC	*Population, Intervention, Comparison, Outcomes, Context*.
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*.
QA	*Question Answering*.
RAG	*Retrieval-Augmented Generation*.
RAGAS	*Retrieval Augmented Generation Assessment*.
RGPD	Regulamento Geral sobre a Proteção de Dados.
RQ	*Research Question*.
SUS	*System Usability Scale*.

Capítulo 1

Introdução

Este capítulo apresenta o contexto e a motivação do trabalho, a organização onde é desenvolvido, o problema abordado, os objetivos e as questões de investigação, a abordagem metodológica, a gestão de riscos, as contribuições esperadas, as considerações éticas e profissionais e a organização do documento.

1.1 Contexto e Motivação

Os bancos de perguntas de escolha múltipla (*Multiple-Choice Question*s (MCQs)) são um recurso habitual na preparação para exames na área da saúde. O Adhara QBank é uma plataforma de estudo da Adhara com cerca de 50 mil perguntas de escolha múltipla em seis línguas, usada por estudantes de medicina, médicos e enfermeiros (Secção 1.2).

Durante o estudo, o utilizador pode ficar com dúvidas que a explicação estática da pergunta não resolve, por exemplo, porque é que uma determinada opção está errada ou como se relaciona um achado da vinheta com a resposta correta. Atualmente, a plataforma não oferece forma de esclarecer essas dúvidas no momento, embora a base de dados contenha mais informação sobre a pergunta do que aquela que é apresentada no ecrã.

Os assistentes conversacionais baseados em *Large Language Model*s (LLMs) têm sido propostos como apoio ao estudo em educação e em educação médica (Abd-alrazaq et al. 2023; Kasneci et al. 2023), com benefícios reportados, por exemplo, num ensaio controlado com estudantes de medicina (Gan et al. 2024). Em contexto médico, porém, recorrer a um assistente genérico é arriscado: os LLMs podem gerar respostas plausíveis mas incorretas ou infiéis ao contexto que lhes é fornecido (Huang et al. 2025), e essas respostas podem não coincidir com o conteúdo validado pela equipa científica. Fundamentar a resposta em informação fornecida ao modelo, por exemplo através de *Retrieval-Augmented Generation* (RAG) (Lewis et al. 2020), pode reduzir este risco (Jang et al. 2025), mas não o elimina (Huang et al. 2025). Além disso, as instruções que limitam o assistente podem ser contornadas por manipulação do *prompt* (Geng et al. 2026; Greshake et al. 2023), o que, num exame, pode comprometer a integridade da avaliação. A literatura aponta ainda a necessidade de orientações para a utilização de Inteligência Artificial (IA) em educação médica (Gordon et al. 2024).

1.2 A Organização e o Adhara QBank

O trabalho é desenvolvido em colaboração com a Adhara (Adhara, Unipessoal, Lda.), uma empresa portuguesa especializada em educação médica digital e em formação pós-graduada

para profissionais de saúde. O Adhara QBank é a sua plataforma de preparação para exames com perguntas de escolha múltipla. Existe em português europeu, português do Brasil, inglês, espanhol, francês e italiano e reúne cerca de 50 mil perguntas no conjunto das línguas. A Adhara tem cerca de 3100 utilizadores, dos quais se espera que 10 a 20% adiram ao QBank.

O utilizador resolve exames de 40 perguntas em três modos: Teste, Estudo e Simulado. Cada pergunta tem informação validada pela equipa científica da Adhara: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação, catalogação e informação complementar. Cada versão linguística do QBank tem o seu próprio conteúdo validado.

No levantamento inicial com a Adhara foram identificados os dados de dimensionamento e as restrições preliminares resumidos na Tabela 1.1. Estas restrições orientam as decisões de desenho do Capítulo 3 e serão consolidadas durante o levantamento de requisitos.

Tabela 1.1: Dimensionamento do Adhara QBank e restrições preliminares indicadas pela Adhara.

Aspeto	**Valor ou estado**
Línguas	Português europeu, português do Brasil, inglês, espanhol, francês e italiano
Perguntas	Cerca de 50 mil, no conjunto das línguas
Utilizadores da Adhara	Cerca de 3100
Adesão esperada ao QBank	10 a 20% dos utilizadores da Adhara, ou seja, 310 a 620
Utilização do assistente	Desconhecida à partida; será medida através das estatísticas de utilização
Tempo de resposta aceitável	2 a 3 segundos
Orçamento para o LLM	Cerca de 100 € por mês
Envio do conteúdo das perguntas para uma *Application Programming Interface* (API) externa	Aceitável para a Adhara
Crescimento da base de dados (cache e registos)	A verificar; hipótese de exportação e limpeza semanal
Validação das respostas	A definir; hipótese de extrair os pares pergunta–resposta do assistente para validação pela equipa da Adhara ou por um agente de IA
Prioridade entre qualidade, custo e privacidade	Por definir
Disponibilidade exigida (*SLA*)	Por definir

1.3 Definição do Problema

Durante a resolução de uma pergunta no Adhara QBank, o utilizador pode precisar de esclarecer aspetos que não são cobertos pela explicação apresentada no ecrã. A base de dados contém informação adicional associada à pergunta, mas não existe uma forma integrada de a consultar através de perguntas em linguagem natural. Recorrer a fontes externas ou a assistentes genéricos pode produzir respostas que não correspondem ao conteúdo validado do item ou que introduzem informação alheia ao contexto.

O problema abordado nesta dissertação é, assim, conceber um assistente conversacional baseado em LLM que responda apenas com a informação já guardada na base de dados

para cada pergunta (vinheta, opções, catalogação, resposta correta, explicação, dicas e informação complementar), sem recorrer a conhecimento externo, e que se mantenha fiel a esse contexto. O assistente não deve responder a questões fora do âmbito da pergunta nem comprometer a integridade da avaliação.

O problema tem as seguintes características:

- **Âmbito por modo.** O QBank tem três modos, mas o assistente só está disponível nos modos Teste e Estudo; não aparece no modo Simulado. Em cada modo, a resposta tem de respeitar as regras do modo e o estado de revelação da resposta correta.
- **Multilinguismo.** O QBank existe em várias línguas e o assistente tem de responder na língua do QBank em que o utilizador está a estudar, com base no conteúdo validado nessa língua.
- **Contexto fechado por item.** O contexto relevante é conhecido à partida (os dados da pergunta em curso) e é fornecido diretamente ao modelo, sem uma etapa de pesquisa num corpus de documentos.
- **Restrições a harmonizar.** As capacidades conversacionais genéricas do modelo têm de ser harmonizadas com restrições de fidelidade ao contexto, qualidade da resposta, segurança, custo, latência e integração na arquitetura do QBank. As restrições preliminares estão na Tabela 1.1 e serão consolidadas com a Adhara. Com 310 a 620 utilizadores esperados no QBank, uma utilização do assistente ainda desconhecida, um tempo de resposta de 2 a 3 segundos e um orçamento de cerca de 100 € por mês, o custo e a latência de cada pedido ao modelo são restrições de desenho e não apenas métricas de avaliação.
- **Várias partes interessadas.** Utilizadores (estudantes, médicos e enfermeiros) e Adhara, incluindo a equipa científica responsável pelo conteúdo.
- **Consequências.** Uma resposta fora do conteúdo validado pode induzir erros de aprendizagem e afetar a credibilidade da plataforma, a privacidade dos utilizadores e os custos de operação (Abd-alrazaq et al. 2023; Huang et al. 2025).

1.4 Objetivos

O objetivo geral é conceber, implementar e avaliar um assistente conversacional integrado no Adhara QBank que esclareça dúvidas sobre cada pergunta de escolha múltipla, usando exclusivamente a informação da base de dados dessa pergunta.

Para o atingir, definem-se os seguintes objetivos específicos:

1. sistematizar o conhecimento existente sobre assistentes conversacionais baseados em LLMs com respostas limitadas a um contexto definido, e sobre a forma como essas respostas são avaliadas (Capítulo 2);
2. levantar, com a Adhara, os requisitos do assistente, incluindo as regras por modo e as restrições de fidelidade, segurança, custo e latência;
3. identificar os campos da base de dados relevantes para responder a dúvidas sobre cada pergunta e definir como são fornecidos ao modelo;
4. conceber e implementar mecanismos para limitar as respostas ao contexto da pergunta, responder na língua do QBank e recusar questões sem suporte nesse contexto;

5. integrar o assistente no fluxo de resolução de perguntas do QBank, nos modos Teste e Estudo;
6. avaliar a correção e a fidelidade das respostas, a capacidade de recusa, o comportamento em várias línguas, a latência e o custo, e a utilidade e usabilidade percebidas pelos utilizadores.

1.5 Questões de Investigação

O trabalho é orientado por duas questões de investigação (*Research Question*s (RQs)), respondidas através da revisão da literatura do Capítulo 2 e usadas para orientar o desenho e a avaliação do assistente:

RQ1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

A RQ1 abrange o mecanismo pelo qual o contexto chega ao modelo, os mecanismos de controlo do âmbito e de segurança e os compromissos de fiabilidade, latência, custo e integração. A RQ2 abrange os métodos, as métricas e os resultados da avaliação das respostas.

1.6 Abordagem Metodológica

O trabalho segue a metodologia *Design Science Research* (DSR), na qual o conhecimento é produzido através da conceção e avaliação de um artefacto que resolve um problema relevante (Hevner et al. 2004). São seguidas as seis atividades propostas por Peffers et al. (2007):

1. **Identificação do problema e motivação**: caracterização do problema com a Adhara (Secções 1.1 e 1.3).
2. **Definição dos objetivos da solução**: objetivos e critérios de sucesso (Secção 1.4), informados pela revisão da literatura (Capítulo 2).
3. **Desenho e desenvolvimento**: requisitos, arquitetura do assistente e integração no QBank (Capítulo 3), desenvolvidos de forma iterativa a partir de um *backlog* priorizado.
4. **Demonstração**: utilização do assistente em perguntas reais do QBank, nos modos Teste e Estudo.
5. **Avaliação**: avaliação técnica com perguntas respondíveis e não respondíveis a partir dos dados de cada item, em várias línguas, analisando correção, fidelidade, recusa, latência e custo; avaliação da correção por especialistas da Adhara; e avaliação da utilidade e usabilidade junto de utilizadores, através de questionário.
6. **Comunicação**: esta dissertação.

O estado da arte é construído através de uma revisão sistemática da literatura, conduzida segundo as orientações de Kitchenham e Charters (2007) e relatada segundo o *Preferred*

Reporting Items for Systematic Reviews and Meta-Analyses (PRISMA) 2020 (Page et al. 2021). O protocolo, a pesquisa, a seleção e a síntese estão descritos no Capítulo 2.

1.7 Gestão de Riscos

Os riscos do projeto foram identificados no início do trabalho e classificados quanto à probabilidade (P) e ao impacto (I), numa escala de 1 (muito baixo) a 5 (muito alto). O nível de cada risco é o produto $P \times I$: baixo até 5, médio de 6 a 11 e alto a partir de 12. A Tabela 1.2 apresenta os riscos e as respetivas medidas de mitigação. Os riscos são revistos no fim de cada iteração do desenvolvimento.

Tabela 1.2: Riscos do projeto, classificação e medidas de mitigação.

Id	Risco	P	I	P×I	Mitigação
R1	Respostas incorretas ou infiéis ao conteúdo validado da pergunta	3	5	15	Contexto fechado por pergunta; instruções de recusa; avaliação da fidelidade com perguntas de teste e por especialistas da Adhara
R2	Custo da API acima de 100 € por mês, sendo a utilização do assistente desconhecida à partida	3	4	12	Estimativa de custo por pedido; contexto compacto; cache de respostas; limites de utilização; monitorização do consumo
R3	Tempo de resposta acima de 2 a 3 segundos	3	4	12	Resposta em *streaming*; contexto compacto; cache; medição da latência desde o início do desenvolvimento
R4	Revelação da resposta correta ou desvio do âmbito por manipulação do *prompt*	3	4	12	Regras de cada modo aplicadas fora do modelo (por exemplo, não enviar dados ainda não revelados); testes adversariais
R5	Qualidade desigual entre as seis línguas	3	3	9	Conjunto de teste em todas as línguas; uso do conteúdo validado da língua do QBank
R6	Pouca disponibilidade dos especialistas da Adhara para a avaliação	3	3	9	Planear a avaliação cedo; usar uma amostra; LLM juiz como apoio, validado numa subamostra
R7	Alteração de preço, de modelo ou indisponibilidade do fornecedor da API	2	4	8	Camada de abstração do fornecedor; alternativa identificada; registo da versão do modelo usada
R8	Atraso no cronograma	3	3	9	*Backlog* priorizado; versão mínima funcional primeiro; acompanhamento com o orientador
R9	Crescimento da base de dados com a cache e os registos	2	2	4	Política de retenção; exportação e limpeza periódica

1.8 Contribuições Esperadas

Como resultados, este trabalho pretende contribuir com:

- uma revisão sistemática sobre assistentes conversacionais baseados em LLMs com respostas limitadas a um contexto definido, em educação e saúde, com uma síntese dos mecanismos de contextualização, de controlo de âmbito e de avaliação (Capítulo 2);
- um assistente conversacional integrado no fluxo de resolução de perguntas do Adhara QBank, que responde na língua do QBank, usando apenas a informação validada da pergunta em curso, e que respeita as regras de cada modo;
- uma abordagem para fornecer ao modelo o contexto fechado de cada pergunta e para recusar questões sem suporte nesse contexto;

- um protocolo e um conjunto de testes para avaliar a correção, a fidelidade ao contexto, a capacidade de recusa, o comportamento multilingue, a latência e o custo do assistente.

1.9 Considerações Éticas e Profissionais

Esta dissertação segue o *Software Engineering Code of Ethics and Professional Practice*, elaborado pela ACM e pela IEEE Computer Society (ACM/IEEE-CS Joint Task Force on Software Engineering Ethics and Professional Practices 1999), considerando os seus princípios relativos ao interesse público, à qualidade do produto, à integridade do julgamento profissional e à responsabilidade dos engenheiros de software. No desenvolvimento do assistente, estes princípios são aplicados através da limitação das respostas ao contexto autorizado, da avaliação da sua correção e fidelidade e da documentação das limitações conhecidas do sistema.

O trabalho observa também o Código Europeu de Conduta para a Integridade da Investigação (ALLEA 2023) e o Código de Ética e de Conduta do P.PORTO (Politécnico do Porto 2020), nomeadamente no que respeita à integridade científica, à referenciação das fontes e à proteção da confidencialidade. O conteúdo do QBank é propriedade da Adhara e é usado apenas no âmbito deste trabalho. Caso sejam recolhidos ou tratados dados pessoais durante a avaliação com utilizadores, o plano de recolha, utilização, conservação e eliminação desses dados será definido de acordo com o Regulamento Geral sobre a Proteção de Dados (RGPD) (Parlamento Europeu e Conselho da União Europeia 2016) e com as orientações do ISEP. Sendo um sistema de IA usado em contexto educativo, são também consideradas as obrigações de transparência do Regulamento da Inteligência Artificial da União Europeia (Parlamento Europeu e Conselho da União Europeia 2024), nomeadamente informar o utilizador de que está a interagir com um sistema de IA.

Utilização de um modelo através de uma API externa. A infraestrutura disponível não permite executar o modelo de linguagem localmente, pelo que o assistente usará um LLM acedido através de uma API externa paga. Isto implica que o pedido do utilizador e o contexto da pergunta são enviados a um serviço de terceiros. Para limitar os riscos:

- são enviados apenas os dados necessários para responder: a mensagem do utilizador, o histórico da conversa sobre a pergunta e os dados dessa pergunta; não são enviados dados identificativos do utilizador;
- o fornecedor será escolhido tendo em conta as suas condições de tratamento de dados, nomeadamente a retenção dos pedidos, a não utilização para treino e a localização do processamento, e a relação com o fornecedor será enquadrada no RGPD (Parlamento Europeu e Conselho da União Europeia 2016);
- a Adhara, enquanto detentora do conteúdo do QBank, considerou aceitável o envio dos dados das perguntas para o fornecedor; as condições serão formalizadas na escolha do fornecedor.

Registo das perguntas para fins estatísticos. As perguntas feitas ao assistente poderão ser registadas e agrupadas por tema, para fins estatísticos e de melhoria do conteúdo. Este registo terá uma finalidade definida, será feito sem associar as perguntas à identidade do utilizador, terá um prazo de conservação definido e será comunicado ao utilizador.

A utilização de ferramentas de IA neste trabalho é declarada de forma transparente:

- **Funcionalidade do protótipo**: o assistente usa um LLM, acedido por API, para gerar as respostas.
- **Revisão da literatura**: foi usado um assistente de IA para apoiar a escrita dos *scripts* de recolha, deduplicação e triagem, para propor decisões de triagem por título e resumo e para apoiar a extração de dados dos textos integrais. Todas as decisões ficaram registadas com o respetivo motivo e foram verificadas pelo autor (Secção 2.2.2). As referências foram verificadas nas fontes originais.
- **Desenvolvimento de software**: assistentes de IA podem ser usados para apoiar a escrita, revisão e depuração de código.
- **Revisão do documento**: ferramentas de IA podem ser usadas para revisão linguística, sem substituir o julgamento do autor sobre o conteúdo.

1.10 Estrutura do Documento

Para além deste capítulo, o documento está organizado da seguinte forma. O Capítulo 2 apresenta o estado da arte: os fundamentos teóricos e uma revisão sistemática da literatura, com o protocolo, os resultados da pesquisa e da seleção, a síntese crítica dos estudos e a lacuna de investigação. O Capítulo 3 descreve o desenho da solução: requisitos e arquitetura do assistente e a sua integração no QBank. Os capítulos seguintes apresentam a implementação, a avaliação e os resultados, e as conclusões e o trabalho futuro.

Capítulo 2

Estado da Arte

Este capítulo apresenta o estado da arte sobre assistentes conversacionais baseados em LLMs cujas respostas são limitadas a um contexto definido pela aplicação, com foco em educação e saúde. Começa por apresentar os fundamentos teóricos (Secção 2.1). Resume depois o método da revisão sistemática da literatura (Secção 2.2). As secções seguintes analisam os estudos por tema: as arquiteturas de contextualização (Secção 2.3), os mecanismos de controlo do âmbito e de segurança (Secção 2.4), as línguas, a latência e o custo (Secção 2.5), a avaliação (Secção 2.6) e os sistemas mais próximos do caso de estudo (Secção 2.7). Seguem-se a lacuna de investigação que resulta desta análise (Secção 2.8), as ameaças à validade (Secção 2.9) e as conclusões do capítulo (Secção 2.10).

2.1 Fundamentos Teóricos

Esta secção apresenta os fundamentos em que o trabalho assenta: o papel das perguntas de escolha múltipla e do *feedback* na aprendizagem, os assistentes conversacionais, o funcionamento e as limitações dos LLMs, as formas de lhes fornecer contexto, o controlo do âmbito e a avaliação das respostas. A literatura recente sobre sistemas concretos é analisada a partir da Secção 2.2, através da revisão sistemática.

2.1.1 Aprendizagem com Perguntas e Feedback

Responder a perguntas não serve apenas para avaliar: o esforço de recordar a informação melhora a retenção a longo prazo mais do que voltar a estudá-la, um fenómeno conhecido como efeito de teste (Roediger e Karpicke 2006). Este efeito foi também observado em educação médica, onde os testes frequentes são propostos como estratégia de aprendizagem e não só de avaliação (Larsen et al. 2008). Os bancos de perguntas como o QBank apoiam-se neste princípio.

O efeito da prática depende do *feedback* que se segue à resposta. Hattie e Timperley (2007) definem o *feedback* como a informação que ajuda o estudante a reduzir a distância entre o desempenho atual e o desejado, respondendo a três perguntas: para onde vou, como estou a ir e qual o passo seguinte. Shute (2008) conclui que o *feedback* elaborado, que explica porque é que uma resposta está certa ou errada, tende a ser mais eficaz do que a simples indicação de certo ou errado, e que deve ser específico e ajustado ao estudante. A explicação de cada pergunta do QBank é um *feedback* elaborado, mas é igual para todos os utilizadores e não responde à dúvida concreta de cada um.

Um assistente conversacional permite aproximar esse *feedback* de uma tutoria individual, na qual o estudante pergunta o que não percebeu. A tutoria individual é há muito associada

a ganhos de aprendizagem elevados face ao ensino em grupo (Bloom 1984), e esta é uma das motivações para o uso de LLMs em educação (Kasneci et al. 2023). O mesmo enquadramento justifica as regras por modo: no modo Teste, um assistente que revele a resposta antes de o estudante responder anula o esforço de recordar, de que depende o efeito de teste.

2.1.2 Assistentes Conversacionais

Os assistentes conversacionais evoluíram de sistemas baseados em regras e padrões, como a ELIZA (Weizenbaum 1966), para sistemas que selecionam respostas de uma base de conhecimento e, mais recentemente, para sistemas generativos baseados em LLMs (Adamopoulou e Moussiades 2020). Podem ser classificados, entre outros critérios, pelo domínio (aberto ou fechado), pelo objetivo (informativo, orientado a tarefas ou de conversa livre) e pelo método de produção da resposta (regras, recuperação ou geração) (Adamopoulou e Moussiades 2020). Nesta classificação, o assistente do QBank é de domínio fechado, informativo e generativo. A sua particularidade é que o domínio não é o da plataforma em geral mas o da pergunta em curso: o contexto muda a cada item.

2.1.3 Modelos de Linguagem de Grande Dimensão

Os LLMs atuais baseiam-se na arquitetura *Transformer*, em que mecanismos de atenção relacionam cada elemento do texto com os restantes (Vaswani et al. 2017). São treinados em grandes corpora para prever o elemento seguinte do texto e, a partir de certa escala, conseguem executar tarefas descritas no *prompt*, com ou sem exemplos, sem alterar os seus parâmetros: a aprendizagem em contexto (*In-Context Learning* (ICL)) (Brown et al. 2020). O ajuste por instruções com *feedback* humano torna os modelos mais capazes de seguir instruções e de produzir respostas úteis (Ouyang et al. 2022). É esta capacidade que permite definir o comportamento de um assistente através de instruções de sistema, mas as instruções orientam o modelo sem garantir que são cumpridas.

O texto é processado em *tokens*, unidades que correspondem aproximadamente a partes de palavras. Cada modelo aceita um número máximo de *tokens* por pedido (a janela de contexto). Nas APIs comerciais, o custo é calculado pelo número de *tokens* de entrada e de saída, e o tempo de resposta cresce com o comprimento da resposta, que é gerada *token* a *token*. A quantidade de dados da pergunta incluída no *prompt* afeta, assim, diretamente o custo e a latência. Além disso, ter a informação no contexto não garante que é usada: Liu et al. (2024a) mostram que o desempenho é melhor quando a informação relevante está no início ou no fim do contexto e piora quando está no meio, o que é relevante para a forma como os campos da pergunta são organizados no *prompt*.

O desempenho dos LLMs varia também com a língua. Numa avaliação de modelos generativos em dezenas de línguas, Ahuja et al. (2023) observaram melhores resultados em inglês e nas línguas com mais recursos do que nas línguas com menos recursos. As seis línguas do QBank são de recursos elevados, mas a diferença entre línguas, incluindo entre as variantes europeia e brasileira do português, tem de ser verificada na avaliação.

2.1.4 Formas de Fornecer Contexto ao Modelo

Na geração aumentada por recuperação (RAG), o sistema pesquisa num corpus os excertos mais relevantes para a pergunta do utilizador e inclui-os no *prompt* antes da geração (Lewis

et al. 2020). Em alternativa, quando o contexto relevante é conhecido à partida, pode ser incluído diretamente no *prompt*, sem pesquisa. Esta forma de condicionar o modelo pelo contexto do *prompt*, sem alterar os seus parâmetros, enquadra-se na aprendizagem em contexto (ICL). No QBank, o contexto é o registo da pergunta em curso, identificado pelo seu ID, pelo que não existe uma etapa de recuperação. Ambas as abordagens dependem de o modelo usar o contexto fornecido e não o seu conhecimento interno. A Figura 2.1 compara as duas: a diferença está no passo destacado, em que a pesquisa por semelhança, sujeita a erros de recuperação, é substituída pela leitura direta do registo do item. Uma terceira alternativa, o ajuste fino (*fine-tuning*), altera os parâmetros do modelo com dados do domínio. Não é adequada ao caso, porque o conhecimento teria de ser atualizado sempre que o conteúdo muda e não garante que a resposta se limita a um item.

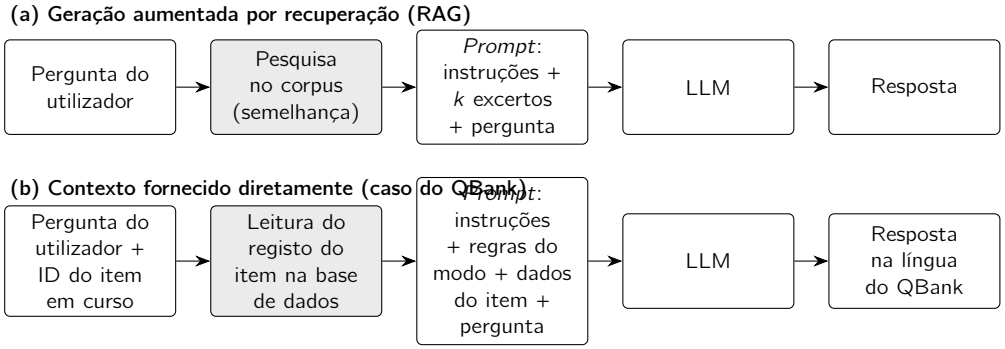


Figura 2.1: Duas formas de fornecer contexto ao modelo: (a) recuperação a partir de um corpus; (b) leitura direta dos dados da pergunta em curso, a abordagem do QBank.

2.1.5 Alucinação, Fidelidade e Recusa

Um LLM gera texto plausível a partir do conhecimento adquirido no treino e do texto que recebe no *prompt*. Designa-se por alucinação a geração de conteúdo incorreto ou não suportado. Huang et al. (2025) distinguem a alucinação de factualidade (conteúdo que contradiz factos do mundo) da alucinação de fidelidade (conteúdo que se afasta do contexto ou das instruções fornecidas). No caso do QBank, a propriedade mais relevante é a fidelidade: o assistente deve responder com base nos dados validados da pergunta, mesmo que o modelo tenha conhecimento próprio diferente.

Uma forma de reduzir respostas sem suporte é o modelo abster-se quando o contexto não contém a informação necessária. Kadavath et al. (2022) mostram que os modelos conseguem, em parte, estimar se sabem a resposta, mas essa estimativa não é perfeita. Num assistente de contexto fechado, a recusa não pode depender só desta capacidade: tem de ser pedida explicitamente nas instruções e avaliada com perguntas cuja resposta não está no contexto.

2.1.6 Controlo do Âmbito e Segurança

Um assistente de âmbito restrito deve recusar pedidos fora desse âmbito (abstenção ou recusa). As instruções que definem esse âmbito podem ser contornadas por injeção de instruções (*prompt injection*), quer diretamente pelo utilizador quer através de conteúdo externo incluído no *prompt* (Geng et al. 2026; Greshake et al. 2023). Os mecanismos de

defesa incluem filtros de entrada e de saída, modelos classificadores dedicados (*guardrails*) e arquiteturas com mais do que um modelo.

Perez e Ribeiro (2022) distinguem dois objetivos destes ataques: desviar o modelo da tarefa definida (*goal hijacking*) e levá-lo a revelar as suas instruções ou o contexto (*prompt leaking*). A *OWASP Top 10 for LLM Applications* coloca a injeção de instruções em primeiro lugar entre os riscos de aplicações com LLMs e inclui a fuga das instruções de sistema (OWASP Foundation 2024). No QBank, uma fuga com consequências seria revelar a resposta correta no modo Teste. Daqui resulta um princípio de desenho: a informação que não pode ser revelada não deve estar no *prompt*, porque nenhuma instrução garante que o modelo não a revela.

2.1.7 Avaliação de Respostas

A avaliação de sistemas de resposta com contexto combina métricas de referência (exatidão, F1, semelhança semântica), métricas específicas de fidelidade ao contexto, como as do *Retrieval Augmented Generation Assessment* (RAGAS) (Es et al. 2024), avaliação por um LLM juiz (*LLM-as-a-judge*) (Zheng et al. 2023), avaliação por especialistas e estudos com utilizadores.

Estas abordagens têm custos e limitações diferentes. As métricas de referência exigem respostas de referência e penalizam formulações corretas mas diferentes. As métricas de fidelidade, como a do RAGAS, decompõem a resposta em afirmações e verificam se cada uma é suportada pelo contexto, sem precisar de uma resposta de referência (Es et al. 2024). Um LLM juiz permite avaliar muitas respostas a baixo custo, mas tem enviesamentos conhecidos, como a preferência pela posição ou por respostas mais longas (Zheng et al. 2023), pelo que deve ser validado com avaliação humana numa amostra. A avaliação por especialistas é a referência para a correção em contexto médico, mas é cara. A utilidade percebida e a usabilidade avaliam-se junto dos utilizadores, por exemplo com a escala *System Usability Scale* (SUS) (Brooke 1996).

2.2 Método da Revisão Sistemática

Para identificar o estado da arte de forma sistemática e repetível, foi conduzida uma revisão sistemática da literatura segundo as orientações de Kitchenham e Charters (2007), relatada segundo o PRISMA 2020 (Page et al. 2021). Esta secção resume o método; o protocolo completo, incluindo a estruturação *Population, Intervention, Comparison, Outcomes, Context* (PICOC), a pesquisa piloto, o registo da pesquisa por fonte e os campos de extração, está no Apêndice A.

2.2.1 Questões, Fontes e Expressões de Pesquisa

A revisão responde às duas questões de investigação definidas no Capítulo 1:

RQ1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

Tabela 2.1: Expressões de pesquisa e questões a que respondem.

Id	RQ	Expressão
Q1	RQ1	`("large language model"OR LLM) AND (grounding OR "context injection"OR "prompt context"OR "retrieval-augmented generation") AND (chatbot OR "conversational system"OR "question answering")`
Q2	RQ2	`("large language model"OR LLM) AND (faithfulness OR factuality OR correctness) AND (chatbot OR "conversational system") AND (evaluation OR benchmark)`
Q3	RQ1	`("large language model"OR LLM) AND ("prompt injection"OR "prompt leakage"OR jailbreak OR guardrails) AND (chatbot OR "conversational system")`
Q4	RQ2	`("large language model"OR LLM) AND ("out-of-scope"OR abstention) AND (evaluation OR benchmark)`

Tabela 2.2: Critérios de inclusão e exclusão.

	Inclusão		Exclusão
I1	Publicado entre 27-10-2021 e 27-10-2026	E1	Duplicado
I2	Em inglês ou português	E2	Sem resumo, editorial, opinião, tutorial, descrição de *workshop* ou sem informação metodológica suficiente
I3	Estudo primário sobre sistema conversacional ou de resposta a perguntas baseado em LLM, aplicado a educação ou saúde, cujas respostas dependem de um contexto definido (RAG, contexto no *prompt* ou base de conhecimento)	E3	Não usa LLM; não é sistema conversacional ou de *Question Answering* (QA); fora de educação e saúde; método genérico sem aplicação; ou sem contexto definido
I4	Descreve a avaliação das respostas ou dos mecanismos de controlo (correção, fidelidade, recusa ou segurança)	E4	Revisão ou *survey* (excluída da síntese; pode apoiar o enquadramento)

Foram pesquisadas três fontes: IEEE Xplore, ACM Digital Library e Scopus. Cada questão é coberta por duas expressões de pesquisa (Tabela 2.1): a RQ1 pela Q1 (contexto) e pela Q3 (segurança do âmbito); a RQ2 pela Q2 (fidelidade e correção) e pela Q4 (recusa fora do âmbito). As expressões foram aplicadas ao título, ao resumo e às palavras-chave, para publicações de 2021 a 2026, e executadas a 2 de novembro de 2026. Foram exportados todos os resultados.

2.2.2 Critérios e Seleção

A Tabela 2.2 apresenta os critérios de seleção. O critério I3 delimita o foco a educação e saúde, os domínios do QBank, e exige que a resposta dependa de um contexto definido, seja ele recuperado ou fornecido diretamente. Excecionalmente, foram incluídos três estudos de outros domínios que avaliam diretamente o efeito do contexto incluído no *prompt*, por ser essa a técnica do caso de estudo.

A seleção foi feita em quatro passos registados e reprodutíveis (Apêndice A): deduplicação por DOI e título; triagem por regras explícitas sobre o título e o resumo (fase A); leitura do título e do resumo dos restantes registos, com uma decisão e um motivo por registo (fase B), com apoio de um assistente de IA e verificação pelo autor; e marcação como prioritários dos estudos mais próximos do caso de estudo, por terem contexto fechado, avaliação explícita

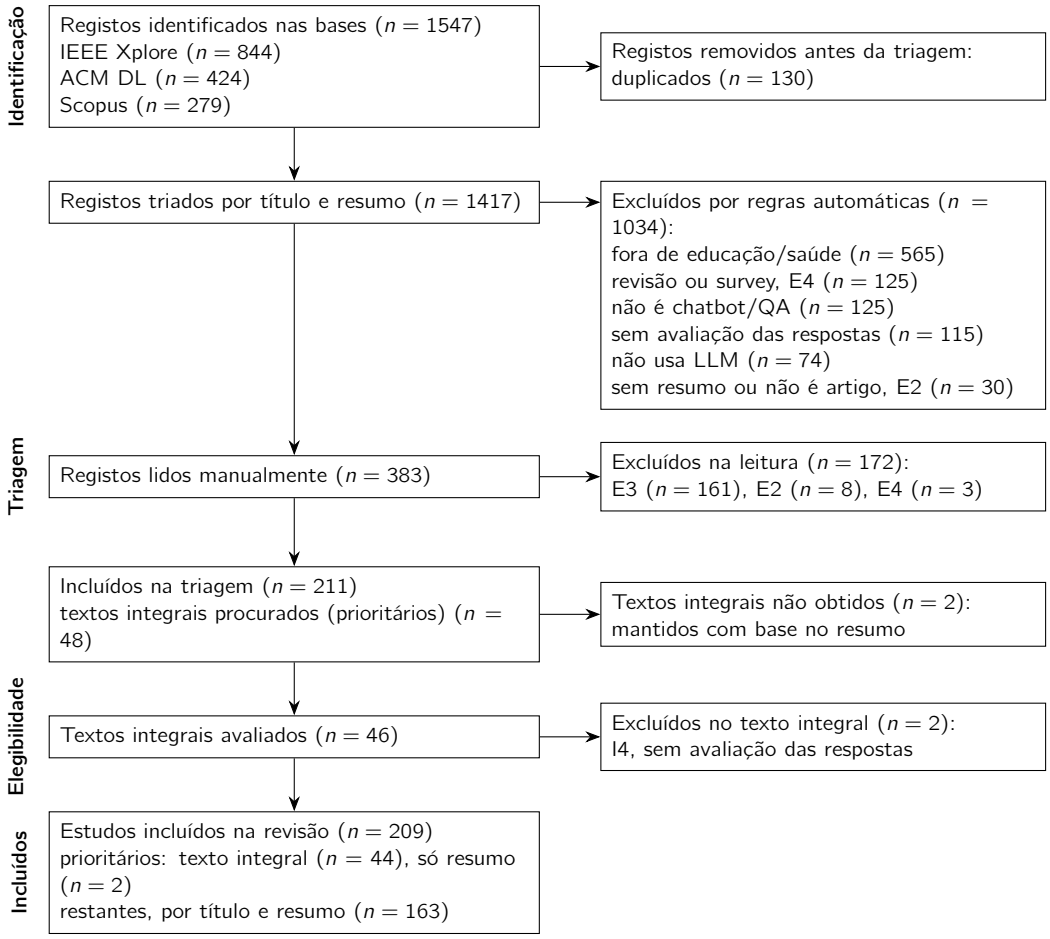


Figura 2.2: Diagrama PRISMA 2020 da seleção dos estudos. A elegibilidade por texto integral foi avaliada para os estudos prioritários.

da correção, fidelidade ou recusa, mecanismos de controlo do âmbito ou suporte a várias línguas.

2.2.3 Resultados da Seleção

O fluxo de seleção está na Figura 2.2. Foram removidos 130 duplicados (126 entre pesquisas da mesma fonte e 4 entre fontes), ficando 1417 registos únicos. As regras da fase A excluíram 1034 registos, sobretudo por estarem fora de educação e saúde (565), por serem revisões (125), por não serem sistemas conversacionais ou de QA (125) ou por não descreverem a avaliação das respostas (115). Na fase B foram lidos 383 registos, dos quais 172 foram excluídos (161 por E3, 8 por E2 e 3 por E4), principalmente por serem métodos de RAG genéricos ou por pertencerem a outros domínios. Foram incluídos 211 estudos, dos quais 48 foram marcados como prioritários. O texto integral dos prioritários foi procurado e obtido para 46; os outros 2 foram mantidos com base no resumo. Na leitura integral foram excluídos 2 estudos por não avaliarem as respostas (I4), pelo que a revisão inclui 209 estudos: 44 prioritários lidos integralmente, 2 prioritários só com resumo e 163 analisados pelo título e resumo.

Dos 211 estudos incluídos, 198 vieram da Q1, 11 da Q2, 12 da Q3 e 4 da Q4 (um estudo pode vir de mais do que uma pesquisa). Por fonte, 153 vieram do IEEE Xplore, 57 da

Tabela 2.3: Indicadores descritivos dos 211 estudos incluídos (a partir de títulos e resumos).

Aspeto referido no título ou resumo	**N.º**	**%**
Origem do contexto (RQ1)		
RAG	170	81
Grafo de conhecimento ou ontologia	32	15
Fine-tuning	35	17
Contexto no *prompt*, ICL ou engenharia de *prompts*	22	10
Controlo do âmbito e aspetos operacionais (RQ1)		
Citações ou rastreabilidade das fontes	21	10
Segurança (injeção, *jailbreak*, *guardrails*)	16	8
Recusa, abstenção ou perguntas fora do âmbito	7	3
Várias línguas ou língua diferente do inglês	27	13
Latência ou tempo de resposta	23	11
Custo	15	7
Avaliação (RQ2)		
Exatidão (*accuracy*)	109	52
Métricas automáticas (fidelidade, RAGAS, ROUGE, BLEU, F1 e semelhantes)	51	24
Benchmark de escolha múltipla ou de exame	36	17
Especialistas, clínicos ou docentes (como avaliadores ou utilizadores)	45	21
Estudo com utilizadores, questionário ou entrevistas	22	10
LLM como juiz	5	2

ACM Digital Library e apenas 1 do Scopus, cujos resultados incluíram muitos registos fora do âmbito, como números completos de revistas e livros de resumos. A literatura é muito recente: 101 estudos são de 2026, 79 de 2025 e 31 de 2024. Por tema, 64 estudos tratam assistentes de saúde para doentes ou profissionais, 54 assistentes de apoio à aprendizagem, 51 QA médico avaliado em *benchmarks*, 27 assistentes institucionais de universidades, 8 segurança e *guardrails*, 4 controlo do âmbito e recusa, e 3 o efeito do contexto incluído no *prompt*.

A Tabela 2.3 resume indicadores descritivos dos 211 estudos, obtidos por pesquisa de termos nos títulos e resumos. São indicadores de frequência e não de eficácia, e tendem a subestimar o que os textos integrais descrevem, porque nem todos os resumos referem todos os aspetos do estudo. A classificação dos 48 estudos prioritários está no Apêndice B.

As secções seguintes analisam os estudos por tema. Em vez de os resumir um a um, descrevem as técnicas que usam, como funcionam e que resultados reportam, e discutem a sua relevância para o QBank. Os detalhes e os valores que se seguem vêm da leitura integral dos 44 estudos prioritários incluídos; os restantes estudos contribuem sobretudo para os indicadores de frequência da Tabela 2.3, obtidos a partir dos títulos e resumos. A frequência de uma técnica descreve a sua utilização, mas não prova que seja a mais eficaz.

2.3 Arquiteturas de Contextualização (RQ1)

O RAG é a forma dominante de limitar as respostas a um contexto, referida em 81% dos estudos incluídos. Em educação, o contexto é tipicamente o material de um curso: manuais, diapositivos, enunciados e registos das aulas (Barzanji et al. 2026; Feng et al. 2024; Han e Emara 2026; Sayeed et al. 2026; Seshadri et al. 2026; Yan e Shi 2026). Em saúde, são

diretrizes clínicas, literatura médica ou bases de perguntas e respostas (Azam et al. 2024; Christiawan et al. 2025; Nurfadhilah et al. 2025; Raputri et al. 2025). Por detrás desta designação comum há, no entanto, arquiteturas muito diferentes, descritas nesta secção.

2.3.1 O Pipeline de Recuperação e as suas Variantes

Um sistema RAG tem duas fases. Na fase de indexação, os documentos são divididos em excertos (*chunks*) e cada excerto é convertido num vetor por um modelo de *embeddings*, sendo os vetores guardados numa base de dados vetorial. A dimensão destes corpora varia muito: 2328 excertos de 17 manuais num tutor universitário (Sayeed et al. 2026) e 125 847 excertos de 18 manuais médicos num estudo de QA médico (Xie et al. 2026). Na fase de consulta, a pergunta do utilizador é convertida no mesmo espaço vetorial, os excertos mais semelhantes (normalmente pela semelhança do cosseno) são recuperados e incluídos no *prompt*, e o modelo gera a resposta (Lewis et al. 2020; Shah et al. 2026).

Os estudos analisados acrescentam vários componentes a este esquema básico, a que Sbai et al. (2025) chamam RAG ingénuo:

- **Modelos de embeddings adaptados.** Usam-se modelos treinados em texto médico, como o PubMedBERT (Shah et al. 2026), modelos multilingues (Nurfadhilah et al. 2025; Sbai et al. 2025) ou modelos ajustados ao domínio: o recuperador do ATU-Tutor foi ajustado com 929 pares pergunta–excerto (Sayeed et al. 2026), e o modelo de *embeddings* do Mufakkir ficou em primeiro lugar num *ranking* de recuperação em árabe (Tawfik et al. 2025).
- **Pesquisa híbrida.** Combina a pesquisa densa, por semelhança semântica, com a pesquisa esparsa, por coincidência de termos (BM25), e funde as duas listas de resultados (*rank fusion*) (Christiawan et al. 2025; Sayeed et al. 2026; Sbai et al. 2025; Tawfik et al. 2025; Yan e Shi 2026). A pesquisa esparsa compensa a dificuldade da pesquisa densa com termos técnicos e siglas, frequentes em medicina.
- **Reordenação.** Um segundo modelo (*cross-encoder*) avalia em conjunto a pergunta e cada excerto recuperado e reordena-os, mantendo apenas os mais relevantes (Christiawan et al. 2025; Sayeed et al. 2026; Sbai et al. 2025).
- **Transformação da pergunta.** A pergunta é expandida com termos relacionados (Sbai et al. 2025) ou reformulada numa pergunta mais geral antes da pesquisa (*step-back prompting*) (Christiawan et al. 2025).
- **Pontuação de confiança.** Uma estimativa de confiança da resposta é usada para reduzir alucinações (Sbai et al. 2025).

Nos estudos de ablação, cada componente contribui para o resultado: no Sanity-LLM, a pesquisa híbrida, a reformulação da pergunta e a reordenação melhoram, cada uma, as métricas face ao RAG ingénuo, atingindo 0,94 de precisão do contexto e 0,88 de fidelidade (Christiawan et al. 2025). A complexidade do *pipeline* cresce, contudo, com cada componente, e cada etapa é um ponto onde o contexto certo pode ser perdido antes de chegar ao modelo.

2.3.2 Conhecimento Estruturado: Grafos e Ontologias

Cerca de 15% dos estudos usam grafos de conhecimento ou ontologias, em três papéis diferentes. No primeiro, o grafo é a forma de representar o contexto: o MediTriR converte

o conhecimento recuperado em triplos (sujeito, relação, objeto) e gera novos triplos a partir deles para apoiar o raciocínio em perguntas médicas de escolha múltipla (Zhang e Shafiq 2025). Ghanbari e Dividino (2025a) compararam representações por triplos e por caminhos no grafo e concluíram que os caminhos dão melhores resultados mas são mais sensíveis ao ruído; aumentar o subgrafo extraído aumenta a cobertura, mas também a quantidade de informação irrelevante, e uma seleção imprecisa leva o desempenho abaixo do modelo sem contexto (Ghanbari e Dividino 2025a,b).

No segundo papel, o grafo organiza a recuperação. Jain et al. (2025) compararam o RAG vetorial com o GraphRAG, que constrói um grafo de entidades a partir do corpus: o RAG vetorial foi a opção de baixo custo para perguntas factuais, o GraphRAG global foi melhor em perguntas temáticas e o GraphRAG local teve a maior exatidão com manuais alterados para contradizer o conhecimento do modelo. O GraphRAG usou, porém, 10 a 20 vezes mais recursos, o que levou os autores a propor um encaminhamento de cada pergunta para o método mais adequado.

No terceiro papel, a ontologia valida a resposta depois de gerada: no CyberBOT, uma ontologia do domínio funciona como camada de raciocínio que restringe e verifica as respostas do modelo, e o sistema foi usado numa unidade curricular de pós-graduação (Zhao et al. 2025). O SAGE usa um grafo do estado do estudante e dos conteúdos do curso para decidir a que conteúdo o modelo pode aceder (Rayhan et al. 2026), um papel de controlo discutido na Secção 2.4.

2.3.3 Orquestração: Agentes, Encaminhamento e Verificação

Um conjunto crescente de estudos divide a resposta em várias etapas, cada uma com um modelo ou uma ferramenta própria. Liu et al. (2026a) usam um agente administrador que encaminha cada pergunta médica para cinco agentes especializados (fisiologia, patologia, clínica, terapêutica e farmacologia, e saúde pública) e combina as respostas por consenso ponderado, através do *Model Context Protocol* (MCP). O sistema multiagente melhorou a exatidão em cerca de 5 pontos percentuais face a um único agente, mas o maior ganho veio da curadoria da base de conhecimento: usar apenas as 500 perguntas de maior qualidade elevou a exatidão para cerca de 80%. Ishadya et al. (2026) compararam pipelines RAG e MCP com a mesma lógica de *prompt*, e o MCP igualou ou superou o RAG em F1, fundamentação nas fontes e abstenção.

Outros estudos acrescentam uma etapa de verificação. No sistema de Bellard et al. (2025), um LLM juiz avalia cada resposta em cinco dimensões (exatidão, segurança, robustez, empatia e clareza) e pede a sua revisão; as respostas que falham a segunda verificação de segurança (4,3%) são substituídas por uma mensagem predefinida. Em sistemas institucionais, o encaminhamento serve para governação: o sistema de Elnozahy et al. (2026) processa e revê o pedido, encaminha-o para a fonte autorizada e devolve uma resposta estruturada e rastreável, e o tutor de Wei et al. (2026) combina recuperação local, verificação de políticas e encaminhamento para a nuvem apenas quando necessário, com um registo explícito de cada execução. No extremo oposto, o assistente de Trang et al. (2025) passa para um modo de conversa geral quando a pergunta não está na base de dados, uma flexibilidade que no QBank seria indesejável.

2.3.4 Engenharia de Prompts

Mesmo com o contexto certo, a forma como o *prompt* é construído influencia a resposta. Os estudos usam: a definição de um papel para o modelo (*role prompting*), o raciocínio passo a passo (*chain-of-thought*) e a verificação das próprias afirmações antes da resposta final (*chain-of-verification*), que em conjunto reduziram as afirmações sem suporte segundo a revisão por especialistas (Ishadya et al. 2026); a adaptação do nível da resposta ao público, por exemplo ao nível de uma licenciatura (Yan e Shi 2026) ou à idade do utilizador (Trang et al. 2025); perguntas de seguimento de estilo socrático, que levam o estudante a raciocinar em vez de receber a resposta (Sayeed et al. 2026); pedidos de clarificação quando a pergunta é ambígua (Trang et al. 2025); e a citação das fontes usadas em cada resposta, que os estudantes valorizaram pela transparência (Seshadri et al. 2026). O *prompt* também pode tornar o modelo mais robusto ao contexto: no estudo de Rahat et al. (2026), exemplos que mostram como rejeitar evidência contraditória e cumprir o formato pedido fizeram a exatidão passar de 20,8% para 59,6% com cinco documentos. Yan e Shi (2026) descrevem a iteração de um *prompt* de sistema a partir das falhas observadas: na versão inicial, o modelo inventou a definição e a derivação de um termo técnico inexistente em vez de o questionar; a versão final obriga a pedir confirmação quando o termo é errado ou invulgar, a perguntar quando a dúvida é ambígua e a citar a base de conhecimento, e usa uma temperatura de 0,1 para reduzir a variabilidade das respostas.

2.3.5 Ajuste Fino como Alternativa ou Complemento

O ajuste fino aparece em 17% dos estudos, geralmente com técnicas eficientes como o LoRA e o QLoRA, que ajustam apenas uma pequena parte dos parâmetros. Pode substituir o contexto: em perguntas sobre relatórios radiológicos, o modelo ajustado superou claramente o *prompting* com exemplos e eliminou as alucinações da taxonomia de erros usada (Hamidi e Roberts 2026). Pode também complementá-lo: o sistema de Shah et al. (2026) combina um modelo ajustado com QLoRA, RAG e *guardrails*. Abrar et al. (2025) separaram o ajuste em duas fases, uma para conhecimento factual e outra para comportamento, com exemplos de recusa de pedidos fora do âmbito. No apoio técnico a utilizadores de computação de alto desempenho, o contexto no *prompt* combinado com RAG sobre o modelo base teve a maior correção, e o modelo ajustado com RAG a menor: o ajuste fino ensinou o modelo a imitar o estilo dos pedidos anteriores, mas piorou a sua capacidade de usar a informação recuperada (Zheng et al. 2026). Por outro lado, BENGMAH et al. (2025) compararam engenharia de *prompts*, ajuste fino e RAG num assistente para a diabetes e escolheram o RAG por ser o único viável com os recursos de *hardware* disponíveis. Para o QBank, com cerca de 50 mil perguntas em seis línguas e conteúdo que muda com as revisões da equipa científica, o ajuste fino teria de ser repetido a cada alteração e não garantiria que a resposta se limita à pergunta em curso; além disso, nem sempre está disponível quando o modelo é usado através de uma API.

2.3.6 Quando o Contexto Prejudica

Os estudos que comparam o mesmo modelo com e sem contexto relatam, em geral, melhorias da correção e da fidelidade (Azam et al. 2024; Nurfadhilah et al. 2025; Raputri et al. 2025). Contudo, um grupo de estudos de QA médico mostra que a recuperação pode piorar os resultados. Xie et al. (2026) observaram que três variantes de RAG ficaram abaixo do modelo sem contexto no MedQA-USMLE: a recuperação corrigiu 5–6% das perguntas mas induziu em erro 6–7%, e a confiança do recuperador não previa quando o contexto ajudava.

Rahat et al. (2026) compararam, no PubMedQA, três condições: sem contexto, o modelo acertou 27,0%; com o contexto correto anotado por humanos, 68,8%; com documentos recuperados, entre 42,6% (um documento) e 17,6% (oito documentos), ou seja, abaixo de não ter contexto. Com contexto ruidoso, o modelo deixou também de cumprir o formato pedido (59,6% de respostas sem formato válido com oito documentos, contra 2,4% com o contexto correto). As falhas deveram-se a contexto que distrai sem conter a resposta (41,8%), a contexto contraditório (37,6%), a contexto irrelevante (13,9%) e a erros de formato (6,7%); um *prompt* com exemplos de como rejeitar evidência contraditória fez a exatidão voltar a 59,6%. Na análise manual de Xie et al. (2026), as causas foram o desajuste do contexto clínico (35%), a extração de frases sem compreensão (40%) e a fragmentação do conhecimento em excertos parciais que, combinados, se tornam incoerentes (25%). Liu et al. (2026a) concluíram que a qualidade da base de conhecimento pesa mais do que a quantidade. Na mesma linha, os estudos que incluem conhecimento de grafos diretamente no *prompt* mostram que contexto pouco relevante pode baixar o desempenho abaixo do modelo sem contexto (Ghanbari e Dividino 2025a,b).

Estes resultados mostram que o contexto não é neutro: um contexto errado ou ruidoso pode ser pior do que nenhum. Em todos estes estudos, a origem do problema está na seleção do contexto, isto é, na recuperação. Quando o contexto é conhecido à partida e validado, como no QBank, este tipo de erro deixa de existir, embora permaneça o risco de o modelo não seguir o contexto fornecido.

2.3.7 Contexto Fechado e Perguntas de Exame

São poucos os estudos em que o contexto é fixo e conhecido à partida, como no QBank. Os mais próximos fundamentam as respostas na aula em curso (Liu et al. 2026b) ou numa apresentação gravada (Xu et al. 2026), ou respondem a perguntas sobre um único relatório radiológico (Hamidi e Roberts 2026). No estudo de Xu et al. (2026), o assistente fundamentado nos materiais da apresentação melhorou a experiência de aprendizagem, enquanto um assistente genérico não superou o vídeo sem assistente, o que sugere que o valor está no contexto e não apenas na presença de um assistente. Zheng et al. (2026) compararam *fine-tuning*, RAG e contexto no *prompt* num serviço de apoio técnico, e a combinação de contexto no *prompt* com RAG obteve a maior correção. Não foi identificado, ao nível dos resumos, nenhum estudo em que o contexto seja o registo completo de uma pergunta de escolha múltipla validada (vinheta, opções, explicação e informação complementar) usado para esclarecer dúvidas do estudante.

Os estudos com perguntas de exame tratam, sobretudo, a escolha da resposta correta em *benchmarks* como o MedQA e o MedMCQA (Liu et al. 2026a; Xie et al. 2026; Zhang e Shafiq 2025), e não a explicação de uma pergunta cuja resposta já é conhecida. A exceção mais próxima é o assistente de Khan et al. (2025), cujo fluxo é quase o do QBank: o estudante escolhe uma pergunta de um exame de acesso à pós-graduação em engenharia, o sistema mostra a solução dessa pergunta e as dúvidas seguintes são respondidas pelo modelo usando o par pergunta–solução como referência. A fidelidade obtida foi de 0,94, mas com cerca de 9 s para gerar cada explicação num modelo local, e o avaliador automático era o próprio modelo avaliado, o que pode favorecê-lo.

Contexto completo e identificação exata. O AskNow fornece ao modelo a transcrição completa da aula até ao momento, guardada em segmentos de 30 s com marcas temporais, sem pesquisa por semelhança; os docentes classificaram 100 respostas aleatórias com uma

correção média entre 4,53 e 4,88 em 5, em três cursos com 117 estudantes (Liu et al. 2026b). Dois estudos mostram por que razão identificar o contexto exato é preferível a pesquisá-lo: no tutor de Wei et al. (2026), a recuperação do documento certo teve precisão de 1,00 quando a pergunta incluía o identificador do curso e caiu para 0,006 sem ele; no assistente de Han e Emara (2026), as perguntas de exame, cheias de identificadores (ano, época, número da pergunta), foram melhor resolvidas por pesquisa lexical do que semântica. No QBank, o identificador da pergunta em curso é sempre conhecido, pelo que a seleção do contexto pode ser exata.

2.4 Mecanismos de Controlo do Âmbito e de Segurança (RQ1)

Os mecanismos de controlo encontrados podem ser organizados pelo momento em que atuam: antes da geração, sobre o pedido do utilizador ou sobre o conteúdo a que o modelo tem acesso; durante a geração, sobre o próprio modelo; e depois da geração, sobre a resposta. A Tabela 2.4 resume-os.

Instruções no prompt não chegam. O resultado mais relevante para o QBank é o de Rayhan et al. (2026): num tutor de programação, os tutores baseados apenas em instruções no *prompt* tiveram uma utilidade semelhante à do sistema proposto (42% e 44%), mas cumpriram as políticas do docente em apenas 30% dos casos, contra 90% com um controlo de acesso ao conteúdo em três camadas: por papel do utilizador, por atributos e pelo estado cognitivo do estudante. A lição é estrutural: o que o modelo não recebe não pode ser revelado. Da mesma forma, o CS50.ai usa *guardrails* pedagógicos para que o assistente apoie o estudante sem lhe dar diretamente as soluções, com o objetivo declarado de se aproximar de um tutor por estudante (Liu et al. 2024b), e o CourseAssist classifica a intenção do estudante e decompõe as perguntas para garantir respostas pedagogicamente adequadas (Feng et al. 2024). Estes mecanismos correspondem às regras por modo do QBank, por exemplo não revelar a resposta correta antes do tempo no modo Teste.

Filtros antes do modelo. A defesa mais avaliada em uso real é a arquitetura com dois modelos. No ChatTEDU, durante dois meses, foram analisadas 4501 interações reais, das quais 180 eram tentativas de ataque por injeção de instruções, *jailbreak* ou manipulação de conteúdo; todas foram bloqueadas, com 0,28% de falsos positivos (Emekci e Budakoglu 2025). O preço foi mensurável: o tempo médio de resposta passou de 6,7 s para 7,9 s, dos quais 0,9 s na verificação pelo primeiro modelo, e para 9,1 s com mais de 100 utilizadores em simultâneo; as chamadas à API duplicaram, o que, descontadas as respostas em *cache* e as rejeições antecipadas, aumentou o custo em cerca de 80%. Dos ataques, 77,8% eram de exploração técnica e 15% eram multilingues, o que indica que um filtro tem de funcionar em todas as línguas do sistema. O SecureContext EDU usa a mesma ideia com categorias de ameaça e uma pontuação de confiança, mas coloca antes do classificador um filtro por regras, sem modelo, que deixa passar diretamente saudações e perguntas claramente do domínio, bloqueia ataques evidentes e só envia ao classificador os casos duvidosos, para reduzir a latência (Kavitha et al. 2026). Em alternativa a um segundo LLM, outros estudos usam classificadores mais pequenos, ajustados para detetar ataques (Mathew et al. 2026; Tien e Huong 2024), que são mais rápidos e baratos mas exigem dados de treino. Walczak e Sawicki (2026) compararam dois modelos de guarda num assistente administrativo universitário, com uma categoria própria de restrição de tema: o Llama Guard 3 classificou cada pedido em 207 ms e detetou 85,5% das ameaças reais, mas bloqueou 42,6% dos pedidos legítimos,

Tabela 2.4: Mecanismos de controlo do âmbito e de segurança encontrados na revisão.

Mecanismo	**Momento**	**Funcionamento**	**Resultados reportados**
Instruções no *prompt*	Geração	A política é descrita nas instruções de sistema	Cumprimento das políticas em 30% dos casos (Rayhan et al. 2026)
Controlo de acesso ao conteúdo	Antes	Regras por papel, atributos e estado do estudante decidem que conteúdo o modelo pode usar	Cumprimento em 90% dos casos (Rayhan et al. 2026)
Classificação da intenção	Antes	O pedido é classificado para escolher uma resposta pedagogicamente adequada	Superior ao GPT-4 em adequação pedagógica (Feng et al. 2024)
Classificador de ataques	Antes	Modelo *Transformer* ajustado deteta injeção e *jailbreak*	F1 de 0,964 (Mathew et al. 2026); 90% de deteção (Kavitha et al. 2026); (Tien e Huong 2024)
Modelo de guarda	Antes ou depois	LLM classificador com categorias de risco, incluindo restrição de tema	Llama Guard 3: 42,6% de falsos positivos, 207 ms; GPT OSS Safeguard: 16,3%, 10,6 s (Walczak e Sawicki 2026)
Dois modelos	Antes	Um LLM filtra o pedido; só os pedidos aprovados chegam ao LLM que responde	100% dos ataques bloqueados, 0,28% de falsos positivos, +1,2 s (+18%) e ≈1,8× o custo (Emekci e Budakoglu 2025)
Regras programáveis	Antes e depois	Biblioteca de *guardrails* (NeMo) com regras de entrada e saída	(Shah et al. 2026)
Ajuste fino para recusa	Treino	Exemplos de pedidos fora do âmbito com a recusa esperada	Precisão de recusa de 0,86, contra 0,82 do GPT-4 (Abrar et al. 2025)
Monitorização interna	Geração	Os estados internos do modelo indicam respostas fora do domínio	Taxas de rejeição elevadas fora do domínio (Li et al. 2026)
Verificação da resposta	Depois	Ontologia ou LLM juiz valida a resposta antes de a mostrar	Mensagem predefinida em 4,3% dos casos; 15,7 s por pergunta (Bellard et al. 2025); (Zhao et al. 2025)

sobretudo saudações curtas tomadas como fora do tema; o GPT OSS Safeguard teve menos falsos positivos (16,3%), mas demorou 10,6 s por pedido, por gerar um raciocínio antes da decisão. Ambos falharam ataques que se fazem passar por uma autoridade ou têm um enquadramento académico, e os resultados em dados sintéticos sobrestimaram os obtidos com pedidos reais. Notaram ainda que as classificações dos especialistas e a perceção dos utilizadores divergem, o que mostra que a fronteira do âmbito é, em parte, subjetiva.

Recusa fora do âmbito. Poucos estudos avaliam a recusa (3% dos incluídos). Além dos modelos de guarda, as abordagens encontradas são o ajuste fino com exemplos de recusa (Abrar et al. 2025) e a monitorização dos estados internos do modelo para detetar respostas fora do domínio (Li et al. 2026). A recusa tem um custo próprio: o assistente de Abrar et al. (2025) recusou corretamente 86% dos pedidos fora do âmbito, mas recusou também muitos pedidos legítimos, com diferenças entre línguas. Quando a verificação de uma resposta falha, o HeartWise substitui-a por uma mensagem fixa e previamente validada, que remete o utilizador para a equipa de saúde (Bellard et al. 2025). Ambas exigem acesso ao modelo: não são possíveis quando o modelo é usado como serviço através de uma API, como no QBank, onde a recusa tem de ser obtida com instruções, com filtros externos ao modelo ou com a verificação da resposta.

Injeção direta e indireta. No QBank, o contexto vem da base de dados validada e não de documentos externos, o que reduz o risco de injeção indireta (Greshake et al. 2023), mas não o de injeção direta pelo utilizador. As defesas por filtros acrescentam latência (18% no ChatTEDU) e falsos positivos, um compromisso a ponderar face ao limite de 2 a 3 segundos.

2.5 Línguas, Latência e Custo (RQ1)

Várias línguas. 13% dos estudos tratam línguas diferentes do inglês ou várias línguas, com três estratégias. A primeira é um *pipeline* multilingue: o sistema de Sbai et al. (2025) responde em árabe, francês e inglês com *embeddings* multilingues e tratamento de texto da direita para a esquerda, e as perguntas em árabe atingiram uma exatidão ao nível das perguntas em francês. A segunda é traduzir para uma língua pivô: o ELENA traduz os documentos e as perguntas em italiano para inglês e a resposta de volta para italiano (Ruga et al. 2025), o que simplifica a recuperação mas acrescenta etapas onde o sentido pode mudar. A terceira é usar modelos adaptados à língua: um modelo adaptado ao indonésio teve maior fidelidade (cerca de 0,95) do que um modelo geral no mesmo *pipeline* (Nurfadhilah et al. 2025), e o ajuste fino melhorou o desempenho em dialetos árabes pouco representados (Abrar et al. 2025). No QBank, cada língua tem o seu próprio conteúdo validado, pelo que não é necessária tradução: o desafio é o modelo responder na língua do QBank, com base no conteúdo dessa língua, e manter a mesma qualidade e a mesma capacidade de recusa nas seis línguas. Estes estudos avaliam o desempenho por língua, mas raramente a consistência com o mesmo conteúdo validado em várias línguas.

Latência e custo. Apenas 11% dos estudos referem a latência e 7% o custo. Quando reportados, mostram que cada etapa adicional tem um preço: o ciclo com LLM juiz de Bellard et al. (2025) demorou em média 15,7 s por pergunta, a cerca de 0,003 USD; a camada de segurança do ChatTEDU acrescentou 1,2 s a uma resposta de 6,7 s (Emekci e Budakoglu 2025); a explicação de soluções de exame com um modelo local demorou cerca de 9 s (Khan et al. 2025); o modelo de guarda mais preciso foi demasiado lento para uso

síncrono (Walczak e Sawicki 2026); e o GraphRAG exigiu 10 a 20 vezes mais recursos do que o RAG vetorial (Jain et al. 2025). Vários estudos executam modelos localmente por razões de privacidade e custo, por exemplo um modelo de 14 mil milhões de parâmetros numa placa gráfica de 16 GB (Trang et al. 2025) ou modelos quantizados em *hardware* modesto (Nurfadhilah et al. 2025; Ruga et al. 2025). Estes valores não são diretamente transponíveis, mas dão uma ordem de grandeza: a um custo de 0,003 USD por pergunta, um orçamento de 100 € por mês corresponderia a cerca de 30 mil perguntas; e um ciclo de verificação de 15 s está muito acima do limite de 2 a 3 s do QBank. Raramente, porém, os estudos relacionam a escolha do mecanismo de contexto com a latência e o custo.

2.6 Avaliação da Correção, da Fidelidade e do Âmbito (RQ2)

Os estudos avaliam as respostas em várias dimensões, com métricas diferentes em cada uma. A Tabela 2.5 organiza as métricas encontradas e os valores reportados nos estudos prioritários.

Tabela 2.5: Métricas de avaliação encontradas na revisão, por dimensão.

Dimensão	**Métrica**	**O que mede**	**Exemplos**
Fidelidade	Fidelidade (RAGAS)	Proporção das afirmações da resposta suportadas pelo contexto	0,88 (Christiawan et al. 2025); ≈0,95 (Nurfadhilah et al. 2025); 0,93 (Sbai et al. 2025)
Contexto	Precisão e cobertura do contexto	Se o contexto recuperado é relevante e se contém a informação necessária	0,94 e 0,71 (Christiawan et al. 2025)
Relevância	Relevância da resposta	Se a resposta trata a pergunta feita	>0,95 (Buti e Mohamed 2026)
Correção	Exatidão; *exact match*; F1; correção da resposta	Coincidência com a resposta de referência	60,7% no MedQA (Xie et al. 2026); 61% EM e 77% F1 (Hamidi e Roberts 2026)
Semelhança textual	BLEU, ROUGE-L, METEOR, BERTScore	Sobreposição ou semelhança com uma resposta de referência	METEOR 0,41 (Nurfadhilah et al. 2025); (Shah et al. 2026)
Recusa	Precisão da recusa; taxa de abstenção; abstenções indevidas	Se recusa o que deve e só o que deve	0,86 (Abrar et al. 2025); (Hamidi e Roberts 2026; Ishadya et al. 2026)
Segurança	Ataques bloqueados; falsos positivos; F1 do classificador	Robustez a injeção e *jailbreak*	100% e 0,28% (Emekci e Budakoglu 2025); F1 0,964 (Mathew et al. 2026)
Políticas	Cumprimento das políticas	Respostas que respeitam as regras definidas pelo docente	90% contra 30% (Rayhan et al. 2026)
Operação	Latência; custo por pergunta	Tempo e custo de cada resposta	15,7 s e 0,003 USD (Bellard et al. 2025)
Utilizadores	SUS; utilidade percebida; entrevistas	Usabilidade e valor percebido	SUS de 77,8 (Barzanji et al. 2026); (Liu et al. 2026b)

Métricas heterogéneas. A métrica mais referida é a exatidão (52%), sobretudo em *benchmarks* de escolha múltipla. A fidelidade ao contexto é medida, em 24% dos estudos, com métricas automáticas do tipo RAGAS (Es et al. 2024): por exemplo, 0,875 de fidelidade num assistente de saúde mental (Christiawan et al. 2025) e cerca de 0,95 num assistente de educação de doentes (Nurfadhilah et al. 2025). Estas métricas dependem, por sua vez, de um LLM avaliador, pelo que herdam as suas limitações (Zheng et al. 2023). Como as métricas, os dados e os modelos diferem entre estudos, os valores não são diretamente comparáveis. Estas métricas não precisam de uma resposta de referência, o que as torna práticas, mas medem a coerência com o contexto e não a correção: uma resposta fiel a um contexto errado tem fidelidade máxima. No QBank, como o contexto é validado, a fidelidade aproxima-se da correção, o que torna esta métrica particularmente adequada.

LLM como juiz, especialistas e utilizadores. Buti e Mohamed (2026) avaliaram um assistente de aconselhamento académico com um LLM juiz num *benchmark* de 55 perguntas revistas por especialistas, e encontraram poucas alucinações (3 em 53), concluindo que o contexto recuperado restringe o modelo sem eliminar o risco de invenção. Liao et al. (2026) combinaram um LLM juiz com auditoria por estudantes de medicina, e Oh et al. (2026) propuseram uma avaliação automática de agentes clínicos em diálogo multi-turno, validada por especialistas. Em educação, os docentes avaliam a correção das respostas (Liu et al. 2026b; Miroyan et al. 2025), e os estudos com utilizadores medem a utilidade percebida e a usabilidade (Barzanji et al. 2026; Han e Emara 2026; Seshadri et al. 2026; Xu et al. 2026). Poucos estudos combinam as três formas de avaliação.

Fidelidade ao contexto versus conhecimento do modelo. Um aspeto pouco avaliado, mas central para o QBank, é se o modelo segue o contexto quando este contradiz o seu conhecimento. Jain et al. (2025) fizeram-no com manuais alterados de propósito para contradizer o conhecimento do modelo, e verificaram diferenças entre abordagens de RAG. As taxonomias de erros de Hamidi e Roberts (2026) e Rahat et al. (2026), que separam alucinação, abstenção indevida e desvio provocado pelo contexto, são uma alternativa mais informativa do que uma única métrica agregada.

Avaliação da recusa. A recusa é avaliada em poucos estudos e de formas diferentes: precisão da recusa (Abrar et al. 2025), taxa de abstenção (Ishadya et al. 2026), falsos positivos e falsos negativos de abstenção (Hamidi e Roberts 2026), cumprimento das políticas do docente (Rayhan et al. 2026) e taxa de rejeição fora do domínio (Li et al. 2026). Ishadya et al. (2026) mostram que menos abstenção e mais respostas suportadas podem coexistir, o que indica que a recusa deve ser avaliada em conjunto com a correção.

Dimensão das avaliações. Muitas avaliações usam conjuntos pequenos: 14 perguntas (Sayeed et al. 2026), 25 pares sintéticos (Bellard et al. 2025), 50 pares (Feng et al. 2024) ou 55 perguntas (Buti e Mohamed 2026). As avaliações em uso real, com centenas ou milhares de utilizadores, medem sobretudo a utilidade percebida e não a fidelidade de cada resposta (Emekci e Budakoglu 2025; Seshadri et al. 2026).

Protocolos aplicáveis ao QBank. A leitura integral mostra várias técnicas de avaliação que podem ser reutilizadas. Buti e Mohamed (2026) construíram um conjunto de 55 perguntas com respostas de referência validadas, dividido em perguntas comuns, perguntas que exigem interpretar regras e casos-limite (fora do âmbito, ambíguas e pedidos para revelar as

instruções de sistema), avaliado por um LLM juiz com temperatura 0, uma rubrica detalhada e saída estruturada; a fidelidade foi de 0,764 e as falhas foram, sobretudo, de recuperação (6), alucinação (3, ou 5,7%) e falta de pedido de clarificação. Hamidi e Roberts (2026) incluíram perguntas sem resposta no documento, em que a abstenção correta conta como acerto. Ishadya et al. (2026) usaram uma frase de recusa fixa, que torna a taxa de recusa mensurável automaticamente, e calcularam as restantes métricas apenas sobre as respostas não recusadas. Jain et al. (2025) usaram manuais com factos alterados de propósito para verificar se o modelo segue o texto ou o seu conhecimento. Para usar um LLM juiz, Liao et al. (2026) calibraram-no contra uma amostra verificada por humanos, corrigindo a exatidão estimada pelas taxas de verdadeiros e falsos positivos do juiz; no sentido contrário, no estudo de Khan et al. (2025), o avaliador era o mesmo modelo que gerava as respostas e atribuiu-lhe 0,94 de fidelidade contra 0,56 ao GPT-3.5, o que ilustra o risco de autopreferência. Por fim, como as respostas variam entre execuções, alguns estudos repetem cada pergunta, por exemplo dez vezes (Nurfadhilah et al. 2025) ou duas vezes (Feng et al. 2024).

2.7 Sistemas Mais Próximos do Caso de Estudo

A Tabela 2.6 compara os sistemas da revisão mais próximos do assistente pretendido com o caso do QBank. Cada um partilha uma ou duas características com o caso de estudo, mas nenhum as reúne todas: contexto fechado e validado por item, regras por modo, várias línguas com conteúdo próprio e avaliação conjunta da correção, da fidelidade e da recusa.

2.7.1 Limitações Recorrentes

Os estudos analisados partilham as seguintes limitações:

- avaliações em conjuntos pequenos, frequentemente sintéticos, e sem validação externa;
- fidelidade medida por LLMs avaliadores, sem verificação humana sistemática;
- recusa e perguntas fora do âmbito raramente avaliadas, e avaliadas separadamente da correção;
- avaliação multilingue centrada no desempenho por língua e não na consistência com o mesmo conteúdo validado;
- latência e custo raramente reportados e não relacionados com as escolhas de arquitetura;
- poucos estudos com contexto fechado e fornecido diretamente, apesar de a evidência mostrar que a recuperação introduz erros próprios.

2.8 Lacuna de Investigação

A Tabela 2.7 apresenta a cadeia que liga a evidência à oportunidade de investigação.

Em síntese, a literatura mostra como fundamentar as respostas de um assistente num contexto, sobretudo através de RAG, e como medir a sua fidelidade. Contudo, no corpus analisado não foi encontrado um assistente de estudo que responda apenas com o contexto fechado e validado de cada pergunta de um banco de perguntas, que respeite regras por modo de exame e que seja avaliado, em várias línguas, quanto à correção, à fidelidade e à

Tabela 2.6: Sistemas mais próximos do caso de estudo, comparados com o assistente do QBank.

Sistema	Domínio	Contexto	Controlo	Avaliação
AskNow (Liu et al. 2026b)	Aulas de informática	Transcrição completa da aula, sem pesquisa	Instruções no *prompt*	Correção 4,5–4,9/5 por docentes; 117 estudantes
Xu et al. (2026)	Apresentações gravadas	Materiais da apresentação	—	Experiência de aprendizagem face a assistente genérico
RadQA (Hamidi e Roberts 2026)	Radiologia	Um relatório	Ajuste fino	EM, F1 e taxonomia de erros, incluindo abstenção
GATE (Khan et al. 2025)	Exame de acesso	Solução da pergunta escolhida	—	Fidelidade 0,94 e relevância (juiz = modelo avaliado); ≈9 s
CS50.ai (Liu et al. 2024b)	Programação	Materiais do curso	*Guardrails* pedagógicos	Experiência em uso real
CourseAssist (Feng et al. 2024)	Informática	Materiais do curso (RAG)	Classificação da intenção	50 pares; utilidade, exatidão e adequação pedagógica
SAGE (Rayhan et al. 2026)	Programação	Grafo do curso	Controlo de acesso	Utilidade e cumprimento das políticas
Abrar et al. (2025)	Serviços ao estudante	Dados institucionais	Ajuste fino para recusa	Exatidão e precisão da recusa em 4 variedades linguísticas
ChatTEDU (Emekci e Budakoglu 2025)	Universidade	Informação institucional	Dois modelos	4501 interações reais; ataques e falsos positivos
QBank (este trabalho)	Perguntas de exame em saúde	Registo validado da pergunta em curso, lido pelo ID	Regras por modo e recusa	Correção, fidelidade e recusa, em 6 línguas; especialistas e utilizadores

Tabela 2.7: Da evidência à oportunidade de investigação.

Evidência	Limitação	Lacuna	Oportunidade
O RAG domina (81%); a recuperação pode introduzir contexto que desvia ou contradiz o modelo.	Poucos estudos usam contexto fechado, validado e fornecido diretamente, como o de uma pergunta de exame.	Pouca evidência sobre a fidelidade de assistentes que respondem apenas com o contexto validado de cada item.	Assistente que usa só os dados da pergunta em curso, avaliado em fidelidade e correção.
Instruções no *prompt* não garantem o cumprimento das políticas (30% contra 90%).	A recusa é avaliada em 3% dos estudos, com métricas diferentes.	Pouca evidência sobre recusa e regras por modo em assistentes de estudo para exames.	Mecanismos de recusa e regras por modo (Teste e Estudo) avaliados com perguntas fora do âmbito.
Estudos multilingues avaliam o desempenho por língua.	Consistência com o mesmo conteúdo validado em várias línguas raramente avaliada.	Pouca evidência sobre fidelidade e recusa em várias línguas em simultâneo.	Avaliação da fidelidade e da recusa nas línguas do QBank.
Avaliações pequenas, com LLM juiz ou só com utilizadores.	Poucos estudos combinam métricas, especialistas e utilizadores.	Falta de protocolos de avaliação completos.	Protocolo que combina testes técnicos, especialistas da Adhara e utilizadores.

recusa em simultâneo. A leitura integral dos estudos prioritários confirmou esta lacuna: os sistemas mais próximos (Tabela 2.6) partilham uma ou duas características com o caso de estudo, mas nenhum as reúne todas. É a esta oportunidade que o presente trabalho procura responder.

2.9 Ameaças à Validade

- **Fontes e campos.** A pesquisa limitou-se a três fontes, ao inglês e ao português e ao título, resumo e palavras-chave. Na IEEE Xplore e na ACM Digital Library, a restrição a estes campos foi feita expandindo cada termo, o que pode não ser exatamente equivalente ao `TITLE-ABS-KEY`. No Scopus, a pesquisa devolveu registos que não são artigos, o que sugere uma restrição de campos menos estrita.
- **Triagem por regras.** A fase A excluiu registos por ausência de termos no título e no resumo. Estudos relevantes que não usem esses termos podem ter sido excluídos (falsos negativos). As regras estão documentadas e podem ser repetidas.
- **Revisor único e apoio de IA.** A triagem foi feita por um único revisor, com apoio de um assistente de IA. Para mitigar o enviesamento, cada decisão tem um critério e um motivo registados e foi verificada pelo autor.
- **Texto integral apenas dos prioritários.** A síntese baseia-se no texto integral dos 44 estudos prioritários incluídos; os indicadores da Tabela 2.3 e os restantes 163 estudos baseiam-se nos títulos e resumos, e dois estudos prioritários foram mantidos só com o resumo por o texto integral não estar disponível. A avaliação da qualidade (QA1–QA5) está por concluir.
- **Janela temporal.** O filtro das interfaces é anual (2021–2026); o cumprimento exato das datas de 27-10-2021 a 27-10-2026 será confirmado na leitura integral.
- **Evolução rápida.** A literatura sobre LLMs evolui depressa: quase metade dos estudos incluídos é de 2026.

2.10 Conclusões do Capítulo

A revisão identificou 1547 registos em três fontes e incluiu 211 estudos para leitura integral, dos quais 48 são prioritários. Quanto à RQ1, a forma dominante de limitar as respostas é o RAG, mas a evidência mostra que a recuperação também introduz erros, e que as instruções no *prompt*, sozinhas, não garantem o cumprimento do âmbito; os mecanismos mais robustos combinam controlo explícito do conteúdo, filtros dedicados e recusa. Os compromissos de latência e custo são pouco reportados. Quanto à RQ2, a avaliação é heterogénea: exatidão em *benchmarks*, métricas automáticas de fidelidade dependentes de LLMs avaliadores, avaliação por especialistas e estudos com utilizadores, raramente combinados, e com pouca avaliação da recusa e do comportamento em várias línguas.

Para o assistente do QBank, estas conclusões traduzem-se em decisões de desenho e de avaliação: fornecer ao modelo apenas o contexto validado da pergunta em curso; não depender apenas de instruções no *prompt* para o âmbito e para as regras por modo; tratar a segurança contra injeção direta; e avaliar a correção, a fidelidade e a recusa em conjunto, nas várias línguas do QBank, combinando testes técnicos, especialistas da Adhara e utilizadores. O Capítulo 3 parte destas conclusões para o desenho da solução.

Capítulo 3

Desenho da Solução

3.1 Requisitos

Os requisitos resultam do levantamento feito com a Adhara.

3.1.1 Requisitos Funcionais

- **RF1.** O assistente responde a dúvidas sobre a pergunta em causa (enunciado, opções, explicações, dicas e informação-chave).
- **RF2.** O assistente usa exclusivamente a informação guardada na base de dados para essa pergunta, sem acesso à Internet nem a conhecimento externo.
- **RF3.** Se a informação necessária não estiver no contexto, o assistente di-lo claramente.
- **RF4.** Perguntas fora do âmbito da pergunta são recusadas com uma frase fixa.
- **RF5.** O assistente está disponível nos modos Teste e Estudo e não no modo Simulado.
- **RF6.** Quando a resposta correta não foi revelada ao aluno, o assistente não a revela.
- **RF7.** O assistente deve responder a perguntas escritas em várias línguas.

3.1.2 Requisitos Não Funcionais

- **RNF1. Latência:** tempo de resposta aceitável entre 2 e 3 segundos.
- **RNF2. Custo:** custo mensal de modelos limitado a um orçamento definido com a Adhara.
- **RNF3. Escalabilidade:** 10 a 20% dos utilizadores em simultâneo (cerca de 250 a 500 em 2500 utilizadores).
- **RNF4. Privacidade:** o envio dos dados das perguntas para uma API externa foi indicado como aceitável pela Adhara; o tratamento de dados dos utilizadores deve cumprir o RGPD.
- **RNF5. Validação:** respostas do assistente validadas pela equipa científica antes de serem consideradas fiáveis (processo a definir).

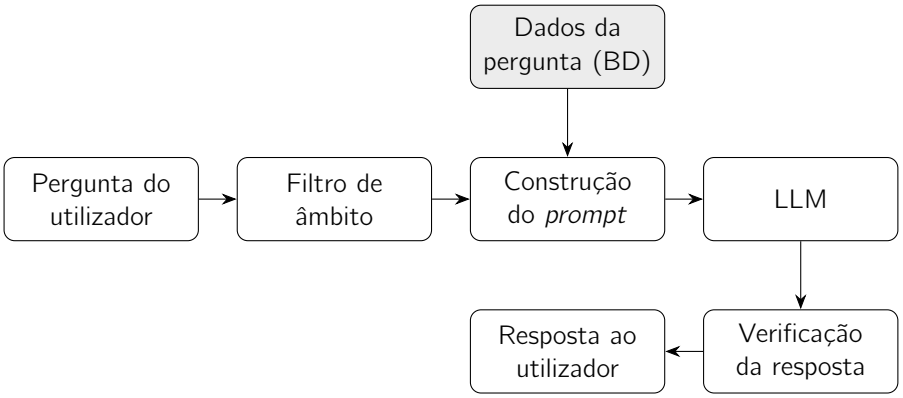


Figura 3.1: Arquitetura proposta do assistente conversacional.

3.2 Contexto de Cada Pergunta

Cada pergunta do QBank está guardada com campos estruturados: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação (geral e de cada opção), catalogação e informação complementar. Para cada pedido, o contexto fornecido ao LLM é construído a partir destes campos, em função do modo do QBank e de a resposta já ter sido revelada ou não.

3.3 Arquitetura

A Figura 3.1 apresenta a arquitetura proposta. Antes de chegar ao LLM, a pergunta do utilizador passa por um filtro de âmbito; depois da geração, a resposta é verificada antes de ser mostrada.

3.4 Estratégias de Prompting e Restrições

O *prompt* do assistente define o seu papel, as regras de contexto, de âmbito, de segurança e de estilo, e o formato de saída. As regras principais são:

- usar apenas a informação do contexto e dizer quando esta não existe;
- recusar assuntos fora da pergunta com uma frase fixa;
- ignorar instruções do utilizador que tentem alterar as regras ou revelar o *prompt*;
- não escrever as letras das opções, referindo-se às opções pelo seu texto, porque a ordem das opções muda entre sessões.

3.5 Verificações Fora do Modelo

Como as restrições só no *prompt* podem não ser cumpridas por todos os modelos, a arquitetura inclui verificações determinísticas:

- **antes do modelo:** filtro de âmbito para recusar perguntas claramente fora do tema;
- **depois do modelo:** deteção de fuga de instruções, de letras de opções e de valores que não existem no contexto.

3.6 Escolha do Modelo

A escolha entre um modelo executado localmente e um serviço externo depende da latência, do custo, da privacidade e da qualidade (fidelidade e cumprimento das regras). Os modelos são comparados no Capítulo **??**.

Bibliografia

Abd-alrazaq, Alaa, Rawan AlSaad, Dari Alhuwail et al. (2023). «Large Language Models in Medical Education: Opportunities, Challenges, and Future Directions». Em: *JMIR Medical Education* 9, e48291. doi: 10.2196/48291.

Abrar, M. et al. (2025). «Domain-Specific Fine-Tuning of LLMs for Multilingual Student Advisory in Higher Education». Em: *2025 2nd International Conference on Advanced Computing and Emerging Technologies (ACET)*. Estudo R0809 da revisão. doi: 10.1109/ACET67282.2025.11430234.

ACM/IEEE-CS Joint Task Force on Software Engineering Ethics and Professional Practices (1999). *Software Engineering Code of Ethics and Professional Practice (Version 5.2)*. url: https://www.acm.org/code-of-ethics/software-engineering-code.

Adamopoulou, Eleni e Lefteris Moussiades (2020). «Chatbots: History, Technology, and Applications». Em: *Machine Learning with Applications* 2, p. 100006. doi: 10.1016/j.mlwa.2020.100006.

Ahuja, Kabir et al. (2023). «MEGA: Multilingual Evaluation of Generative AI». Em: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 4232–4267. doi: 10.18653/v1/2023.emnlp-main.258.

ALLEA (2023). *The European Code of Conduct for Research Integrity – Revised Edition 2023*. Berlin: ALLEA – All European Academies. doi: 10.26356/ECOC.

Azam, A., Z. Naz e M. U. G. Khan (2024). «CancerBot: A Retrieval-Augmented Generation based Cancer Chatbot Using Large Language Models». Em: *2024 18th International Conference on Open Source Systems and Technologies (ICOSST)*. Estudo R0162 da revisão. doi: 10.1109/ICOSST64562.2024.10871155.

Barzanji, Chrakhan et al. (2026). «ST-Buddy: Designing and Evaluating a Course-Grounded LLM Chatbot for Academic and Administrative Support». Em: *Proceedings of the Extended Abstracts of the 2026 CHI Conference on Human Factors in Computing Systems*. Estudo R1019 da revisão. doi: 10.1145/3772363.3798558.

Bellard, B. et al. (2025). «Development and Evaluation of an Agentic RAG with Embedded LLM-as-a Judge for Heart Failure Management: A Pilot Study». Em: *2025 IEEE International Conference on Big Data (BigData)*. Estudo R0561 da revisão. doi: 10.1109/BigData66926.2025.11402164.

BENGMAH, A. et al. (2025). «AI-Driven Diabetes Management: A Retrieval-Augmented Conversational Approach*». Em: *2025 12th International Conference on Wireless Networks and Mobile Communications (WINCOM)*. Estudo R0514 da revisão. doi: 10.1109/WINCOM65874.2025.11313355.

Bloom, Benjamin S. (1984). «The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring». Em: *Educational Researcher* 13.6, pp. 4–16. doi: 10.3102/0013189X013006004.

Brooke, John (1996). «SUS: A "Quick and Dirty" Usability Scale». Em: *Usability Evaluation in Industry*. Ed. por Patrick W. Jordan et al. London: Taylor & Francis, pp. 189–194.

Brown, Tom B. et al. (2020). «Language Models are Few-Shot Learners». Em: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, pp. 1877–1901.

Bui, Tuan et al. (2025). «Formal Reasoning for Intelligent QA Systems: A Case Study in the Educational Domain». Em: *Proceedings of the 2nd ACM Workshop in AI-Powered Question & Answering Systems*. Estudo R1110 da revisão. doi: 10.1145/3746274.3760392.

Buti, Ronit e Abdallah Mohamed (2026). «Evaluating RAG-Based Course Advising Chatbots Using LLM-as-a-Judge Methodology». Em: *Proceedings of the 28th Western Canadian Conference on Computing Education*. Estudo R1022 da revisão. doi: 10.1145/3828792.3828802.

Christiawan, J. et al. (2025). «Sanity-LLM: Enhancing Mental Health Chatbots with Retrieval-Augmented Generation (RAG)». Em: *2025 International Conference on Informatics, Multimedia, Cyber and Information System (ICIMCIS)*. Estudo R0071 da revisão. doi: 10.1109/ICIMCIS68501.2025.11327020.

Elnozahy, W. A., G. A. El Khayat e E. I. Aboulsafa (2026). «A Governed Closed-Domain Question Answering System for Decision Assistance in Education». Em: *2026 IEEE International Conference on Smart Sustainable Systems for Computer and Engineering Applications (3SCEA)*. Estudo R0446 da revisão. doi: 10.1109/3SCEA68071.2026.11603208.

Emekci, H. e G. Budakoglu (2025). «Securing With Dual-LLM Architecture: ChatTEDU an Open Access Chatbot's Defense». Em: *IEEE Access*. Estudo R0765 da revisão. doi: 10.1109/ACCESS.2025.3623268.

Es, Shahul et al. (2024). «RAGAS: Automated Evaluation of Retrieval Augmented Generation». Em: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pp. 150–158. doi: 10.18653/v1/2024.eacl-demo.16.

Feng, Ty, Sa Liu e Dipak Ghosal (2024). «CourseAssist: Pedagogically Appropriate AI Tutor for Computer Science Education». Em: *Proceedings of the 2024 on ACM Virtual Global Computing Education Conference V. 2*. Estudo R1060 da revisão. doi: 10.1145/3649409.3691094.

Fu, R. et al. (2024). «Chatbots on a Mid-Scale Knowledge Base: Using an R2 University as an Example». Em: *2024 5th International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE)*. Estudo R0753 da revisão. doi: 10.1109/ICBAIE63306.2024.11116920.

Gan, Wenyi, Jianfeng Ouyang, Hua Li et al. (2024). «Integrating ChatGPT in Orthopedic Education for Medical Undergraduates: Randomized Controlled Trial». Em: *Journal of Medical Internet Research* 26, e57037. doi: 10.2196/57037.

Geng, T. et al. (2026). «Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies». Em: *Computers, Materials & Continua* 87.1. url: https://www.techscience.com/cmc/v87n1/66084.

Ghanbari, M. e R. Dividino (2025a). «Evaluating Knowledge Graph-Enhanced Context for Multiple-Choice Question Answering». Em: *2025 IEEE International Conference on Knowledge Graph (ICKG)*. Estudo R0559 da revisão. doi: 10.1109/ICKG66886.2025.00020.

– (2025b). «Quantifying Informativeness in Knowledge Graph-Augmented In-Context Learning for Multiple Choice Query Answering». Em: *2025 IEEE International Conference on Knowledge Graph (ICKG)*. Estudo R0619 da revisão. doi: 10.1109/ICKG66886.2025.00021.

Gordon, Morris, Michelle Daniel, Aderonke Ajiboye et al. (2024). «A scoping review of artificial intelligence in medical education: BEME Guide No. 84». Em: *Medical Teacher* 46.4, pp. 446–470. doi: 10.1080/0142159X.2024.2314198.

Greshake, Kai et al. (2023). «Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection». Em: *Proceedings of the*

16th ACM Workshop on Artificial Intelligence and Security (AISec '23), pp. 79–90. doi: 10.1145/3605764.3623985.

Hamidi, A. e K. Roberts (2026). «Large Language Models for Radiology QA: Benchmarking and Error Taxonomy on RadQA». Em: *2026 IEEE 14th International Conference on Healthcare Informatics (ICHI)*. Estudo R0794 da revisão. doi: 10.1109/ICHI69079.2026.00034.

Han, Yuanrong e Salma Emara (2026). «Textbook-Embedded Virtual Teaching Assistant That Answers CS1 Questions With Verifiable Citations». Em: *Proceedings of the 2026 IEEE/ACM 48th International Conference on Software Engineering*. Estudo R0965 da revisão. doi: 10.1145/3774748.3795670.

Hattie, John e Helen Timperley (2007). «The Power of Feedback». Em: *Review of Educational Research* 77.1, pp. 81–112. doi: 10.3102/003465430298487.

Hevner, Alan R. et al. (2004). «Design Science in Information Systems Research». Em: *MIS Quarterly* 28.1, pp. 75–105.

Huang, Lei et al. (2025). «A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions». Em: *ACM Transactions on Information Systems* 43.2. doi: 10.1145/3703155.

Ishadya, A. P. D., A. Withanaarachchi e S. Jayalal (2026). «Mitigating Bias and Hallucinations in LLMs Through Prompt Engineering and Knowledge-Grounded Approaches in Healthcare Domain». Em: *2026 6th International Conference on Advanced Research in Computing (ICARC)*. Estudo R0558 da revisão. doi: 10.1109/ICARC68737.2026.11453821.

Jain, A., L. Cui e S. Chen (2025). «Aligning LLMs for the Classroom with Knowledge-Based Retrieval: A Comparative RAG Study». Em: *2025 IEEE International Conference on Teaching, Assessment, and Learning for Engineering (TALE)*. Estudo R0616 da revisão. doi: 10.1109/TALE66047.2025.11346682.

Jang, D. et al. (2025). «MedTutor: A Retrieval-Augmented LLM System for Case-Based Medical Education». Em: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 319–353. url: https://aclanthology.org/2025.emnlp-demos.24/.

Kadavath, Saurav et al. (2022). *Language Models (Mostly) Know What They Know*. arXiv: 2207.05221.

Kasneci, Enkelejda, Kathrin Sessler, Stefan Küchemann et al. (2023). «ChatGPT for good? On opportunities and challenges of large language models for education». Em: *Learning and Individual Differences* 103, p. 102274. doi: 10.1016/j.lindif.2023.102274.

Kavitha, G., H. A. M e P. R (2026). «SecureContext EDU: An Open Source University Assistant using Dual - LLM Architecture». Em: *2026 4th International Conference on Sustainable Computing and Smart Systems (ICSCSS)*. Estudo R0237 da revisão. doi: 10.1109/ICSCSS69635.2026.11645927.

Khan, U. A. et al. (2025). «Towards Efficient Educational Chatbots: Benchmarking RAG Frameworks». Em: *2025 International Conference on Emerging Technologies in Computing and Communication (ETCC)*. Estudo R0452 da revisão. doi: 10.1109/ETCC65847.2025.11108323.

Kitchenham, Barbara e Stuart Charters (2007). *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. Rel. téc. EBSE-2007-01. Keele University e Durham University.

Larsen, Douglas P., Andrew C. Butler e Henry L. Roediger (2008). «Test-Enhanced Learning in Medical Education». Em: *Medical Education* 42.10, pp. 959–966. doi: 10.1111/j.1365-2923.2008.03124.x.

Lewis, Patrick et al. (2020). «Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks». Em: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, pp. 9459–9474.

Li, Boquan et al. (2026). «Be Responsible in Your Answers! Monitoring Out-of-Domain Behaviors in Domain-Specific LLMs». Em: *Proceedings of the ACM Web Conference 2026*. Estudo R1183 da revisão. doi: 10.1145/3774904.3792621.

Liao, Yiming et al. (2026). «Med-HEAL: Analyzing and Mitigating Hallucinations in Medical LLMs with Hallucination-Aware In-Context Learning». Em: *Proceedings of the 17th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*. Estudo R1120 da revisão. doi: 10.1145/3807503.3819453.

Liu, Nelson F. et al. (2024a). «Lost in the Middle: How Language Models Use Long Contexts». Em: *Transactions of the Association for Computational Linguistics* 12, pp. 157–173. doi: 10.1162/tacl_a_00638.

Liu, Rongxin et al. (2024b). «Teaching CS50 with AI: Leveraging Generative Artificial Intelligence in Computer Science Education». Em: *Proceedings of the 55th ACM Technical Symposium on Computer Science Education V. 2*. Estudo R1187 da revisão. doi: 10.1145/3626253.3635427.

Liu, T., M. Zhu e S. P. Zhai (2026a). «Quality Outweighs Quantity: Advancing Medical Question Answering with RAG-MCP Muti-Agent LLM Framework and Curated Knowledge Databases». Em: *2026 IEEE 16th Annual Computing and Communication Workshop and Conference (CCWC)*. Estudo R0301 da revisão. doi: 10.1109/CCWC67433.2026.11393764.

Liu, Ziqi et al. (2026b). «AskNow: An LLM-powered Interactive System for Real-Time Question Answering in Large-Scale Classrooms». Em: *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Estudo R0934 da revisão. doi: 10.1145/3772318.3790328.

Mathew, A. K., D. Rajeev e A. Ravi (2026). «Privacy-Preserving Federated Transformer Framework for Detecting Adversarial Prompts in Healthcare Chatbots». Em: *2026 International Conference on Innovations in Computational Intelligence (ICICI)*. Estudo R0771 da revisão. doi: 10.1109/ICICI68867.2026.11564888.

Miroyan, Mihran et al. (2025). «Analyzing Pedagogical Quality and Efficiency of LLM Responses with TA Feedback to Live Student Questions». Em: *Proceedings of the 56th ACM Technical Symposium on Computer Science Education V. 1*. Estudo R0991 da revisão. doi: 10.1145/3641554.3701965.

Nurfadhilah, E., A. Santosa e P. K. Putra (2025). «Retrieval-Augmented Large Language Models for a Chronic Kidney Disease Patient Education Chatbot». Em: *2025 International Conference on Computer, Control, Informatics and its Applications (IC3INA)*. Estudo R0157 da revisão. doi: 10.1109/IC3INA68387.2025.11325127.

Oh, G., S. Park e B. -H. Kim (2026). «AutoMedic: An Automated Evaluation Framework for Clinical Conversational Agents with Medical Dataset Grounding». Em: *IEEE Journal of Biomedical and Health Informatics*. Estudo R0686 da revisão. doi: 10.1109/JBHI.2026.3703097.

Ouyang, Long et al. (2022). «Training Language Models to Follow Instructions with Human Feedback». Em: *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, pp. 27730–27744.

OWASP Foundation (2024). *OWASP Top 10 for LLM Applications 2025*. url: https://genai.owasp.org/llm-top-10/.

Page, Matthew J. et al. (2021). «The PRISMA 2020 statement: an updated guideline for reporting systematic reviews». Em: *BMJ* 372, n71. doi: 10.1136/bmj.n71.

Parlamento Europeu e Conselho da União Europeia (2016). *Regulamento (UE) 2016/679 relativo à proteção das pessoas singulares no que diz respeito ao tratamento de dados pessoais (Regulamento Geral sobre a Proteção de Dados)*. url: https://eur-lex.europa.eu/eli/reg/2016/679/oj.

– (2024). *Regulamento (UE) 2024/1689 que cria regras harmonizadas em matéria de inteligência artificial (Regulamento da Inteligência Artificial)*. url: https://eur-lex.europa.eu/eli/reg/2024/1689/oj.

Peffers, Ken et al. (2007). «A Design Science Research Methodology for Information Systems Research». Em: *Journal of Management Information Systems* 24.3, pp. 45–77. doi: 10.2753/MIS0742-1222240302.

Perez, Fábio e Ian Ribeiro (2022). *Ignore Previous Prompt: Attack Techniques for Language Models*. NeurIPS ML Safety Workshop. arXiv: 2211.09527.

Politécnico do Porto (2020). *Código de Ética e de Conduta do Politécnico do Porto*. url: https://www.ipp.pt.

Rahat, M. T. I. et al. (2026). «Noise, Distraction, and Mitigation: An Analysis of RAG Failure Modes in Medical Question Answering». Em: *2026 International Conference on Artificial Intelligence in Information and Communication (ICAIIC)*. Estudo R0414 da revisão. doi: 10.1109/ICAIIC68212.2026.11454362.

Raputri, E. et al. (2025). «Retrieval-Augmented LLMs with Indonesian Clinical Trials Guidelines: A Comparative Study». Em: *2025 8th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*. Estudo R0281 da revisão. doi: 10.1109/ISRITI68345.2025.11393253.

Rayhan, M. H. et al. (2026). «SAGE: Student-Focused Adaptive Guidance Engine for Intelligent Tutoring with Regulated Learning». Em: *2026 IEEE International Conference on Human-Machine Systems (ICHMS)*. Estudo R0807 da revisão. doi: 10.1109/ICHMS69701.2026.11602253.

Roediger, Henry L. e Jeffrey D. Karpicke (2006). «Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention». Em: *Psychological Science* 17.3, pp. 249–255. doi: 10.1111/j.1467-9280.2006.01693.x.

Ruga, T. et al. (2025). «A Conversational Agent for Rare Eye Disease Knowledge Support in Local Italian Healthcare Contexts: The ELENA Framework». Em: *2025 IEEE International Conference on Big Data (BigData)*. Estudo R0555 da revisão. doi: 10.1109/BigData66926.2025.11402191.

Sayeed, M. S. et al. (2026). «ATU-Tutor: A RAG-Based Socratic Tutoring System with Agentic AI Adaptive Assessment». Em: *2026 IEEE World AI IoT Congress (AIIoT)*. Estudo R0469 da revisão. doi: 10.1109/AIIoT68874.2026.11569566.

Sbai, A., I. Guessous e E. H. Nfaoui (2025). «Advanced Trilingual RAG Framework: Progressive Architectures for Robust Educational Question Answering». Em: *2025 4th International Conference on Embedded Systems and Artificial Intelligence (ESAI)*. Estudo R0165 da revisão. doi: 10.1109/ESAI67033.2025.11438335.

Seshadri, Vaibhav et al. (2026). «Alan: A Classroom Deployment of An Educational Chatbot That Cites Resources». Em: *Proceedings of the 57th ACM Technical Symposium on Computer Science Education V.2*. Estudo R1001 da revisão. doi: 10.1145/3770761.3777344.

Shah, A. et al. (2026). «Enhancing medical data processing with RAG-augmented fine-tuned LLMs and guardrails». Em: *International Conference on Advancing Technology in Engineering and Science (ICATES 2025)*. Estudo R0709 da revisão. doi: 10.1049/icp.2025.4700.

Shute, Valerie J. (2008). «Focus on Formative Feedback». Em: *Review of Educational Research* 78.1, pp. 153–189. doi: 10.3102/0034654307313795.

Tawfik, M. K. et al. (2025). «Mufakkir: RAG-Based Arabic Educational Chatbot for University Students». Em: *2025 Twelfth International Conference on Intelligent Computing and Information Systems (ICICIS)*. Estudo R0443 da revisão. doi: 10.1109/ICICIS66182.2025.11313212.

Tien, L. A. e P. Van Huong (2024). «Optimizing Transformer Models for Prompt Jailbreak Attack Detection in AI Assistant Systems». Em: *2024 1st International Conference On Cryptography And Information Security (VCRIS)*. Estudo R0763 da revisão. doi: 10.1109/VCRIS63677.2024.10813380.

Trang, T. N. A. et al. (2025). «A Customized AI Chatbot for Educational Environments: Integrating Retrieval-Augmented Generation with Curriculum-Aligned Responses». Em: *2025 RIVF International Conference on Computing and Communication Technologies (RIVF)*. Estudo R0113 da revisão. doi: 10.1109/RIVF68649.2025.11365126.

Vaswani, Ashish et al. (2017). «Attention Is All You Need». Em: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 5998–6008.

Walczak, J. e B. Sawicki (2026). «Comparative Evaluation of Llama Guard 3 and GPT OSS Safeguard as LLM Guardrails for a University Administrative Chatbot». Em: *2026 Progress in Applied Electrical Engineering (PAEE)*. Estudo R0762 da revisão. doi: 10.1109/PAEE71887.2026.11660667.

Wei, H. et al. (2026). «Cloud-Edge Retrieval-Augmented Agent Tutor for Trustworthy Personalized Learning in Resource-Constrained Higher Education». Em: *2026 5th International Conference on Artificial Intelligence, Internet of Things and Cloud Computing Technology (AIoTC)*. Estudo R0437 da revisão. doi: 10.1109/AIoTC71250.2026.11689071.

Weizenbaum, Joseph (1966). «ELIZA – A Computer Program for the Study of Natural Language Communication between Man and Machine». Em: *Communications of the ACM* 9.1, pp. 36–45. doi: 10.1145/365153.365168.

Xie, Weidong et al. (2026). «When Retrieval Hurts: A Critical Analysis of RAG in Medical Question Answering». Em: *Proceedings of the 2025 3rd International Conference on Artificial Intelligence, Systems and Network Security*. Estudo R0878 da revisão. doi: 10.1145/3797161.3797211.

Xu, Haiyang et al. (2026). «EchoMind: Augmenting Recorded Presentations with Context-Grounded Conversational Agents and Collective Viewer Signals». Em: *Proceedings of the 14th Nordic Conference on Human-Computer Interaction*. Estudo R1056 da revisão. doi: 10.1145/3829807.3829883.

Yan, Jiameng e Jingzhuo Shi (2026). «Question-Answering Agent Based on Prompt Engineering and RAG». Em: *Proceedings of the 2026 International Conference on Artificial Intelligence, Digital Media and Education*. Estudo R0859 da revisão. doi: 10.1145/3839592.3839607.

Zhang, H. e M. O. Shafiq (2025). «MediTriR: A Triple-Driven Approach to Retrieval-Augmented Generation for Medical Question Answering Tasks». Em: *2025 19th International Conference on Semantic Computing (ICSC)*. Estudo R0042 da revisão. doi: 10.1109/ICSC64641.2025.00032.

Zhao, Chengshuai et al. (2025). «CyberBOT: Ontology-Grounded Retrieval Augmented Generation for Reliable Cybersecurity Education». Em: *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. Estudo R0826 da revisão. doi: 10.1145/3746252.3761478.

Zheng, Lianmin et al. (2023). «Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena». Em: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*.

Zheng, Mingkai et al. (2026). «A Comparative Study on LLM-enabled HPC User Support». Em: *Proceedings of the Practice and Experience in Advanced Research Computing 2026: Resilient Roots + Empowered Communities*. Estudo R0995 da revisão. doi: 10.1145/3785462.3815796.

Apêndice A

Protocolo e Registo da Revisão Sistemática

Este apêndice documenta o protocolo da revisão sistemática resumida na Secção 2.2: a estruturação das questões, as fontes, a pesquisa piloto, a adaptação das expressões a cada fonte, o registo da pesquisa, os passos da seleção, a avaliação da qualidade e os campos de extração. Os ficheiros exportados, os *scripts* e as decisões de triagem permitem repetir todos os passos.

A.1 Estruturação das Questões

O âmbito das questões foi estruturado com os critérios PICOC (População, Intervenção, Comparação, Resultados e Contexto) recomendados por Kitchenham e Charters (2007). A Tabela A.1 mostra cada critério e onde é aplicado: a população, a intervenção e os resultados dão origem aos blocos das expressões de pesquisa; o contexto é aplicado nos critérios de seleção, para não excluir na pesquisa estudos que não mencionam o domínio no título ou no resumo.

Tabela A.1: Critérios PICOC da revisão e onde são aplicados.

Critério	**Definição**	**Aplicação**
População	Sistemas conversacionais e de resposta a perguntas baseados em LLMs	Blocos LLM e *chatbot*/QA (Q1–Q4)
Intervenção	Limitação das respostas a um contexto definido pela aplicação (RAG, contexto no *prompt*, *grounding*) e controlo do âmbito (*guardrails*, recusa)	Bloco de contexto (Q1), segurança (Q3) e recusa (Q4)
Comparação	Entre formas de fornecer o contexto e com o modelo sem contexto, quando reportada	Extração (não restringe a pesquisa)
Resultados	Correção factual, fidelidade ao contexto, adesão ao âmbito e recusa, robustez a manipulação; latência e custo	Bloco de avaliação (Q2, Q4); critério I4; extração
Contexto	Educação e saúde; estudos primários publicados entre 2021 e 2026	Filtro de anos; critérios I1–I3

A.2 Fontes e Pesquisa

Fontes. Foram usadas três fontes: IEEE Xplore e ACM Digital Library, que cobrem a literatura de engenharia informática, sistemas e IA, e Scopus, uma base multidisciplinar que cobre também revistas de educação e saúde. As fontes foram escolhidas antes da pesquisa final.

Tabela A.2: Registo da pesquisa (2 de novembro de 2026; título, resumo e palavras-chave; 2021–2026).

Fonte	Q1	Q2	Q3	Q4	Exportados
IEEE Xplore	756 (753)	24	38	29	844
ACM Digital Library	358	24	16	25 (26)	424
Scopus	102	131	14	32	279
Total					**1547**

Total indicado pela fonte; entre parênteses, o número exportado quando é diferente.

Pesquisa piloto. Antes de fixar as expressões, foi feita uma pesquisa piloto nas três fontes, limitada aos primeiros 30 títulos de cada pesquisa. O piloto levou a três decisões: (i) estreitar as expressões a sistemas conversacionais e de resposta a perguntas, porque as versões gerais devolviam sobretudo geração de código, *hardware* de inferência e recomendação; (ii) retirar latência e custo dos blocos de pesquisa e tratá-los como campos de extração, pelo mesmo motivo; (iii) separar a segurança do âmbito (Q3) e a recusa fora do âmbito (Q4) em expressões próprias.

Campos pesquisados. Em todas as fontes, as expressões foram aplicadas ao título, ao resumo e às palavras-chave, com o filtro de anos 2021–2026. No Scopus foi usado o campo `TITLE-ABS-KEY(...)`. No IEEE Xplore e na ACM Digital Library, que não têm um campo equivalente, cada termo foi expandido para os três campos (por exemplo, no IEEE Xplore, `("Document Title":LLM OR "Abstract":LLM OR "Author Keywords":LLM)`), mantendo a lógica booleana. A versão exata executada em cada fonte está guardada no registo da pesquisa.

Execução e registo. As pesquisas foram executadas a 2 de novembro de 2026. Foram exportados todos os resultados de cada pesquisa, com resumo, em RIS (IEEE Xplore e Scopus) ou BibTeX (ACM Digital Library). Para cada par fonte–pesquisa foram registados a expressão executada, a data, os filtros, o total indicado pela fonte e o número de registos exportados (Tabela A.2).

A Tabela A.2 apresenta o registo da pesquisa. Foram exportados 1547 registos: 844 do IEEE Xplore, 424 da ACM Digital Library e 279 do Scopus. No IEEE Xplore, 3 dos 756 resultados da Q1 não puderam ser exportados pela própria plataforma; na ACM Digital Library, a exportação da Q4 devolveu 26 registos para um total indicado de 25. A Q1 concentra a maior parte dos resultados, por cobrir a literatura de RAG aplicada a qualquer domínio.

A.3 Seleção dos Estudos

A seleção seguiu quatro passos, todos registados em ficheiros e reprodutíveis através de *scripts*:

1. **Deduplicação.** Os registos das três fontes foram juntos e os duplicados removidos, primeiro pelo DOI normalizado e depois pelo título normalizado. Cada registo guarda a fonte e a pesquisa de onde veio.
2. **Triagem por regras (fase A).** Foram aplicadas regras explícitas sobre o título e o resumo, que implementam os critérios E2, E3 e E4 e o foco do I3 e do I4: registo sem

Tabela A.3: Campos de extração de dados.

#	Campo	Descrição	Questão
1	Referência	Autores, ano, fonte e tipo de publicação	—
2	Domínio e utilizadores	Educação ou saúde; estudantes, doentes, profissionais	RQ1
3	Origem do contexto	RAG, grafo de conhecimento, contexto no *prompt*, base de dados ou outro	RQ1
4	Controlo da resposta	Instruções, filtros, citações, verificação, recusa, *guardrails*	RQ1, RQ2
5	Modelo e componentes	Modelo de linguagem, *fine-tuning*, execução local ou na nuvem	RQ1
6	Avaliação	Método (métricas, LLM juiz, especialistas, utilizadores), dados e dimensão da amostra	RQ2
7	Resultados	Correção, fidelidade, recusa e segurança	RQ2
8	Compromissos e limitações	Latência, custo, integração, privacidade e limitações reportadas	RQ1

resumo ou que não é artigo; revisão ou *survey*; ausência de termos de LLM; ausência de termos de sistema conversacional ou QA; ausência de termos de educação ou saúde; e ausência de termos de avaliação das respostas. As regras e os termos usados estão no *script* de triagem.

3. **Triagem por leitura (fase B).** Os registos que passaram a fase A foram lidos (título e resumo) e classificados como incluídos ou excluídos, com um critério e um motivo por registo. Esta triagem foi feita com apoio de um assistente de IA, que propôs as decisões e os motivos; as decisões foram verificadas pelo autor (Secção 1.9).

4. **Priorização.** Dentro dos incluídos, foram marcados como prioritários os estudos que cumprem pelo menos uma das seguintes condições, escolhidas pela proximidade ao caso de estudo: (a) contexto fechado e próximo do QBank (perguntas de exame ou de escolha múltipla, materiais de um curso ou um documento específico); (b) avaliação explícita da correção, da fidelidade ou da recusa; (c) mecanismo de controlo do âmbito ou de segurança; (d) suporte a várias línguas.

A.4 Avaliação da Qualidade e Extração de Dados

Na leitura do texto integral, cada estudo será avaliado com cinco critérios de qualidade, cada um classificado como *sim* (1), *parcial* (0,5) ou *não* (0): (QA1) o objetivo está claro; (QA2) o sistema, o modelo e a origem do contexto estão descritos; (QA3) os dados, as perguntas ou os cenários de avaliação estão descritos; (QA4) o método de avaliação é adequado às conclusões; (QA5) as limitações e ameaças à validade são discutidas. A pontuação não exclui estudos: serve para ponderar a evidência na síntese.

Os campos de extração estão na Tabela A.3. Nesta fase, a extração foi feita a partir dos resumos; os campos serão confirmados e completados com o texto integral.

Apêndice B

Estudos Prioritários da Revisão

Este apêndice classifica os 48 estudos prioritários da revisão sistemática (Capítulo 2). A classificação foi feita a partir dos títulos e resumos e será confirmada na leitura do texto integral. A coluna Q indica a pesquisa de onde o estudo veio.

Tabela B.1: Classificação dos estudos prioritários.

Estudo	Q	Domínio	Contexto e controlo	Avaliação
Zhang e Shafiq (2025)	Q1	QA médico (MCQ)	RAG com triplos de grafo	Exatidão em MedMCQA e Medical QA
Christiawan et al. (2025)	Q1,Q2	Saúde mental	RAG híbrido com reordenação	RAGAS: fidelidade 0,875
Trang et al. (2025)	Q1	Educação escolar	RAG e regras sobre planos de aula	Descrição do sistema; execução local
Nurfadhilah et al. (2025)	Q1,Q2	Educação de doentes	RAG; LLM adaptado à língua	700 respostas; fidelidade e correção (LLM avaliador)
Azam et al. (2024)	Q1,Q2	Oncologia	RAG sobre literatura	Fidelidade e relevância vs. LLM base
Sbai et al. (2025)	Q1	Educação (trilingue)	RAG com embeddings multilingues	Correção e fidelidade por língua
Kavitha et al. (2026)	Q1,Q3	Universidade	Dois LLM: filtro e RAG controlado	Deteção de ameaças (90%)
Raputri et al. (2025)	Q1,Q2	Diagnóstico clínico	RAG sobre diretrizes locais	Comparação com e sem RAG; médico
Liu et al. (2026a)	Q1	QA médico (MCQ)	RAG multiagente; base curada	Exatidão em MedMCQA e MedQA
Rahat et al. (2026)	Q1	QA médico	RAG sobre PubMed	Exatidão; análise de 165 erros
Wei et al. (2026)	Q1	Ensino superior	RAG local com verificação de políticas	Dados públicos; auditoria de casos
Tawfik et al. (2025)	Q1	Ensino superior (árabe)	RAG híbrido	Exatidão e semelhança da resposta
Elnozahy et al. (2026)	Q1	Ensino superior	QA de domínio fechado com encaminhamento	Proposta de arquitetura
Khan et al. (2025)	Q1,Q2	Exame de acesso (GATE)	RAG sobre soluções de exame	Fidelidade, relevância, latência; avaliação humana
Sayeed et al. (2026)	Q1	Ensino superior	RAG sobre manuais abertos	14 perguntas; LLM e heurísticas
BENGMAH et al. (2025)	Q1	Diabetes	Prompt vs. fine-tuning vs. RAG	Comparação das três abordagens
Ruga et al. (2025)	Q1	Oftalmologia (italiano)	RAG com tradução	Viabilidade técnica
Ishadya et al. (2026)	Q1,Q4	Saúde	Prompting estruturado + RAG/MCP	Exatidão, abstenção, evidência; especialistas
Ghanbari e Dividino (2025a)	Q1	Transferível (MCQ)	Grafo de conhecimento no prompt	Exatidão vs. sem contexto
Bellard et al. (2025)	Q1	Insuficiência cardíaca	RAG com LLM juiz	25 pares; latência e custo
Jain et al. (2025)	Q1	Sala de aula	RAG vetorial vs. grafo	3176 perguntas; manuais alterados

Estudo	Q	Domínio	Contexto e controlo	Avaliação
Ghanbari e Dividino (2025b)	Q1	Transferível (MCQ)	Subgrafos no prompt	Efeito da relevância do contexto
Oh et al. (2026)	Q1	Clínica	Pacientes virtuais de datasets	Métrica CARE; validação por especialistas
Shah et al. (2026)	Q1,Q3	Saúde	RAG, fine-tuning e guardrails	BLEU, ROUGE-L, BERTScore
Zhao et al. (2025)	Q1	Cibersegurança (curso)	RAG validado por ontologia	Implementado num curso
Yan e Shi (2026)	Q1	Eletrónica (curso)	RAG e engenharia de prompts	Exatidão e estabilidade
Xie et al. (2026)	Q1	QA médico (MCQ)	Três variantes de RAG	Exatidão no MedQA; efeito do RAG
Liu et al. (2026b)	Q1	Sala de aula	Contexto da aula em curso	117 estudantes; docentes avaliam correção
Han e Emara (2026)	Q1	Programação (CS1)	RAG sobre o manual, com citações	Citações corretas; inquérito
Miroyan et al. (2025)	Q1	Programação	RAG (GPT-4)	Avaliação e edição por TAs
Zheng et al. (2026)	Q1	Transferível (apoio técnico)	Fine-tuning vs. RAG vs. ICL	Correção; humanos e LLM juiz
Seshadri et al. (2026)	Q1	Programação	RAG sobre materiais, com citações	250 estudantes; inquérito
Barzanji et al. (2026)	Q1	Engenharia de software	Materiais do curso	32 estudantes; SUS 77,8
Buti e Mohamed (2026)	Q1,Q2	Aconselhamento académico	RAG	55 perguntas; LLM juiz
Xu et al. (2026)	Q1	Vídeo-aulas	Materiais da apresentação	Estudo com 75 participantes
Feng et al. (2024)	Q1	Programação	RAG, intenção e decomposição	50 pares vs. GPT-4; entrevistas
Bui et al. (2025)	Q1	Procedimentos académicos	LLM com verificação formal	Benchmark EduMC-QA
Liao et al. (2026)	Q1	Clínica (EHR)	Autocrítica e ICL com exemplos	LLM juiz e estudantes de medicina
Fu et al. (2024)	Q2	Universidade	Base de conhecimento web	Correção e completude; alucinações
Walczak e Sawicki (2026)	Q3	Universidade	Guardrails com restrição de tema	Precisão, recall, latência
Tien e Huong (2024)	Q3	Universidade	Classificador de jailbreak	Exatidão da deteção
Emekci e Budakoglu (2025)	Q3	Universidade	Dois LLM: filtro e geração	4501 interações reais; 0,28% falsos positivos
Mathew et al. (2026)	Q3	Saúde	Deteção federada de injeção	Exatidão e F1
Li et al. (2026)	Q3	Vários domínios	Monitorização de estados internos	Taxa de rejeição fora do domínio
Liu et al. (2024b)	Q3	Programação (CS50)	Guardrails pedagógicos	Demonstração; experiência de uso
Hamidi e Roberts (2026)	Q4	Radiologia	QA sobre um relatório	EM, F1; taxonomia com abstenção
Rayhan et al. (2026)	Q4	Programação	Controlo de acesso por grafo	Políticas: 90% vs. 30% (prompt)
Abrar et al. (2025)	Q4	Universidade (multilingue)	Fine-tuning com exemplos de recusa	Precisão da recusa 0,86