ISEP INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Francisco Reis

Dissertação para obtenção do Grau de Mestre em Engenharia Informática, Área de Especialização em Software Engineering

Orientador: Nuno Silva
Supervisor: Bruno Guimarães

Porto, 9 de novembro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 9 de novembro de 2026

Resumo

O Adhara QBank é uma plataforma de estudo na área da saúde. Estudantes e profissionais resolvem nela exames de perguntas de escolha múltipla, em várias línguas, nos modos Teste, Estudo e Simulado. A equipa científica valida a informação de cada pergunta: a vinheta clínica, as opções, a resposta correta, a explicação, as dicas e a informação complementar. A explicação mostrada no ecrã nem sempre resolve as dúvidas do estudante. Esta dissertação, desenvolvida com a Adhara, concebe, implementa e avalia um assistente conversacional multilingue integrado no QBank, disponível nos modos Teste e Estudo. O assistente responde a dúvidas sobre a pergunta em curso apenas com a informação dessa pergunta, lida a partir da base de dados. Respeita as regras de cada modo e recusa questões fora desse contexto.

Uma revisão sistemática de 1547 registos em três fontes, com 38 estudos incluídos, mostra que a recuperação de contexto pode introduzir erros e que as instruções no *prompt* não garantem o cumprimento do âmbito. A avaliação mede a correção e a fidelidade das respostas, a capacidade de recusa, a latência, o custo e a utilidade e a usabilidade percebidas pelos utilizadores. O trabalho segue a metodologia *Design Science Research*.

Palavras-chave: Modelos de Linguagem, Banco de Perguntas, Educação Médica, Geração Fundamentada em Contexto, Assistente Conversacional, Engenharia de Prompts

Abstract

Adhara QBank is a health-sciences study platform. Students and professionals use it to take multiple-choice exams in several languages, in Test, Study and Mock Exam modes. The scientific team validates the information of each question: the clinical vignette, the options, the correct answer, the explanation, the hints and the supplementary information. The explanation shown on screen does not always resolve the student's doubts. This dissertation, developed with Adhara, designs, implements and evaluates a multilingual conversational assistant integrated into QBank and available in Test and Study modes. The assistant answers doubts about the current question using only that question's information, read from the database. It follows the rules of each mode and refuses questions outside that context.

A systematic review of 1547 records from three sources, with 38 included studies, shows that context retrieval can introduce errors and that prompt instructions do not guarantee scope compliance. The evaluation measures answer correctness and faithfulness, refusal capability, latency, cost, and users' perceived usefulness and usability. The work follows the Design Science Research methodology.

Agradecimentos

Índice

Lista de Figuras **xiii**

Lista de Tabelas **xv**

Lista de Acrónimos **xvii**

1 Introdução **1**
1.1 Contexto e Motivação . . . 1
1.2 A Organização e o Adhara QBank . . . 1
1.3 Definição do Problema . . . 2
1.4 Objetivos . . . 3
1.5 Questões de Investigação . . . 3
1.6 Abordagem Metodológica . . . 3
1.7 Gestão de Riscos . . . 4
1.8 Contribuições Esperadas . . . 4
1.9 Considerações Éticas e Profissionais . . . 4
1.10 Estrutura do Documento . . . 7

2 Estado da Arte **9**
2.1 Fundamentos Teóricos . . . 9
2.1.1 Aprendizagem com Perguntas e *Feedback* . . . 9
2.1.2 Assistentes Conversacionais . . . 10
2.1.3 Modelos de Linguagem de Grande Dimensão . . . 10
2.1.4 *Tokens*, Janela de Contexto e Línguas . . . 14
2.1.5 *Prompts* e Parâmetros de Geração . . . 15
2.1.6 Conversas com Vários Turnos e *Cache* . . . 17
2.1.7 Representações Vetoriais e Semelhança Semântica . . . 17
2.1.8 Execução Local e por *Application Programming Interface* (API) . . . 17
2.1.9 Formas de Fornecer Contexto ao Modelo . . . 18
2.1.10 Alucinação, Fidelidade e Recusa . . . 19
2.1.11 Controlo do Âmbito e Segurança . . . 20
2.1.12 Avaliação de Respostas . . . 20
2.2 Método da Revisão Sistemática . . . 21
2.2.1 Questões, Fontes e Expressões de Pesquisa . . . 21
2.2.2 Critérios e Seleção . . . 21
2.2.3 Resultados da Seleção . . . 23
2.3 Arquiteturas de Contextualização (RQ1) . . . 24
2.3.1 O *Pipeline* de Recuperação e as suas Variantes . . . 24
2.3.2 Conhecimento Estruturado: Grafos e Ontologias . . . 26
2.3.3 Orquestração: Agentes, Encaminhamento e Verificação . . . 26
2.3.4 Engenharia de *Prompts* . . . 27

2.3.5 Ajuste Fino como Alternativa ou Complemento 27
2.3.6 Quando o Contexto Prejudica 28
2.3.7 Contexto Fechado e Perguntas de Exame 28
2.4 Mecanismos de Controlo do Âmbito e de Segurança (RQ1) 29
2.5 Línguas, Latência e Custo (RQ1) 32
2.6 Avaliação da Correção, da Fidelidade e do Âmbito (RQ2) 33
2.7 Sistemas Mais Próximos do Caso de Estudo 36
2.7.1 Limitações Recorrentes 36
2.8 Lacuna de Investigação 37
2.9 Ameaças à Validade 38
2.10 Conclusões do Capítulo 38

Bibliografia **41**

Apêndice A Protocolo e Registo da Revisão Sistemática **47**
A.1 Estruturação das Questões 47
A.2 Fontes e Pesquisa 47
A.3 Seleção dos Estudos 48
A.4 Avaliação da Qualidade e Extração de Dados 49

Apêndice B Estudos Incluídos na Revisão **51**

Lista de Figuras

2.1 Arquitetura do Transformer 11
2.2 Evolução dos principais LLM por arquitetura 12
2.3 Ajuste fino com LoRA 13
2.4 Construção do prompt no EchoMind 16
2.5 Efeito da temperatura na escolha do token seguinte 16
2.6 Agrupamento de perguntas no AskNow 18
2.7 Duas formas de fornecer contexto ao modelo 19
2.8 Diagrama PRISMA da seleção dos estudos 24
2.9 Arquitetura do AskNow 29
2.10 Defesa em camadas e custos reportados 31
2.11 Fluxo de decisão do ChatTEDU 32

Lista de Tabelas

1.1 Riscos do projeto, classificação e medidas de mitigação. 5

2.1 Famílias de *Large Language Model*s (LLMs) usadas nos 38 estudos incluídos na revisão. 14
2.2 Comparação das formas de limitar as respostas a um contexto, à luz do caso do QBank. 19
2.3 Expressões de pesquisa e questões a que respondem. 22
2.4 Critérios de inclusão e exclusão. 22
2.5 Indicadores descritivos dos 38 estudos incluídos (a partir de títulos e resumos). 25
2.6 Mecanismos de controlo do âmbito e de segurança encontrados na revisão. 30
2.7 Métricas de avaliação encontradas na revisão, por dimensão. 34
2.8 Sistemas mais próximos do caso de estudo, comparados com o assistente do QBank. 36
2.9 Da evidência ao contributo: evidência, limitação, lacuna, questão de investigação e contributo. 37

A.1 Critérios *Population, Intervention, Comparison, Outcomes, Context* (PICOC) da revisão e onde são aplicados. 47
A.2 Registo da pesquisa (2 de novembro de 2026; título, resumo e palavras-chave; 2021–2026). 48
A.3 Campos de extração de dados. 50

B.1 Classificação e qualidade dos estudos incluídos. 51

Lista de Acrónimos

API	*Application Programming Interface*.
DSR	*Design Science Research*.
IA	Inteligência Artificial.
ICL	*In-Context Learning*.
LLM	*Large Language Model*.
MCQ	*Multiple-Choice Question*.
PICOC	*Population, Intervention, Comparison, Outcomes, Context*.
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*.
QA	*Question Answering*.
RAG	*Retrieval-Augmented Generation*.
RAGAS	*Retrieval Augmented Generation Assessment*.
RGPD	Regulamento Geral sobre a Proteção de Dados.
RQ	*Research Question*.
SUS	*System Usability Scale*.

Capítulo 1

Introdução

Este capítulo apresenta o contexto e a motivação do trabalho, a organização onde decorre e o problema abordado. Define depois os objetivos, as questões de investigação, a abordagem metodológica e a gestão de riscos. Termina com as contribuições esperadas, as considerações éticas e profissionais e a estrutura do documento.

1.1 Contexto e Motivação

Os bancos de perguntas de escolha múltipla (*Multiple-Choice Question*s (MCQs)) são um recurso habitual na preparação para exames na área da saúde. O Adhara QBank é uma plataforma de estudo da Adhara com perguntas de escolha múltipla em várias línguas. Estudantes de medicina, médicos e enfermeiros usam-na para preparar exames (Secção 1.2).

Durante o estudo, o utilizador pode ter dúvidas que a explicação da pergunta não resolve. Pode querer saber, por exemplo, porque é que uma opção está errada ou como um achado da vinheta se relaciona com a resposta correta. A plataforma não permite esclarecer essas dúvidas no momento. No entanto, a base de dados guarda mais informação sobre cada pergunta do que a que aparece no ecrã.

A literatura propõe assistentes conversacionais baseados em *Large Language Model*s (LLMs) como apoio ao estudo em educação e em educação médica (Abd-alrazaq et al. 2023; Kasneci et al. 2023). Num ensaio controlado com estudantes de medicina, um destes assistentes trouxe benefícios para a aprendizagem (Gan et al. 2024). Em contexto médico, porém, um assistente genérico traz riscos. Os LLMs podem gerar respostas plausíveis mas incorretas ou infiéis ao contexto que recebem (Hu et al. 2025; Jain et al. 2025), e essas respostas podem contradizer o conteúdo validado pela equipa científica. Fundamentar a resposta em informação dada ao modelo, por exemplo com *Retrieval-Augmented Generation* (RAG) (Hu et al. 2025), reduz este risco (Jang et al. 2025), mas não o elimina (Rahat et al. 2026; Xie et al. 2026). Além disso, um utilizador pode contornar as instruções do assistente através da manipulação do *prompt* (Emekci e Budakoglu 2025; Geng et al. 2026). Num exame, isso compromete a integridade da avaliação. A literatura aponta ainda a falta de orientações para o uso de Inteligência Artificial (IA) em educação médica (Gordon et al. 2024).

1.2 A Organização e o Adhara QBank

O trabalho decorre em colaboração com a Adhara (Adhara, Unipessoal, Lda.), uma empresa portuguesa de educação médica digital e de formação pós-graduada para profissionais de

saúde. O Adhara QBank é a plataforma da empresa para a preparação de exames com perguntas de escolha múltipla. Existe em várias línguas e terá algumas centenas de utilizadores.

O utilizador resolve exames em três modos: Teste, Estudo e Simulado. A equipa científica da Adhara valida a informação de cada pergunta: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação, catalogação e informação complementar. Cada versão linguística do QBank tem o seu próprio conteúdo validado.

1.3 Definição do Problema

Ao resolver uma pergunta no Adhara QBank, o utilizador pode precisar de esclarecer aspetos que a explicação no ecrã não cobre. A base de dados guarda informação adicional sobre a pergunta, mas o utilizador não a consegue consultar com perguntas em linguagem natural. As fontes externas e os assistentes genéricos podem dar respostas que contradizem o conteúdo validado do item ou que acrescentam informação alheia ao contexto.

O problema desta dissertação é conceber um assistente conversacional baseado em LLM que responda apenas com a informação que a base de dados guarda para cada pergunta. Essa informação inclui a vinheta, as opções, a catalogação, a resposta correta, a explicação, as dicas e a informação complementar. O assistente não deve recorrer a conhecimento externo e deve manter-se fiel a esse contexto. Também não deve responder a questões fora do âmbito da pergunta nem comprometer a integridade da avaliação.

O problema tem as seguintes características:

- **Modos com regras diferentes.** O QBank tem modos de estudo e de avaliação. Uma resposta que revele a resposta correta antes de o utilizador responder anula o exercício num modo de avaliação.
- **Multilinguismo.** Cada versão linguística do QBank tem o seu próprio conteúdo validado. Uma resposta tem de ser coerente com o conteúdo da língua em que o utilizador estuda.
- **Contexto fechado por item.** O contexto relevante é conhecido à partida: são os dados da pergunta em curso. Não é preciso procurá-lo num corpus de documentos.
- **Restrições a harmonizar.** A solução tem de conciliar as capacidades conversacionais do modelo com a fidelidade ao contexto, a qualidade da resposta, a segurança, o custo, a latência e a integração na plataforma. Numa conversa, o utilizador espera uma resposta em poucos segundos, e cada pedido a um modelo comercial tem um custo por *token*. Com algumas centenas de utilizadores e uma utilização desconhecida à partida, o custo e a latência de cada pedido são restrições de desenho e não apenas métricas de avaliação.
- **Várias partes interessadas.** Os utilizadores (estudantes, médicos e enfermeiros) e a Adhara, incluindo a equipa científica responsável pelo conteúdo.
- **Consequências.** Uma resposta fora do conteúdo validado pode induzir erros de aprendizagem e afetar a credibilidade da plataforma, a privacidade dos utilizadores e os custos de operação (Abd-alrazaq et al. 2023; Hu et al. 2025).

1.4 Objetivos

O objetivo geral é conceber, implementar e avaliar um assistente conversacional integrado no Adhara QBank. O assistente esclarece dúvidas sobre cada pergunta de escolha múltipla e usa apenas a informação da base de dados dessa pergunta.

Para atingir este objetivo, o trabalho define cinco objetivos específicos, cada um com uma evidência verificável:

O1 Sistematizar a literatura sobre assistentes conversacionais baseados em LLMs com respostas limitadas a um contexto definido, e sobre a avaliação dessas respostas. *Evidência:* revisão com protocolo, diagrama *Preferred Reporting Items for Systematic Reviews and Meta-Analyses* (PRISMA) e síntese por *Research Question* (RQ) (Capítulo 2).

O2 Levantar com a Adhara os requisitos, as regras por modo e os campos da base de dados que formam o contexto de cada pergunta. *Evidência:* requisitos e *backlog* revistos pela Adhara.

O3 Implementar e integrar o assistente no fluxo de resolução de perguntas do QBank. *Evidência:* versão integrada e demonstrada em perguntas reais.

O4 Aplicar as regras de cada modo e a recusa fora do âmbito, sem depender só das instruções ao modelo. *Evidência:* testes de âmbito e adversariais aprovados.

O5 Avaliar a correção, a fidelidade, a recusa, o comportamento em várias línguas, a latência, o custo e a utilidade percebida. *Evidência:* resultados da avaliação face aos critérios de sucesso definidos nos requisitos.

1.5 Questões de Investigação

Duas questões de investigação (RQs) orientam o trabalho. A revisão sistemática do Capítulo 2 responde-lhes, e as respostas orientam o desenho do assistente (objetivos O3 e O4) e a sua avaliação (objetivo O5):

RQ1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais reportam essas abordagens?

RQ2 Como avaliam estes sistemas a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

A RQ1 abrange a forma como o contexto chega ao modelo, os mecanismos de controlo do âmbito e de segurança e os compromissos de fiabilidade, latência, custo e integração. A RQ2 abrange os métodos, as métricas e os resultados da avaliação das respostas.

1.6 Abordagem Metodológica

O trabalho segue a metodologia *Design Science Research* (DSR), que produz conhecimento através da conceção e avaliação de um artefacto que resolve um problema relevante (Hevner et al. 2004). O trabalho segue as seis atividades propostas por Peffers et al. (2007):

1. **Identificação do problema e motivação**: caracterização do problema com a Adhara (Secções 1.1 e 1.3).
2. **Definição dos objetivos da solução**: objetivos e critérios de sucesso (Secção 1.4), apoiados na revisão da literatura (Capítulo 2).
3. **Desenho e desenvolvimento**: arquitetura do assistente e integração no QBank, em iterações sobre um *backlog* priorizado.
4. **Demonstração**: utilização do assistente em perguntas reais do QBank.
5. **Avaliação**: testes técnicos em várias línguas, avaliação por especialistas e questionário aos utilizadores.
6. **Comunicação**: esta dissertação.

Para construir o estado da arte, o autor conduziu uma revisão sistemática da literatura segundo as orientações de Kitchenham e Charters (2007) e relatou-a segundo o PRISMA 2020 (Page et al. 2021). O Capítulo 2 descreve o protocolo, a pesquisa, a seleção e a síntese.

1.7 Gestão de Riscos

O autor identificou os riscos do projeto no início do trabalho e classificou-os quanto à probabilidade (P) e ao impacto (I), numa escala de 1 (muito baixo) a 5 (muito alto). O nível de cada risco é o produto $P \times I$: baixo até 5, médio de 6 a 11 e alto a partir de 12. A Tabela 1.1 apresenta os riscos e as medidas de mitigação. Os riscos são revistos no fim de cada iteração do desenvolvimento.

1.8 Contribuições Esperadas

O trabalho pretende contribuir com:

- uma revisão sistemática sobre assistentes conversacionais baseados em LLMs com respostas limitadas a um contexto definido, em educação e saúde, com uma síntese dos mecanismos de contextualização, de controlo de âmbito e de avaliação (Capítulo 2);
- um assistente conversacional integrado no fluxo de resolução de perguntas do Adhara QBank, que responde na língua do QBank com a informação validada da pergunta em curso e respeita as regras de cada modo;
- uma abordagem para entregar ao modelo o contexto fechado de cada pergunta e para recusar questões sem suporte nesse contexto;
- um protocolo e um conjunto de testes para avaliar a correção, a fidelidade ao contexto, a capacidade de recusa, o comportamento multilingue, a latência e o custo do assistente.

1.9 Considerações Éticas e Profissionais

Códigos seguidos. Esta dissertação segue, na íntegra, o *Software Engineering Code of Ethics and Professional Practice* da ACM e da IEEE Computer Society (ACM/IEEE-CS Joint Task Force on Software Engineering Ethics and Professional Practices 1999), que

Tabela 1.1: Riscos do projeto, classificação e medidas de mitigação.

Id	Risco	P	I	P×I	Mitigação
R1	Respostas incorretas ou infiéis ao conteúdo validado da pergunta	3	5	15	Contexto fechado por pergunta; instruções de recusa; avaliação da fidelidade com perguntas de teste e por especialistas
R2	Custo do modelo elevado, com uma utilização do assistente desconhecida à partida	3	4	12	Estimativa de custo por pedido; contexto compacto; cache de respostas; limites de utilização; monitorização do consumo
R3	Tempo de resposta demasiado longo para uma conversa	3	4	12	Resposta em *streaming*; contexto compacto; cache; medição da latência desde o início do desenvolvimento
R4	Revelação da resposta correta ou desvio do âmbito por manipulação do *prompt*	3	4	12	Regras de cada modo aplicadas fora do modelo (por exemplo, não enviar dados ainda não revelados); testes adversariais
R5	Qualidade desigual entre as línguas do QBank	3	3	9	Conjunto de teste em todas as línguas; uso do conteúdo validado da língua do QBank
R6	Pouca disponibilidade de especialistas para a avaliação	3	3	9	Planear a avaliação cedo; usar uma amostra; LLM juiz como apoio, validado numa subamostra
R7	Alteração de preço, de modelo ou indisponibilidade do fornecedor da *Application Programming Interface* (API)	2	4	8	Camada de abstração do fornecedor; alternativa identificada; registo da versão do modelo usada
R8	Atraso no cronograma	3	3	9	*Backlog* priorizado; versão mínima funcional primeiro; acompanhamento com o orientador
R9	Crescimento da base de dados com a cache e os registos	2	2	4	Política de retenção; exportação e limpeza periódica

define princípios relativos ao interesse público, ao cliente e ao empregador, à qualidade do produto e à integridade do julgamento profissional. Segue também o Código Europeu de Conduta para a Integridade da Investigação (ALLEA 2023) e o Código de Boas Práticas e de Conduta do P.PORTO (Politécnico do Porto 2020).

Integridade da investigação. O trabalho não fabrica, não falsifica nem omite dados ou resultados. Os resultados da avaliação são apresentados na íntegra, incluindo os negativos, com as incertezas e as limitações que restam. Todas as referências existem, foram lidas e foram verificadas na fonte original através do DOI. As figuras de outros autores são reproduzidas com a indicação da fonte e da licença. Para que a revisão possa ser repetida, as expressões de pesquisa, os registos exportados, as decisões de seleção com o respetivo motivo e os *scripts* estão guardados e versionados (Apêndice A).

Enviesamento. A revisão foi feita por um único revisor, um risco de enviesamento discutido nas ameaças à validade (Secção 2.9). Na avaliação do assistente, o conjunto de teste e os critérios de sucesso são definidos antes de se conhecerem os resultados, para evitar o enviesamento de confirmação. Os resultados são reportados por língua, para que nenhuma língua do QBank fique em desvantagem sem que isso seja visível.

Dissertação numa empresa. O trabalho decorre ao abrigo de um protocolo de colaboração entre a Adhara e o ISEP. O conteúdo do QBank pertence à Adhara, é confidencial e o trabalho usa-o apenas neste projeto. A propriedade do código e dos resultados, e o que pode ser descrito na dissertação e em publicações, são acordados por escrito com a Adhara

no início da dissertação. O autor desenvolve e avalia um produto para a empresa onde decorre o trabalho, o que constitui um potencial conflito de interesses. Para o mitigar, a avaliação segue um protocolo definido à partida, inclui especialistas e utilizadores, e os resultados desfavoráveis são reportados.

Participação humana e dados pessoais. O questionário a utilizadores pede consentimento informado e explica o que é recolhido, porquê, durante quanto tempo e quem tem acesso. Recolhe apenas os dados necessários, guarda as respostas de forma anónima, em armazenamento institucional seguro, e nunca em contas pessoais nem em ferramentas de IA externas. O tratamento segue o Regulamento Geral sobre a Proteção de Dados (RGPD) (Parlamento Europeu e Conselho da União Europeia 2016) e as orientações do ISEP. O Código do P.PORTO pede os mais elevados padrões éticos na investigação que envolva pessoas, dados pessoais ou sistemas de IA, e a apreciação por uma comissão de ética quando a lei o exija (Politécnico do Porto 2020). A necessidade dessa apreciação para o questionário será confirmada com o orientador antes da recolha.

Impacto nos utilizadores. Uma resposta errada pode induzir erros de aprendizagem num domínio em que esses erros têm consequências. As preocupações éticas traduzem-se em comportamento do sistema: o assistente usa apenas o contexto validado da pergunta, recusa o que está fora do âmbito, não revela a resposta correta antes do tempo e é testado contra utilizações abusivas, como a manipulação do *prompt*. A correção das respostas é verificada por especialistas, porque o autor não tem formação médica. O assistente informa o utilizador de que interage com um sistema de IA, como exige o Regulamento da Inteligência Artificial da União Europeia (Parlamento Europeu e Conselho da União Europeia 2024).

Utilização de um modelo através de uma API externa. O desenho compara um LLM executado localmente com um LLM acedido através de uma API externa paga. Na segunda opção, o pedido do utilizador e o contexto da pergunta seguem para um serviço de terceiros. Para limitar os riscos:

- o sistema envia apenas os dados necessários para responder: a mensagem do utilizador, o histórico da conversa sobre a pergunta e os dados dessa pergunta; não envia dados que identifiquem o utilizador;
- a escolha do fornecedor considera as suas condições de tratamento de dados, em particular a retenção dos pedidos, a não utilização para treino e a localização do processamento; a relação com o fornecedor segue o RGPD (Parlamento Europeu e Conselho da União Europeia 2016);
- o envio do conteúdo do QBank a um fornecedor externo exige a autorização da Adhara, detentora desse conteúdo.

Registo das perguntas para fins estatísticos. O sistema poderá registar as perguntas feitas ao assistente e agrupá-las por tema, para fins estatísticos e de melhoria do conteúdo. Este registo terá uma finalidade definida, terá um prazo de conservação definido e será comunicado ao utilizador. Dados pseudonimizados continuam a ser dados pessoais. Por isso, ou o registo é anónimo, ou é tratado como dados pessoais segundo o RGPD.

Uso de ferramentas de IA generativa. O autor é o único responsável pelo conteúdo desta dissertação; as ferramentas de IA não são autoras. O autor usou o Claude, da Anthropic, através do Claude Code, nas seguintes tarefas:

- **Revisão da literatura**: escrita dos *scripts* de recolha, deduplicação e triagem; proposta de decisões de triagem por título e resumo; extração de dados dos textos integrais. O autor verificou cada decisão, que tem um motivo registado (Secção 2.2.2), e os valores extraídos nos textos originais. As decisões finais de inclusão e a avaliação da qualidade são do autor.
- **Escrita**: apoio à estrutura e à revisão linguística do texto. O julgamento sobre o conteúdo e as conclusões é do autor.
- **Desenvolvimento de software**: escrita, revisão e depuração de código, verificado pelo autor com testes.

O conteúdo do QBank e o código da Adhara não são enviados a ferramentas de IA externas sem a autorização da Adhara. O uso destas ferramentas é acordado com o orientador para cada tarefa. O próprio assistente usa um LLM para gerar as respostas, como descrito acima.

1.10 Estrutura do Documento

Além deste capítulo, o documento tem a seguinte estrutura. O Capítulo 2 apresenta o estado da arte: os fundamentos teóricos e uma revisão sistemática da literatura, com o protocolo, os resultados da pesquisa e da seleção, a síntese dos estudos e a lacuna de investigação. Os apêndices contêm o protocolo da revisão sistemática e a classificação dos estudos incluídos.

Capítulo 2

Estado da Arte

Este capítulo apresenta o estado da arte sobre assistentes conversacionais baseados em LLMs cujas respostas são limitadas a um contexto definido pela aplicação, com foco em educação e saúde. Começa por apresentar os fundamentos teóricos (Secção 2.1). Resume depois o método da revisão sistemática da literatura (Secção 2.2). As secções seguintes analisam os estudos por tema. A Secção 2.3 trata as arquiteturas de contextualização e a Secção 2.4 os mecanismos de controlo do âmbito e de segurança. A Secção 2.5 aborda as línguas, a latência e o custo, a Secção 2.6 a avaliação e a Secção 2.7 os sistemas mais próximos do caso de estudo. Seguem-se a lacuna de investigação que resulta desta análise (Secção 2.8), as ameaças à validade (Secção 2.9) e as conclusões do capítulo (Secção 2.10).

2.1 Fundamentos Teóricos

Esta secção apresenta os fundamentos do trabalho. Começa pelo papel das perguntas de escolha múltipla e do *feedback* na aprendizagem e pelos assistentes conversacionais. Segue-se o funcionamento dos LLMs: a sua evolução e as famílias de modelos, o seu uso em medicina, os modelos usados nos estudos da revisão, *tokens*, *prompts*, parâmetros de geração, conversas com vários turnos, *embeddings* e formas de execução. Por fim, trata as formas de fornecer contexto ao modelo, as suas limitações, o controlo do âmbito e a avaliação das respostas. Sempre que possível, cada conceito é ilustrado com os estudos encontrados na revisão sistemática. A literatura recente sobre sistemas concretos é analisada a partir da Secção 2.2, através da revisão sistemática.

2.1.1 Aprendizagem com Perguntas e Feedback

Responder a perguntas não serve apenas para avaliar: o esforço de recordar a informação melhora a retenção a longo prazo mais do que voltar a estudá-la, um fenómeno conhecido como efeito de teste (Roediger e Karpicke 2006). Este efeito foi também observado em educação médica, onde os testes frequentes são propostos como estratégia de aprendizagem e não só de avaliação (Larsen et al. 2008). Os bancos de perguntas como o QBank apoiam-se neste princípio.

O efeito da prática depende do *feedback* que se segue à resposta. Hattie e Timperley (2007) definem o *feedback* como a informação que ajuda o estudante a reduzir a distância entre o desempenho atual e o desejado, respondendo a três perguntas: para onde vou, como estou a ir e qual o passo seguinte. Shute (2008) conclui que o *feedback* elaborado, que explica porque é que uma resposta está certa ou errada, tende a ser mais eficaz do que a simples indicação de certo ou errado, e que deve ser específico e ajustado ao estudante. A

explicação de cada pergunta do QBank é um *feedback* elaborado, mas é igual para todos os utilizadores e não responde à dúvida concreta de cada um.

Um assistente conversacional permite aproximar esse *feedback* de uma tutoria individual, na qual o estudante pergunta o que não percebeu. A tutoria individual produz ganhos de aprendizagem superiores aos do ensino em grupo (Bloom 1984). Esta é uma das motivações para o uso de LLMs em educação médica, onde podem adaptar os conteúdos a cada estudante e condensar informação médica complexa (Hu et al. 2025). O mesmo enquadramento justifica as regras por modo: no modo Teste, um assistente que revele a resposta antes de o estudante responder anula o esforço de recordar, de que depende o efeito de teste.

2.1.2 Assistentes Conversacionais

Os assistentes conversacionais evoluíram de sistemas baseados em regras e padrões, como a ELIZA (Weizenbaum 1966), para sistemas que selecionam respostas de uma base de conhecimento e, mais recentemente, para sistemas generativos baseados em LLMs (Adamopoulou e Moussiades 2020). Podem ser classificados, entre outros critérios, pelo domínio (aberto ou fechado), pelo objetivo (informativo, orientado a tarefas ou de conversa livre) e pelo método de produção da resposta (regras, recuperação ou geração) (Adamopoulou e Moussiades 2020). Nesta classificação, o assistente do QBank é de domínio fechado, informativo e generativo. A sua particularidade é que o domínio não é o da plataforma em geral mas o da pergunta em curso: o contexto muda a cada item.

2.1.3 Modelos de Linguagem de Grande Dimensão

Os LLMs são redes neuronais com milhares de milhões de parâmetros, treinadas de forma autossupervisionada em grandes quantidades de texto não anotado (Raiaan et al. 2024). Baseiam-se na arquitetura *Transformer*, cujo mecanismo de autoatenção avalia a importância relativa de cada elemento do texto face aos restantes. Este mecanismo capta relações entre partes distantes do texto e permite treinar o modelo em paralelo (Raiaan et al. 2024; Shao et al. 2024). A Figura 2.1 mostra a arquitetura original, com um codificador, que transforma o texto de entrada numa representação, e um descodificador, que gera o texto de saída *token* a *token* a partir dessa representação e do que já gerou. As capacidades dos modelos resultam da sua dimensão, da quantidade de dados de treino e dos recursos de computação investidos, numa relação descrita por leis de escala (Cai et al. 2025). Algumas capacidades só surgem acima de certa dimensão (Wu et al. 2023). É o caso da aprendizagem em contexto (*In-Context Learning* (ICL)): o modelo executa uma tarefa descrita no *prompt*, com ou sem exemplos, sem atualizar os seus parâmetros. O GPT-3, apresentado em 2020 com 175 mil milhões de parâmetros, foi o primeiro modelo a ultrapassar os 100 mil milhões e introduziu esta capacidade (Wu et al. 2023). Os modelos são depois alinhados com as preferências humanas por aprendizagem por reforço com *feedback* humano: pessoas comparam respostas do modelo, essas comparações treinam um modelo de recompensa e este orienta o ajuste do modelo de linguagem (Wu et al. 2023). É esta capacidade de seguir instruções que permite definir o comportamento de um assistente através de instruções de sistema, mas as instruções orientam o modelo sem garantir que são cumpridas.

Evolução e famílias de modelos. Os LLMs dividem-se em três arquiteturas derivadas do *Transformer*: só com codificador, adequadas a tarefas de compreensão, como o BERT; só com descodificador, otimizadas para gerar texto, como a série GPT; e com codificador e descodificador (Raiaan et al. 2024; Shao et al. 2024). Os assistentes conversacionais usam

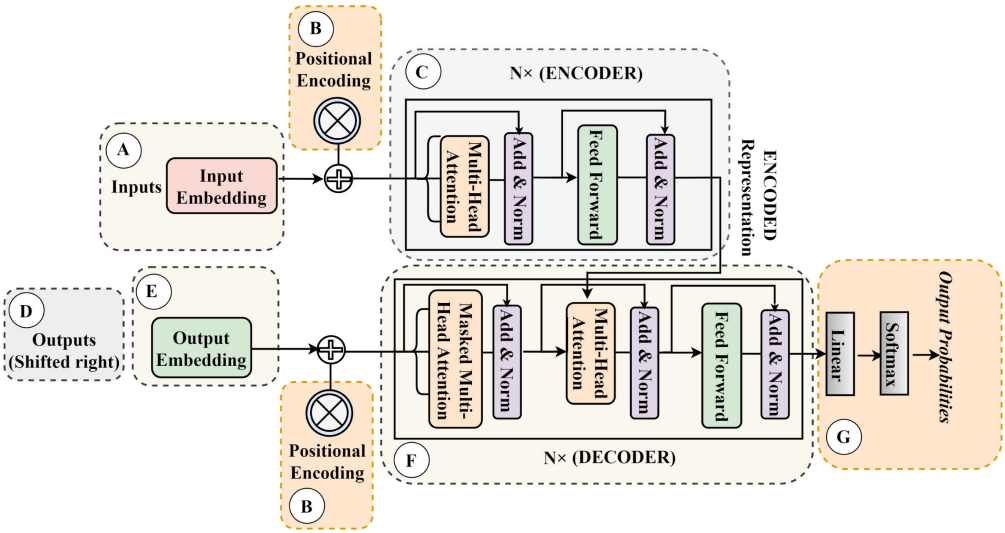


Figura 2.1: Arquitetura do *Transformer*: os *tokens* de entrada são convertidos em vetores (A) e somados a uma codificação da posição (B); o codificador (C) aplica camadas de atenção e de rede neuronal; o descodificador (F) gera a saída a partir dos *tokens* já gerados (D, E) e da representação do codificador; a camada final (G) dá a probabilidade de cada *token* seguinte.
Fonte: reproduzido de Raiaan et al. (2024), licença CC BY-NC-ND 4.0.

a segunda. A Figura 2.2 mostra a evolução dos principais modelos entre 2018 e 2024, agrupados por estas três arquiteturas: o ramo só com descodificador, onde estão o GPT, o LLaMA e o Mistral, concentra a maior parte dos modelos lançados desde 2021. O ChatGPT, lançado no fim de 2022, juntou estas técnicas: um modelo pré-treinado de grande escala da série GPT-3.5, a aprendizagem em contexto e o alinhamento com *feedback* humano (Wu et al. 2023). A partir daí, os modelos seguiram dois caminhos. Os modelos comerciais, como o Gemini ou o Copilot, são usados como serviço, através de uma API ou de uma interface própria (Elkin et al. 2026). Os modelos de pesos abertos podem ser descarregados e executados pela própria organização. O LLaMA, da Meta, foi disponibilizado com 7 a 65 mil milhões de parâmetros para poder ser executado localmente, embora sem superar claramente o GPT-3 (Shao et al. 2024). Para crescer sem aumentar na mesma proporção o custo de cada resposta, vários modelos abertos adotaram a mistura de especialistas, em que cada *token* ativa apenas uma parte da rede. O Mixtral-8x7B usa apenas 13 mil milhões de parâmetros ativos e iguala ou supera o Llama-2-70B e o GPT-3.5 em vários *benchmarks* (Cai et al. 2025). Adaptar estes modelos a um domínio também é caro: o ajuste completo do Llama-3.1-405B exige cerca de 3,25 TB de memória (Xu et al. 2026b). As técnicas de ajuste eficiente treinam apenas uma pequena parte dos parâmetros. O LoRA congela os pesos originais e treina matrizes de baixa dimensão inseridas nas camadas do *Transformer* (Figura 2.3); no GPT-3, isso corresponde a cerca de 0,01% dos parâmetros e reduz a memória da placa gráfica a um terço da do ajuste completo, com resultados comparáveis (Feng et al. 2025).

Modelos de linguagem em medicina. Os LLMs têm sido avaliados com perguntas de escolha múltipla de exames médicos, como as do exame de licenciamento médico dos Estados Unidos (USMLE) e do *benchmark* MedQA, construído a partir delas (Hu et al. 2025). Os modelos mais recentes têm resultados elevados. Em 427 perguntas de um exame médico

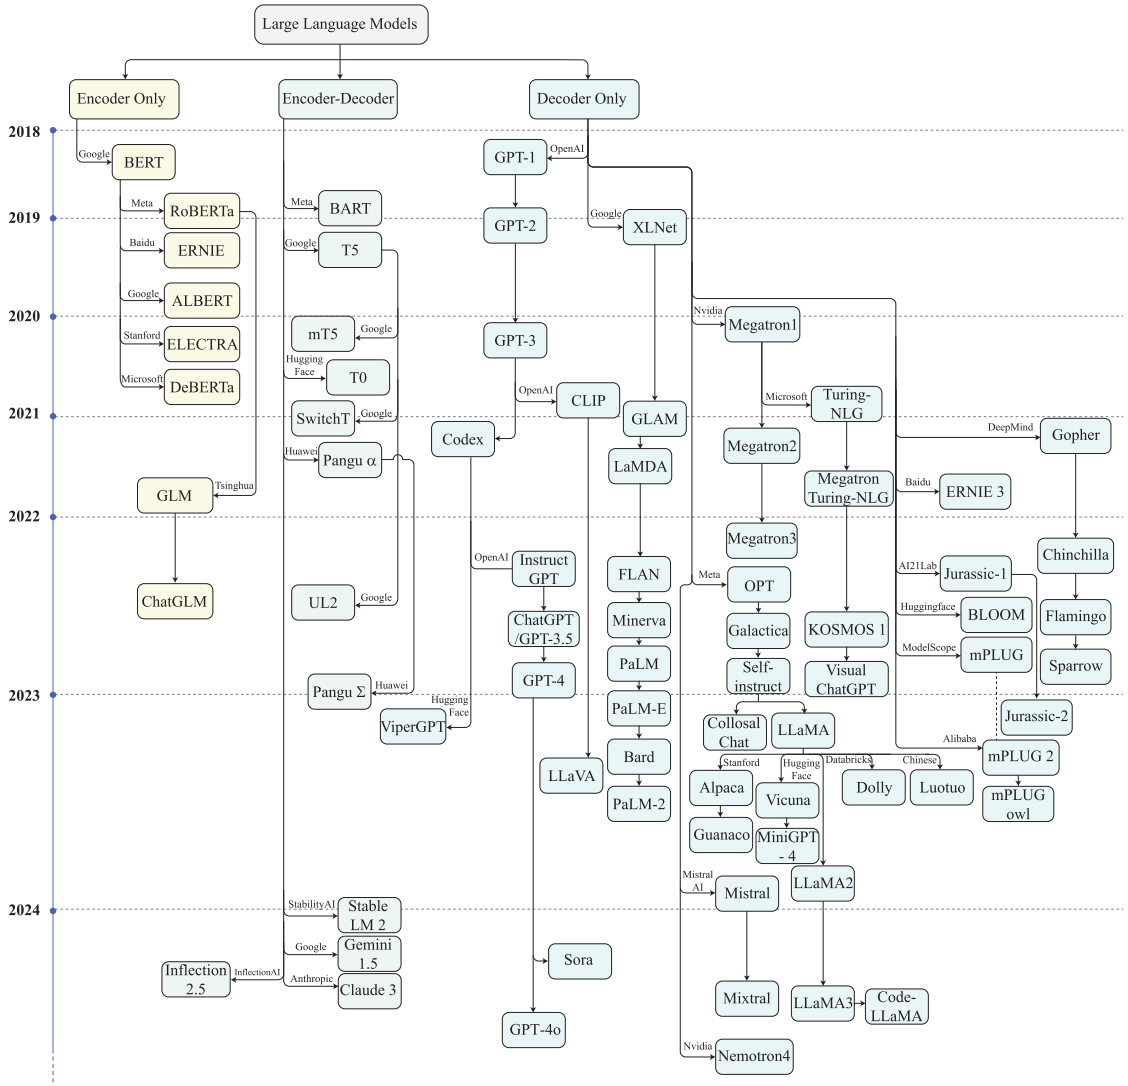


Figura 2.2: Evolução dos principais LLMs entre 2018 e 2024, agrupados por arquitetura: só com codificador, com codificador e descodificador, e só com descodificador. As linhas ligam modelos da mesma linhagem ou da mesma organização. Fonte: reproduzido de Shao et al. (2024), licença CC BY-NC-ND 4.0.

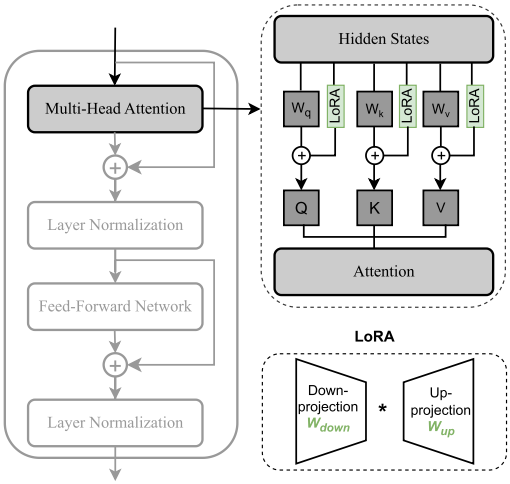


Figura 2.3: Ajuste fino com LoRA: os pesos da atenção (W_q, W_k, W_v) ficam congelados e só são treinadas as matrizes de baixa dimensão acrescentadas ao lado deles, que projetam a entrada para uma dimensão pequena e de volta à original. Fonte: reproduzido de Xu et al. (2026b) (painel c da Figura 3), licença CC BY 4.0.

indiano, o GPT-4 Turbo acertou cerca de 93% e o Gemini Advanced e o LLaMA 3.1 de 70 mil milhões de parâmetros cerca de 87% (Pattanshetti et al. 2025). Em 313 perguntas de exemplo do USMLE, o Gemini acertou 90,7%, o Copilot 93,6% e o Llama 3 de 70 mil milhões de parâmetros 82,4% (Elkin et al. 2026). Nesse estudo, um modelo destilado de um modelo de raciocínio ficou-se pelos 55,3%, o que levou os autores a concluir que um bom desempenho geral em raciocínio não significa preparação para a saúde. Os modelos pequenos executados localmente ficam bastante abaixo: o Mistral de 7 mil milhões de parâmetros acertou 42,7% no MedQA (Ahmed e Sadka 2026). Estes resultados mostram que os modelos gerais têm conhecimento médico. Os riscos de alucinação e de informação não factual exigem, contudo, validação clínica antes do uso em saúde (Ali et al. 2023). Os próprios *benchmarks* médicos têm limitações: cenários pouco complexos, pouca cobertura de dados reais, dificuldade em avaliar respostas abertas e pouca diversidade linguística e cultural (Hu et al. 2025). Para o QBank, a diferença é importante: os *benchmarks* medem a capacidade de escolher a resposta correta, enquanto o assistente tem de explicar uma resposta já validada sem a contradizer. Um modelo com bom conhecimento médico pode, aliás, preferir o seu conhecimento ao conteúdo da pergunta (Secção 2.1.10).

Modelos usados nos estudos da revisão. A Tabela 2.1 agrupa os modelos usados nos 38 estudos incluídos na revisão sistemática (Secção 2.2). Há um padrão claro. Os sistemas usados por estudantes reais recorrem a modelos proprietários por API (Buti e Mohamed 2026; Feng et al. 2024; Liu et al. 2026b; Miroyan et al. 2025; Seshadri et al. 2026). Os protótipos executados localmente usam modelos de pesos abertos de 8 a 13 mil milhões de parâmetros, quantizados para caberem numa placa gráfica, por razões de privacidade e custo (Azam et al. 2024; Khan et al. 2025; Sayeed et al. 2026; Sbai et al. 2025). O preço desta opção é a latência: a explicação de soluções de exame com um modelo local de 8 mil milhões de parâmetros demorou 9,35 s (Khan et al. 2025). Os estudos que comparam modelos sugerem que o contexto pesa mais do que o modelo escolhido. Com

RAG sobre diretrizes clínicas, as diferenças entre o GPT, o DeepSeek e o Qwen não foram estatisticamente significativas (Raputri et al. 2025). Os autores do AskNow compararam o Claude 3.5 Haiku, o GPT-4o-mini e o GPT-4o e escolheram o GPT-4o pelo equilíbrio entre exatidão e custo (Liu et al. 2026b).

Tabela 2.1: Famílias de LLMs usadas nos 38 estudos incluídos na revisão.

Família	**Acesso**	**Utilização nos estudos**
GPT (OpenAI)	API	GPT-4 em sistemas usados por estudantes (Feng et al. 2024; Miroyan et al. 2025; Seshadri et al. 2026); GPT-4o e GPT-4o-mini na geração (Christiawan et al. 2025; Liu et al. 2026b; Zhang e Shafiq 2025); GPT-4 e GPT-4o como juízes (Bellard et al. 2025; Liao et al. 2026)
Gemini (Google)	API	Geração e juiz num assistente académico (Buti e Mohamed 2026); juiz da correção (Nurfadhilah et al. 2025)
DeepSeek	API ou pesos abertos	DeepSeek-V3 por API (Yan e Shi 2026); DeepSeek-R1 de 8 mil milhões de parâmetros, quantizado e local (Sbai et al. 2025); comparado com o GPT e o Qwen (Raputri et al. 2025)
Llama (Meta)	Pesos abertos	Modelos de 3 a 13 mil milhões de parâmetros, muitas vezes quantizados (Azam et al. 2024; Hamidi e Roberts 2026; Khan et al. 2025; Zheng et al. 2026); variante médica (Rahat et al. 2026); variante adaptada ao indonésio (Nurfadhilah et al. 2025); modelo de guarda Llama Guard 3 (Walczak e Sawicki 2026)
Qwen (Alibaba)	Pesos abertos	Qwen3 de 8 mil milhões de parâmetros (Sayeed et al. 2026; Xie et al. 2026); Qwen2 de 72 mil milhões (Tawfik et al. 2025)
Mistral	Pesos abertos	Mistral-Small de 22 mil milhões de parâmetros, com ajuste fino (Hamidi e Roberts 2026)
Classificadores pequenos	Pesos abertos	RoBERTa ajustado para detetar injeção de instruções (Mathew et al. 2026)

2.1.4 Tokens, Janela de Contexto e Línguas

Os LLMs não processam palavras, mas *tokens*. Estes podem ser caracteres, sub-palavras, símbolos ou palavras, conforme o modelo, e são obtidos por algoritmos de segmentação como o WordPiece, o UnigramLM ou o *byte-pair encoding* (Raiaan et al. 2024). Cada *token* recebe um identificador numérico, que o modelo converte num vetor. Cada modelo aceita um número máximo de *tokens* por pedido, a janela de contexto. Nos modelos comparados por Raiaan et al. (2024), esta janela ia de 512 *tokens* a 32 768 no GPT-4. Num dos estudos da revisão, a janela de 4096 *tokens* do modelo local limitou o contexto que era possível incluir (Azam et al. 2024). Nas APIs comerciais, o custo é calculado pelo número de *tokens* de entrada e de saída, e o tempo de resposta cresce com o comprimento da resposta, que é gerada *token* a *token*. A quantidade de dados da pergunta incluída no *prompt* afeta, assim, diretamente o custo e a latência.

Ter a informação no contexto não garante que o modelo a use bem. A ordem do conteúdo no *prompt* e a sua formulação podem alterar significativamente a resposta (Hu et al. 2025). Em conversas longas, a janela de contexto fixa impede o modelo de usar todo o histórico (Hu et al. 2025). Para o QBank, isto significa que a ordem dos campos da pergunta no *prompt* e o tamanho do histórico enviado são decisões de desenho a avaliar.

A segmentação em *tokens* e o desempenho dos modelos também dependem da língua. Raiaan et al. (2024) apontam a sensibilidade à tokenização como um dos desafios dos LLMs, e tornar os modelos eficazes em línguas com menos recursos e dados como um problema em aberto. Os *benchmarks* médicos têm, além disso, pouca diversidade linguística e cultural (Hu et al. 2025). Os estudos da revisão que trabalham com várias línguas confirmam diferenças entre línguas. Num assistente para estudantes em inglês e em variantes do árabe, a precisão da recusa variou entre línguas (Abrar et al. 2025). Num sistema com árabe, francês e inglês, o árabe exigiu ferramentas próprias para extrair o texto dos documentos (Sbai et al. 2025). As línguas do QBank são de recursos elevados, mas o custo, o tempo de resposta e a qualidade de uma mesma pergunta podem variar entre elas, incluindo entre as variantes europeia e brasileira do português. Por isso, devem ser medidos por língua e não apenas em média.

2.1.5 Prompts e Parâmetros de Geração

Nas APIs de conversação, o pedido ao modelo é uma lista de mensagens com papéis distintos: as instruções de sistema, que definem o comportamento e as regras do assistente; as mensagens do utilizador; e as respostas anteriores do assistente. O contexto da aplicação (no QBank, os dados da pergunta) é incluído numa destas mensagens. A Figura 2.4 mostra um exemplo, retirado do EchoMind (Xu et al. 2026a): o *prompt* (d) junta as instruções de sistema, o histórico da conversa e o contexto obtido para a pergunta, e o modelo devolve uma resposta estruturada com uma pontuação de confiança (f). A engenharia de *prompts* consiste em desenhar e otimizar estas entradas para que o modelo produza respostas que cumpram requisitos específicos, sem treino com dados do domínio (Hu et al. 2025). Sobre esta estrutura aplicam-se três técnicas. A primeira dá ao modelo exemplos do comportamento pretendido (*few-shot*) ou apenas a descrição da tarefa (*zero-shot*), as formas básicas de aprendizagem em contexto (Wu et al. 2023). A segunda pede uma cadeia de passos intermédios de raciocínio antes da resposta (*chain-of-thought*), que melhora a resolução de problemas aritméticos, de senso comum e de lógica (Wu et al. 2023). A terceira pede uma saída estruturada, por exemplo em JSON, que o sistema pode validar e processar. Os estudos da revisão usam todas estas técnicas: exemplos para rejeitar evidência contraditória (Rahat et al. 2026), raciocínio e verificação passo a passo (Ishadya et al. 2026) e saídas em JSON para a avaliação por um LLM juiz (Buti e Mohamed 2026).

A geração depende também de parâmetros de amostragem. Para cada posição, o modelo produz uma distribuição de probabilidade sobre o *token* seguinte. A temperatura controla a concentração dessa distribuição e, com ela, a variação das respostas entre execuções. A Figura 2.5 ilustra o seu efeito. Ahmed e Sadka (2026) avaliaram o mesmo modelo com temperatura 0,7, para reproduzir a variação esperada no uso real, e com temperatura 0, para eliminar a variação aleatória e permitir comparações estatísticas emparelhadas. Temperaturas baixas tornam as respostas previsíveis e repetíveis, como convém a um assistente que segue um contexto validado. Os estudos da revisão usam temperaturas de 0 a 0,1 na geração (Xie et al. 2026; Yan e Shi 2026) e nos juízes de avaliação (Bellard et al. 2025; Buti e Mohamed 2026). Alguns limitam também a escolha aos *tokens* mais prováveis (*top-p*): o agente de Yan e Shi (2026) usou temperatura 0,1 e *top-p* 0,95. O raciocínio passo a passo, por outro lado, aumenta o número de *tokens* gerados e, portanto, a latência: o modelo de guarda que raciocinava antes de decidir demorou 10,6 s por pedido, contra 207 ms do que devolvia apenas a categoria (Walczak e Sawicki 2026).

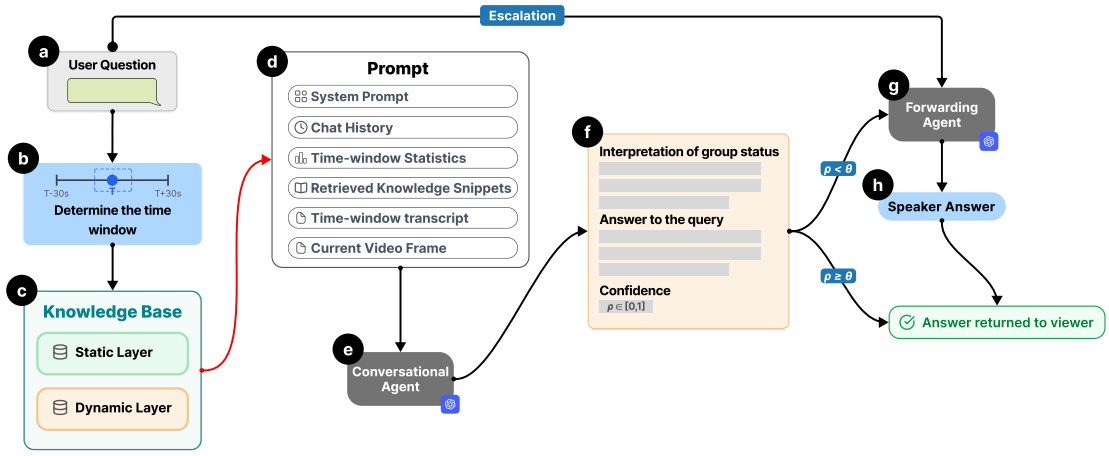


Figura 2.4: Construção do *prompt* no EchoMind: a pergunta do utilizador (a) determina o excerto relevante (b); o contexto obtido da base de conhecimento (c) é junto às instruções de sistema e ao histórico da conversa num *prompt* estruturado (d), enviado ao agente conversacional (e). Fonte: reproduzido de Xu et al. (2026a), licença CC BY 4.0.

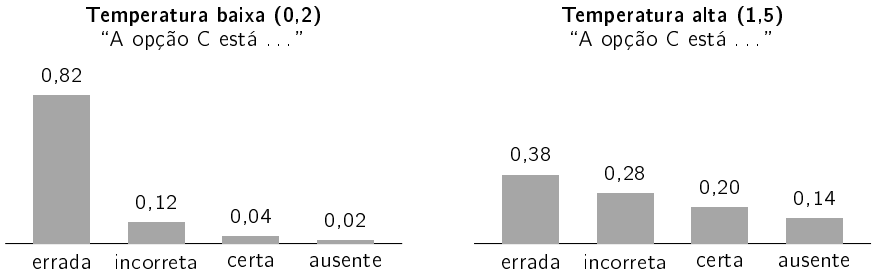


Figura 2.5: Efeito ilustrativo da temperatura na probabilidade do *token* seguinte: com temperatura baixa, a escolha concentra-se no *token* mais provável; com temperatura alta, as alternativas ganham peso e as respostas variam mais entre execuções. As probabilidades são valores fictícios, não medidos. Fonte: elaboração própria.

2.1.6 Conversas com Vários Turnos e Cache

Os modelos acedidos por API não guardam estado entre pedidos. Para manter uma conversa, a aplicação reenvia o histórico relevante em cada turno. Por isso, o número de *tokens*, o custo e a latência crescem com a conversa. Os estudos da revisão limitam este crescimento de duas formas: truncam o histórico a um número máximo de turnos (Yan e Shi 2026) ou enviam apenas a parte nova do contexto (Liu et al. 2026b). No QBank, cada conversa está associada a uma pergunta, o que limita naturalmente o seu tamanho. Para reduzir custo e latência pode também guardar-se em *cache* a resposta a pedidos repetidos; no ChatTEDU, as respostas em *cache* e as rejeições antecipadas reduziram o custo da arquitetura com dois modelos (Emekci e Budakoglu 2025). Muitos utilizadores resolvem a mesma pergunta do QBank, pelo que as dúvidas semelhantes tendem a repetir-se. A *cache* tem, contudo, de respeitar a língua e o modo em que a resposta foi gerada.

2.1.7 Representações Vetoriais e Semelhança Semântica

Os *embeddings* de palavras representam cada palavra num espaço vetorial contínuo, de forma que as relações semânticas fiquem expressas na posição dos vetores. Estas representações servem para medir a semelhança entre palavras e para as agrupar por domínio semântico (Raiaan et al. 2024). Os modelos de *embeddings* usados nos estudos da revisão aplicam o mesmo princípio a textos inteiros: convertem cada excerto ou pergunta num vetor de dimensão fixa, por exemplo de 1536 dimensões (Christiawan et al. 2025), e comparam os vetores pela semelhança do cosseno (Azam et al. 2024; Rahat et al. 2026). Esta representação é a base da recuperação densa no RAG, mas tem outros usos. O AskNow agrupa as perguntas dos estudantes por semelhança e mostra ao docente, em tempo real, os temas com mais dúvidas (Liu et al. 2026b). O Alan apresenta aos docentes as perguntas mais frequentes (Seshadri et al. 2026). É este o uso previsto no QBank para as estatísticas das perguntas feitas ao assistente. A Figura 2.6 mostra a interface do docente no AskNow, com perguntas reais agrupadas por tema (b) e os temas mais frequentes (c). A semelhança semântica tem, contudo, limites: não distingue um excerto que contém a resposta de outro que apenas trata o mesmo tema (Rahat et al. 2026), e falha quando o contexto certo depende de um identificador exato (Wei et al. 2026).

2.1.8 Execução Local e por API

Um LLM pode ser executado localmente, com modelos de pesos abertos, ou acedido como serviço através de uma API. A execução local dá controlo sobre os dados, mas exige memória gráfica proporcional ao tamanho do modelo; o GPT-3, por exemplo, ocupa cerca de 350 GB (Lang et al. 2024). Para a reduzir, os pesos são quantizados, isto é, representados com menos bits, por exemplo inteiros de 8 bits em vez de números de vírgula flutuante de 32 bits (Lang et al. 2024). A perda de qualidade depende do método e do número de bits: num estudo com LLMs médicos, a quantização a 4 bits manteve a exatidão próxima da original, enquanto a 3 e a 2 bits a perda foi progressivamente maior (Tasfia et al. 2026). Na revisão, os estudos com execução local usaram modelos de 8 a 13 mil milhões de parâmetros quantizados a 4 bits, por exemplo numa placa gráfica de 16 GB (Azam et al. 2024; Sayeed et al. 2026). No estudo de Walczak e Sawicki (2026), a quantização a 8 bits reduziu a memória de 15,6 para 9,0 GB sem perda de F1, mas a quantização a 4 bits degradou a qualidade. A API dispensa infraestrutura própria e dá acesso a modelos maiores, com um custo por *token*, mas implica enviar os dados a terceiros, pelo que a escolha do fornecedor deve considerar as suas políticas de retenção e de treino (Barzanji et al. 2026). Também

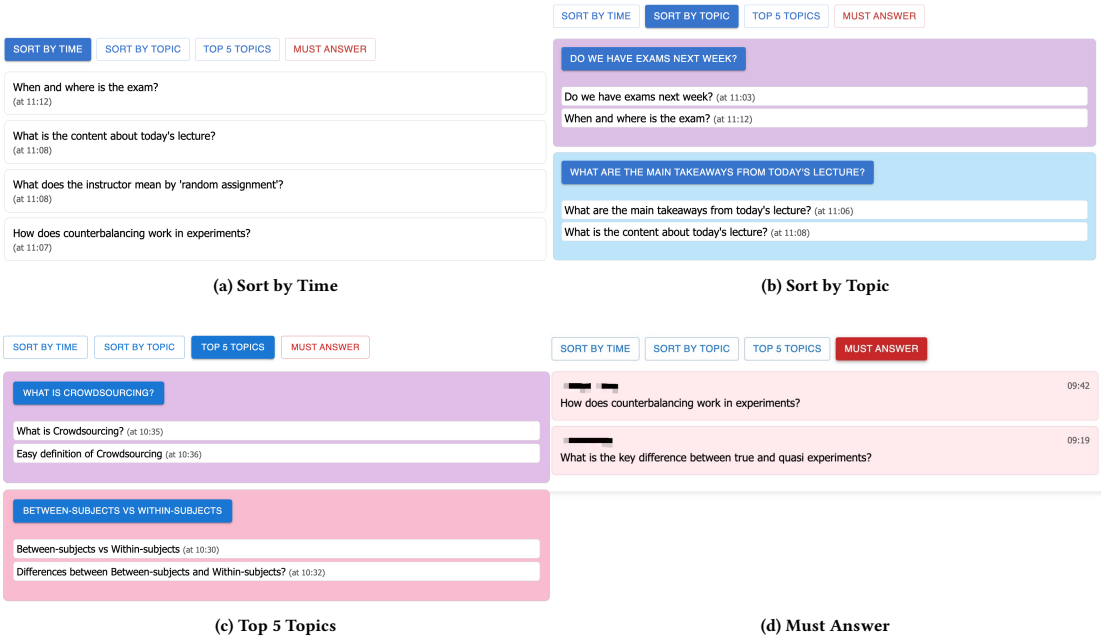


Figura 2.6: Interface do docente no AskNow, em uso real: (a) perguntas por ordem temporal; (b) perguntas agrupadas por semelhança (*embeddings* e K-means); (c) os cinco temas mais frequentes; (d) perguntas marcadas pelos estudantes para resposta do docente, com os nomes ocultados. Fonte: reproduzido de Liu et al. (2026b), licença CC BY 4.0.

limita os mecanismos disponíveis: técnicas que exigem acesso aos parâmetros ou aos estados internos, como o ajuste fino para recusa ou a monitorização interna (Abrar et al. 2025; Li et al. 2026), deixam de ser possíveis ou ficam dependentes do que o fornecedor oferece.

2.1.9 Formas de Fornecer Contexto ao Modelo

Os LLMs respondem a partir do conhecimento guardado nos seus parâmetros. A geração aumentada por recuperação (RAG) combina esse conhecimento com fontes externas: o sistema pesquisa numa base de conhecimento os excertos mais relevantes para a pergunta do utilizador e inclui-os no *prompt* antes da geração (Hu et al. 2025). Esta técnica surgiu como forma de reduzir as alucinações (Wu et al. 2023). Em medicina, permite que modelos mais pequenos superem modelos maiores em *benchmarks* (Hu et al. 2025). Em alternativa, quando o contexto relevante é conhecido à partida, pode ser incluído diretamente no *prompt*, sem pesquisa. Esta forma de condicionar o modelo pelo contexto do *prompt*, sem alterar os seus parâmetros, enquadra-se na aprendizagem em contexto (ICL). No QBank, o contexto é o registo da pergunta em curso, identificado pelo seu ID, pelo que não existe uma etapa de recuperação. Ambas as abordagens dependem de o modelo usar o contexto fornecido e não o seu conhecimento interno. A Figura 2.7 compara as duas: a diferença está no passo destacado, em que a pesquisa por semelhança, sujeita a erros de recuperação, é substituída pela leitura direta do registo do item. Uma terceira alternativa, o ajuste fino (*fine-tuning*), altera os parâmetros do modelo com dados do domínio. Não é adequada ao caso, porque o conhecimento teria de ser atualizado sempre que o conteúdo muda e não garante que a resposta se limita a um item.

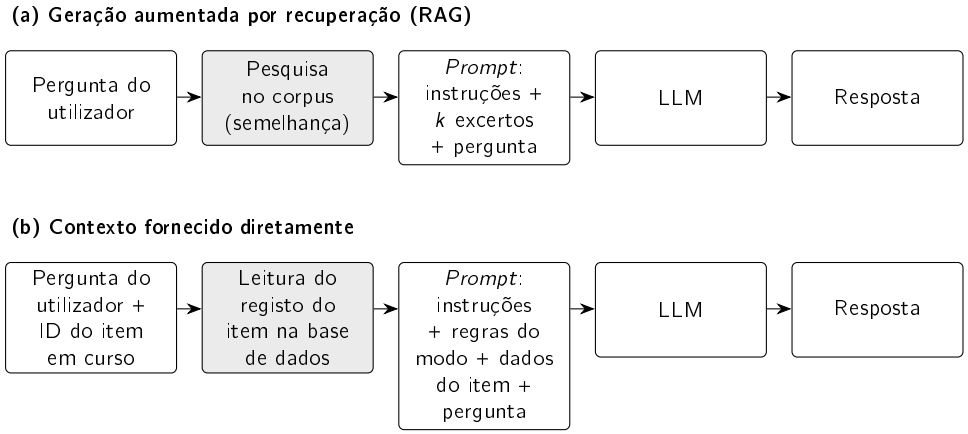


Figura 2.7: Duas formas de fornecer contexto ao modelo: (a) recuperação a partir de um corpus; (b) leitura direta dos dados da pergunta em curso. Fonte: elaboração própria, com base em Hu et al. (2025).

A Tabela 2.2 compara as abordagens segundo os critérios relevantes para o QBank, com a evidência encontrada na revisão.

Tabela 2.2: Comparação das formas de limitar as respostas a um contexto, à luz do caso do QBank.

Critério	RAG	Ajuste fino	Contexto direto por item
Seleção do contexto	Pesquisa por semelhança; pode trazer contexto que distrai ou contradiz (Rahat et al. 2026; Xie et al. 2026)	Não há contexto: o conhecimento fica nos parâmetros	Exata, pelo identificador da pergunta (Wei et al. 2026)
Efeito na exatidão	Varia: pode ficar abaixo do modelo sem contexto (Xie et al. 2026)	Alto em tarefas fechadas (Hamidi e Roberts 2026); pode piorar o uso de contexto (Zheng et al. 2026)	Próximo do contexto correto: 68,8% contra 27,0% sem contexto (Rahat et al. 2026)
Atualização do conteúdo	Reindexar os documentos	Voltar a treinar	Imediata: lê o registo atual
Rastreabilidade	Citação dos excertos recuperados (Seshadri et al. 2026)	Fraca	Total: os campos do item
Custo e latência	Recuperação, reordenação e contexto mais longo	Treino inicial; inferência barata	Só a geração; depende do tamanho do item
Limite	Qualidade da recuperação	Acesso ao modelo; não restringe a um item	Só serve quando o contexto é conhecido à partida

2.1.10 Alucinação, Fidelidade e Recusa

Um LLM gera texto plausível a partir do conhecimento adquirido no treino e do texto que recebe no *prompt*. Designa-se por alucinação a geração de informação plausível mas incorreta, um risco sério em contexto clínico (Hu et al. 2025). Pode resultar de erros e de ruído nos dados de treino, e o funcionamento interno do modelo não permite explicar porque é que gerou uma dada resposta (Wu et al. 2023). Num assistente com contexto, interessa também outra propriedade: a fidelidade, isto é, se as afirmações da resposta são suportadas pelo contexto fornecido. A métrica de fidelidade do *Retrieval Augmented Generation Assessment* (RAGAS), por exemplo, decompõe a resposta em afirmações e

verifica se cada uma decorre do contexto (Nurfadhilah et al. 2025). O conhecimento do modelo pode entrar em conflito com o contexto. Para o testar, Jain et al. (2025) usaram manuais em que factos-chave foram alterados de forma sistemática e verificaram se o sistema seguia o texto ou o conhecimento do modelo. No caso do QBank, a propriedade mais relevante é a fidelidade: o assistente deve responder com base nos dados validados da pergunta, mesmo que o modelo tenha conhecimento próprio diferente.

Uma forma de reduzir respostas sem suporte é o modelo abster-se quando o contexto não contém a informação necessária. Nos estudos da revisão, a abstenção é pedida explicitamente nas instruções. Ishadya et al. (2026) impuseram uma frase de abstenção fixa, o que permite medir a taxa de abstenção automaticamente. Hamidi e Roberts (2026) incluíram perguntas sem resposta no documento, em que a abstenção correta conta como acerto, e classificaram os erros em abstenções indevidas e respostas a perguntas sem resposta. A recusa tem também um custo: o assistente de Abrar et al. (2025) recusou muitos pedidos legítimos. Num assistente de contexto fechado, a recusa tem, assim, de ser pedida nas instruções e avaliada nos dois sentidos, com perguntas cuja resposta não está no contexto e com perguntas legítimas.

2.1.11 Controlo do Âmbito e Segurança

Um assistente de âmbito restrito deve recusar pedidos fora desse âmbito (abstenção ou recusa). As instruções que definem esse âmbito podem ser contornadas por mensagens escritas para isso: a injeção de instruções (*prompt injection*) e o *jailbreak* (Kavitha et al. 2026; Tien e Huong 2024). Estes ataques acontecem em sistemas reais. Num assistente institucional público, 180 das 4501 interações registadas no período de matrículas foram tentativas maliciosas, 15% delas noutras línguas que não o inglês (Emekci e Budakoglu 2025). Os mecanismos de defesa incluem filtros de entrada e de saída, modelos classificadores dedicados (*guardrails*) e arquiteturas com mais do que um modelo (Emekci e Budakoglu 2025; Kavitha et al. 2026; Walczak e Sawicki 2026).

Os objetivos destes ataques incluem desviar o assistente do seu tema e levá-lo a revelar as suas instruções. A taxonomia de ameaças usada por Walczak e Sawicki (2026) inclui, ao lado da injeção de instruções, uma categoria própria para a restrição de tema. O conjunto de teste de Buti e Mohamed (2026) inclui pedidos para extrair as instruções de sistema, ao lado de perguntas fora do âmbito e ambíguas. No QBank, uma fuga com consequências seria revelar a resposta correta no modo Teste. Daqui resulta uma implicação para o desenho: a informação que não pode ser revelada não deve estar no *prompt*, porque nenhuma instrução garante que o modelo não a revela.

2.1.12 Avaliação de Respostas

A avaliação de sistemas de resposta com contexto combina cinco abordagens: métricas de referência (exatidão, F1, semelhança semântica); métricas de fidelidade ao contexto, como as do RAGAS (Christiawan et al. 2025; Nurfadhilah et al. 2025); um LLM juiz (*LLM-as-a-judge*) (Bellard et al. 2025; Buti e Mohamed 2026); especialistas; e estudos com utilizadores.

Estas abordagens têm custos e limitações diferentes. As métricas de referência exigem respostas de referência e penalizam formulações corretas mas diferentes. As métricas de fidelidade, como a do RAGAS, decompõem a resposta em afirmações e verificam se cada uma é suportada pelo contexto, sem precisar de uma resposta de referência (Nurfadhilah et al. 2025). Um LLM juiz permite avaliar muitas respostas a baixo custo, mas o seu

julgamento também pode errar. Buti e Mohamed (2026) reconhecem que o seu juiz não foi validado contra avaliadores humanos. Liao et al. (2026) calibraram o juiz com um subconjunto verificado por humanos e corrigiram os resultados com as taxas de erro do juiz nesse subconjunto. Um juiz deve, por isso, ser validado com avaliação humana numa amostra. A avaliação por especialistas é a referência para a correção em contexto médico, mas é cara. A utilidade percebida e a usabilidade avaliam-se junto dos utilizadores, por exemplo com a escala *System Usability Scale* (SUS) (Brooke 1996).

2.2 Método da Revisão Sistemática

Para identificar o estado da arte de forma sistemática e repetível, foi conduzida uma revisão sistemática da literatura segundo as orientações de Kitchenham e Charters (2007), relatada segundo o PRISMA 2020 (Page et al. 2021). Esta secção resume o método; o protocolo completo, incluindo a estruturação *Population, Intervention, Comparison, Outcomes, Context* (PICOC), a pesquisa piloto, o registo da pesquisa por fonte e os campos de extração, está no Apêndice A.

2.2.1 Questões, Fontes e Expressões de Pesquisa

A revisão responde às duas questões de investigação definidas no Capítulo 1:

RQ1 Como utilizam os sistemas conversacionais baseados em LLMs um contexto específico da aplicação para limitar as respostas, e que compromissos operacionais são reportados para essas abordagens?

RQ2 Como são avaliadas, nestes sistemas, a correção factual, a fidelidade ao contexto fornecido e a adesão ao âmbito definido?

Foram pesquisadas três fontes: IEEE Xplore, ACM Digital Library e Scopus. Cada questão é coberta por duas expressões de pesquisa (Tabela 2.3): a RQ1 pela Q1 (contexto) e pela Q3 (segurança do âmbito); a RQ2 pela Q2 (fidelidade e correção) e pela Q4 (recusa fora do âmbito). As expressões foram aplicadas ao título, ao resumo e às palavras-chave, para publicações de 2021 a 2026, e executadas a 2 de novembro de 2026. Foram exportados todos os resultados. A janela de cinco anos começa depois da apresentação do GPT-3, em 2020, que introduziu a aprendizagem em contexto em modelos de grande escala, e inclui o lançamento do ChatGPT, no fim de 2022 (Wu et al. 2023). Cobre assim o período em que os assistentes baseados em LLMs com contexto da aplicação passaram a ser estudados e usados.

2.2.2 Critérios e Seleção

A Tabela 2.4 apresenta os critérios de seleção. O critério I3 delimita o foco a educação e saúde, os domínios do QBank, e exige que a resposta dependa de um contexto definido, seja ele recuperado ou fornecido diretamente. Excecionalmente, foram incluídos três estudos de outros domínios que avaliam diretamente o efeito do contexto incluído no *prompt*, por ser essa a técnica do caso de estudo.

O critério I5 restringe a revisão aos estudos mais próximos do caso de estudo, para que todos os incluídos possam ser lidos integralmente. Um estudo cumpre o I5 se tiver pelo menos uma das seguintes características: (a) contexto fechado e próximo do QBank, como perguntas de exame ou de escolha múltipla, materiais de um curso ou um documento específico; (b)

Tabela 2.3: Expressões de pesquisa e questões a que respondem.

Id	RQ	Expressão
Q1	RQ1	("large language model"OR LLM) AND (grounding OR "context injection"OR "prompt context"OR "retrieval-augmented generation") AND (chatbot OR "conversational system"OR "question answering")
Q2	RQ2	("large language model"OR LLM) AND (faithfulness OR factuality OR correctness) AND (chatbot OR "conversational system") AND (evaluation OR benchmark)
Q3	RQ1	("large language model"OR LLM) AND ("prompt injection"OR "prompt leakage"OR jailbreak OR guardrails) AND (chatbot OR "conversational system")
Q4	RQ2	("large language model"OR LLM) AND ("out-of-scope"OR abstention) AND (evaluation OR benchmark)

Tabela 2.4: Critérios de inclusão e exclusão.

	Inclusão		Exclusão
I1	Publicado entre 27-10-2021 e 27-10-2026	E1	Duplicado
I2	Em inglês ou português	E2	Sem resumo, editorial, opinião, tutorial, descrição de *workshop* ou sem informação metodológica suficiente
I3	Estudo primário sobre sistema conversacional ou de resposta a perguntas baseado em LLM, aplicado a educação ou saúde, cujas respostas dependem de um contexto definido (RAG, contexto no *prompt* ou base de conhecimento)	E3	Não usa LLM; não é sistema conversacional ou de *Question Answering* (QA); fora de educação e saúde; método genérico sem aplicação; ou sem contexto definido
I4	Descreve a avaliação das respostas ou dos mecanismos de controlo (correção, fidelidade, recusa ou segurança)	E4	Revisão ou *survey* (excluída da síntese; pode apoiar o enquadramento)
I5	Próximo do caso de estudo: cumpre pelo menos uma das condições (a) a (d) descritas no texto	E5	Não cumpre nenhuma das condições (a) a (d)
		E6	Texto integral não obtido

avaliação explícita da correção, da fidelidade ou da recusa; (c) mecanismo de controlo do âmbito ou de segurança; (d) suporte a várias línguas.

A seleção seguiu cinco passos registados e reprodutíveis (Apêndice A). Primeiro, a deduplicação por DOI e título. Segundo, a triagem por regras explícitas sobre o título e o resumo (fase A). Terceiro, a leitura do título e do resumo dos restantes registos, com uma decisão e um motivo por registo, segundo os critérios I1 a I5 (fase B); um assistente de IA propôs as decisões e o autor verificou-as. Quarto, a leitura do texto integral dos estudos selecionados, que confirmou os critérios I3 e I4. Quinto, a avaliação da qualidade de cada estudo com cinco critérios (QA1 a QA5): objetivo claro; sistema, modelo e origem do contexto descritos; dados de avaliação descritos; método de avaliação adequado às conclusões; e limitações discutidas. Cada critério vale 1 (*sim*), 0,5 (*parcial*) ou 0 (*não*). Os estudos com menos de 3,5 pontos em 5 foram excluídos, porque a sua evidência não permite sustentar as conclusões da síntese.

2.2.3 Resultados da Seleção

O fluxo de seleção está na Figura 2.8. Foram removidos 130 duplicados (126 entre pesquisas da mesma fonte e 4 entre fontes), ficando 1417 registos únicos. As regras da fase A excluíram 1034 registos, sobretudo por estarem fora de educação e saúde (565), por serem revisões (125), por não serem sistemas conversacionais ou de QA (125) ou por não descreverem a avaliação das respostas (115). Na fase B foram lidos 383 registos, dos quais 335 foram excluídos. Destes, 172 não cumpriam os critérios I1 a I4 (161 por E3, 8 por E2 e 3 por E4), principalmente por serem métodos de RAG genéricos ou por pertencerem a outros domínios. Os outros 163 cumpriam os critérios I1 a I4, mas não o I5. O texto integral foi procurado para os 48 estudos restantes e obtido para 46. Na leitura integral, 2 estudos foram excluídos por não avaliarem as respostas (I4) e 6 por terem uma pontuação de qualidade abaixo de 3,5. A revisão inclui, assim, 38 estudos, todos lidos integralmente.

Dos 38 estudos incluídos, 31 vieram da Q1, 6 da Q2, 4 da Q3 e 4 da Q4 (um estudo pode vir de mais do que uma pesquisa). Por fonte, 25 vieram do IEEE Xplore e 13 da ACM Digital Library. Nenhum estudo do Scopus chegou à inclusão: os seus resultados tinham muitos registos fora do âmbito, como números completos de revistas e livros de resumos. A literatura é recente: 20 estudos são de 2026, 16 de 2025 e 2 de 2024. Por tema, 15 estudos tratam assistentes de apoio à aprendizagem, 7 assistentes de saúde para doentes ou profissionais e 7 QA médico avaliado em *benchmarks*. Os restantes tratam controlo do âmbito e recusa (4), o efeito do contexto incluído no *prompt* (3) e segurança e *guardrails* (2).

A Tabela 2.5 resume indicadores descritivos dos 38 estudos, obtidos por pesquisa de termos nos títulos e resumos, para que todos os estudos sejam medidos da mesma forma. São indicadores de frequência e não de eficácia, e tendem a subestimar o que os textos integrais descrevem, porque nem todos os resumos referem todos os aspetos do estudo. A classificação e a pontuação de qualidade dos 38 estudos estão no Apêndice B.

As secções seguintes analisam os estudos por tema. Em vez de os resumir um a um, descrevem as técnicas que usam, como funcionam e que resultados reportam, e discutem a sua relevância para o QBank. Os detalhes e os valores que se seguem vêm da leitura integral dos 38 estudos incluídos. A frequência de uma técnica descreve a sua utilização, mas não prova que seja a mais eficaz. Os sistemas descritos servem como termo de comparação e

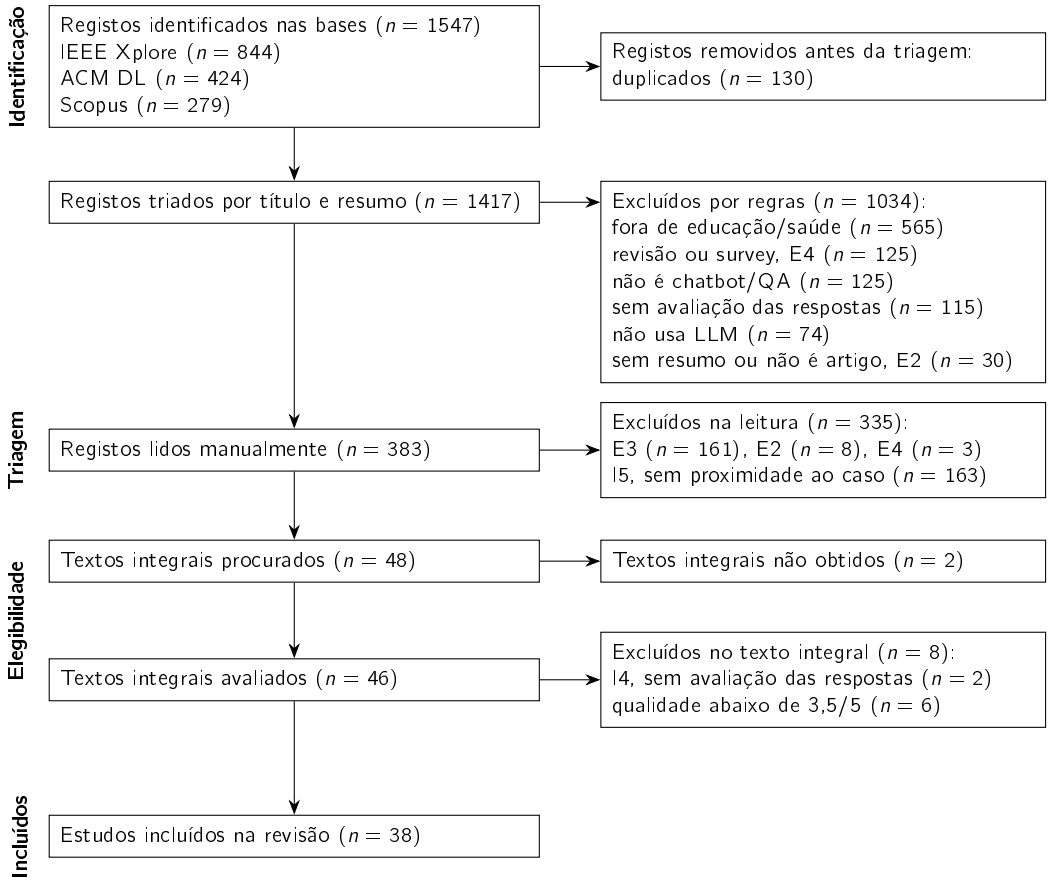


Figura 2.8: Diagrama PRISMA 2020 da seleção dos estudos. Fonte: elaboração própria, segundo o modelo PRISMA 2020 (Page et al. 2021).

não implicam que sejam adotados: as escolhas de arquitetura, de mecanismos de controlo e de modelo serão feitas e justificadas no desenho da solução, à luz das restrições do QBank.

2.3 Arquiteturas de Contextualização (RQ1)

O RAG é a forma dominante de limitar as respostas a um contexto, referida em 26 dos 38 estudos incluídos (68%). Em educação, o contexto é tipicamente o material de um curso: manuais, diapositivos, enunciados e registos das aulas (Barzanji et al. 2026; Feng et al. 2024; Sayeed et al. 2026; Seshadri et al. 2026; Yan e Shi 2026). Em saúde, são diretrizes clínicas, literatura médica ou bases de perguntas e respostas (Azam et al. 2024; Christiawan et al. 2025; Nurfadhilah et al. 2025; Raputri et al. 2025). Esta designação comum esconde, no entanto, arquiteturas diferentes, que esta secção descreve.

2.3.1 O Pipeline de Recuperação e as suas Variantes

Um sistema RAG tem duas fases. Na fase de indexação, os documentos são divididos em excertos (*chunks*) e cada excerto é convertido num vetor por um modelo de *embeddings*, sendo os vetores guardados numa base de dados vetorial. A dimensão destes corpora varia: 2328 excertos de 17 manuais num tutor universitário (Sayeed et al. 2026) e 125 847 excertos de 18 manuais médicos num estudo de QA médico (Xie et al. 2026). Na fase de consulta, a

Tabela 2.5: Indicadores descritivos dos 38 estudos incluídos (a partir de títulos e resumos).

Aspeto referido no título ou resumo	**N.º**	**%**
Origem do contexto (RQ1)		
RAG	26	68
Grafo de conhecimento ou ontologia	5	13
Fine-tuning	8	21
Contexto no *prompt*, ICL ou engenharia de *prompts*	9	24
Controlo do âmbito e aspetos operacionais (RQ1)		
Citações ou rastreabilidade das fontes	3	8
Segurança (injeção, *jailbreak*, *guardrails*)	4	11
Recusa, abstenção ou perguntas fora do âmbito	6	16
Várias línguas ou língua diferente do inglês	6	16
Latência ou tempo de resposta	6	16
Custo	4	11
Avaliação (RQ2)		
Exatidão (*accuracy*)	25	66
Métricas automáticas (fidelidade, RAGAS, ROUGE, BLEU, F1 e semelhantes)	12	32
Benchmark de escolha múltipla ou de exame	10	26
Especialistas, clínicos ou docentes (como avaliadores ou utilizadores)	12	32
Estudo com utilizadores, questionário ou entrevistas	12	32
LLM como juiz	4	11

pergunta do utilizador é convertida no mesmo espaço vetorial, os excertos mais semelhantes (normalmente pela semelhança do cosseno) são recuperados e incluídos no *prompt*, e o modelo gera a resposta (Azam et al. 2024; Rahat et al. 2026).

Os estudos analisados acrescentam vários componentes a este esquema básico, a que Sbai et al. (2025) chamam RAG ingénuo:

- **Modelos de embeddings adaptados.** Os estudos usam modelos multilingues (Nurfadhilah et al. 2025; Sbai et al. 2025) ou modelos ajustados ao domínio. Os autores do ATU-Tutor ajustaram o recuperador com 929 pares pergunta–excerto (Sayeed et al. 2026). O modelo de *embeddings* do Mufakkir ficou em primeiro lugar num *ranking* de recuperação em árabe (Tawfik et al. 2025).
- **Pesquisa híbrida.** Combina a pesquisa densa, por semelhança semântica, com a pesquisa esparsa, por coincidência de termos (BM25), e funde as duas listas de resultados (*rank fusion*) (Christiawan et al. 2025; Sayeed et al. 2026; Sbai et al. 2025; Tawfik et al. 2025; Yan e Shi 2026). A pesquisa esparsa compensa a dificuldade da pesquisa densa com termos técnicos e siglas, frequentes em medicina.
- **Reordenação.** Um segundo modelo (*cross-encoder*) avalia em conjunto a pergunta e cada excerto recuperado e reordena-os, mantendo apenas os mais relevantes (Christiawan et al. 2025; Sayeed et al. 2026; Sbai et al. 2025).
- **Transformação da pergunta.** A pergunta é expandida com termos relacionados (Sbai et al. 2025) ou reformulada numa pergunta mais geral antes da pesquisa (*step-back prompting*) (Christiawan et al. 2025).

- **Pontuação de confiança.** Uma estimativa de confiança da resposta é usada para reduzir alucinações (Sbai et al. 2025).

Nos estudos de ablação, cada componente contribui para o resultado. No Sanity-LLM, a pesquisa híbrida, a reformulação da pergunta e a reordenação melhoram, cada uma, as métricas face ao RAG ingénuo; o sistema completo atinge 0,9391 de precisão do contexto e 0,8754 de fidelidade (Christiawan et al. 2025). A complexidade do *pipeline* cresce, contudo, com cada componente, e cada etapa é um ponto onde o contexto certo pode ser perdido antes de chegar ao modelo.

2.3.2 Conhecimento Estruturado: Grafos e Ontologias

Cinco dos 38 estudos (13%) referem grafos de conhecimento ou ontologias, que surgem em três papéis diferentes. No primeiro, o grafo é a forma de representar o contexto: o MediTriR converte o conhecimento recuperado em triplos (sujeito, relação, objeto) e gera novos triplos a partir deles para apoiar o raciocínio em perguntas médicas de escolha múltipla (Zhang e Shafiq 2025). Ghanbari e Dividino (2025a) compararam representações por triplos e por caminhos no grafo: os caminhos dão melhores resultados, mas são mais sensíveis ao ruído. Um subgrafo maior aumenta a cobertura, mas também a informação irrelevante. Uma seleção imprecisa leva o desempenho abaixo do modelo sem contexto (Ghanbari e Dividino 2025a,b).

No segundo papel, o grafo organiza a recuperação. Jain et al. (2025) compararam o RAG vetorial com o GraphRAG, que constrói um grafo de entidades a partir do corpus. O RAG vetorial foi a opção de baixo custo para perguntas factuais e o GraphRAG global foi melhor em perguntas temáticas. O GraphRAG local teve a maior exatidão com manuais alterados para contradizer o conhecimento do modelo. O GraphRAG usou, porém, 10 a 20 vezes mais recursos, o que levou os autores a propor um encaminhamento de cada pergunta para o método mais adequado.

No terceiro papel, o grafo controla o acesso ao conteúdo. O SAGE usa um grafo do estado do estudante e dos conteúdos do curso para decidir a que conteúdo o modelo pode aceder (Rayhan et al. 2026), um papel de controlo discutido na Secção 2.4.

2.3.3 Orquestração: Agentes, Encaminhamento e Verificação

Um conjunto crescente de estudos divide a resposta em várias etapas, cada uma com um modelo ou uma ferramenta própria. Liu et al. (2026a) usam um agente administrador que encaminha cada pergunta médica para cinco agentes especializados (fisiologia, patologia, clínica, terapêutica e farmacologia, e saúde pública) e combina as respostas por consenso ponderado, através do *Model Context Protocol* (MCP). O sistema multiagente subiu a exatidão de 66–70% para 71–75% face a um único agente. O maior ganho veio, porém, da curadoria da base de conhecimento: com apenas as 500 perguntas de maior qualidade, a exatidão chegou perto de 80%. Ishadya et al. (2026) compararam pipelines RAG e MCP com a mesma lógica de *prompt*, e o MCP igualou ou superou o RAG em F1, fundamentação nas fontes e abstenção.

Outros estudos acrescentam uma etapa de verificação. No sistema de Bellard et al. (2025), um LLM juiz avalia cada resposta em cinco dimensões (exatidão, segurança, robustez, empatia e clareza) e pede a sua revisão. Uma mensagem predefinida substitui as respostas

que falham a segunda verificação de segurança (4,3%). Em sistemas institucionais, o encaminhamento serve para governação. O tutor de Wei et al. (2026) combina recuperação local, verificação de políticas e encaminhamento para a nuvem apenas quando necessário, e regista cada execução.

2.3.4 Engenharia de Prompts

Mesmo com o contexto certo, a forma como o *prompt* é construído influencia a resposta. Os estudos usam as seguintes técnicas:

- definir um papel para o modelo (*role prompting*), raciocinar passo a passo (*chain-of-thought*) e verificar as próprias afirmações antes da resposta final (*chain-of-verification*); em conjunto, estas técnicas reduziram as afirmações sem suporte na revisão por especialistas (Ishadya et al. 2026);
- adaptar o nível da resposta ao público, por exemplo a uma licenciatura (Yan e Shi 2026);
- fazer perguntas de seguimento de estilo socrático, que levam o estudante a raciocinar em vez de receber a resposta (Sayeed et al. 2026);
- pedir clarificação quando a pergunta é ambígua (Yan e Shi 2026);
- citar as fontes usadas em cada resposta, o que os estudantes valorizaram pela transparência (Seshadri et al. 2026).

O *prompt* também torna o modelo menos sensível a contexto ruidoso. No estudo de Rahat et al. (2026), exemplos de como rejeitar evidência contraditória e cumprir o formato pedido subiram a exatidão de 20,8% para 59,6% com cinco documentos. Yan e Shi (2026) descrevem a iteração de um *prompt* de sistema a partir das falhas observadas. Na versão inicial, o modelo inventou a definição e a derivação de um termo técnico inexistente, em vez de o questionar. A versão final obriga o modelo a pedir confirmação quando o termo é errado ou invulgar, a perguntar quando a dúvida é ambígua e a citar a base de conhecimento. Usa ainda uma temperatura de 0,1 para reduzir a variabilidade das respostas.

2.3.5 Ajuste Fino como Alternativa ou Complemento

O ajuste fino aparece em 8 dos 38 estudos (21%), geralmente com técnicas eficientes como o LoRA e o QLoRA (Feng et al. 2025; Xu et al. 2026b), que ajustam apenas uma pequena parte dos parâmetros. Pode substituir o contexto: em perguntas sobre relatórios radiológicos, o modelo ajustado superou o *prompting* com exemplos e eliminou as alucinações da taxonomia de erros usada (Hamidi e Roberts 2026). Abrar et al. (2025) separaram o ajuste em duas fases, uma para conhecimento factual e outra para comportamento, com exemplos de recusa de pedidos fora do âmbito. No apoio técnico a utilizadores de computação de alto desempenho, o modelo base com contexto no *prompt* e RAG teve a maior correção, e o modelo ajustado com RAG a menor. O ajuste fino ensinou o modelo a imitar o estilo dos pedidos anteriores, mas piorou o uso da informação recuperada (Zheng et al. 2026). O QBank tem muitas perguntas em várias línguas, e o conteúdo muda com as revisões da equipa científica. Assim, o ajuste fino teria de ser repetido a cada alteração e não garantiria que a resposta se limita à pergunta em curso. Além disso, nem sempre está disponível quando o modelo é usado através de uma API.

2.3.6 Quando o Contexto Prejudica

Os estudos que comparam o mesmo modelo com e sem contexto relatam, em geral, melhorias da correção e da fidelidade (Azam et al. 2024; Nurfadhilah et al. 2025; Raputri et al. 2025). Contudo, um grupo de estudos de QA médico mostra que a recuperação pode piorar os resultados. Xie et al. (2026) observaram que três variantes de RAG ficaram abaixo do modelo sem contexto no MedQA-USMLE: a recuperação corrigiu 5–6% das perguntas mas induziu em erro 6–7%, e a confiança do recuperador não previa quando o contexto ajudava. Rahat et al. (2026) compararam, no PubMedQA, três condições: sem contexto, o modelo acertou 27,0%; com o contexto correto anotado por humanos, 68,8%; com documentos recuperados, entre 42,6% (um documento) e 17,6% (oito documentos), ou seja, abaixo de não ter contexto. Com contexto ruidoso, o modelo deixou também de cumprir o formato pedido (59,6% de respostas sem formato válido com oito documentos, contra 2,4% com o contexto correto). As falhas tiveram quatro causas: contexto que distrai sem conter a resposta (41,8%), contexto contraditório (37,6%), contexto irrelevante (13,9%) e erros de formato (6,7%). Um *prompt* com exemplos de como rejeitar evidência contraditória fez a exatidão voltar a 59,6%. Na análise manual de Xie et al. (2026), as causas foram o desajuste do contexto clínico (35%), a extração de frases sem compreensão (40%) e a fragmentação do conhecimento em excertos parciais que, combinados, se tornam incoerentes (25%). Liu et al. (2026a) concluíram que a qualidade da base de conhecimento pesa mais do que a quantidade. Na mesma linha, os estudos que incluem conhecimento de grafos diretamente no *prompt* mostram que contexto pouco relevante pode baixar o desempenho abaixo do modelo sem contexto (Ghanbari e Dividino 2025a,b).

Estes resultados mostram que o contexto não é neutro: um contexto errado ou ruidoso pode ser pior do que nenhum. Em todos estes estudos, a origem do problema está na seleção do contexto, isto é, na recuperação. Quando o contexto é conhecido à partida e validado, como no QBank, este tipo de erro deixa de existir, embora permaneça o risco de o modelo não seguir o contexto fornecido.

2.3.7 Contexto Fechado e Perguntas de Exame

São poucos os estudos em que o contexto é fixo e conhecido à partida, como no QBank. Os mais próximos fundamentam as respostas na aula em curso (Liu et al. 2026b) ou numa apresentação gravada (Xu et al. 2026a), ou respondem a perguntas sobre um único relatório radiológico (Hamidi e Roberts 2026). No estudo de Xu et al. (2026a), o assistente fundamentado nos materiais da apresentação melhorou a experiência de aprendizagem. Um assistente genérico não superou o vídeo sem assistente. O valor está, portanto, no contexto e não na mera presença de um assistente. Zheng et al. (2026) compararam *fine-tuning*, RAG e contexto no *prompt* num serviço de apoio técnico, e a combinação de contexto no *prompt* com RAG obteve a maior correção. Nos estudos incluídos, não foi identificado nenhum em que o contexto seja o registo completo de uma pergunta de escolha múltipla validada (vinheta, opções, explicação e informação complementar) usado para esclarecer dúvidas do estudante.

Os estudos com perguntas de exame tratam, sobretudo, a escolha da resposta correta em *benchmarks* como o MedQA e o MedMCQA (Liu et al. 2026a; Xie et al. 2026; Zhang e Shafiq 2025), e não a explicação de uma pergunta cuja resposta já é conhecida. A exceção mais próxima é o assistente de Khan et al. (2025), com um fluxo próximo do QBank. O estudante escolhe uma pergunta de um exame de acesso à pós-graduação em engenharia e o sistema mostra a solução dessa pergunta. O modelo responde depois às dúvidas com o par

pergunta–solução como referência. A fidelidade foi de 0,94, mas cada explicação demorou 9,35 s a gerar num modelo local. Além disso, o avaliador automático era o próprio modelo avaliado, o que pode favorecê-lo.

Contexto completo e identificação exata. O AskNow fornece ao modelo a transcrição completa da aula até ao momento, guardada em segmentos de 30 s com marcas temporais, sem pesquisa por semelhança. Em três cursos com 117 estudantes, os docentes classificaram 100 respostas aleatórias com uma correção média entre 4,53 e 4,88 em 5 (Liu et al. 2026b). O tutor de Wei et al. (2026) mostra por que razão identificar o contexto exato é preferível a pesquisá-lo: a recuperação do documento certo teve precisão de 1,00 com o identificador do curso na pergunta e de 0,006 sem ele. No QBank, o identificador da pergunta em curso é sempre conhecido, pelo que a seleção do contexto pode ser exata. A Figura 2.9 reproduz a arquitetura do AskNow.

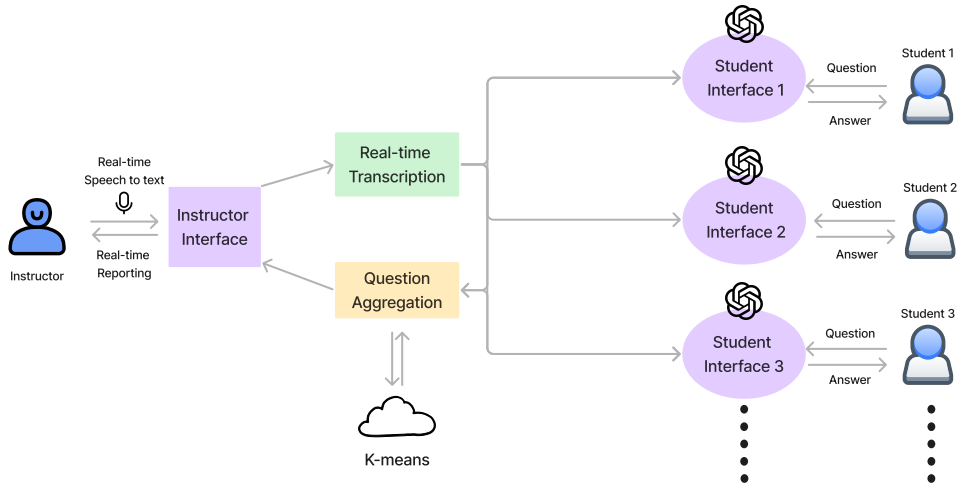


Figura 2.9: Arquitetura do AskNow: a transcrição da aula em curso é usada como contexto das respostas, e as perguntas são agrupadas (K-means) para o docente. Fonte: reproduzido de Liu et al. (2026b), licença CC BY 4.0.

2.4 Mecanismos de Controlo do Âmbito e de Segurança (RQ1)

Os mecanismos de controlo encontrados organizam-se pelo momento em que atuam. Antes da geração, atuam sobre o pedido do utilizador ou sobre o conteúdo a que o modelo tem acesso. Durante a geração, atuam sobre o próprio modelo; depois, sobre a resposta. A Tabela 2.6 resume-os.

Instruções no prompt não chegam. O resultado mais relevante para o QBank é o de Rayhan et al. (2026). Num tutor de programação, os tutores baseados apenas em instruções no *prompt* tiveram uma utilidade semelhante à do sistema proposto (42% e 44%). No entanto, cumpriram as políticas do docente em 30% dos casos, contra 90% do sistema proposto. Este usa um controlo de acesso ao conteúdo em três camadas: por papel do utilizador, por atributos e pelo estado cognitivo do estudante. A lição é estrutural: o que o modelo não recebe não pode ser revelado. O CourseAssist classifica a intenção do estudante

Tabela 2.6: Mecanismos de controlo do âmbito e de segurança encontrados na revisão.

Mecanismo	Momento	Funcionamento	Resultados reportados
Instruções no *prompt*	Geração	A política é descrita nas instruções de sistema	Cumprimento das políticas em 30% dos casos (Rayhan et al. 2026)
Controlo de acesso ao conteúdo	Antes	Regras por papel, atributos e estado do estudante decidem que conteúdo o modelo pode usar	Cumprimento em 90% dos casos (Rayhan et al. 2026)
Classificação da intenção	Antes	O pedido é classificado para escolher uma resposta pedagogicamente adequada	Superior ao GPT-4 em adequação pedagógica (Feng et al. 2024)
Classificador de ataques	Antes	Modelo *Transformer* ajustado deteta injeção e *jailbreak*	F1 de 0,964 (Mathew et al. 2026)
Modelo de guarda	Antes ou depois	LLM classificador com categorias de risco, incluindo restrição de tema	Llama Guard 3: 42,6% de falsos positivos, 207 ms; GPT OSS Safeguard: 16,3%, 10,6 s (Walczak e Sawicki 2026)
Dois modelos	Antes	Um LLM filtra o pedido; só os pedidos aprovados chegam ao LLM que responde	100% dos ataques bloqueados, 0,28% de falsos positivos, +1,2 s (+18%) e 1,8× o custo (Emekci e Budakoglu 2025)
Ajuste fino para recusa	Treino	Exemplos de pedidos fora do âmbito com a recusa esperada	Precisão de recusa de 0,86, contra 0,82 do GPT-4 (Abrar et al. 2025)
Monitorização interna	Geração	Os estados internos do modelo indicam respostas fora do domínio	Taxas de rejeição elevadas fora do domínio (Li et al. 2026)
Verificação da resposta	Depois	Um LLM juiz valida a resposta antes de a mostrar	Mensagem predefinida em 4,3% dos casos; 15,7 s por pergunta (Bellard et al. 2025)

e decompõe as perguntas para dar respostas pedagogicamente adequadas (Feng et al. 2024). Estes mecanismos correspondem às regras por modo do QBank, por exemplo não revelar a resposta correta antes do tempo no modo Teste.

A Figura 2.10 organiza estes mecanismos como camadas sucessivas, com os custos reportados nos estudos.

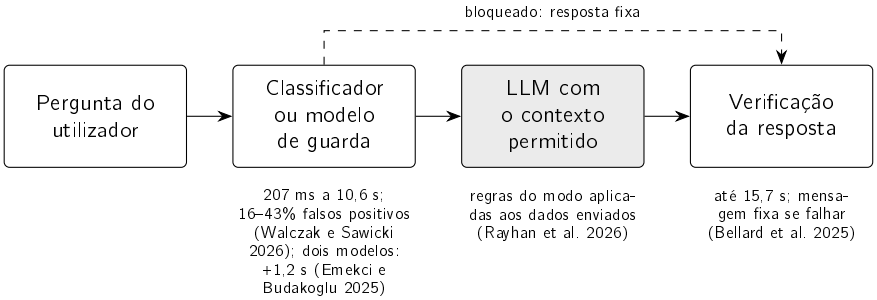


Figura 2.10: Defesa em camadas de um assistente de âmbito restrito, com os tempos e taxas de falsos positivos reportados nos estudos da revisão. Cada camada acrescenta latência; os pedidos bloqueados recebem uma resposta fixa. Fonte: elaboração própria, com os valores dos estudos indicados.

Filtros antes do modelo. A defesa mais avaliada em uso real é a arquitetura com dois modelos. No ChatTEDU, durante dois meses, foram analisadas 4501 interações reais, das quais 180 eram tentativas de ataque por injeção de instruções, *jailbreak* ou manipulação de conteúdo; todas foram bloqueadas, com 0,28% de falsos positivos (Emekci e Budakoglu 2025). Os autores mediram o custo desta proteção. O tempo médio de resposta passou de 6,7 s para 7,9 s, dos quais 0,9 s na verificação pelo primeiro modelo, e para 9,1 s com mais de 100 utilizadores em simultâneo. As chamadas à API duplicaram; descontadas as respostas em *cache* e as rejeições antecipadas, o custo subiu 1,8 vezes. Dos ataques, 77,8% eram de exploração técnica e 15% eram multilingues, o que indica que um filtro tem de funcionar em todas as línguas do sistema. A Figura 2.11 mostra o fluxo de decisão do ChatTEDU.

Em alternativa a um segundo LLM, Mathew et al. (2026) usam um classificador mais pequeno, ajustado para detetar ataques, que é mais rápido e barato mas exige dados de treino. Walczak e Sawicki (2026) compararam dois modelos de guarda num assistente administrativo universitário, com uma categoria própria de restrição de tema. O Llama Guard 3 classificou cada pedido em 207 ms e detetou 85,5% das ameaças reais. Bloqueou, porém, 42,6% dos pedidos legítimos, sobretudo saudações curtas que tomou como fora do tema. O GPT OSS Safeguard teve menos falsos positivos (16,3%), mas demorou 10,6 s por pedido, porque gera um raciocínio antes da decisão. Ambos falharam ataques que se fazem passar por uma autoridade ou têm um enquadramento académico, e os resultados em dados sintéticos sobrestimaram os obtidos com pedidos reais. Notaram ainda que as classificações dos especialistas e a perceção dos utilizadores divergem, o que mostra que a fronteira do âmbito é, em parte, subjetiva.

Recusa fora do âmbito. Só 6 dos 38 estudos (16%) referem a recusa ou a abstenção no título ou no resumo. Além dos modelos de guarda, as abordagens encontradas são o ajuste fino com exemplos de recusa (Abrar et al. 2025) e a monitorização dos estados internos do modelo para detetar respostas fora do domínio (Li et al. 2026). A recusa tem um custo próprio: o assistente de Abrar et al. (2025) recusou corretamente 86% dos pedidos fora

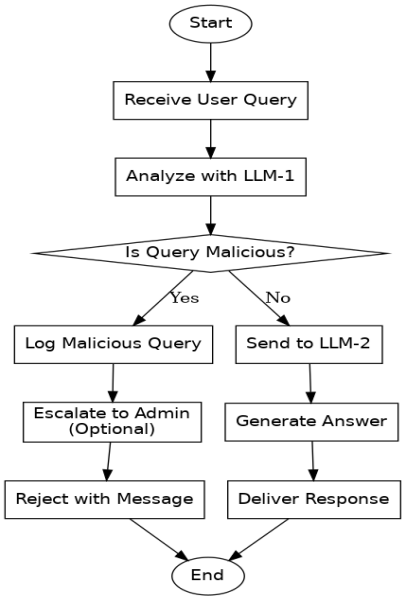


Figura 2.11: Fluxo de decisão do ChatTEDU: o primeiro modelo analisa o pedido e só os pedidos considerados seguros são enviados ao segundo modelo, que gera a resposta. Fonte: reproduzido de Emekci e Budakoglu (2025), licença CC BY 4.0.

do âmbito, mas recusou também muitos pedidos legítimos, com diferenças entre línguas. Quando a verificação de uma resposta falha, o HeartWise substitui-a por uma mensagem fixa e previamente validada, que remete o utilizador para a equipa de saúde (Bellard et al. 2025). O ajuste fino e a monitorização interna exigem acesso ao modelo e não são possíveis quando este é usado como serviço através de uma API. Nesse caso, a recusa depende de instruções, de filtros externos ao modelo ou da verificação da resposta, como a do HeartWise.

Injeção direta e indireta. Nos sistemas com RAG, as instruções maliciosas podem chegar também através dos documentos recuperados e não só da mensagem do utilizador: é a injeção indireta (Emekci e Budakoglu 2025). No QBank, o contexto vem da base de dados validada e não de documentos externos, o que reduz este risco de injeção indireta, mas não o de injeção direta pelo utilizador. As defesas por filtros acrescentam latência (18% no ChatTEDU) e falsos positivos, um compromisso a ponderar num assistente de conversa, em que o utilizador espera a resposta em poucos segundos.

2.5 Línguas, Latência e Custo (RQ1)

Várias línguas. Seis dos 38 estudos (16%) tratam línguas diferentes do inglês ou várias línguas, com três estratégias. A primeira é um *pipeline* multilingue. O sistema de Sbai et al. (2025) responde em árabe, francês e inglês, com *embeddings* multilingues e tratamento de texto da direita para a esquerda; as perguntas em árabe atingiram uma exatidão próxima das perguntas em francês. A segunda é traduzir para uma língua pivô. O ELENA traduz os documentos e as perguntas em italiano para inglês e a resposta de volta para italiano (Ruga et al. 2025). A tradução simplifica a recuperação, mas acrescenta etapas onde o sentido pode mudar. A terceira é usar modelos adaptados à língua. Um modelo adaptado ao indonésio teve maior fidelidade (acima de 0,9) do que um modelo geral no mesmo *pipeline*

(Nurfadhilah et al. 2025). O ajuste fino melhorou o desempenho em dialetos árabes pouco representados (Abrar et al. 2025). No QBank, cada língua tem o seu próprio conteúdo validado, pelo que a tradução não é necessária. O desafio é o modelo responder na língua do QBank, com o conteúdo dessa língua, e manter a qualidade e a capacidade de recusa em todas as línguas. Estes estudos avaliam o desempenho por língua, mas raramente a consistência com o mesmo conteúdo validado em várias línguas.

Latência e custo. Apenas 6 dos 38 estudos (16%) referem a latência e 4 (11%) o custo. Os valores reportados mostram que cada etapa adicional tem um preço:

- o ciclo com LLM juiz de Bellard et al. (2025) demorou em média 15,74 s por pergunta, a 0,00312 USD;
- a camada de segurança do ChatTEDU acrescentou 1,2 s a uma resposta de 6,7 s (Emekci e Budakoglu 2025);
- a explicação de soluções de exame com um modelo local demorou 9,35 s (Khan et al. 2025);
- o modelo de guarda mais preciso demorou 10,6 s por pedido, demasiado para uso síncrono (Walczak e Sawicki 2026);
- o GraphRAG exigiu 10 a 20 vezes mais recursos do que o RAG vetorial (Jain et al. 2025).

Vários estudos executam modelos localmente por razões de privacidade e custo, por exemplo um modelo quantizado de 8 mil milhões de parâmetros numa placa gráfica de 16 GB (Sayeed et al. 2026) ou modelos quantizados em *hardware* modesto (Nurfadhilah et al. 2025; Ruga et al. 2025). Estes valores não são diretamente transponíveis, porque dependem do modelo, do *hardware* e do tamanho do contexto, mas dão uma ordem de grandeza. Um custo de 0,003 USD por pergunta torna o custo de um assistente dominado pelo volume de utilização. Já uma verificação de 15,74 s é demasiado lenta para uma resposta síncrona e só serve para uma validação posterior. Raramente, porém, os estudos relacionam a escolha do mecanismo de contexto com a latência e o custo.

2.6 Avaliação da Correção, da Fidelidade e do Âmbito (RQ2)

Os estudos avaliam as respostas em várias dimensões, com métricas diferentes em cada uma. A Tabela 2.7 organiza as métricas encontradas e os valores reportados nos estudos incluídos.

Métricas heterogéneas. A métrica mais referida é a exatidão (66% dos estudos), sobretudo em *benchmarks* de escolha múltipla. As métricas automáticas aparecem em 32% dos estudos. A fidelidade ao contexto é medida com métricas do tipo RAGAS: por exemplo, 0,8754 de fidelidade num assistente de saúde mental (Christiawan et al. 2025) e mais de 0,9 num assistente de educação de doentes (Nurfadhilah et al. 2025). Estas métricas dependem, por sua vez, de um LLM avaliador (Nurfadhilah et al. 2025), pelo que herdam as suas limitações. Como as métricas, os dados e os modelos diferem entre estudos, os valores não são diretamente comparáveis. Estas métricas não precisam de uma resposta de referência, o que as torna práticas, mas medem a coerência com o contexto e não a correção: uma resposta fiel a um contexto errado tem fidelidade máxima. No QBank, como o contexto

Tabela 2.7: Métricas de avaliação encontradas na revisão, por dimensão.

Dimensão	Métrica	O que mede	Exemplos
Fidelidade	Fidelidade (RAGAS)	Proporção das afirmações da resposta suportadas pelo contexto	0,8754 (Christiawan et al. 2025); >0,9 (Nurfadhilah et al. 2025); 0,93 (Sbai et al. 2025)
Contexto	Precisão e cobertura do contexto	Se o contexto recuperado é relevante e se contém a informação necessária	0,94 e 0,71 (Christiawan et al. 2025)
Relevância	Relevância da resposta	Se a resposta trata a pergunta feita	>0,95 (Buti e Mohamed 2026)
Correção	Exatidão; *exact match*; F1; correção da resposta	Coincidência com a resposta de referência	60,7% no MedQA (Xie et al. 2026); 61% EM e 77% F1 (Hamidi e Roberts 2026)
Semelhança textual	BLEU, ROUGE-L, METEOR, BERTScore	Sobreposição ou semelhança com uma resposta de referência	METEOR 0,41 (Nurfadhilah et al. 2025)
Recusa	Precisão da recusa; taxa de abstenção; abstenções indevidas	Se recusa o que deve e só o que deve	0,86 (Abrar et al. 2025); (Hamidi e Roberts 2026; Ishadya et al. 2026)
Segurança	Ataques bloqueados; falsos positivos; F1 do classificador	Robustez a injeção e *jailbreak*	100% e 0,28% (Emekci e Budakoglu 2025); F1 0,964 (Mathew et al. 2026)
Políticas	Cumprimento das políticas	Respostas que respeitam as regras definidas pelo docente	90% contra 30% (Rayhan et al. 2026)
Operação	Latência; custo por pergunta	Tempo e custo de cada resposta	15,7 s e 0,003 USD (Bellard et al. 2025)
Utilizadores	SUS; utilidade percebida; entrevistas	Usabilidade e valor percebido	SUS de 77,8 (Barzanji et al. 2026); (Liu et al. 2026b)

é validado, a fidelidade aproxima-se da correção, o que torna esta métrica particularmente adequada.

LLM como juiz, especialistas e utilizadores. Buti e Mohamed (2026) avaliaram um assistente de aconselhamento académico com um LLM juiz num *benchmark* de 55 perguntas revistas por especialistas. Encontraram 3 alucinações em 53 respostas e concluíram que o contexto recuperado restringe o modelo, sem eliminar o risco de invenção. Liao et al. (2026) combinaram um LLM juiz com auditoria por estudantes de medicina, e Oh et al. (2026) propuseram uma avaliação automática de agentes clínicos em diálogo multi-turno, validada por especialistas. Em educação, os docentes avaliam a correção das respostas (Liu et al. 2026b; Miroyan et al. 2025), e os estudos com utilizadores medem a utilidade percebida e a usabilidade (Barzanji et al. 2026; Seshadri et al. 2026; Xu et al. 2026a). Poucos estudos combinam as três formas de avaliação.

Fidelidade ao contexto versus conhecimento do modelo. Um aspeto pouco avaliado, mas central para o QBank, é se o modelo segue o contexto quando este contradiz o seu conhecimento. Jain et al. (2025) fizeram-no com manuais alterados de propósito para contradizer o conhecimento do modelo, e verificaram diferenças entre abordagens de RAG. As taxonomias de erros de Hamidi e Roberts (2026) e Rahat et al. (2026), que separam alucinação, abstenção indevida e desvio provocado pelo contexto, são uma alternativa mais informativa do que uma única métrica agregada.

Avaliação da recusa. Poucos estudos avaliam a recusa, e fazem-no de formas diferentes. Uns medem a precisão da recusa (Abrar et al. 2025) ou a taxa de abstenção (Ishadya et al. 2026). Outros medem os falsos positivos e falsos negativos de abstenção (Hamidi e Roberts 2026), o cumprimento das políticas do docente (Rayhan et al. 2026) ou a taxa de rejeição fora do domínio (Li et al. 2026). Ishadya et al. (2026) mostram que menos abstenção e mais respostas suportadas podem coexistir, o que indica que a recusa deve ser avaliada em conjunto com a correção.

Dimensão das avaliações. Muitas avaliações usam conjuntos pequenos: 14 perguntas (Sayeed et al. 2026), 25 pares sintéticos (Bellard et al. 2025), 50 pares (Feng et al. 2024) ou 55 perguntas (Buti e Mohamed 2026). As avaliações em uso real, com centenas ou milhares de utilizadores, medem sobretudo a utilidade percebida e não a fidelidade de cada resposta (Emekci e Budakoglu 2025; Seshadri et al. 2026).

Protocolos aplicáveis ao QBank. A leitura integral mostra várias técnicas de avaliação que podem ser reutilizadas. Buti e Mohamed (2026) construíram um conjunto de 55 perguntas com respostas de referência validadas. O conjunto divide-se em perguntas comuns, perguntas que exigem interpretar regras e casos-limite: perguntas fora do âmbito, ambíguas e pedidos para revelar as instruções de sistema. Um LLM juiz avaliou as respostas com temperatura 0, uma rubrica detalhada e saída estruturada. A fidelidade foi de 0,764; as falhas foram sobretudo de recuperação (6), de alucinação (3, ou 5,7%) e de falta de pedido de clarificação. Hamidi e Roberts (2026) incluíram perguntas sem resposta no documento, em que a abstenção correta conta como acerto. Ishadya et al. (2026) usaram uma frase de recusa fixa, que torna a taxa de recusa mensurável automaticamente, e calcularam as restantes métricas apenas sobre as respostas não recusadas. Jain et al. (2025) usaram manuais com factos alterados de propósito para verificar se o modelo segue o texto ou o seu

conhecimento. Para usar um LLM juiz, Liao et al. (2026) calibraram-no contra uma amostra verificada por humanos e corrigiram a exatidão estimada com as taxas de verdadeiros e falsos positivos do juiz. No sentido contrário, no estudo de Khan et al. (2025), o avaliador era o modelo que gerava as respostas. Atribuiu-lhe 0,94 de fidelidade, contra 0,56 ao GPT-3.5, o que ilustra o risco de autopreferência. Por fim, como as respostas variam entre execuções, alguns estudos repetem cada pergunta, por exemplo dez vezes (Nurfadhilah et al. 2025) ou duas vezes (Feng et al. 2024).

2.7 Sistemas Mais Próximos do Caso de Estudo

A Tabela 2.8 compara os sistemas da revisão mais próximos do assistente pretendido com o caso do QBank. Cada um partilha uma ou duas características com o caso de estudo, mas nenhum as reúne todas. Essas características são o contexto fechado e validado por item, as regras por modo, as várias línguas com conteúdo próprio e a avaliação conjunta da correção, da fidelidade e da recusa.

Tabela 2.8: Sistemas mais próximos do caso de estudo, comparados com o assistente do QBank.

Sistema	Domínio	Contexto	Controlo	Avaliação
AskNow (Liu et al. 2026b)	Aulas de informática	Transcrição completa da aula, sem pesquisa	Instruções no *prompt*	Correção 4,5–4,9/5 por docentes; 117 estudantes
Xu et al. (2026a)	Apresentações gravadas	Materiais da apresentação	—	Experiência de aprendizagem face a assistente genérico
RadQA (Hamidi e Roberts 2026)	Radiologia	Um relatório	Ajuste fino	EM, F1 e taxonomia de erros, incluindo abstenção
GATE (Khan et al. 2025)	Exame de acesso	Solução da pergunta escolhida	—	Fidelidade 0,94 e relevância (juiz = modelo avaliado); ≈9 s
CourseAssist (Feng et al. 2024)	Informática	Materiais do curso (RAG)	Classificação da intenção	50 pares; utilidade, exatidão e adequação pedagógica
SAGE (Rayhan et al. 2026)	Programação	Grafo do curso	Controlo de acesso	Utilidade e cumprimento das políticas
Abrar et al. (2025)	Serviços ao estudante	Dados institucionais	Ajuste fino para recusa	Exatidão e precisão da recusa em 4 variedades linguísticas
ChatTEDU (Emekci e Budakoglu 2025)	Universidade	Informação institucional	Dois modelos	4501 interações reais; ataques e falsos positivos
QBank (este trabalho)	Perguntas de exame em saúde	Registo validado da pergunta em curso, lido pelo ID	Regras por modo e recusa	Correção, fidelidade e recusa, em várias línguas; especialistas e utilizadores

2.7.1 Limitações Recorrentes

Os estudos analisados partilham as seguintes limitações:

- avaliações em conjuntos pequenos, frequentemente sintéticos, e sem validação externa;

- fidelidade medida por LLMs avaliadores, sem verificação humana sistemática;
- recusa e perguntas fora do âmbito raramente avaliadas, e avaliadas separadamente da correção;
- avaliação multilingue centrada no desempenho por língua e não na consistência com o mesmo conteúdo validado;
- latência e custo raramente reportados e não relacionados com as escolhas de arquitetura;
- poucos estudos com contexto fechado e fornecido diretamente, apesar de a evidência mostrar que a recuperação introduz erros próprios.

2.8 Lacuna de Investigação

A lacuna resulta da síntese das secções anteriores. A Tabela 2.9 apresenta a cadeia que liga cada evidência à limitação que revela, à lacuna que daí resulta, à questão de investigação que a analisou e ao contributo deste trabalho, identificado pelo objetivo correspondente (Secção 1.4).

Tabela 2.9: Da evidência ao contributo: evidência, limitação, lacuna, questão de investigação e contributo.

Evidência	Limitação	Lacuna	RQ	Contributo (objetivo)
O RAG domina (68%); a recuperação pode introduzir contexto que desvia ou contradiz o modelo (Rahat et al. 2026; Xie et al. 2026).	Poucos estudos usam contexto fechado, validado e fornecido diretamente, como o de uma pergunta de exame.	Pouca evidência sobre a fidelidade de assistentes que respondem apenas com o contexto validado de cada item.	RQ1	Assistente que usa só os dados da pergunta em curso, lidos pelo identificador (O3), avaliado em fidelidade e correção (O5).
Instruções no *prompt* não garantem o cumprimento das políticas: 30% contra 90% (Rayhan et al. 2026).	A recusa é referida em 16% dos estudos, com métricas diferentes.	Pouca evidência sobre recusa e regras por modo em assistentes de estudo para exames.	RQ1, RQ2	Regras por modo aplicadas no contexto enviado e recusa fora do âmbito (O4), avaliadas com testes adversariais (O5).
Estudos multilingues avaliam o desempenho por língua (Abrar et al. 2025; Sbai et al. 2025).	Consistência com o mesmo conteúdo validado em várias línguas raramente avaliada.	Pouca evidência sobre fidelidade e recusa em várias línguas em simultâneo.	RQ2	Avaliação da fidelidade e da recusa por língua do QBank (O5).
Avaliações pequenas, com LLM juiz ou só com utilizadores.	Poucos estudos combinam métricas, especialistas e utilizadores.	Falta de protocolos de avaliação completos.	RQ2	Protocolo que combina testes técnicos, especialistas e utilizadores (O5).
Latência e custo referidos em 16% e 11% dos estudos; cada etapa de controlo acrescenta tempo (Bellard et al. 2025; Emekci e Budakoglu 2025).	Raramente relacionados com as escolhas de arquitetura.	Pouca evidência sobre o custo de cada mecanismo de controlo num assistente síncrono.	RQ1	Medição da latência e do custo de cada alternativa desde o primeiro incremento (O3, O5).

Em síntese, a literatura mostra como fundamentar as respostas de um assistente num contexto, sobretudo através de RAG, e como medir a sua fidelidade. Contudo, o corpus analisado não contém nenhum assistente de estudo que responda apenas com o contexto fechado

e validado de cada pergunta de um banco de perguntas. Também não contém nenhum que respeite regras por modo de exame e seja avaliado, em várias línguas, quanto à correção, à fidelidade e à recusa em simultâneo. A leitura integral dos estudos incluídos confirmou esta lacuna: os sistemas mais próximos (Tabela 2.8) partilham uma ou duas características com o caso de estudo, mas nenhum as reúne todas. É a esta oportunidade que o presente trabalho procura responder.

2.9 Ameaças à Validade

- **Fontes e campos.** A pesquisa limitou-se a três fontes, ao inglês e ao português e ao título, resumo e palavras-chave. Na IEEE Xplore e na ACM Digital Library, a restrição a estes campos foi feita expandindo cada termo, o que pode não ser exatamente equivalente ao `TITLE-ABS-KEY`. No Scopus, a pesquisa devolveu registos que não são artigos, o que sugere uma restrição de campos menos estrita.
- **Triagem por regras.** A fase A excluiu registos por ausência de termos no título e no resumo. Estudos relevantes que não usem esses termos podem ter sido excluídos (falsos negativos). As regras estão documentadas e podem ser repetidas.
- **Revisor único e apoio de IA.** A triagem foi feita por um único revisor, com apoio de um assistente de IA. Para mitigar o enviesamento, cada decisão tem um critério e um motivo registados e foi verificada pelo autor.
- **Critério de proximidade e limiar de qualidade.** O critério I5 e o limiar de qualidade reduziram a revisão a 38 estudos, para que todos pudessem ser lidos integralmente. Os 163 estudos excluídos pelo I5 cumpriam os restantes critérios e podem conter evidência útil, sobretudo sobre arquiteturas RAG genéricas. O I5 e o limiar de 3,5 foram definidos durante a revisão, e não no protocolo inicial, o que é uma alteração ao protocolo. A pontuação de qualidade foi atribuída por um único revisor (Apêndice B). Dois textos integrais não foram obtidos, e esses estudos foram excluídos.
- **Janela temporal.** O filtro das interfaces é anual (2021–2026) e, por isso, mais largo do que o critério I1. Os 38 estudos incluídos foram publicados entre 2024 e 2026.
- **Sem snowballing.** A revisão usou apenas a pesquisa nas bases de dados. A consulta das referências dos estudos incluídos e dos estudos que os citam (*snowballing*) não foi feita e poderia encontrar estudos relevantes que não usem os termos das expressões de pesquisa.
- **Evolução rápida.** A literatura sobre LLMs evolui depressa: 20 dos 38 estudos incluídos são de 2026.

2.10 Conclusões do Capítulo

A revisão identificou 1547 registos em três fontes e incluiu 38 estudos, todos lidos integralmente e com avaliação da qualidade. Quanto à RQ1, a forma dominante de limitar as respostas é o RAG. A evidência mostra, porém, que a recuperação introduz erros próprios e que as instruções no *prompt*, sozinhas, não garantem o cumprimento do âmbito. Os mecanismos com melhores resultados combinam controlo explícito do conteúdo, filtros dedicados e recusa. Os compromissos de latência e custo são pouco reportados. Quanto à RQ2, a avaliação é heterogénea: exatidão em *benchmarks*, métricas automáticas de fidelidade

dependentes de LLMs avaliadores, avaliação por especialistas e estudos com utilizadores, raramente combinados, e com pouca avaliação da recusa e do comportamento em várias línguas.

Para o assistente do QBank, estas conclusões têm implicações para o desenho e a avaliação:

- fornecer ao modelo apenas o contexto validado da pergunta em curso;
- não depender só de instruções no *prompt* para o âmbito e para as regras por modo;
- tratar a segurança contra injeção direta;
- avaliar a correção, a fidelidade e a recusa em conjunto, nas várias línguas do QBank, com testes técnicos, especialistas e utilizadores.

O desenho da solução partirá destas conclusões.

Bibliografia

Abd-alrazaq, Alaa, Rawan AlSaad, Dari Alhuwail et al. (2023). «Large Language Models in Medical Education: Opportunities, Challenges, and Future Directions». Em: *JMIR Medical Education* 9, e48291. doi: 10.2196/48291.

Abrar, M. et al. (2025). «Domain-Specific Fine-Tuning of LLMs for Multilingual Student Advisory in Higher Education». Em: *2025 2nd International Conference on Advanced Computing and Emerging Technologies (ACET)*. Estudo R0809 da revisão. doi: 10.1109/ACET67282.2025.11430234.

ACM/IEEE-CS Joint Task Force on Software Engineering Ethics and Professional Practices (1999). *Software Engineering Code of Ethics and Professional Practice (Version 5.2)*. url: https://www.acm.org/code-of-ethics/software-engineering-code.

Adamopoulou, Eleni e Lefteris Moussiades (2020). «Chatbots: History, Technology, and Applications». Em: *Machine Learning with Applications* 2, p. 100006. doi: 10.1016/j.mlwa.2020.100006.

Ahmed, Hosameldin O. A. e Abdul Hamid Sadka (2026). «Auditing Demographic Bias in Mistral: An Open-Source LLM's Diagnostic Performance on the MedQA Benchmark». Em: *IEEE Access* 14, pp. 12526–12543. doi: 10.1109/ACCESS.2026.3656396.

Ali, Hazrat et al. (2023). «ChatGPT and Large Language Models in Healthcare: Opportunities and Risks». Em: *2023 IEEE International Conference on Artificial Intelligence, Blockchain, and Internet of Things (AIBThings)*, pp. 1–4. doi: 10.1109/AIBThings58340.2023.10291020.

ALLEA (2023). *The European Code of Conduct for Research Integrity – Revised Edition 2023*. Berlin: ALLEA – All European Academies. doi: 10.26356/ECOC.

Azam, A., Z. Naz e M. U. G. Khan (2024). «CancerBot: A Retrieval-Augmented Generation based Cancer Chatbot Using Large Language Models». Em: *2024 18th International Conference on Open Source Systems and Technologies (ICOSST)*. Estudo R0162 da revisão. doi: 10.1109/ICOSST64562.2024.10871155.

Barzanji, Chrakhan et al. (2026). «ST-Buddy: Designing and Evaluating a Course-Grounded LLM Chatbot for Academic and Administrative Support». Em: *Proceedings of the Extended Abstracts of the 2026 CHI Conference on Human Factors in Computing Systems*. Estudo R1019 da revisão. doi: 10.1145/3772363.3798558.

Bellard, B. et al. (2025). «Development and Evaluation of an Agentic RAG with Embedded LLM-as-a Judge for Heart Failure Management: A Pilot Study». Em: *2025 IEEE International Conference on Big Data (BigData)*. Estudo R0561 da revisão. doi: 10.1109/BigData66926.2025.11402164.

Bloom, Benjamin S. (1984). «The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring». Em: *Educational Researcher* 13.6, pp. 4–16. doi: 10.3102/0013189X013006004.

Brooke, John (1996). «SUS: A "Quick and Dirty" Usability Scale». Em: *Usability Evaluation in Industry*. Ed. por Patrick W. Jordan et al. London: Taylor & Francis, pp. 189–194.

Bui, Tuan et al. (2025). «Formal Reasoning for Intelligent QA Systems: A Case Study in the Educational Domain». Em: *Proceedings of the 2nd ACM Workshop in AI-Powered*

Question & Answering Systems. Estudo R1110 da revisão. doi: 10.1145/3746274.3760392.

Buti, Ronit e Abdallah Mohamed (2026). «Evaluating RAG-Based Course Advising Chatbots Using LLM-as-a-Judge Methodology». Em: *Proceedings of the 28th Western Canadian Conference on Computing Education*. Estudo R1022 da revisão. doi: 10.1145/3828792.3828802.

Cai, Weilin et al. (2025). «A Survey on Mixture of Experts in Large Language Models». Em: *IEEE Transactions on Knowledge and Data Engineering* 37.7, pp. 3896–3915. doi: 10.1109/TKDE.2025.3554028.

Christiawan, J. et al. (2025). «Sanity-LLM: Enhancing Mental Health Chatbots with Retrieval-Augmented Generation (RAG)». Em: *2025 International Conference on Informatics, Multimedia, Cyber and Information System (ICIMCIS)*. Estudo R0071 da revisão. doi: 10.1109/ICIMCIS68501.2025.11327020.

Elkin, Peter L. et al. (2026). «Semantic Clinical Knowledge Augmentation Improves Medical Question Answering Across Commercial and Open Large Language Models». Em: *IEEE Journal of Biomedical and Health Informatics*. doi: 10.1109/JBHI.2026.3742187.

Emekci, H. e G. Budakoglu (2025). «Securing With Dual-LLM Architecture: ChatTEDU an Open Access Chatbot's Defense». Em: *IEEE Access*. Estudo R0765 da revisão. doi: 10.1109/ACCESS.2025.3623268.

Feng, Ty, Sa Liu e Dipak Ghosal (2024). «CourseAssist: Pedagogically Appropriate AI Tutor for Computer Science Education». Em: *Proceedings of the 2024 on ACM Virtual Global Computing Education Conference V. 2*. Estudo R1060 da revisão. doi: 10.1145/3649409.3691094.

Feng, Zeqin et al. (2025). «A Survey of Low-Rank Adaptation Techniques». Em: *2025 8th International Conference on Advanced Electronic Materials, Computers and Software Engineering (AEMCSE)*, pp. 215–224. doi: 10.1109/AEMCSE65292.2025.11042839.

Gan, Wenyi, Jianfeng Ouyang, Hua Li et al. (2024). «Integrating ChatGPT in Orthopedic Education for Medical Undergraduates: Randomized Controlled Trial». Em: *Journal of Medical Internet Research* 26, e57037. doi: 10.2196/57037.

Geng, T. et al. (2026). «Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies». Em: *Computers, Materials & Continua* 87.1. url: https://www.techscience.com/cmc/v87n1/66084.

Ghanbari, M. e R. Dividino (2025a). «Evaluating Knowledge Graph-Enhanced Context for Multiple-Choice Question Answering». Em: *2025 IEEE International Conference on Knowledge Graph (ICKG)*. Estudo R0559 da revisão. doi: 10.1109/ICKG66886.2025.00020.

– (2025b). «Quantifying Informativeness in Knowledge Graph-Augmented In-Context Learning for Multiple Choice Query Answering». Em: *2025 IEEE International Conference on Knowledge Graph (ICKG)*. Estudo R0619 da revisão. doi: 10.1109/ICKG66886.2025.00021.

Gordon, Morris, Michelle Daniel, Aderonke Ajiboye et al. (2024). «A scoping review of artificial intelligence in medical education: BEME Guide No. 84». Em: *Medical Teacher* 46.4, pp. 446–470. doi: 10.1080/0142159X.2024.2314198.

Hamidi, A. e K. Roberts (2026). «Large Language Models for Radiology QA: Benchmarking and Error Taxonomy on RadQA». Em: *2026 IEEE 14th International Conference on Healthcare Informatics (ICHI)*. Estudo R0794 da revisão. doi: 10.1109/ICHI69079.2026.00034.

Hattie, John e Helen Timperley (2007). «The Power of Feedback». Em: *Review of Educational Research* 77.1, pp. 81–112. doi: 10.3102/003465430298487.

Hevner, Alan R. et al. (2004). «Design Science in Information Systems Research». Em: *MIS Quarterly* 28.1, pp. 75–105.

Hu, Zhenlin et al. (2025). «Advancing Healthcare with Large Language Models: Techniques and Application». Em: *IEEE/CAA Journal of Automatica Sinica* 12.12, pp. 2371–2398. doi: 10.1109/JAS.2025.125540.

Ishadya, A. P. D., A. Withanaarachchi e S. Jayalal (2026). «Mitigating Bias and Hallucinations in LLMs Through Prompt Engineering and Knowledge-Grounded Approaches in Healthcare Domain». Em: *2026 6th International Conference on Advanced Research in Computing (ICARC)*. Estudo R0558 da revisão. doi: 10.1109/ICARC68737.2026.11453821.

Jain, A., L. Cui e S. Chen (2025). «Aligning LLMs for the Classroom with Knowledge-Based Retrieval: A Comparative RAG Study». Em: *2025 IEEE International Conference on Teaching, Assessment, and Learning for Engineering (TALE)*. Estudo R0616 da revisão. doi: 10.1109/TALE66047.2025.11346682.

Jang, D. et al. (2025). «MedTutor: A Retrieval-Augmented LLM System for Case-Based Medical Education». Em: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 319–353. url: https://aclanthology.org/2025.emnlp-demos.24/.

Kasneci, Enkelejda, Kathrin Sessler, Stefan Küchemann et al. (2023). «ChatGPT for good? On opportunities and challenges of large language models for education». Em: *Learning and Individual Differences* 103, p. 102274. doi: 10.1016/j.lindif.2023.102274.

Kavitha, G., H. A. M e P. R (2026). «SecureContext EDU: An Open Source University Assistant using Dual - LLM Architecture». Em: *2026 4th International Conference on Sustainable Computing and Smart Systems (ICSCSS)*. Estudo R0237 da revisão. doi: 10.1109/ICSCSS69635.2026.11645927.

Khan, U. A. et al. (2025). «Towards Efficient Educational Chatbots: Benchmarking RAG Frameworks». Em: *2025 International Conference on Emerging Technologies in Computing and Communication (ETCC)*. Estudo R0452 da revisão. doi: 10.1109/ETCC65847.2025.11108323.

Kitchenham, Barbara e Stuart Charters (2007). *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. Rel. téc. EBSE-2007-01. Keele University e Durham University.

Lang, Jiedong, Zhehao Guo e Shuyu Huang (2024). «A Comprehensive Study on Quantization Techniques for Large Language Models». Em: *2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC)*, pp. 224–231. doi: 10.1109/ICAIRC64177.2024.10899941.

Larsen, Douglas P., Andrew C. Butler e Henry L. Roediger (2008). «Test-Enhanced Learning in Medical Education». Em: *Medical Education* 42.10, pp. 959–966. doi: 10.1111/j.1365-2923.2008.03124.x.

Li, Boquan et al. (2026). «Be Responsible in Your Answers! Monitoring Out-of-Domain Behaviors in Domain-Specific LLMs». Em: *Proceedings of the ACM Web Conference 2026*. Estudo R1183 da revisão. doi: 10.1145/3774904.3792621.

Liao, Yiming et al. (2026). «Med-HEAL: Analyzing and Mitigating Hallucinations in Medical LLMs with Hallucination-Aware In-Context Learning». Em: *Proceedings of the 17th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*. Estudo R1120 da revisão. doi: 10.1145/3807503.3819453.

Liu, T., M. Zhu e S. P. Zhai (2026a). «Quality Outweighs Quantity: Advancing Medical Question Answering with RAG-MCP Muti-Agent LLM Framework and Curated Knowledge Databases». Em: *2026 IEEE 16th Annual Computing and Communication Workshop*

and Conference (CCWC). Estudo R0301 da revisão. doi: 10.1109/CCWC67433.2026.11393764.

Liu, Ziqi et al. (2026b). «AskNow: An LLM-powered Interactive System for Real-Time Question Answering in Large-Scale Classrooms». Em: *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Estudo R0934 da revisão. doi: 10.1145/3772318.3790328.

Mathew, A. K., D. Rajeev e A. Ravi (2026). «Privacy-Preserving Federated Transformer Framework for Detecting Adversarial Prompts in Healthcare Chatbots». Em: *2026 International Conference on Innovations in Computational Intelligence (ICICI)*. Estudo R0771 da revisão. doi: 10.1109/ICICI68867.2026.11564888.

Miroyan, Mihran et al. (2025). «Analyzing Pedagogical Quality and Efficiency of LLM Responses with TA Feedback to Live Student Questions». Em: *Proceedings of the 56th ACM Technical Symposium on Computer Science Education V. 1*. Estudo R0991 da revisão. doi: 10.1145/3641554.3701965.

Nurfadhilah, E., A. Santosa e P. K. Putra (2025). «Retrieval-Augmented Large Language Models for a Chronic Kidney Disease Patient Education Chatbot». Em: *2025 International Conference on Computer, Control, Informatics and its Applications (IC3INA)*. Estudo R0157 da revisão. doi: 10.1109/IC3INA68387.2025.11325127.

Oh, G., S. Park e B. -H. Kim (2026). «AutoMedic: An Automated Evaluation Framework for Clinical Conversational Agents with Medical Dataset Grounding». Em: *IEEE Journal of Biomedical and Health Informatics*. Estudo R0686 da revisão. doi: 10.1109/JBHI.2026.3703097.

Page, Matthew J. et al. (2021). «The PRISMA 2020 statement: an updated guideline for reporting systematic reviews». Em: *BMJ* 372, n71. doi: 10.1136/bmj.n71.

Parlamento Europeu e Conselho da União Europeia (2016). *Regulamento (UE) 2016/679 relativo à proteção das pessoas singulares no que diz respeito ao tratamento de dados pessoais (Regulamento Geral sobre a Proteção de Dados)*. url: https://eur-lex.europa.eu/eli/reg/2016/679/oj.

– (2024). *Regulamento (UE) 2024/1689 que cria regras harmonizadas em matéria de inteligência artificial (Regulamento da Inteligência Artificial)*. url: https://eur-lex.europa.eu/eli/reg/2024/1689/oj.

Pattanshetti, Rohan M. et al. (2025). «Assessing the Performance of Large Language Models on the Foreign Medical Graduate Examination (FMGE): Insights from GPT-4 Turbo, Gemini Advanced, and LLaMA 3.1 (70B)». Em: *2025 International Conference on Biomedical Engineering and Sustainable Healthcare (ICBMESH)*, pp. 1–6. doi: 10.1109/ICBMESH66209.2025.11182217.

Peffers, Ken et al. (2007). «A Design Science Research Methodology for Information Systems Research». Em: *Journal of Management Information Systems* 24.3, pp. 45–77. doi: 10.2753/MIS0742-1222240302.

Politécnico do Porto (2020). *Código de Ética e de Conduta do Politécnico do Porto*. url: https://www.ipp.pt.

Rahat, M. T. I. et al. (2026). «Noise, Distraction, and Mitigation: An Analysis of RAG Failure Modes in Medical Question Answering». Em: *2026 International Conference on Artificial Intelligence in Information and Communication (ICAIIC)*. Estudo R0414 da revisão. doi: 10.1109/ICAIIC68212.2026.11454362.

Raiaan, Mohaimenul Azam Khan et al. (2024). «A Review on Large Language Models: Architectures, Applications, Taxonomies, Open Issues and Challenges». Em: *IEEE Access* 12, pp. 26839–26874. doi: 10.1109/ACCESS.2024.3365742.

Raputri, E. et al. (2025). «Retrieval-Augmented LLMs with Indonesian Clinical Trials Guidelines: A Comparative Study». Em: *2025 8th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*. Estudo R0281 da revisão. doi: 10.1109/ISRITI68345.2025.11393253.

Rayhan, M. H. et al. (2026). «SAGE: Student-Focused Adaptive Guidance Engine for Intelligent Tutoring with Regulated Learning». Em: *2026 IEEE International Conference on Human-Machine Systems (ICHMS)*. Estudo R0807 da revisão. doi: 10.1109/ICHMS69701.2026.11602253.

Roediger, Henry L. e Jeffrey D. Karpicke (2006). «Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention». Em: *Psychological Science* 17.3, pp. 249–255. doi: 10.1111/j.1467-9280.2006.01693.x.

Ruga, T. et al. (2025). «A Conversational Agent for Rare Eye Disease Knowledge Support in Local Italian Healthcare Contexts: The ELENA Framework». Em: *2025 IEEE International Conference on Big Data (BigData)*. Estudo R0555 da revisão. doi: 10.1109/BigData66926.2025.11402191.

Sayeed, M. S. et al. (2026). «ATU-Tutor: A RAG-Based Socratic Tutoring System with Agentic AI Adaptive Assessment». Em: *2026 IEEE World AI IoT Congress (AIIoT)*. Estudo R0469 da revisão. doi: 10.1109/AIIoT68874.2026.11569566.

Sbai, A., I. Guessous e E. H. Nfaoui (2025). «Advanced Trilingual RAG Framework: Progressive Architectures for Robust Educational Question Answering». Em: *2025 4th International Conference on Embedded Systems and Artificial Intelligence (ESAI)*. Estudo R0165 da revisão. doi: 10.1109/ESAI67033.2025.11438335.

Seshadri, Vaibhav et al. (2026). «Alan: A Classroom Deployment of An Educational Chatbot That Cites Resources». Em: *Proceedings of the 57th ACM Technical Symposium on Computer Science Education V.2*. Estudo R1001 da revisão. doi: 10.1145/3770761.3777344.

Shao, Minghao et al. (2024). «Survey of Different Large Language Model Architectures: Trends, Benchmarks, and Challenges». Em: *IEEE Access* 12, pp. 188664–188706. doi: 10.1109/ACCESS.2024.3482107.

Shute, Valerie J. (2008). «Focus on Formative Feedback». Em: *Review of Educational Research* 78.1, pp. 153–189. doi: 10.3102/0034654307313795.

Tasfia, Tanha et al. (2026). «How Low Can Medical LLMs Go? An Empirical Study of Low-Bit Quantization». Em: *2026 IEEE 19th Dallas Circuits and Systems Conference (DCAS)*, pp. 1–6. doi: 10.1109/DCAS69364.2026.11545012.

Tawfik, M. K. et al. (2025). «Mufakkir: RAG-Based Arabic Educational Chatbot for University Students». Em: *2025 Twelfth International Conference on Intelligent Computing and Information Systems (ICICIS)*. Estudo R0443 da revisão. doi: 10.1109/ICICIS66182.2025.11313212.

Tien, L. A. e P. Van Huong (2024). «Optimizing Transformer Models for Prompt Jailbreak Attack Detection in AI Assistant Systems». Em: *2024 1st International Conference On Cryptography And Information Security (VCRIS)*. Estudo R0763 da revisão. doi: 10.1109/VCRIS63677.2024.10813380.

Walczak, J. e B. Sawicki (2026). «Comparative Evaluation of Llama Guard 3 and GPT OSS Safeguard as LLM Guardrails for a University Administrative Chatbot». Em: *2026 Progress in Applied Electrical Engineering (PAEE)*. Estudo R0762 da revisão. doi: 10.1109/PAEE71887.2026.11660667.

Wei, H. et al. (2026). «Cloud-Edge Retrieval-Augmented Agent Tutor for Trustworthy Personalized Learning in Resource-Constrained Higher Education». Em: *2026 5th International Conference on Artificial Intelligence, Internet of Things and Cloud Computing Technology (AIoTC)*. Estudo R0437 da revisão. doi: 10.1109/AIoTC71250.2026.11689071.

Weizenbaum, Joseph (1966). «ELIZA – A Computer Program for the Study of Natural Language Communication between Man and Machine». Em: *Communications of the ACM* 9.1, pp. 36–45. doi: 10.1145/365153.365168.

Wu, Tianyu et al. (2023). «A Brief Overview of ChatGPT: The History, Status Quo and Potential Future Development». Em: *IEEE/CAA Journal of Automatica Sinica* 10.5, pp. 1122–1136. doi: 10.1109/JAS.2023.123618.

Xie, Weidong et al. (2026). «When Retrieval Hurts: A Critical Analysis of RAG in Medical Question Answering». Em: *Proceedings of the 2025 3rd International Conference on Artificial Intelligence, Systems and Network Security*. Estudo R0878 da revisão. doi: 10.1145/3797161.3797211.

Xu, Haiyang et al. (2026a). «EchoMind: Augmenting Recorded Presentations with Context-Grounded Conversational Agents and Collective Viewer Signals». Em: *Proceedings of the 14th Nordic Conference on Human-Computer Interaction*. Estudo R1056 da revisão. doi: 10.1145/3829807.3829883.

Xu, Lingling et al. (2026b). «Parameter-Efficient Fine-Tuning Methods for Pretrained Language Models: A Critical Review and Assessment». Em: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 48.6, pp. 6107–6126. doi: 10.1109/TPAMI.2026.3657354.

Yan, Jiameng e Jingzhuo Shi (2026). «Question-Answering Agent Based on Prompt Engineering and RAG». Em: *Proceedings of the 2026 International Conference on Artificial Intelligence, Digital Media and Education*. Estudo R0859 da revisão. doi: 10.1145/3839592.3839607.

Zhang, H. e M. O. Shafiq (2025). «MediTriR: A Triple-Driven Approach to Retrieval-Augmented Generation for Medical Question Answering Tasks». Em: *2025 19th International Conference on Semantic Computing (ICSC)*. Estudo R0042 da revisão. doi: 10.1109/ICSC64641.2025.00032.

Zheng, Mingkai et al. (2026). «A Comparative Study on LLM-enabled HPC User Support». Em: *Proceedings of the Practice and Experience in Advanced Research Computing 2026: Resilient Roots + Empowered Communities*. Estudo R0995 da revisão. doi: 10.1145/3785462.3815796.

Apêndice A

Protocolo e Registo da Revisão Sistemática

Este apêndice documenta o protocolo da revisão sistemática resumida na Secção 2.2: a estruturação das questões, as fontes, a pesquisa piloto, a adaptação das expressões a cada fonte, o registo da pesquisa, os passos da seleção, a avaliação da qualidade e os campos de extração. Os ficheiros exportados, os *scripts* e as decisões de triagem permitem repetir todos os passos.

A.1 Estruturação das Questões

O âmbito das questões foi estruturado com os critérios PICOC (População, Intervenção, Comparação, Resultados e Contexto) recomendados por Kitchenham e Charters (2007). A Tabela A.1 mostra cada critério e onde é aplicado: a população, a intervenção e os resultados dão origem aos blocos das expressões de pesquisa; o contexto é aplicado nos critérios de seleção, para não excluir na pesquisa estudos que não mencionam o domínio no título ou no resumo.

Tabela A.1: Critérios PICOC da revisão e onde são aplicados.

Critério	**Definição**	**Aplicação**
População	Sistemas conversacionais e de resposta a perguntas baseados em LLMs	Blocos LLM e *chatbot*/QA (Q1–Q4)
Intervenção	Limitação das respostas a um contexto definido pela aplicação (RAG, contexto no *prompt*, *grounding*) e controlo do âmbito (*guardrails*, recusa)	Bloco de contexto (Q1), segurança (Q3) e recusa (Q4)
Comparação	Entre formas de fornecer o contexto e com o modelo sem contexto, quando reportada	Extração (não restringe a pesquisa)
Resultados	Correção factual, fidelidade ao contexto, adesão ao âmbito e recusa, robustez a manipulação; latência e custo	Bloco de avaliação (Q2, Q4); critério I4; extração
Contexto	Educação e saúde; estudos primários publicados entre 2021 e 2026	Filtro de anos; critérios I1–I3

A.2 Fontes e Pesquisa

Fontes. Foram usadas três fontes: IEEE Xplore e ACM Digital Library, que cobrem a literatura de engenharia informática, sistemas e IA, e Scopus, uma base multidisciplinar que cobre também revistas de educação e saúde. As fontes foram escolhidas antes da pesquisa final.

Tabela A.2: Registo da pesquisa (2 de novembro de 2026; título, resumo e palavras-chave; 2021–2026).

Fonte	Q1	Q2	Q3	Q4	Exportados
IEEE Xplore	756 (753)	24	38	29	844
ACM Digital Library	358	24	16	25 (26)	424
Scopus	102	131	14	32	279
Total					**1547**

Total indicado pela fonte; entre parênteses, o número exportado quando é diferente.

Pesquisa piloto. Antes de fixar as expressões, foi feita uma pesquisa piloto nas três fontes, limitada aos primeiros 30 títulos de cada pesquisa. O piloto levou a três decisões: (i) estreitar as expressões a sistemas conversacionais e de resposta a perguntas, porque as versões gerais devolviam sobretudo geração de código, *hardware* de inferência e recomendação; (ii) retirar latência e custo dos blocos de pesquisa e tratá-los como campos de extração, pelo mesmo motivo; (iii) separar a segurança do âmbito (Q3) e a recusa fora do âmbito (Q4) em expressões próprias.

Campos pesquisados. Em todas as fontes, as expressões foram aplicadas ao título, ao resumo e às palavras-chave, com o filtro de anos 2021–2026. No Scopus foi usado o campo `TITLE-ABS-KEY(...)`. No IEEE Xplore e na ACM Digital Library, que não têm um campo equivalente, cada termo foi expandido para os três campos (por exemplo, no IEEE Xplore, `("Document Title":LLM OR "Abstract":LLM OR "Author Keywords":LLM)`), mantendo a lógica booleana. A versão exata executada em cada fonte está guardada no registo da pesquisa.

Execução e registo. As pesquisas foram executadas a 2 de novembro de 2026. Foram exportados todos os resultados de cada pesquisa, com resumo, em RIS (IEEE Xplore e Scopus) ou BibTeX (ACM Digital Library). Para cada par fonte–pesquisa foram registados a expressão executada, a data, os filtros, o total indicado pela fonte e o número de registos exportados (Tabela A.2).

A Tabela A.2 apresenta o registo da pesquisa. Foram exportados 1547 registos: 844 do IEEE Xplore, 424 da ACM Digital Library e 279 do Scopus. No IEEE Xplore, 3 dos 756 resultados da Q1 não puderam ser exportados pela própria plataforma; na ACM Digital Library, a exportação da Q4 devolveu 26 registos para um total indicado de 25. A Q1 concentra a maior parte dos resultados, por cobrir a literatura de RAG aplicada a qualquer domínio.

A.3 Seleção dos Estudos

A seleção seguiu seis passos, todos registados em ficheiros e reprodutíveis através de *scripts*:

1. **Deduplicação.** Os registos das três fontes foram juntos e os duplicados removidos, primeiro pelo DOI normalizado e depois pelo título normalizado. Cada registo guarda a fonte e a pesquisa de onde veio.
2. **Triagem por regras (fase A).** Foram aplicadas regras explícitas sobre o título e o resumo, que implementam os critérios E2, E3 e E4 e o foco do I3 e do I4: registo sem

resumo ou que não é artigo; revisão ou *survey*; ausência de termos de LLM; ausência de termos de sistema conversacional ou QA; ausência de termos de educação ou saúde; e ausência de termos de avaliação das respostas. As regras e os termos usados estão no *script* de triagem.

3. **Triagem por leitura (fase B).** Os registos que passaram a fase A foram lidos (título e resumo) e classificados como incluídos ou excluídos, com um critério e um motivo por registo. Esta triagem foi feita com apoio de um assistente de IA, que propôs as decisões e os motivos; as decisões foram verificadas pelo autor (Secção 1.9).
4. **Critério de proximidade (I5).** Na mesma leitura, cada registo que cumpria os critérios I1 a I4 foi verificado quanto ao I5. O I5 exige pelo menos uma das seguintes condições, escolhidas pela proximidade ao caso de estudo: (a) contexto fechado e próximo do QBank (perguntas de exame ou de escolha múltipla, materiais de um curso ou um documento específico); (b) avaliação explícita da correção, da fidelidade ou da recusa; (c) mecanismo de controlo do âmbito ou de segurança; (d) suporte a várias línguas. Dos 211 registos que cumpriam os critérios I1 a I4, 48 cumpriam o I5. O I5 foi acrescentado durante a revisão, para limitar o conjunto final a um número de estudos que pudesse ser lido integralmente.
5. **Texto integral.** O texto integral dos 48 estudos foi procurado nas três fontes e obtido para 46. Na leitura, os critérios I3 e I4 foram confirmados; 2 estudos foram excluídos por não avaliarem as respostas (I4).
6. **Avaliação da qualidade.** Os 44 estudos restantes foram pontuados com os critérios da Secção A.4, e 6 foram excluídos por ficarem abaixo do limiar.

A.4 Avaliação da Qualidade e Extração de Dados

Na leitura do texto integral, cada estudo foi avaliado com cinco critérios de qualidade, cada um classificado como *sim* (1), *parcial* (0,5) ou *não* (0): (QA1) o objetivo está claro; (QA2) o sistema, o modelo e a origem do contexto estão descritos; (QA3) os dados, as perguntas ou os cenários de avaliação estão descritos; (QA4) o método de avaliação é adequado às conclusões; (QA5) as limitações e ameaças à validade são discutidas. A pontuação máxima é 5. Foram excluídos os estudos com menos de 3,5, isto é, os que falham pelo menos um critério e são parciais noutro, ou parciais em três ou mais. O limiar foi definido durante a revisão, tal como o I5. A pontuação de cada estudo incluído está no Apêndice B; a de todos os estudos, com a justificação, está no ficheiro `qualidade.csv` dos *scripts* da revisão.

Os campos de extração estão na Tabela A.3. A extração foi feita a partir do texto integral dos 38 estudos incluídos.

Tabela A.3: Campos de extração de dados.

#	**Campo**	**Descrição**	**Questão**
1	Referência	Autores, ano, fonte e tipo de publicação	—
2	Domínio e utilizadores	Educação ou saúde; estudantes, doentes, profissionais	RQ1
3	Origem do contexto	RAG, grafo de conhecimento, contexto no *prompt*, base de dados ou outro	RQ1
4	Controlo da resposta	Instruções, filtros, citações, verificação, recusa, *guardrails*	RQ1, RQ2
5	Modelo e componentes	Modelo de linguagem, *fine-tuning*, execução local ou na nuvem	RQ1
6	Avaliação	Método (métricas, LLM juiz, especialistas, utilizadores), dados e dimensão da amostra	RQ2
7	Resultados	Correção, fidelidade, recusa e segurança	RQ2
8	Compromissos e limitações	Latência, custo, integração, privacidade e limitações reportadas	RQ1

Apêndice B

Estudos Incluídos na Revisão

Este apêndice classifica os 38 estudos incluídos na revisão sistemática (Capítulo 2). A coluna Q indica a pesquisa de onde o estudo veio, e a coluna QA a pontuação de qualidade (QA1 a QA5, máximo 5; limiar de inclusão 3,5).

Tabela B.1: Classificação e qualidade dos estudos incluídos.

Estudo	Q	Domínio	Contexto e controlo	Avaliação	QA
Zhang e Shafiq (2025)	Q1	QA médico (MCQ)	RAG com triplos de grafo	Exatidão em MedMCQA e Medical QA	4,5
Christiawan et al. (2025)	Q1,Q2	Saúde mental	RAG híbrido com reordenação	RAGAS: fidelidade 0,875	4,0
Nurfadhilah et al. (2025)	Q1,Q2	Educação de doentes	RAG; LLM adaptado à língua	700 respostas; fidelidade e correção (LLM avaliador)	4,5
Azam et al. (2024)	Q1,Q2	Oncologia	RAG sobre literatura	Fidelidade e relevância vs. LLM base	3,5
Sbai et al. (2025)	Q1	Educação (trilingue)	RAG com embeddings multilingues	Correção e fidelidade por língua	4,0
Raputri et al. (2025)	Q1,Q2	Diagnóstico clínico	RAG sobre diretrizes locais	Comparação com e sem RAG; médico	4,0
Liu et al. (2026a)	Q1	QA médico (MCQ)	RAG multiagente; base curada	Exatidão em MedMCQA e MedQA	4,0
Rahat et al. (2026)	Q1	QA médico	RAG sobre PubMed	Exatidão; análise de 165 erros	4,5
Wei et al. (2026)	Q1	Ensino superior	RAG local com verificação de políticas	Dados públicos; auditoria de casos	5,0
Tawfik et al. (2025)	Q1	Ensino superior (árabe)	RAG híbrido	Exatidão e semelhança da resposta	3,5
Khan et al. (2025)	Q1,Q2	Exame de acesso (GATE)	RAG sobre soluções de exame	Fidelidade, relevância, latência; avaliação humana	4,0
Sayeed et al. (2026)	Q1	Ensino superior	RAG sobre manuais abertos	14 perguntas; LLM e heurísticas	3,5
Ruga et al. (2025)	Q1	Oftalmologia (italiano)	RAG com tradução	Viabilidade técnica	4,0
Ishadya et al. (2026)	Q1,Q4	Saúde	Prompting estruturado + RAG/MCP	Exatidão, abstenção, evidência; especialistas	4,5
Ghanbari e Dividino (2025a)	Q1	Transferível (MCQ)	Grafo de conhecimento no prompt	Exatidão vs. sem contexto	5,0
Bellard et al. (2025)	Q1	Insuficiência cardíaca	RAG com LLM juiz	25 pares; latência e custo	4,0
Jain et al. (2025)	Q1	Sala de aula	RAG vetorial vs. grafo	3176 perguntas; manuais alterados	4,5
Ghanbari e Dividino (2025b)	Q1	Transferível (MCQ)	Subgrafos no prompt	Efeito da relevância do contexto	5,0
Oh et al. (2026)	Q1	Clínica	Pacientes virtuais de datasets	Métrica CARE; validação por especialistas	5,0

Estudo	Q	Domínio	Contexto e controlo	Avaliação	QA
Yan e Shi (2026)	Q1	Eletrónica (curso)	RAG e engenharia de prompts	Exatidão e estabilidade	4,0
Xie et al. (2026)	Q1	QA médico (MCQ)	Três variantes de RAG	Exatidão no MedQA; efeito do RAG	5,0
Liu et al. (2026b)	Q1	Sala de aula	Contexto da aula em curso	117 estudantes; docentes avaliam correção	5,0
Miroyan et al. (2025)	Q1	Programação	RAG (GPT-4)	Avaliação e edição por TAs	4,5
Zheng et al. (2026)	Q1	Transferível (apoio técnico)	Fine-tuning vs. RAG vs. ICL	Correção; humanos e LLM juiz	4,0
Seshadri et al. (2026)	Q1	Programação	RAG sobre materiais, com citações	250 estudantes; inquérito	3,5
Barzanji et al. (2026)	Q1	Engenharia de software	Materiais do curso	32 estudantes; SUS 77,8	4,0
Buti e Mohamed (2026)	Q1,Q2	Aconselhamento académico	RAG	55 perguntas; LLM juiz	4,5
Xu et al. (2026a)	Q1	Vídeo-aulas	Materiais da apresentação	Estudo com 75 participantes	5,0
Feng et al. (2024)	Q1	Programação	RAG, intenção e decomposição	50 pares vs. GPT-4; entrevistas	3,5
Bui et al. (2025)	Q1	Procedimentos académicos	LLM com verificação formal	Benchmark EduMC-QA	5,0
Liao et al. (2026)	Q1	Clínica (EHR)	Autocrítica e ICL com exemplos	LLM juiz e estudantes de medicina	4,5
Walczak e Sawicki (2026)	Q3	Universidade	Guardrails com restrição de tema	Precisão, recall, latência	4,5
Emekci e Budakoglu (2025)	Q3	Universidade	Dois LLM: filtro e geração	4501 interações reais; 0,28% falsos positivos	4,5
Mathew et al. (2026)	Q3	Saúde	Deteção federada de injeção	Exatidão e F1	4,5
Li et al. (2026)	Q3	Vários domínios	Monitorização de estados internos	Taxa de rejeição fora do domínio	4,5
Hamidi e Roberts (2026)	Q4	Radiologia	QA sobre um relatório	EM, F1; taxonomia com abstenção	4,5
Rayhan et al. (2026)	Q4	Programação	Controlo de acesso por grafo	Políticas: 90% vs. 30% (prompt)	4,0
Abrar et al. (2025)	Q4	Universidade (multilingue)	Fine-tuning com exemplos de recusa	Precisão da recusa 0,86	5,0