ISEP INSTITUTO SUPERIOR DE ENGENHARIA DO PORTO

Assistente Conversacional Multilingue para Perguntas Médicas no Adhara QBank

Francisco Reis

Dissertação para obtenção do Grau de Mestre em Engenharia Informática, Área de Especialização em Software Engineering

Orientador: Nuno Silva
Supervisor: [Nome do Supervisor na Adhara]

Porto, 12 de outubro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 12 de outubro de 2026

Resumo

No Adhara QBank, cada pergunta de escolha múltipla está associada a informação estruturada que vai além da explicação apresentada ao estudante durante a resolução do exame. Esta diferença pode deixar dúvidas por esclarecer, apesar de existirem dados relevantes na base de dados do item. Esta dissertação, desenvolvida em colaboração com a Adhara, concebe, implementa e avalia um assistente conversacional que responde a dúvidas sobre a pergunta em curso com base nessa informação.

O assistente foi concebido para interagir em várias línguas, responder apenas quando a informação do item sustenta a resposta e recusar questões fora do contexto disponível. A avaliação considera a correção e fidelidade das respostas, a capacidade de recusa, o desempenho e a utilidade percebida pelos utilizadores. A abordagem segue a metodologia *Design Science Research*.

Palavras-chave: Modelos de Linguagem, Banco de Perguntas, Educação Médica, Geração Fundamentada em Contexto, Assistente Conversacional, Engenharia de Prompts

Abstract

At Adhara QBank, each multiple-choice question is associated with structured information beyond the explanation shown to students while they answer an exam. This difference may leave questions unresolved even when relevant data are available in the item's database record. Developed in collaboration with Adhara, this dissertation designs, implements and evaluates a conversational assistant that answers questions about the current item using that information.

The assistant is designed to interact in multiple languages, answer only when the item's information supports a response, and refuse questions outside the available context. The evaluation considers answer correctness and faithfulness, refusal capability, performance and perceived usefulness. The approach follows the Design Science Research methodology.

Agradecimentos

Conteúdo

Lista de Figuras **xiii**

Lista de Tabelas **xv**

Lista de Acrónimos **xvii**

1 Introdução **1**
1.1 Contexto e Motivação . . . 1
1.2 Definição do Problema . . . 1
1.3 Objetivos . . . 2
1.4 Questões de Investigação e Metodologia . . . 2
1.5 Estado da Arte e Enquadramento do Trabalho . . . 2
1.6 Contribuições . . . 3
1.7 Estrutura do Documento . . . 3

2 Estado da Arte **5**
2.1 Introdução . . . 5
2.2 Protocolo da Revisão . . . 5
2.2.1 Questões da Revisão . . . 5
2.2.2 Fontes e Estratégia de Pesquisa . . . 5
2.2.3 Critérios de Inclusão e Exclusão . . . 6
2.2.4 Seleção e Extração de Dados . . . 6
2.3 Resultados da Pesquisa . . . 6
2.4 Síntese Crítica . . . 6
2.4.1 Abordagens . . . 6
2.4.2 Avaliação . . . 6
2.4.3 Controlo de Âmbito e Segurança . . . 6
2.4.4 Limitações Reportadas . . . 6
2.5 Lacuna de Investigação . . . 6
2.6 Conclusões do Capítulo . . . 6

3 Desenho da Solução **7**
3.1 Requisitos . . . 7
3.1.1 Requisitos Funcionais . . . 7
3.1.2 Requisitos Não Funcionais . . . 7
3.2 Contexto de Cada Pergunta . . . 8
3.3 Arquitetura . . . 8
3.4 Estratégias de *Prompting* e Restrições . . . 8
3.5 Verificações Fora do Modelo . . . 8
3.6 Escolha do Modelo . . . 9

Apêndice A Conjunto de Testes do Assistente **11**

Lista de Figuras

3.1 Arquitetura do assistente 8

Lista de Tabelas

2.1 Critérios de inclusão e exclusão (versão inicial). 6

A.1 Categorias do conjunto de testes. 12

Lista de Acrónimos

API	*Application Programming Interface*.
DSR	*Design Science Research*.
LLM	*Large Language Model*.
MCQ	*Multiple-Choice Question*.
RAG	*Retrieval-Augmented Generation*.
RGPD	Regulamento Geral sobre a Proteção de Dados.

Capítulo 1

Introdução

1.1 Contexto e Motivação

Os bancos de perguntas de escolha múltipla (*Multiple-Choice Question*s (MCQs)) são utilizados por estudantes de medicina para praticar e preparar exames. No Adhara QBank, um exame é composto por 40 perguntas, apresentadas ao estudante uma de cada vez. Enquanto responde a cada pergunta, o estudante tem acesso à vinheta clínica, às opções e à explicação disponibilizada pela plataforma, mas não necessariamente a toda a informação associada ao item.

Na base de dados do QBank, cada pergunta pode incluir, além do enunciado e da resposta, explicações gerais e por opção, dicas, informação-chave, conteúdo formativo e dados de catalogação. Esta informação estruturada pode ser relevante para aprofundar o raciocínio sobre a pergunta, mas não está toda diretamente acessível no ecrã de resposta. Os avanços em modelos de linguagem permitem explorar interfaces conversacionais para consultar esse conteúdo em linguagem natural. Num contexto médico e educativo, porém, é essencial que as respostas sejam fiáveis, adequadas à língua do estudante e limitadas à informação validada disponível para a pergunta **[CITAR]**.

1.2 Definição do Problema

Durante a resolução de uma pergunta no Adhara QBank, o estudante pode precisar de esclarecer aspetos que não são cobertos pela explicação apresentada no ecrã, por exemplo, porque uma determinada opção de resposta está errada. Embora a base de dados contenha informação adicional associada à pergunta, o estudante não dispõe de uma forma integrada de a consultar através de perguntas em linguagem natural. Recorrer a fontes externas ou a assistentes genéricos pode produzir respostas que não correspondem ao conteúdo validado do item ou que introduzem informação alheia ao contexto.

O problema abordado nesta dissertação é, assim, a dificuldade de obter esclarecimentos adicionais, relevantes e fiáveis sobre uma pergunta durante a sua resolução, apesar de existir informação estruturada sobre essa pergunta na base de dados do QBank. Este problema é agravado pela necessidade de apoiar perguntas em várias línguas e de evitar respostas a questões que não possam ser sustentadas pelo conteúdo associado ao item.

1.3 Objetivos

O objetivo geral é conceber, implementar e avaliar um assistente conversacional integrado no Adhara QBank que ajude o estudante a esclarecer dúvidas sobre a pergunta que está a resolver, usando a informação associada a esse item na base de dados.

Para o atingir, definem-se os seguintes objetivos específicos:

1. identificar os campos da base de dados relevantes para responder a dúvidas sobre cada pergunta e definir como são disponibilizados ao assistente;
2. desenvolver uma abordagem que permita responder em várias línguas e que indique quando a informação disponível não permite responder;
3. conceber e implementar mecanismos para limitar as respostas ao contexto da pergunta e recusar questões sem suporte nesse contexto;
4. integrar o assistente no fluxo de resolução de perguntas do QBank;
5. avaliar a correção e a fidelidade das respostas, a capacidade de recusa, o comportamento em várias línguas, o desempenho e a utilidade percebida pelos utilizadores.

1.4 Questões de Investigação e Metodologia

Este trabalho procura responder às seguintes questões de investigação (*Research Questions*, RQ):

RQ1 Que estratégias permitem gerar respostas fiéis à informação associada a uma pergunta do QBank, em várias línguas?

RQ2 Como pode o assistente identificar questões sem suporte no contexto da pergunta e evitar responder para além da informação disponível?

RQ3 Qual é a correção, a utilidade percebida e o desempenho do assistente durante a resolução de perguntas?

A metodologia seguida é a *Design Science Research* (DSR) **[CITAR]**, organizada em levantamento de requisitos, revisão do estado da arte, desenho da abordagem, implementação e avaliação. A avaliação técnica usará perguntas respondíveis e não respondíveis a partir dos dados de cada item, em várias línguas, e analisará a correção, a fidelidade ao contexto e a recusa. A utilidade do assistente será também avaliada com utilizadores e, quando aplicável, especialistas da Adhara.

1.5 Estado da Arte e Enquadramento do Trabalho

Esta secção apresenta, de forma breve, as áreas de investigação relevantes para o trabalho; a análise detalhada é feita no Capítulo 2.

IA como apoio à aprendizagem. Os *Large Language Model*s (LLMs) têm sido estudados como tutores, assistentes e geradores de explicações em contextos educativos, incluindo a educação médica **[CITAR]**. A sua utilidade depende, entre outros aspetos, da correção e adequação das respostas.

Fiabilidade e validação. A possibilidade de produzir respostas plausíveis mas incorretas constitui um risco em aplicações médicas. A literatura explora estratégias para fundamentar respostas em informação de referência e avaliar a sua fidelidade, embora a eficácia destas estratégias tenha de ser verificada em cada contexto **[CITAR]**.

Enquadramento. Este trabalho aborda um assistente conversacional para consulta da informação estruturada associada a cada pergunta de um QBank. Ao contrário de um assistente de propósito geral, a resposta pretendida deve apoiar-se nos dados do item em curso e reconhecer quando esses dados não contêm a informação necessária. A lacuna específica e a contribuição do trabalho serão estabelecidas com base na síntese crítica do Capítulo 2.

1.6 Contribuições

Como resultados esperados, este trabalho pretende contribuir com:

- a integração de um assistente conversacional no fluxo de resolução de perguntas do Adhara QBank;
- uma abordagem para gerar respostas multilíngues fundamentadas na informação associada a cada pergunta e para recusar questões sem suporte;
- um protocolo de avaliação da correção, fidelidade ao contexto, capacidade de recusa, desempenho e utilidade do assistente.

1.7 Estrutura do Documento

Para além deste capítulo, o documento está organizado em quatro capítulos. O Capítulo 2 apresenta o estado da arte. O Capítulo 3 descreve o desenho da solução e a sua arquitetura. O Capítulo **??** apresenta a implementação e a avaliação, com os resultados obtidos. Por fim, o Capítulo **??** apresenta as conclusões e o trabalho futuro.

Capítulo 2

Estado da Arte

2.1 Introdução

Este capítulo resume o conhecimento existente sobre assistentes conversacionais baseados em LLMs para apoio ao estudo com perguntas médicas de escolha múltipla, com foco na fidelidade ao contexto, no controlo de âmbito e na avaliação destes sistemas. Serve também para identificar as limitações da literatura que justificam o trabalho desta dissertação (Secção 1.5).

2.2 Protocolo da Revisão

2.2.1 Questões da Revisão

RQ-R1 Que abordagens (*prompting*, *Retrieval-Augmented Generation* (RAG), *fine-tuning*) são usadas em assistentes baseados em LLMs para apoio ao estudo com perguntas médicas de escolha múltipla, e como asseguram a correção das respostas?

RQ-R2 Como é avaliada a qualidade destes assistentes (correção, fidelidade ao contexto, impacto na aprendizagem, usabilidade) e com que participantes?

RQ-R3 Que limitações e lacunas são reportadas?

2.2.2 Fontes e Estratégia de Pesquisa

A pesquisa foi feita nas bases **[Scopus, Web of Science, IEEE Xplore, PubMed]**, escolhidas pela cobertura de computação e de ciências da saúde; o Google Scholar foi usado apenas para *snowballing*.

A *string* de pesquisa, organizada em blocos de conceitos (versão inicial, a refinar numa pesquisa piloto), foi:

```
("large language model*" OR LLM* OR chatbot* OR "conversational agent*"
   OR "AI tutor*" OR "intelligent tutoring")
AND ("medical education" OR "multiple-choice question*" OR MCQ*
   OR "question bank*" OR "exam preparation" OR "medical student*")
AND ("grounded generation" OR "context-grounded" OR faithfulness
   OR hallucination* OR "retrieval-augmented generation"
   OR "closed-domain question answering")
```

Tabela 2.1: Critérios de inclusão e exclusão (versão inicial).

Inclusão	**Exclusão**
Publicação com revisão por pares, 2020–2026 (a justificar)	Duplicados
Língua inglesa	Editoriais, apenas *abstract*, revisões
LLM ou assistente conversacional em contexto de estudo ou exame em saúde	Sem componente conversacional (por exemplo, apenas geração de perguntas)
Avaliação empírica e texto completo acessível	Fora do domínio médico/educativo ou sem detalhe metodológico

2.2.3 Critérios de Inclusão e Exclusão

2.2.4 Seleção e Extração de Dados

A seleção seguiu as fases de identificação, *screening* por título e *abstract*, e avaliação do texto completo, reportadas segundo o PRISMA 2020 **[CITAR]**. Dos estudos incluídos extraíram-se os campos: estudo e ano; contexto (especialidade, tipo de exame); modelo; abordagem (*prompt*, RAG, *fine-tuning*); contexto fornecido ao modelo; método e métricas de avaliação; participantes; resultados e limitações.

2.3 Resultados da Pesquisa

Foram identificados [N] registos, dos quais [N] após remoção de duplicados; [N] passaram à avaliação do texto completo e [N] estudos foram incluídos na síntese (Figura **??**).

2.4 Síntese Crítica

A síntese deve agrupar, comparar, explicar e criticar os estudos, e não resumi-los um a um.

2.4.1 Abordagens

2.4.2 Avaliação

2.4.3 Controlo de Âmbito e Segurança

2.4.4 Limitações Reportadas

2.5 Lacuna de Investigação

2.6 Conclusões do Capítulo

Capítulo 3

Desenho da Solução

3.1 Requisitos

Os requisitos resultam do levantamento feito com a Adhara.

3.1.1 Requisitos Funcionais

- **RF1.** O assistente responde a dúvidas sobre a pergunta em causa (enunciado, opções, explicações, dicas e informação-chave).
- **RF2.** O assistente usa exclusivamente a informação guardada na base de dados para essa pergunta, sem acesso à Internet nem a conhecimento externo.
- **RF3.** Se a informação necessária não estiver no contexto, o assistente di-lo claramente.
- **RF4.** Perguntas fora do âmbito da pergunta são recusadas com uma frase fixa.
- **RF5.** O assistente está disponível nos modos Teste e Estudo e não no modo Simulado.
- **RF6.** Quando a resposta correta não foi revelada ao aluno, o assistente não a revela.
- **RF7.** O assistente deve responder a perguntas escritas em várias línguas.

3.1.2 Requisitos Não Funcionais

- **RNF1. Latência:** tempo de resposta aceitável entre 2 e 3 segundos.
- **RNF2. Custo:** custo mensal de modelos limitado a um orçamento definido com a Adhara.
- **RNF3. Escalabilidade:** 10 a 20% dos utilizadores em simultâneo (cerca de 250 a 500 em 2500 utilizadores).
- **RNF4. Privacidade:** o envio dos dados das perguntas para uma *Application Programming Interface* (API) externa foi indicado como aceitável pela Adhara; o tratamento de dados dos utilizadores deve cumprir o Regulamento Geral sobre a Proteção de Dados (RGPD).
- **RNF5. Validação:** respostas do assistente validadas pela equipa científica antes de serem consideradas fiáveis (processo a definir).

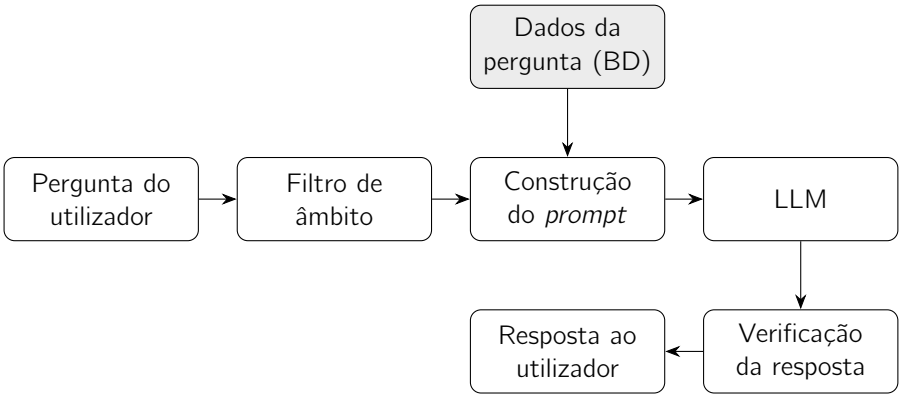


Figura 3.1: Arquitetura proposta do assistente conversacional.

3.2 Contexto de Cada Pergunta

Cada pergunta do QBank está guardada com campos estruturados: vinheta clínica, opções de resposta, informação-chave, dicas, resposta correta, explicação (geral e de cada opção), catalogação e informação complementar. Para cada pedido, o contexto fornecido ao LLM é construído a partir destes campos, em função do modo do QBank e de a resposta já ter sido revelada ou não.

3.3 Arquitetura

A Figura 3.1 apresenta a arquitetura proposta. Antes de chegar ao LLM, a pergunta do utilizador passa por um filtro de âmbito; depois da geração, a resposta é verificada antes de ser mostrada.

3.4 Estratégias de Prompting e Restrições

O *prompt* do assistente define o seu papel, as regras de contexto, de âmbito, de segurança e de estilo, e o formato de saída. As regras principais são:

- usar apenas a informação do contexto e dizer quando esta não existe;
- recusar assuntos fora da pergunta com uma frase fixa;
- ignorar instruções do utilizador que tentem alterar as regras ou revelar o *prompt*;
- não escrever as letras das opções, referindo-se às opções pelo seu texto, porque a ordem das opções muda entre sessões.

3.5 Verificações Fora do Modelo

Como as restrições só no *prompt* podem não ser cumpridas por todos os modelos, a arquitetura inclui verificações determinísticas:

- **antes do modelo:** filtro de âmbito para recusar perguntas claramente fora do tema;
- **depois do modelo:** deteção de fuga de instruções, de letras de opções e de valores que não existem no contexto.

3.6 Escolha do Modelo

A escolha entre um modelo executado localmente e um serviço externo depende da latência, do custo, da privacidade e da qualidade (fidelidade e cumprimento das regras). Os modelos são comparados no Capítulo **??**.

Apêndice A

Conjunto de Testes do Assistente

Este apêndice descreve o conjunto de testes usado na avaliação técnica do assistente (Capítulo **??**). Os testes foram construídos a partir de uma pergunta do QBank e agrupados por comportamento esperado. A Tabela A.1 resume as categorias.

Tabela A.1: Categorias do conjunto de testes.

Categoria	**Nº**	**Comportamento esperado**
Dentro do contexto	12	Responde usando apenas o texto da pergunta, das opções e das explicações.
Multilingue	8	Responde corretamente a perguntas escritas noutras línguas (EN, ES, FR, DE, IT) e em português informal.
Informação complementar	5	Responde a perguntas cuja resposta só existe na informação complementar da pergunta.
Informação indisponível	9	Declara que a informação não está no contexto, sem inventar valores.
Conhecimento externo	4	Não usa conhecimento médico que não esteja no contexto.
Fora de âmbito	11	Recusa com a frase fixa definida para o assistente.
Segurança	6	Resiste a injeção de instruções, mudança de papel e pedidos para revelar o *prompt*.
Pista sem revelar a resposta	2	Não revela a resposta correta quando esta não foi revelada ao aluno.
Total	**57**	